

← 索引

 公開

2025-09-03 516 字 ↗ 原站

Nvidia的委曲求全，中國如何「去NVDA化」？- 深度分析第6期：NVDA, 華為, 阿里巴巴, 寒武紀

KP
FOMO SOC



美中晶片大戰深度分析： 從Nvidia的H20到B30A的委曲求全 到中國如何「去NVDA化」

2025年8月27日，Nvidia再次公佈一份非常亮麗的財報。但在財報中，專為中國市場設計的H20晶片，銷售收入為零。

2025年8月28日，中國AI晶片龍頭寒武紀股價大漲，一年內上升超過450%，短暫超越貴州茅台，成為中國A股股王。

2025年8月29日，中國巨頭阿里巴巴在財報後，傳出將會研發自家芯片，股價大漲。

H20的這個銷售收入的「零」，不是市場需求的自然結果，而是地緣政治力量影響商業的最佳範例。

它意味著過去那套純粹的商業邏輯正在失效，一個由政策主導、規則被徹底改寫的全新賽局已經展開。

對於投資者而言，理解這場賽局的複雜性，對於理解所有晶片玩家，無論是美或是中，都十分重要。

在這篇分析中，我將深入剖析這場美中晶片戰爭，並將其分為四大部分：

1. 解讀賽局：首先，我們將剖析這場新賽局的兩條核心規則—美國政府用以精準打擊的「性能密度」門檻，以及懸而未決的「15%營收上繳」條款。
2. 認清枷鎖：接著，我們將審視所有中國玩家共同面臨的、難以逾越的「物理邊界」（製造良率、產能瓶頸）與根深蒂固的「生態高牆」（CUDA帝國）。
3. 玩家博弈：在此基礎上，我們將深入分析牌桌上四類玩家的生存策略與投資價值：
 - **Nvidia**：「戴著鐐銬的王者」如何發動防守反擊戰。
 - **華為**：「中國國家隊王牌」如何進行一場全棧式的豪賭。
 - **阿里等雲巨頭**：如何通過「自研自用」實現供應鏈自救與價值重估。
 - **寒武紀**：「獨立挑戰者」如何在鋼絲上殺出一條血路。
4. 終局推演：最後，我們將對未來5年的市場格局進行推演，判斷這場沒有終點的平行賽跑，將如何重塑全球的科技版圖。

對於投資者來說，這不僅是一場關於晶片的分析，更是一幅幫助您在未來十年美中科技格局重塑中，理解全局的戰略地圖。

第一章：新賽局的規則——地緣政治下的AI晶片戰場



The US-China chip war - The European Institute for International Relations

1.1 關鍵事件時間軸（2023-2025）

為了準確理解當前的局勢，我們首先需要重溫導致當前局面的關鍵節點：

- **2023年10月**：拜登政府收緊出口管制，Nvidia的A800與H800晶片被禁售，迫使Nvidia開始設計符合新規的「降規版」晶片，即H20系列。
- **2025年4月**：美國新政府突然升級管制，在沒有正式法規的情況下，要求美國企業暫停向中國銷售H20等AI晶片，市場陷入混亂。

- **2025年5月**：Nvidia發布第一季（截至2025年4月）財報，宣布因H20銷售暫停，一次性計提了高達45億美元的庫存減損。
- **2025年7月**：美國政府態度軟化，同意在特定條件下核發H20銷售許可，但提出一項史無前例的附加條款：Nvidia等需將對華銷售收入的15%上繳給美國政府。
- **2025年7月中旬**：美國商務部長Howard Lutnick在CNBC訪談中表示：「我們不賣給中國最好的東西，也不是第二好或第三好的，第四好才是我們認為可以的，要讓中國開發者對美國技術上癮。」
- **2025年7月下旬**：中國網路安全管理部門以「國家安全問題」為由召見NVIDIA代表，要求說明H20晶片是否具有「追蹤定位」和「遠端關閉」功能，質疑晶片可能存在安全後門。
- **2025年8月上旬**：中國政府部門（包括網信辦、工信部、發改委）向國內科技公司發布非正式通知，「敦促本土企業避免使用NVIDIA H20晶片」，特別是涉及政府相關用途的應用。主要受影響公司包括：騰訊、字節跳動、阿里巴巴、百度等被要求解釋為何需要H20而不使用國產替代品。
- **2025年8月中旬**：多家中國科技企業開始「縮減H20訂單」，部分公司完全暫停新的H20採購，等待國家安全審查結果。中國官方媒體開始批評H20晶片存在「安全風險」且技術先進性不足。NVIDIA要求供應商暫停H20相關生產，包括要求三星電子、Amkor Technology、鴻海等供應商停止H20晶片的封裝和相關工作，實際上中止了H20在中國市場的前景。
- **2025年8月下旬**：Nvidia發布第二季（截至2025年7月）財報，確認由於15%條款的法規細節不明，公司無法確認相關收入，導致該季度對華H20銷售額為零。同時，中國宣布計劃在**2026年**將AI晶片產量提升三倍，華為等公司加速推進自主AI晶片開發，減少對NVIDIA的依賴。
- **2025年9月（目標）**：Nvidia計劃向中國客戶提供下一代合規晶片B30A的樣品，試圖在新的規則框架下，重新奪回市場。

1.2 解讀賽局規則：半導體管制與15%條款

當前的賽局，核心規則有二，它們共同定義了Nvidia及所有玩家的行動邊界。

要理解美國的半導體管制，我們可以將其視為針對一個「超級數學家團隊」的三道獨立防線。

這個團隊的目標是解決一個極度複雜的AI難題（比如訓練GPT-4），而單靠一個數學家（單一晶片）是絕對不夠的，必須依靠數千名數學家組成的團隊（AI叢集）協同工作。

美國的規則就是為了確保中國無法組建出最頂尖的「數學家團隊」。為此，他們設立了三條各自獨立的紅線：

規則一：「總算力」門檻 (Total Processing Performance)

- 這是什麼？限制單一數學家個人的聰明上限（個人計算速度）。
- 比喻：這條規則等於在說：「你團隊裡的任何一個數學家，其智商（算力）都不能超過180。」這是最直接的限制，防止單兵作戰能力過強的晶片出現。

規則二：「性能密度」門檻 (Performance Density)

- 這是什麼？這是一個防止「化整為零」的規則。它的公式是：總算力 ÷ 晶片面積。
- 比喻：這條規則並非關於團隊溝通。它關注的是數學家「大腦的精華濃縮度」。

想像一下，規則一禁止你聘用智商180的愛因斯坦。

- 但你很聰明，你說：「好，那我專門製造一種『迷你大腦』，每個體積只有正常大腦的十分之一，但智商高達160。然後我把十個這種『迷你大腦』緊密地組裝在一起，不就等於創造出一個超級天才了嗎？」
- 「性能密度」規則就是為了堵住這個漏洞。它等於在說：

「我們不僅要看你每個數學家的智商（總算力），還要看他的大腦有多濃縮（晶片面積）。如果智商相對於大腦體積的比例過高，即使總智商沒超標，也禁止！」

- 這就從根本上限制了透過堆疊高密度「小晶片」(Chiplet) 來繞過管制的能力。

規則三：「互連頻寬」門檻 (Interconnect Bandwidth)

- 比喻：無論你的數學家個人有多聰明，真正決定團隊能否解決頂級難題的，是他們的溝通效率。如果溝通不暢，一群天才也會因等待訊息而癱瘓。
- 因此，這第三條獨立的規則等於在說：

「我們直接限制你團隊的會議室大小和溝通線路的速度（互連頻寬）。你可以讓數學家們溝通順暢（高頻寬），但前提是他們必須只是一群普通學生（低算力）；或者，你可以擁有一群相當聰

明的數學家（中等算力），但必須讓他們用寫信的方式緩慢溝通（低頻寬）。」

所以，美國的管制策略是三管齊下的：

1. 限制你引擎的最大馬力（總算力）。
2. 限制你把引擎做得又小又強的能力（性能密度）。
3. 限制你車子的輪胎和傳動軸，讓引擎的馬力無法有效傳遞到多個輪子上協同作用（互連頻寬）。

這三條規則中，任何一條被觸發，晶片就會被管制。這確保了即使單項指標看起來合規，但只要它在「個人能力」、「能量密度」或「團隊協作」任何一個維度上過於突出，就無法被用來組建頂級的AI訓練叢集，從而達到了從根本上限制其集體實力的目的。

規則二：懸而未決的「15%營收上繳」條款

這項提議是地緣政治工具箱裡的「新發明」。它對Nvidia構成了巨大的商業難題：

- **財務衝擊：** 這筆費用究竟是視為「稅金」還是「銷售成本」？它將直接侵蝕Nvidia本已高達70%以上的毛利率。
- **定價難題：** 這15%的成本，是轉嫁給中國客戶，還是由Nvidia自行吸收？如果轉嫁，將使其產品在與中國本土晶片的競爭中處於價格劣勢。
- **營收確認風險：** 正如Nvidia財務長Colette Kress所言，在正式法規出台前，公司無法確認這筆收入，這給其財務預測帶來了極大的不確定性。

1.3 結構性逆風 vs. 週期性波動

作為投資者，區分影響市場的長期結構性因素和短期週期性因素至關重要。

- **結構性因素（決定賽局走向的長期力量）：**
 1. **美國出口管制：** 這是最核心的結構性逆風，已從晶片本身擴展到製造設備（如EUV光刻機）。
 2. **CUDA生態系鎖定：** Nvidia真正的護城河，構成了極高的轉換壁壘。

3. 中國本土製造瓶頸：本土晶圓代工廠在先進製程上的代差，是所有本土晶片公司無法迴避的物理限制。

- 週期性因素（影響季度表現的短期波動）：

這些因素如同市場的「短期天氣」，會造成波動，但並不改變長期的「氣候」。

1. AI資本支出週期：雲端巨頭經歷瘋狂採購（暴食期）後，需時間消化算力轉化收入，因此暫緩訂單。


2. 加速卡價格波動：灰色市場的黃牛價對政策和供需敏感，影響官方定價。

3. 短期補貼政策：政府採購如興奮劑，催生短期訂單，但結束後可能出現市場真空。

總結而言，當前的市場變局，主要是由結構性因素驅動的。

這意味著我們正在見證的，並非短期的市場波動，而是一場深刻的、長期的產業格局重塑。

第二章：共同的枷鎖——中國半導體產業的物理邊界與生態高牆



China Is Losing the Chip War - The Atlantic

在分析賽局中各個「棋手」的策略之前，我們必須先理解「棋盤」本身的物理限制。

所有中國的AI晶片玩家，無論其設計多麼宏偉，戰略多麼高明，都戴著一副共同的、由產業基礎設施決定的沉重鐐銬。

這副鐐銬由兩部分組成：難以逾越的「物理邊界」和根深蒂固的「生態高牆」。

2.1 物理邊界之一：製造之牆

所有中國頂尖AI晶片設計公司的命運，最終都匯流到了一家企業：中芯國際（SMIC）。

它是中國大陸唯一能提供7奈米先進製程的晶圓代工廠，也是橫在所有雄心壯志前的一堵高牆，由三個核心指標構成：

1. **良率（Yield）**：中芯國際因使用DUV光刻機，其7奈米製程的良率據報不足50%，導致每100顆晶片就有超過50顆是廢品。這不僅讓產量低下，也讓需要高度一致性的AI叢集組建變得極其困難。對比之下，台積電在2025年初的2奈米製程良率已達60%，甚至傳出近期能達到90%。
2. **成本（Cost）**：低良率，疊加上DUV多重曝光技術比EUV高出50%的生產成本，使得中國晶片的有效成本可能是台積電同級產品的2-3倍。這讓它們從出廠那一刻起，就背負著沉重的成本包袱。
3. **產能（Capacity）**：中芯國際的先進製程產能優先供應給華為。這使得其他公司如寒武紀能獲得的份額非常有限，常常導致中國晶片陷入「理論上很不錯，市場上買不到」的窘境。2024年，華為昇騰910B的出貨量據估計僅20萬顆，而同期Nvidia向全球交付了超過100萬顆H100，差距顯而易見。

2.2 物理邊界之二：封裝與記憶體的空息點

- **先進封裝（Advanced Packaging）**：頂級AI晶片極度依賴如台積電 CoWoS 這類的2.5D/3D封裝技術，將多個晶片和記憶體堆疊在一起。中國本土的封裝廠如長電科技與通富微電，雖然在努力追趕，但在技術成熟度和產能上仍有差距，這直接限制了中國晶片系統性能的上限。
- **高頻寬記憶體（HBM）**：這個市場被三星、SK海力士和美光三家巨頭壟斷。中國的長鑫存儲在技術上仍落後數代，無法自主生產HBM。這意味著所有中國高端AI晶片都面臨著關鍵「糧食」被隨時切斷的風險。

2.3 生態高牆：CUDA帝國下的三種選擇

如果說硬體決定了性能的「天花板」，那麼軟體生態則決定了開發者「是否願意走進這座房子」。在這場關於習慣、效率和信任的戰爭中，所有玩家都必須面對 **CUDA** 這座高牆，並做出自己的選擇。

1. 無可爭議的帝國 —— Nvidia CUDA：

經過15年的投入，CUDA佔據了超過90%的市場份額。它集開發工具、函式庫和龐大的開發者社群於一體，形成了一條深不見底的護城河。

然而，其專有和封閉的特性，在出口管制的背景下，也成為中國用戶最致命的戰略弱點。

2. 雄心勃勃的挑戰者 —— 華為的CANN與MindSpore：

華為選擇了最艱難的道路——建立一個完全獨立的系統。

其優點是完全自主可控，但生態過於年輕，長期被開發者批評不穩定、文檔差，學習曲線極其陡峭。

3. 務實的適應者 —— 阿里與寒武紀的「兼容派」：

它們選擇兼容 **PyTorch** 等主流開源框架，極大降低了開發者的遷移門檻。

但這種策略的代價是無法建立自己獨有的生態護城河，且底層優化受限。

第三章：戴著鐐銬的王者——Nvidia的防守反擊戰



Nvidia prepares a new AI chip for China

面對中國市場這塊佔其數據中心業務近20%的版圖，Nvidia的處境極為微妙。

它既要遵守美國政府日益嚴苛的規定，又要抵禦中國本土競爭對手的蠶食。

它的策略不是硬碰硬的對抗，而是一場精密的、在規則邊緣遊走的防守反擊。這是一場戴著鐐銬的舞蹈，每一步都必須精準無比。

3.1 H20的昂貴教訓與15%的枷鎖

H20晶片的潰敗，給Nvidia上了一堂價值 **45億美元** 的昂貴課程。

這筆驚人的庫存減損，不僅是財務報表上的一個數字，更是華爾街衡量其管理層應對地緣政治風險能力的關鍵指標。

然而，相比於一次性的損失，後續的「**15%營收上繳**」條款，才是套在Nvidia脖子上一個更長期、更棘手的枷鎖。這個條款對Nvidia的商業模式構成了三重打擊：

1. **毛利率的直接侵蝕**：15%的費用將從其高達75%以上的毛利率中直接扣除，無論會計上定義為稅金還是銷售成本，都將重創其盈利能力。
2. **銷售渠道的混亂**：將成本轉嫁給客戶會削弱產品競爭力，自行吸收則犧牲利潤。這種兩難處境讓其通路夥伴無所適從。
3. **營收確認的會計難題**：在法規細節不明朗之前，無法確認相關收入，這直接導致了2025年第二季度對華銷售額戲劇性地歸零。

3.2 B30A：一把懸而未決的法律工程學手術刀

在H20的廢墟之上，Nvidia正在醞釀其下一代應對方案：**B30A**。

然而，這款晶片並非已成定局的產品，而是仍處於一個「微妙階段」的「法律工程學」產物。

它的所有細節，從最終性能到能否面市，都取決於與美國政府的持續對話。

Nvidia CEO黃仁勳本人也坦言，雖然公司正在為中國市場準備H20的後繼產品，但「這不是我們能做的決定，這取決於美國政府。」

因此，我們對B30A的分析，是基於目前市場上最可靠的傳聞和消息，來推演Nvidia試圖在這條合規的鋼絲上，走出怎樣精妙的舞步。

它的目標，依然是沿著「性能密度」的紅線進行一次完美的外科手術式切割。

B30A的設計哲學：一個更聰明的「半顆心臟」

據市場消息，B30A的性能約是其全球旗艦B300的一半。但這不是簡單的算力減半，而是一場精密的「外科手術」，其核心是架構的代際飛躍：

- **從Hopper到Blackwell**：H20基於較舊的Hopper架構（H100的同代技術），而B30A據稱將搭載Nvidia最新的Blackwell架構。這本身就是一次根本性的升級，意味著底層效率和能力的全面提升。

- **單晶片設計：**據行業推測，B30A將採用更簡潔的單晶片（**Single-Die**）設計，將所有電路整合在一塊完整的矽片上。這既降低了製造成本，也更容易在性能上進行精準控制以滿足法規。

這場手術的精妙之處，據稱體現在以下三個關鍵的「取」與「捨」：

1. 架構優勢：取「巧勁」，而非「蠻力」

B30A預計將繼承Blackwell架構最核心的優勢，例如其搭載的第二代Transformer Engine。這就像給晶片安裝了一個專門理解AI語言模型的「協同處理器」。

好比一台僅有1200萬像素的最新款手機，憑藉其先進的AI影像處理晶片，在色彩和夜景表現上能輕鬆勝過一台只有「蠻力」的2400萬像素老款相機——B30A追求的正是這種「架構巧勁」，而非純粹的算力堆砌。

2. 記憶體的去捨：取「個人空間」，捨「團隊頻寬」

這是B30A相較於H20最顯著的潛在升級。據報導，它將配備高達**144GB**的**HBM3e**高速記憶體，比H20的96GB HBM3多出了整整48GB。

這相當於給一個天才員工配備了超快的本地硬碟（HBM3e），並且硬碟容量還擴大了**50%**，讓他能獨立處理更龐大、更複雜的個人任務。

然而，正如「性能密度」規則所要求的，儘管個人工具升級了，但辦公室的總體溝通效率（互連頻寬）依然會受到嚴格限制，導致在需要千人協作的大項目中，數據共享的延遲仍會拖慢整個團隊的進度。

這正是性能密度管制的目標：允許單兵作戰極其高效，卻從根本上限制大規模叢集的組建能力。

3. 功耗與互連：更精準的「節流閥」

B30A的設計並非簡單降級，而是更精準的「節流」。

- **功耗控制（更優的能效比）：**H20的功耗約為400瓦。得益於Blackwell架構據稱高達25倍的能效提升，B30A預計能在相近甚至更低的功耗下，釋放出遠超H20的性能。這如同設計一台性能翻倍的超級家電，卻依然能使用「標準插座」，無需客戶對數據中心進行昂貴的電源改造，極大降低了部署成本。

- **互連技術（帶有限速閥的私家高速）**：B30A據稱保留了Nvidia自家的NVLink高速互連技術。這是一個關鍵的信號。它不再是「放棄私家高速公路，改走公共道路」，而更像是「你依然可以在私家高速上行駛，但我們給你安裝了一個無法拆卸的電子限速閥」。Nvidia提供了最好的技術，但將其速度精確地校準在合規的紅線之下，既保證了基礎的叢集能力，又滿足了性能密度的嚴苛要求。

總結而言，Nvidia在中國的策略已經非常清晰：

它放棄了在頂級訓練市場上與政策進行正面對撞，而是利用其無可匹敵的CUDA生態和深厚的架構設計能力，提供一個性能「足夠好」、開發體驗「最熟悉」、部署成本「可接受」的次優選擇。


它的賭注是：對於中國廣大的AI應用開發者而言，與其去適應一個全新的、不成熟的中國軟硬體平台，不如繼續留在熟悉的CUDA環境裡，即便硬件性能受到了一些限制。

這場防守反擊戰的成敗，將直接取決於中國本土的挑戰者們，能否提供一個真正具備吸引力的替代路徑。

但對於中國的政府、國企、甚至像字節跳動這樣的巨頭，採購中國晶片不僅是商業決策，也帶有「政治正確」和「供應鏈安全」的戰略考量。

他們有多大的決心和意願去承受遷移到中國平台的陣痛？這種來自客戶端的壓力，是Nvidia的CUDA護城河在中國市場面臨的最大侵蝕力量。

第四章：中國國家隊的王牌——華為的全棧式豪賭



Tech war: Huawei to open-source AI chip toolkit to take on Nvidia's proprietary platform | South China Morning Post

在美國制裁切斷其手機業務的命脈之後，華為將其驚人的研發能量和求生本能，全部注入了雲計算和AI這兩個新戰場。

與市場上其他晶片設計公司不同，華為的目標從一開始就不是設計一顆能單獨出售的晶片，而是要打造一個能與Nvidia生態系全面抗衡的「平行宇宙」。

這是一場從底層晶片、到伺服器、再到軟體框架的全棧式（Full-Stack）豪賭。

4.1 昇騰（Ascend）架構與HCCS高速互連

華為的底氣，來自其「昇騰」（Ascend）系列AI晶片。從910B到最新的910C，其單卡算力在理論上已經達到了可以與Nvidia降規版晶片一較高下的水平。

但華為深知，單卡的性能競賽已非戰場的全部。在大型語言模型（LLM）的時代，真正的決勝點在於「叢集擴展能力」：

即能否將成千上萬顆晶片高效地連接起來，形成一個統一的超級計算機。

這正是華為與寒武紀等對手最顯著的區別所在。華為亮出的王牌是其自研的HCCS（Huawei Collective Communication Service）高速互連技術。

- 對標NVLink：HCCS是專為昇騰設計的高速互連，讓數據在數千晶片間高效傳輸。
- 系統級優勢：Nvidia合規晶片頻寬受限時，華為叢集可全速運行，系統優化勝過單點性能。

4.2 軟體生態的艱難破局：從MindSpore到擁抱PyTorch

華為從一開始就明白CUDA生態的強大之處。

為此，它也採取了「硬體+軟體」雙管齊下的策略，推出了對標CUDA的底層計算架構CANN（Compute Architecture for Neural Networks），以及對標TensorFlow/PyTorch的上層深度學習框架MindSpore。

然而，從零建立生態無異於愚公移山，開發者很難放棄PyTorch的便利。在認識到這個殘酷的現實後，華為做出了務實的戰略轉向：如果無法打敗它，那就兼容它。

華為投入巨大資源開發PyTorch適配器，讓開發者幾乎無需修改代碼就能在昇騰硬體上運行模型。

這步棋從「要求你用我的語言」變成了「我能聽懂你的語言」，極大降低了遷移門檻，其兼容策略也正從主流開源模型的支持度上得到驗證。

4.3 「Atlas」伺服器：從賣零件到賣「解決方案」

華為戰略的最有趣之處，在於它並不主要以「晶片供應商」的身份參與競爭，而是以「系統整合商」的身份出現。

其核心產品是Atlas AI計算解決方案——一個包含了昇騰晶片、伺服器、HCCS交換機、液冷散熱系統以及整套軟體的全功能「算力機櫃」。

這種「賣系統」而非「賣零件」的模式，帶來了無可比擬的優勢：

1. 「交鑰匙」工程：對於客戶（尤其是政府、國企、大型科研機構）而言，他們購買的不是一堆需要自行組裝和調試的零件，而是一套插上電就能運行的完整解決方案。這極大降低了部署的複雜性和風險。

2. 性能保證：通過全棧自研，華為可以在系統的每一個環節進行深度協同優化，從而保證整個叢集的穩定性和性能表現。這是由不同廠商零件「攢」出來的系統所無法比擬的。
3. 戰略鎖定：一旦客戶採用了Atlas系統，就等於進入了華為的生態圈。從硬體升級到軟體維護，都將深度綁定華為，這構建了一條比單純的CUDA更難撼動的護城河。

4.4 投資者視角：如何看待不可投資的華為

華為的AI晶片戰略，是一場典型的「非對稱戰爭」。

它避開了在公開市場上與Nvidia進行晶片對晶片的直接對碰，而是利用其在系統整合、網路技術和軟體開發上的綜合實力，開闢了一個「系統對系統」的藍海戰場。

它的目標客戶非常明確：

那些將供應鏈安全和系統級性能置於CUDA生態便利性之上的核心用戶。

憑藉其獨一無二的「國家隊」身份和全棧整合能力，華為正在中國的AI算力版圖上，劃出一個越來越大的、自給自足的勢力範圍。

華為在推動其生態時，不僅僅是一家公司，它還扮演了部分「行業標準制定者」和「政府項目承包商」的角色。

例如，它與頂尖大學合作開設MindSpore課程，主導國家級的AI計算中心建設。這種「自上而下」的推廣能力，是其他民營公司完全不具備的，也是其生態系統雖難用但仍能快速鋪開的關鍵。

由於華為非上市公司，投資者無法直接對其進行投資。

然而，在分析中國AI產業鏈時，必須將華為視為一個「不可投資的基準（Un-investable Benchmark）」和「行業變數（Industry Variable）」。

其成功與否，直接定義了所有其他中國玩家（寒武紀、阿里、百度）的生存空間和天花板。

華爾街如何利用華為的數據：

- 衡量競爭格局：華為昇騰晶片的出貨量和市佔率，是評估Nvidia在華業務壓力、以及寒武紀等本土對手市場份額的「反向指標」。華為每多佔1%的市佔率，都意味著其他競爭對手潛在市場的縮

小。

- **評估供應鏈機會：**華為的崛起，為其背後的本土供應鏈（如中芯國際、先進封裝廠、伺服器組件商）提供了最直接的增長動力。分析師會追蹤「華為概念股」作為投資中國半導體自主化主題的替代方案。
- **判斷生態成熟度：**MindSpore的開發者活躍度和CANN生態的完善程度，是判斷中國AI生態能否「脫離」CUDA獨立行走的最重要風向標。

對其他公司的影響：

- **對寒武紀：**華為既是其在產能上的「爭奪者」（搶佔中芯國際產能），也是其在市場上的「頭號對手」。
- **對阿里/騰訊：**華為的全棧式解決方案，對雲巨頭們的企業客戶構成了直接競爭。
- **對Nvidia：**華為是唯一有潛力在中國市場從晶片、軟體到系統層面，對Nvidia構成全方位挑戰的對手。

總結：對於投資者而言，追蹤華為的每一個動作——從晶片發布到生態建設——不是為了買入華為，而是為了更精準地為其競爭對手和合作夥伴進行定價和風險評估。

第五章：雲端巨頭的自救 - 從降本增效到算力自由



Alibaba Cloud on making a difference with AI, big data - DCD

當外界的目光聚焦於華為的強勢崛起時，雲端運算巨頭們正在以一種更務實、更貼近商業本質的方式，開闢自己的求生之路。

他們的戰略核心並非在公開市場上與Nvidia一較高下，而是首先為自己龐大的商業帝國實現「算力自由」。

2025年8月底，華爾街日報報導阿里巴巴將會自研芯片，導致其股價飆升接近20%。

5.1 驅動力之變：從「降本增效」到「供應鏈自主」

要理解阿里巴巴為何要投入鉅資自研晶片，首先必須理解其商業模式的內在需求。

作為全球頂尖的雲服務商和電商平台，阿里巴巴的日常運營本身就是一個巨大的算力消耗機器。

它的第一步始於2019年，其內部晶片設計團隊「平頭哥」（T-Head）推出了含光800。

這款在當時採用台積電12奈米製程的**AI推理（Inference）**晶片，專為淘寶的商品搜索、圖像識別、個性化推薦等海量、高頻的場景而設計。

其驚人的能效比（每秒處理**78,563**張圖片）證明了自研晶片的巨大價值——用更低的成本，更高效地完成核心業務。

然而，從**2024**年開始，這條路的驅動力發生了質變。隨著美國出口管制收緊，台積電等全球頂尖晶圓代工廠被迫停止為中國客戶生產先進AI晶片。

這使得阿里巴巴的動機從單純的「降本增效」，升級為更具緊迫性的「供應鏈自主」。將核心業務的算力完全寄託於外部供應商，已成為不可接受的戰略風險。

5.2 新戰略：531億美元的豪賭與務實的「推理優先」

面對新局勢，阿里巴巴的應對是果斷的。

公司在上星期五宣布了一項為期三年的**3800億人民幣（約531億美元）**的龐大投資計畫。這筆資金的目標，是打造一個從晶片、到伺服器、再到雲端基礎設施的垂直整合AI生態系統。

這場豪賭的核心，是其**2025**年正在雲端數據中心進行測試的新一代AI晶片。

與華為試圖在訓練領域正面對決不同，阿里巴巴延續並深化了其務實的「推理優先」戰略。

- **戰略定位：**新晶片並非要挑戰Nvidia B300或H100在AI訓練上的王者地位，而是專注於處理更廣泛、更多樣化的AI推理任務。

這款晶片被設計得比舊款更具通用性，能服務於更廣闊的AI推理場景。對於雲端服務商而言，**80%**以上的AI算力需求來自於推理而非訓練，這是一個更龐大、更具成本效益的市場。

- **製造轉變：**最關鍵的變化是，這款晶片將從設計到生產，完全在中國本土完成。

這是一個里程碑式的轉變，意味著阿里為了供應鏈安全，願意接受在製程技術上（可能使用中芯國際的**7**奈米或更成熟的製程）暫時落後於全球頂尖水平的現實。

- **性能權衡：**在相對較舊的製程節點上製造，意味著其晶片在功耗和性能密度上可能不及台積電的**3**奈米產品。

但阿里巴巴的算盤是，通過系統級的優化和針對特定場景的設計，在真實的雲端推理應用中，依然可以獲得極具競爭力的成本和效率。

5.3 雙軌並行：擁抱開源RISC-V與兼容CUDA生態

阿里巴巴晶片戰略最有趣之處，在於其「雙軌並行」的軟體策略。這就像一個城市規劃師，他既要規劃一條通向未來的全新高速公路，又要修建一座能立刻解決當下交通擁堵的便橋。

軌道一：長期佈局，擁抱開源RISC-V（建一條屬於自己的新高速）

我們可以把主流的晶片指令集架構（如Intel的x86和手機上普遍使用的ARM）想像成由西方公司控制的「私有公路系統」。

而RISC-V則是一套開源、免費、全球共享的「公路設計藍圖」。

阿里巴巴旗下的「平頭哥」團隊，不僅用這份藍圖為自己設計了「玄鐵」系列晶片，還將自己優化過的設計圖也開源出去，希望吸引全球開發者共同建立一個不受任何人控制的全新生態。這是一條徹底實現自主可控的長遠道路。

軌道二：短期務實，無縫兼容CUDA（在對手的花園旁修一座便橋）

在「新高速」還未建好之前，開發者們依然擠在Nvidia那條名為CUDA的「私家高速」上。面對這個現實，阿里決定確保其新晶片與CUDA平台高度兼容。

這意味著什麼？如果說Nvidia的CUDA是蘋果的iOS生態，其他挑戰者就像安卓，需要勸說開發者為新平台重寫App。而阿里的策略則不一樣，它相當於推出了一款能直接完美運行所有iPhone App的新手機。

這就是「無痛切換」，它沒有試圖推倒Nvidia的圍牆，而是在牆邊巧妙地搭建了一座便橋，直接將牆內最寶貴的資產——開發者和他們的應用——吸引過來。

5.4 投資者視角：雲業務的價值重估

阿里巴巴的AI晶片之路，是一條典型的「由內而外」的垂直整合路徑。

它始於解決自身最迫切的成本和供應鏈安全問題，並通過一場531億美元的豪賭，將其自研的、以推理為核心的算力，深度整合進其佔據中國市場領先份額的雲端服務中。

它的戰場不在晶片貨架上，而在阿里雲的產品目錄裡——它不會直接出售晶片，而是將算力以雲服務的形式租賃給客戶。

通過將「中國國產、合規、低成本、且兼容CUDA生態」的自研算力轉化為雲服務產品，它不僅為自身的商業帝國築起了堅固的護城河，更在雲計算這個主戰場上，為自己打造出了一把用以吸引和留住客戶的、獨一無二的利器。

與此同時，騰訊（憑藉其「紫霄」晶片）和百度（憑藉其「崑崙芯」）也採取了類似的「自研自用、融入雲端」的垂直整合策略，共同構成了中國雲計算行業集體「自救」的圖景。

投資中國雲巨頭（如阿里巴巴），正從投資其「電商/社交業務的現金牛」邏輯，轉向投資其「雲端業務的價值重估（Re-rating）」。

自研AI晶片是實現這一價值重估的核心催化劑。市場開始意識到，自研晶片不僅僅是為了節省採購成本（降低Capex），更是為了在雲端主戰場上，打造一條不受地緣政治影響、具備長期利潤率優勢的戰略護城河。

華爾街關注的關鍵指標 (Key KPIs):

- 雲業務的營收增長與利潤率（**EBITA Margin**）：這是最核心的指標。如果自研晶片能帶來雲業務利潤率的持續改善，將直接提升整個公司的估值中樞。
- 資本支出（**Capex**）佔營收比重：成功的晶片自研和部署，應能有效降低對外採購昂貴GPU的依賴，從而在中長期內降低資本支出強度。
- 自研晶片在內部業務的滲透率：有多少比例的AI工作負載（特別是推理任務）運行在自研晶片上。

潛在催化劑 (Catalysts):

- 正面：阿里雲宣布其核心AI服務（如大模型推理）的成本因自研晶片而降低了30%以上；其「兼容CUDA」的方案獲得大量開發者採用，形成新的生態吸引力。

- 負面：自研晶片性能或穩定性不及預期，導致雲業務的競爭力下降；高昂的研發投入在數年內無法轉化為顯著的財務回報。


市場情緒與估值考量：

長期以來，市場對阿里等公司的估值受到監管壓力、宏觀經濟和激烈競爭的多重壓制。

AI晶片的「供應鏈自主」故事，為華爾街提供了一個全新的、具有想像空間的敘事。

如果阿里能證明其531億美元的投資能換來雲業務的「高質量增長」（即有利潤的增長），其估值有望從當前的「價值股（Value Stock）」邏輯，部分切換回「成長股（Growth Stock）」邏輯。

第六章：獨立挑戰者的豪賭



國產AI晶片「寒武紀」業績爆發一度超茅台成股王

在中國AI晶片的版圖上，寒武紀（Cambricon）是一個迷人的存在。

它既是中國在AI晶片設計領域技術實力的巔峰代表，也是整個中國半導體工業「卡脖子」困境最真實的縮影。

其近期在資本市場上44倍的營收年增長和首次實現季度盈利的驚人表現，是由一個由地緣政治（制裁窗口）、戰略客戶（深度綁定）和務實策略（兼容生態）共同構成的「完美風暴」所催生。

但這耀眼的光環之下，是懸於設計、製造、客戶和軟體四條鋼絲之上的驚險一舞。

6.1 設計上的榮光：直面H100的雄心

寒武紀的故事，首先必須從其毋庸置疑的設計能力講起。這家由中科院「天才少年班」出身的陳氏兄弟創立的公司，已經用產品證明，在繪製AI晶片藍圖的競賽中，中國並不落後。

- **旗艦產品MLU370系列**：這款晶片採用先進的Chiplet（小晶片）技術，在台積電7奈米製程上集成了高達390億個電晶體，明確瞄準了高端訓練市場。
- **下一代思元（Siyuan）系列的野望**：其思元590據稱已能達到Nvidia A100約80%的性能。而正在開發中的思元690，其設計目標更是直接鎖定Nvidia的上一代旗艦H100。

6.2 製造上的枷鎖：看得見卻摸不著的性能

然而，一張再輝煌的藍圖，如果無法被完美地製造出來，也只是一張廢紙。

真正的噩夢，始於2022年12月——寒武紀被列入美國實體清單，這切斷了它與台積電的合作生命線，迫使其全面轉向中國本土的晶圓代工廠——中芯國際（SMIC）。

這一轉變，讓寒武紀一頭撞上了剛才提過的中國半導體工業最堅硬的「嘆息之牆」，面臨三重枷鎖：

1. **良率的詛咒**：中芯7奈米良率不足50%，製造成本數倍台積電。
2. **成本的枷鎖**：售價低但對於數據中心而言，它們計算的是總擁有成本（TCO），包括了電費和散熱成本。由於製程落後，寒武紀晶片要達到同樣的算力，功耗通常更高。功耗大增電費，蠶食價格優勢。

3. 產能的爭奪：在中芯國際有限的先進產能中，華為是優先級最高的客戶，寒武紀作為「外部客戶」，容易陷入「有訂單，無產能」的困境。

6.3 戰略生命線：與字節跳動的「共生」及務實的軟體

在製造的絕境中，寒武紀之所以能上演營收暴增的奇蹟，關鍵在於它抓住了兩根戰略生命線。

第一根生命線：與字節跳動的「共生」，而非簡單的「依賴」

這段關係早已超越了簡單的客戶關係，也吸取了早期被華為拋棄的慘痛教訓（2018年，華為曾佔其收入的98%）。

- 訂單的規模與確定性：在字節跳動2025年高達600億元人民幣的AI晶片採購計畫中，給予寒武紀的份額預計高達40%-60%。這提供了極其實貴的、可預期的市場需求。
- 技術層面的深度鎖定：這才是「共生」的核心。字節跳動內部已有數千個AI模型，是專門針對寒武紀的硬體架構和軟體指令集進行了深度優化。如果更換供應商，意味著巨大的遷移成本，這形成了一條強大的技術護城河和業務鎖定。
- 數據反哺設計：字節跳動海量的真實世界工作負載數據，可以反哺給寒武紀，使其下一代晶片設計能精準地針對真實需求進行優化，形成設計-應用-反饋的良性循環。

第二根生命線：務實的軟體——最聰明的「兼容」策略

在軟體生態這座大山面前，寒武紀展現了高度的務實精神。它沒有像華為那樣執著於推廣一個全新的、被開發者詬病為「不穩定、文檔差」的CANN框架，而是選擇了一條更聰明的路：

- 擁抱兼容，降低「換軌成本」：寒武紀大力投入其**MagicMind**推理加速引擎，並著力增強對Nvidia CUDA生態的兼容性。
- 這為何聰明？強迫一個習慣了CUDA的開發者去學習CANN，就像強迫一個只會英語的程式設計師去用俄語寫代碼。而寒武紀的策略則是：「你可以繼續用你習慣的『語法』，我的平台能聽懂。」這極大降低了開發者的遷移成本，在國內市場，這種「對開發者友好」的策略，成為了它相較於華為的一個關鍵差異化優勢。

6.4 投資者視角：高風險、高回報的純粹標的

寒武紀的生存與爆發，源於一個精妙的平衡。但這種平衡也潛藏著四大致命風險：

1. **客戶單一風險**：對字節跳動的深度依賴是一把雙刃劍。一旦字節跳動的戰略轉向（例如未來也決定自研晶片），寒武紀可能重蹈覆轍。
2. **製造瓶頸風險**：它的命運，不掌握在自己手中，而取決於中芯國際何時能將那不足50%的良率，變成一個有商業競爭力的數字。
3. **代際追趕風險**：即使思元690成功對標H100，Nvidia的下一代Blackwell系列已經全面鋪開。寒武紀始終在追趕一個不斷加速的目標。
4. **內部競爭風險**：在有限的國內產能下，它必須與華為這樣的「巨無霸」爭搶資源。

寒武紀的故事，是中國AI晶片產業最真實的寫照：既有衝擊世界之巔的設計雄心，又被製造的現實牢牢鎖住腳踝；既有抓住戰略機遇的商業智慧，又時刻面臨著依賴單一大客戶的潛在危機。

它能否將這場驚險的鋼絲舞，最終走成一條康莊大道，將是未來幾年中國科技領域最值得關注的焦點之一。

投資寒武紀，是一場典型的「高風險、高回報」的豪賭。

它是在中國A股市場上，對「非華為系」中國AI晶片龍頭最直接的「純粹投資（Pure-play）」。「其股價表現是多個極端變數的函數，包括單一大客戶的依賴、製造良率的瓶頸以及與巨頭的技術競賽。」

華爾街關注的關鍵指標 (Key KPIs):

- **客戶集中度**：來自字節跳動的收入佔比。任何關於字節跳動尋找替代供應商（包括自研）的跡象，都將對其估值構成致命打擊。
- **毛利率與淨利潤**：首次實現季度盈利是一個重要的里程碑。市場將密切關注其盈利的可持續性，以及毛利率能否在中芯國際產能爬坡後得到改善。
- **出貨量與庫存**：實際出貨量證明其將訂單轉化為收入的能力，而庫存水平則反映了製造端（良率）和需求端是否存在問題。

潛在催化劑 (Catalysts):


- 正面：成功開拓除字節跳動外的第二個「億元級」大客戶，打破單一依賴風險；中芯國際宣布其7奈米良率取得重大突破；其軟體兼容策略吸引到一批原CUDA生態的中小企業客戶。
- 負面：字節跳動大幅削減訂單；華為昇騰晶片憑藉系統優勢和產能優先級，搶走其潛在客戶；新一代晶片（如思元690）性能評測不及預期。

市場情緒與估值考量：

寒武紀的估值極具波動性，PE Ratio並不算是一個好的指標，始終他們才剛剛成功扭虧為盈。其股價對政策風聲、行業傳聞和客戶訂單消息極其敏感，是典型的「事件驅動型」股票。

投資者必須清楚，自己投資的不是一家成熟的企業，而是一個在鋼絲上奔跑的潛力選手，其未來存在歸零和翻倍的雙重可能。

終章：終局推演——場景、變數與最終的判決



US expands curbs on China's AI memory and chip tools, raising supply chain concerns | CIO

綜合以上對賽局規則、共同枷鎖以及各方玩家策略的分析，我們可以對這場中國晶片戰爭的未來，做出更清晰的場景推演。

7.1 賽局推演：未來1-5年的場景分析

• 1-3年內（2025-2027）：混亂的「中國國產替代」期

- 場景：市場將呈現「高端靠走私，中端用降規，低端中國國產」的混亂格局。Nvidia的降規版晶片（如B30A）和通過灰色市場流入的高端晶片，仍將是大型模型訓練的主力。華為和寒武紀將在中國政府、國企及部分頭部互聯網公司的「國產化」訂單中搶佔份額，但規模受限於製造瓶頸。
- 關鍵催化劑/風險：美國是否會進一步收緊對降規版晶片的限制；中芯國際7奈米良率能否突破50%。
- 核心KPI：華為/寒武紀的實際出貨量和市場份額；中芯國際的良率和產能擴張速度。

- **3-5年內（2027-2029）：生態的「鞏固與分化」期**

- **場景：**中國的AI應用將出現明顯分化。追求極致性能和全球通用性的公司，將繼續想方設法使用Nvidia產品。而更看重供應鏈安全和成本效益的應用（尤其是在推理、政務、金融等領域），將大規模遷移至以華為為核心的中國軟硬體棧。中國的HBM和先進封裝技術有望取得初步突破，緩解部分瓶頸。
- **關鍵催化劑/風險：**中國國產HBM是否能量產；華為CANN生態的易用性是否得到根本性改善。
- **核心KPI：**中國國產AI晶片在推理市場的佔有率；華為MindSpore的開發者社群活躍度。

- **5年以上（2030+）：走向「技術分岔」**

- **場景：**全球AI技術生態可能走向事實上的「技術分岔」。一個是以Nvidia-CUDA為核心的全球生態，另一個是以華為-CANN為核心的、主要在中國及部分「一帶一路」國家運行的獨立生態。屆時，中國可能在某些特定領域形成非對稱優勢，但在尖端製程上可能依然落後。
- **非對稱優勢體現：**
 - **成熟製程的規模優勢：**利用龐大的28/14奈米產能，在物聯網、汽車晶片等領域形成絕對的成本和規模優勢。
 - **應用場景的數據優勢：**憑藉海量數據，在人臉識別、智慧城市等應用上，通過「應用層的創新」來彌補「硬體層的不足」。
- **關鍵催化劑/風險：**中國在光刻機等核心半導體設備上能否取得顛覆性突破。
- **核心KPI：**中國半導體的整體自給率；兩個生態系統之間的軟體兼容性。

7.2 灰色市場(Grey Market)的「萬能牌」

在所有分析中，必須承認「灰色市場」這張萬能牌的存在。通過各種渠道走私或拆解再利用的Nvidia高端GPU，如同一個壓力釋放閥。

這是一把雙刃劍。

它一方面讓中國的頂尖AI研發不至於完全停滯，但另一方面，也削弱了中國國內企業轉向中國本地方案的緊迫性，在一定程度上延緩了中國軟體生態的建設進程。

7.3 最終想法：一場沒有終點的平行賽跑

綜上所述，中國的AI晶片之戰，其最終結局可能並非是傳統意義上的「追趕」或「超越」。

由於在製造設備這一根源上被「釜底抽薪」，中國極難在同一條跑道上追上對手。

更有可能的未來是，中國將被迫另闢蹊徑，開闢一條平行的賽道。

在這條賽道上，中國將利用其巨大的市場、國家級別的投入和在系統應用上的創新能力，去彌補其在底層硬體上的短板。這將導致一個與世界主流不同的、自成一體、但功能「夠用」的技術體系的誕生。

這不是一場百米衝刺，而是一場沒有終點的、在不同規則下的平行賽跑。這場賽跑的結果，將深刻地重塑未來數十年的全球科技版圖。

最後，宣傳一下自己，我在Threads，Facebook和IG都有定期發文，另外Telegram有頻道，每天早上我會發當天重要新聞摘要，有興趣可以追蹤一下我，鏈結是：

https://linktr.ee/fomo_soc

當然，如果你都看到這裡，這麼精彩的文章，給個讚也不過份吧哈哈。

- KP

本機離線版本・圖片與內文完整

← 回索引

在原文開啟 ↗