


[← 索引](#) [💎 付費](#) 2025-10-28 796 字 [↗ 原站](#)

70%毛利的秘密：CUDA，NVIDIA的「軟體稅」 - 深度分析第17期：NVDA護城河 (下)



70%毛利的秘密： CUDA，NVIDIA的「軟體稅」 深度分析：NVDA護城河(下)

在上篇的「深入分析」中，我們討論了NVIDIA用各種線纜和晶片組成的「硬體護城河」。

那是一道看得見的牆，就像樂高積木一樣，雖然複雜，但你至少能看到它的形狀和結構。

但是，NVIDIA帝國最堅固的防線，其實是一道看不見的牆。它不是由硬體構成，而是由軟體編織而成。這個軟體的名字，叫做 **CUDA**。

想像一下，你為什麼選擇使用Windows或macOS作業系統？是因為它們的電腦外殼更漂亮嗎？不完全是。

你選擇它們，是因為你習慣了它們的操作方式，更重要的是，所有你需要的軟體——從Office辦公套件到Photoshop，再到各種遊戲——都只能在這些系統上完美運行。

CUDA，就是NVIDIA為自家GPU打造的「Windows系統」。

過去十五年，NVIDIA投入了無數資源，讓全世界最聰明的開發者和科學家都習慣於在CUDA這個「系統」上工作。

久而久之，這形成了一種巨大的依賴性。這份依賴，比任何硬體連接都更難以撼動。它是一種看不見的引力，把所有人都牢牢吸附在NVIDIA的生態系統裡。

這篇文章，我將為您揭開這個「軟體帝國」的秘密：

- **CUDA究竟是什麼？** 它如何從一個陌生的名詞，變成AI世界的「通用語言」？
- **開發者為何「叛逃」不了？** CUDA是如何用一個規模懸殊的生態系，將開發者牢牢鎖定？
- **對手們的反擊：** 為什麼AMD明明能造出記憶體頻寬高出60%的強大晶片，卻始終無法挑戰NVIDIA的地位？
- **這道軟體牆，**如何轉化為華爾街夢寐以求的8.1倍營運槓桿和70%以上的驚人毛利率？
- **軟硬體如何聯手，**讓NVIDIA的霸權像滾雪球一樣，越滾越大？
- **ASIC的崛起：** 為何雲端巨頭選擇另闢蹊徑，打造自己的專用晶片？
- **我們應該如何看待Nvidia的CUDA護城河？**

讓我們回到故事的開頭，看看CUDA是如何誕生的。

在開始之前，想跟大家同步一下本週文章的小變動。

我目前人正在外地和家人旅遊，雖然旅途中仍心繫市場，但考量到寫作一篇深度研究需要非常專注的狀態和完整的資料庫支援，為了不辜負大家對內容的期待，我認為倉促地在本週趕出兩篇文章，並不是最好的做法。

所以，我做了一點小小的調動：

- 本週：我會先發佈大家期待已久的「Nvidia 護城河(下篇)」。
- 下週：之前由會員們票選出來的「Cybersecurity 資訊安全」主題，將會和另一篇文章在下週一起發佈。

這也意味著，下週大家會一次收到兩篇熱騰騰的深度文章！文章總數一篇都不會少，只是讓我能用最好的狀態，把最好的內容呈現給你。

謝謝你的理解和支持，讓我們繼續!

第一章：CUDA創世紀

CPU與GPU的差異		
	CPU(中央處理器)	GPU(圖形處理器)
功能	處理伺服器主要處理功能的一般元件	擅長平行運算的專用元件
處理	專為串列指令處理而設計	專為平行指令處理而設計
設計	核心更少、更強大	核心較CPU多、但功能不如CPU內核
適合	一般用途運算應用程式	高效能運算應用程式

製表時間 2023.06.02: 雲霄學堂整理

在CUDA誕生前，電腦核心住著兩位員工：**CPU**，一位能處理複雜邏輯的「超級博士」，但他分身乏術；**GPU**，一支由成千上萬士兵組成的「人海大軍」，只會簡單指令卻能同時開工。

這支大軍曾是「繪圖特種兵」，語言不通，只能透過**DirectX**和**OpenGL**等高度特化的「繪圖指揮部」接受命令。程式設計師無法直接指揮它進行通用計算——這扇大門是緊鎖的。

風暴前的「黑魔法師」

然而，對強大算力的渴望無法被禁錮。**CUDA**出現前，一小群頂尖科學家，如同中世紀的煉金術士，發明了一種被稱為**GPGPU (通用圖形處理器編程)**的「黑魔法」。

他們用極其巧妙的方式，將自己的科學問題「偽裝」成繪圖問題來欺騙**GPU**。

例如，一位想計算大型矩陣乘法的科學家，會對**GPU**說：「我這裡有兩張特殊的『圖片』（矩陣數字編碼成像素顏色），請你用特製的『濾鏡』（乘法運算偽裝成渲染效果）處理，再把生成的新『圖片』交給我。」科學家拿到結果後，再將顏色解碼還原成數據。

這個過程痛苦、複雜、效率低落，且僅有極少數天才得以掌握。它就像逼迫畫家寫小說，你只能給他顏料，讓他把每個字都「畫」出來。

然而，這些「黑魔法師」的存在，向**NVIDIA**傳遞了一個無比清晰的信號：市場對通用、大規模並行計算存在巨大渴求，只缺一把好用的鑰匙。

革命的火花 —— **CUDA**的誕生

NVIDIA的高層與工程師憑藉敏銳洞察，決定親手打造那把鑰匙。**CUDA**的誕生，並非偶然的賭博，而是一場匯集了技術演進、學術契機與宏大商業遠見的完美風暴。

1. **技術成熟**：GPU硬體正經歷一場革命，從「固定功能管線」演進為「可程式化著色器」。這意味著GPU核心單元不再是功能寫死的晶片，而是更像微型、可編程的處理器。硬體的大門已悄然打開。
2. **學術契機**：史丹佛大學博士生Ian Buck的研究項目Brook，旨在開發更簡單的GPU通用編程模型。**NVIDIA**看到其巨大潛力，果斷將其團隊招致麾下，將學術藍圖轉化為工業級平台。
3. **宏大遠見**：**NVIDIA** CEO黃仁勳預見到，依賴CPU的摩爾定律即將觸頂，計算的未來必然屬於「並行計算」。他的策略不是自己淘金，而是成為向所有淘金者出售頂級「鏟子和十字鎬」的人。


NVIDIA的戰略一以貫之：用最頂尖的硬體定義市場，再用最前瞻的軟體生態鎖定未來。每一次看似冒險的投資，都是對未來生態的精準佈局。

這種敢於為未來下大注的基因，深植於NVIDIA的歷史。

從90年代末瀕臨破產時，傾盡所有豪賭RIVA 128晶片，用頂級硬體與微軟標準的結合死裡逃生；到AI浪潮前夕，慷慨地將當時世界最強的AI超算DGX-1捐贈給尚名不見經傳的OpenAI。

NVIDIA的戰略一以貫之：用最頂尖的硬體定義市場，再用最前瞻的軟體生態鎖定未來。每一次看似冒險的投資，都是對未來生態的精準佈局。

於是，2006年，**CUDA (Compute Unified Device Architecture, 統一計算設備架構)** 正式問世。




CUDA究竟是什麼？它就是「指揮手冊」與「翻譯官兼總指揮」的集合體。

- **作為翻譯官：**它提供了一套基於C++、Python等流行語言的擴充，讓程式設計師用熟悉語法下達通用計算命令，再由CUDA翻譯成GPU能懂的指令。
- **作為總指揮：**它能將龐大任務智能分解成成千上萬個並行子任務，分派給GPU每個核心，並在完成後高效匯總結果。

CUDA的出現，徹底終結了「黑魔法」時代。它將**GPU**從「繪圖特種兵」解放出來，變成了一支能投入任何大規模計算戰場的「通用方面軍」。

降維打擊與無心插柳

CUDA推出時，AI仍在學術的象牙塔中沉睡。NVIDIA的首要目標，是一個已存在且利潤豐厚的市場：**高效能運算 (HPC)**。



他們的策略是「降維打擊」——用相對廉價、可大規模部署的GPU方案，去搶佔原本屬於昂貴專用超級電腦的市場。

- 對科學界：「不必再等數百萬美元的超算。買幾十片我們的顯卡，就能用CUDA搭建自己的小型超算，做天氣預報、藥物研發。」

- **對華爾街：**「用GPU跑金融定價模型，幾小時的計算縮短到幾分鐘，讓你們在市場中搶佔先機。」
- **對能源產業：**「用GPU分析地震數據，可以更快找到地底的石油和天然氣。」

這是一個極其穩健的商業計畫，為NVIDIA帶來了豐厚回報。

然而，一個他們未曾預料的巨浪，即將到來。

根據NVIDIA現任首席科學家Bill Dally回憶，歷史的轉捩點發生在2011年。當時他的史丹佛同事、AI先驅吳恩達（Andrew Ng）在Google Brain用16,000顆CPU在網路上尋找貓的圖片。

Dally意識到GPU的潛力，指派了一位研究員與吳恩達合作，最終僅用48顆NVIDIA GPU就實現了更快的速度。這個專案的成果，直接催生了**cuDNN**函式庫的誕生，為即將到來的深度學習革命奠定了基礎。

一年後的2012年，Geoffrey Hinton的團隊使用兩張NVIDIA GPU，透過CUDA訓練出神經網路**AlexNet**，在全球權威的ImageNet圖像識別大賽中以碾壓性優勢奪冠。

這聲巨響，震驚了整個科技界。

它證明了「深度學習 + 強大算力 (GPU)」這條道路的正确性。對NVIDIA而言，他們驚訝地發現，為HPC市場打造的工具，竟在一個未曾預料的領域引爆了一場革命。AI市場的潛力，遠比他們想像的任何市場都龐大。


從此，CUDA的應用場景呈爆炸式擴散。它不僅是學術研究的利器，更成為了產業變革的核心引擎：從DeepMind用AlphaFold解開蛋白質摺疊之謎，到特斯拉利用其進行自動駕駛模型的訓練，甚至在加密貨幣的浪潮中，無數的GPU也曾夜以繼日地為加密貨幣挖礦而轟鳴。CUDA的影響力早已超出了NVIDIA最初的設想。的設想。

• 本章總結:

- CUDA的誕生，是將GPU從僅限繪圖的「特種兵」解放為通用計算「方面軍」的革命，終結了此前複雜低效的「黑魔法」編程時代。

- NVIDIA最初以「降維打擊」策略，用CUDA搶佔高效能運算（HPC）市場，這為其帶來了穩定的早期回報與生態基礎。
- 2012年AlexNet的突破是歷史的轉捩點，無心插柳地將CUDA推向AI革命的中心，其潛力遠超NVIDIA最初的預期。

第二章：究竟CUDA是甚麼？



當我們談論 NVIDIA 在 AI 領域的霸主地位時，許多人會想到他們的 GPU 硬體。但這只看到了冰山一角。NVIDIA 真正打造的並非單一產品，而是一個精心雕琢、環環相扣的「四位一體」開發者王國。這個王國的設計初衷，就是讓所有進入的開發者，都能感受到前所未有的強大與便捷，最終舒適地「定居」下來，再也不想離開。

想像一下，您想蓋一座史上最宏偉、最酷炫的樂高城堡。NVIDIA 的 GPU 顯示卡，就像是給了您一座堆積如山的樂高積木，擁有無限的可能性。

而 CUDA，就是您蓋城堡時，附贈的一套「超級豪華魔法工具箱」。這套工具箱裡，有四樣緊密配合的法寶：

第一重：王國的基礎法則 —— 編程模型與 API

這是 CUDA 王國的「物理定律」，是一切的基石。它定義了開發者如何與 GPU 這片新大陸溝通的「官方語言」。

它用清晰的規則告訴你：如何定義一個可以在 GPU 上運行的核心程式（**Kernels**），如何組織和指揮那成千上萬的計算士兵（管理線程 **Threads**），以及如何在 CPU 指揮官和 GPU 大軍之間高效地傳遞糧草與數據（管理記憶體）。

例如，開發者會使用一個特殊的關鍵字 `__global__` 來定義一個將在 GPU 上運行的函數（即「核心程式」），然後用一個獨特的 `<<<...>>>` 語法來指定要動用多少「計算士兵」（線程）來執行這次任務。這幾個簡單的符號，就是進入並行計算世界的「魔法咒語」，是 CUDA 王國的官方語言。

【用樂高來理解】

這就像是工具箱裡的「終極說明書」。

它會寫得清清楚楚，告訴您 A 積木要怎麼和 B 積木完美地卡在一起，教您蓋出一面牆、或一座高塔的基本規則。如果沒有這本說明書，您可能只會對著那座積木山發呆，不知從何下手。

第二重：現成的神兵利器 —— 殺手級函式庫 (Libraries)



這才是 CUDA 生態系真正的靈魂，也是 NVIDIA 最具智慧的一步。NVIDIA 深知，不是每位開發者都有時間或精力，從零開始創造複雜的底層演算法。

於是，NVIDIA 聘請了數千名全球頂尖的博士與工程師，為開發者預先打造好了一套套威力無窮、針對自家硬體優化到極致的「傳世武功秘籍」。這就是**函式庫**。NVIDIA官方將其打包為 **CUDA-X**，一個包含超過 900個 專用函式庫、框架和模型的龐大集合。

- **cuDNN (CUDA Deep Neural Network library)**：專為深度學習打造的「內功心法」，所有主流 AI 框架（如 TensorFlow）都依賴它來實現底層運算。
- **cuBLAS (CUDA Basic Linear Algebra Subroutines)**：科學計算的「基礎拳腳」，提供最高效的矩陣運算。
- **TensorRT**：專為AI「推理」打造的「速度增幅器」，能將訓練好的模型進行極致壓縮和優化，讓其在實際應用中跑得更快、成本更低。
- **NCCL (NVIDIA Collective Communications Library)**：用於大規模模型訓練的「集團軍通訊系統」，負責在數千張GPU之間高效傳遞數據，是訓練萬億級參數模型的生命線。
- **cuFFT**：用於「快速傅立葉變換」的數學武器，在信號處理、物理模擬等領域不可或缺。
- **RAPIDS**：一套完整的資料科學加速函式庫，讓資料科學家可以直接在GPU上完成從數據處理到模型訓練的全流程，速度比傳統CPU流程快數十倍。

NVIDIA為幾乎每一個需要龐大算力的垂直領域，都鍛造了一把專屬的「屠龍刀」。相比之下，其主要競爭對手AMD ROCm的核心函式庫數量約在50-100個之間，規模相差近 9到18倍。

這些函式庫，讓開發者無需從「蹲馬步」開始練起，可以直接調用這些千錘百鍊的招式，發揮驚人威力。

【用樂高來理解】

這就像是工具箱裡預先組合好的「魔法零件」。

您城堡的大門需要一個巨大又華麗的吊橋，如果一塊一塊積木慢慢拼，可能要花上好幾個星期。但您會驚訝地發現：NVIDIA 已經請了全世界最厲害的樂高大師，先把整個吊橋都幫您蓋好了！您需要做的，就只是「喀」一聲，把它裝到您的城堡上。

無論是 AI 模型需要的複雜樓梯，還是科學計算需要打的穩固地基，工具箱裡都已經準備好了這些現成的「魔法零件」。

第三重：忠誠的專屬譯者——NVCC 編譯器

開發者用 **CUDA C++** 寫下的「高階指令」，如同優美的詩篇，但 **GPU** 大軍的士兵們只聽得懂最直接、最簡潔的戰吼。**NVCC 編譯器**，就是這位至關重要的「專屬翻譯官」。

它不僅僅是翻譯，更是一位深諳兵法的軍師。它深刻理解每一代 **NVIDIA GPU**（如 **Hopper**、**Blackwell** 架構）的細微差異，能將開發者的意圖，翻譯成最能榨乾硬體潛能的機器指令，確保每一分電力都轉化為實實在在的算力。

【用樂高來理解】

這就像是工具箱裡的「聰明建築小幫手」。

您在設計圖上寫著：「在這裡蓋一座藍色的高塔」。這個小幫手不只會照做，他還會說：「主人，我看到您想蓋高塔。根據您手上的積木，如果您用這種特殊的蓋法，並把這塊積木轉個 5 度，您的高塔不但會堅固 2 倍，蓋的速度還能快 3 倍喔！」

他會自動優化您的計畫，讓它變得最高效、最省力。

第四重：全知的透視神鏡——分析與除錯工具

最後，**NVIDIA** 還提供了一整套如同「醫療儀器」般的工具，例如 **Nsight Profiler**（性能分析器）和 **CUDA-GDB**（除錯器）。

這些工具賦予了開發者一雙「透視神鏡」。他們能像一位神醫，為自己的程式碼「聽診」，精準地找出性能瓶頸；也能像一位偵探，深入 **GPU** 運行的內部，揪出隱藏的錯誤。這極大地降低了開發和優化的難度。

【用樂高來理解】

這就像是工具箱裡的「X光透視眼鏡」。

如果城堡的一面牆搖搖晃晃，戴上它，您就能直接看穿內部：「啊，找到問題了！原來是底層有一塊紅色的積木沒卡緊。」

或者，如果發現西邊的牆蓋得特別慢，眼鏡會告訴您：「喔，是因為您用了太多小積木了，建議直接換上一大片預先蓋好的牆壁零件。」

這副眼鏡讓找出並解決問題變得超級簡單。

結論：歡迎來到這個無法離開的世界

因此，當一位 **AI** 研究員選擇 **NVIDIA** 的 **GPU** 時，他得到的絕不僅僅是一塊冰冷的硬體。

他得到的是一整套從思想到實踐的完整解決方案。NVIDIA 提供的不是一條魚，甚至不是一支釣竿。

它提供的是：一片蘊藏豐富魚群的專屬海洋、一支由最高效漁船組成的艦隊、一部能探測所有魚群位置的聲納儀，以及一本代代相傳、繪滿了所有航道與暗礁的航海日誌。

CUDA 不是一個工具，它是一個將開發者「溫柔地迎進來」，然後憑藉其無與倫比的便利性和強大功能，讓他們「舒適到再也無法離開」的引力世界。

而這個世界的引力，正是 NVIDIA 最深、最難以被複製的護城河。

因此，當我們分析CUDA時，我們分析的不僅是技術，更是NVIDIA這台印鈔機最核心的齒輪。

• 本章總結:

- CUDA並非單一工具，而是一個「四位一體」的開發王國，由編程模型、殺手級函式庫、專屬編譯器與分析工具構成。
- 核心武器是其規模龐大的函式庫（如cuDNN），由NVIDIA投入巨資預先打造，讓開發者能直接使用現成的「神兵利器」，而非從零開始。
- 這套組合拳提供了從思想到實踐的無縫體驗，其便利性與強大功能，正是將開發者「溫柔地鎖定」在其生態系中的關鍵。

第三章：引力的深淵——CUDA的同心圓鎖定

相比「護城河」，我會形容**CUDA**為一個巨大引力場。分別在於，牆是靜態的，是被動的防禦。但一旦你進入**CUDA**的影響範圍，無論是作為開發者、公司還是研究機構，你都會發現自己身不由己地向其核心滑落。

這股強大的引力由四個層層遞進的同心圓構成，越靠近核心，引力越是無可抗拒。

第一層引力（最外層）：生態系統的軌道



引力場的最外層，是那些看似獨立運行的「行星」——以**PyTorch**和**TensorFlow**為首的深度學習框架。

那麼，**PyTorch** 和 **TensorFlow** 究竟是什麼？您可以把它們想像成是設計 AI 的「大腦」或「藍圖」。它們負責規劃 AI 的結構和任務，例如訓練一個像 **ChatGPT** 這樣的語言模型。

然而，光有藍圖不夠，還需要強大的「肌肉」來執行海量的運算。**NVIDIA** 的 **GPU** 就是這塊「肌肉」。而 **CUDA**，就是連接「大腦」與「肌肉」的專用神經系統。

它是一種特殊的語言，能讓 **PyTorch** 設計的複雜任務，完美地交給 **NVIDIA** 的 **GPU** 高速執行。沒有這個神經系統，兩者之間的溝通就會變得極其低效。

理解了這層關係，我們就能看清**NVIDIA**的策略。

從PyTorch等框架誕生之初，NVIDIA就投入了海量資源進行合作與優化。結果是什麼？這些框架的預設高性能後端，就是基於CUDA和cuDNN（NVIDIA的深度神經網路庫）的。

當一個數據科學家輸入`import torch`時，底層的CUDA支持已經像空氣一樣自然地存在。


這形成了一種微妙的綁定：框架本身是自由的，但追求極致性能的路徑卻只有一條，那就是通往NVIDIA GPU。

就像一顆衛星，PyTorch雖然擁有自己的運行軌道，但它始終圍繞著NVIDIA這個巨大的引力核心旋轉。

它將數百萬用戶和開發者一同帶入了這個軌道，讓他們在不知不覺中成為了CUDA引力場的一部分。

想要讓PyTorch在其他硬體（如AMD的GPU）上達到同等性能和穩定性，就需要付出不成比例的巨大努力，這就是第一層引力鎖定。

第二層引力（中間層）：程式碼資產的行星帶



當你更深入引力場，你會撞上一片由數億行程式碼構成的、密不透風的「行星帶」。這就是企業和研究機構多年來積累的CUDA程式碼資產。

這些程式碼不僅僅是演算法，更包含了大量為特定NVIDIA GPU架構手動優化的**kernel**（核心函數）、數值計算庫和數據處理流程。

它們是無數工程師耗費心血，為了榨乾硬體最後一絲性能而寫下的「數字黃金」。

對於一家公司而言，遷移這些資產的成本是天文數字。這不僅僅是「翻譯」程式碼，更是：

1. 性能回歸的風險：翻譯後的程式碼幾乎不可能在AMD或Intel的硬體上達到同等性能，需要重新進行漫長的優化。

2. **結果驗證的成本**：在科學計算和金融等領域，演算法的精確性至關重要。遷移後必須投入大量資源來驗證結果是否與原來完全一致。

3. **維護性的災難**：維護兩套（一套CUDA，一套ROCm）高度優化的程式碼庫，對任何工程團隊來說都是一場噩夢。

這些程式碼資產如同一條條沉重的鎖鏈，將企業牢牢鎖定在NVIDIA的硬體上。放棄它們，等於放棄了過去十年的巨額投資。這就是第二層引力鎖定。

第三層引力（內層）：人力資本的定居者

Learn CUDA Programming

A beginner's guide to GPU programming and parallel computing with
CUDA 10.x and C/C++



Packt>

www.packt.com

Jaegeun Han and Bharatkumar Sharma

再往裡走，我們遇到了引力場中最「活」的部分：全球超過400萬的CUDA開發者。他們不是冰冷的程式碼，而是適應了這個生態系統的「定居者」。

他們的技能、經驗，甚至「肌肉記憶」都與CUDA深度綁定。

- **教育體系：**全世界頂尖大學的平行計算課程，幾乎都在教授CUDA。畢業生進入職場時，已經是「CUDA-ready」的人才。
- **職業發展：**一位精通CUDA優化的工程師，在就業市場上極具價值。讓他轉而去學習一個市場份額小、生態不成熟的平台（如AMD的ROCm），不僅學習曲線陡峭，更是對其職業生涯的一場豪賭。
- **社群知識：**當開發者遇到問題時，他們可以在Stack Overflow、NVIDIA開發者論壇上找到海量的、經過驗證的解決方案。這種知識沉澱是其他平台無法比擬的。

這400萬開發者構成了NVIDIA最堅固的護城河。他們是這個生態的建造者，也是最強大的捍衛者。只要人才供給和需求都圍繞著CUDA，任何挑戰者都很難建立起一個有活力的替代生態。這就是第三層引力鎖定。

引力核心：性能與信任的恆星

所有引力的來源，是這個系統最中心的、熾熱的「恆星」——NVIDIA軟硬體協同所帶來的極致性能和無可動搖的信任。

這不僅僅是紙面上的浮點運算次數（FLOPS）更高，而是一種「它就是能用」（It just works）的黃金標準。當你投入數百萬美元、耗時數月訓練一個大型語言模型時，你最無法承受的就是穩定性問題、驅動崩潰或無法預期的錯誤。

NVIDIA通過數十年的迭代，將硬體、驅動、CUDA運行時、函式庫緊密地耦合在一起，形成了一個高度穩定、性能可預測的「黑盒子」。

開發者信任它，企業依賴它。這種由時間和無數成功案例建立起來的信任，是挑戰者最難複製的東西。

AMD的GPU或許在某些特定任務上能達到理論峰值性能，但在通用性、穩定性和生態成熟度上，與NVIDIA存在「代差」。

這個由性能和信任構成的引力核心，是整個CUDA帝國的基石。正是它的存在，才讓外層的生態、程式碼和人才甘願被其引力捕獲，圍繞它旋轉。

Warren Buffett曾說，他尋找的是擁有寬闊且持久護城河的企業。

NVIDIA用CUDA構建的，正是這樣一條教科書級的護城河。這四大引力共同指向一個結論：NVIDIA在可預見的未來，將繼續享受行業的絕大部分利潤。

這條由「硬體性能 + 軟體鎖定 + 生態依賴」構成的護城河，最終轉化為NVIDIA最令華爾街垂涎的東西：無可匹敵的定價權和驚人的毛利率。

這在財務報表上體現得淋漓盡致。NVIDIA的數據中心業務毛利率穩定在 72% 至 75% 的驚人水平，這在硬體產業中幾乎是聞所未聞的，更像是壟斷性軟體平台的利潤結構。

相比之下，其主要競爭對手AMD的毛利率約在 50-53% 左右。這超過20個百分點的差距，就是CUDA護城河的直接價值體現。

這種超高利潤，讓NVIDIA有充足的彈藥投入到下一代技術的研發中。2025財年，其研發投入高達129.1億美元，比前一年增長近49%。

這個數字讓NVIDIA能夠持續發動「速度戰」，不斷拓寬護城河，形成一個強大的正向循環：軟體護城河 → 高定價權 → 高利潤 → 高研發投入 → 更強的軟硬體 → 更深的護城河。


• 本章總結:

- CUDA的鎖定效應如同一座引力場，由四個同心圓構成：外層的AI框架生態、中層的企業程式碼資產、內層的人力資本（開發者），以及最核心的性能與信任。
- 每一層引力都顯著增加了遷移至其他平台的成本與風險，從而將整個產業鏈（從開發者到企業）牢牢吸附在NVIDIA的硬體上。
- 這道由軟體構成的深厚護城河，最終轉化為NVIDIA在財務上無可匹敵的定價權、超過70%的驚人毛利率與強大的正向循環。

第四章：挑戰者聯盟的「反引力牆」之戰

歷史上從不缺乏挑戰巨人的勇士。在AI計算的戰場上，面對NVIDIA這座不可一世的巨像，挑戰者們組成了鬆散而目標一致的聯盟。他們的主要力量來自三股：**AMD**的鏡像追趕、**Intel**的開放標準，以及開源社區的游擊戰。

一、AMD與ROCm：鏡像世界的追趕者



在所有挑戰者中，AMD是與NVIDIA最相似、也是最直接的對手。它的策略可以被概括為：成為CUDA的「鏡像」。

ROCm的誕生與使命：

AMD推出的ROCm（Radeon Open Compute platform）從一開始就背負著沉重的使命：在功能和體驗上，無限趨近於CUDA。

它的核心戰略是「開放」。ROCm是開源的，允許開發者自由修改和客製化，以此來對抗CUDA的「封閉」和「廠商鎖定」。


核心武器：HIP (Heterogeneous-compute Interface for Portability)

AMD的底氣來自其強大的硬體。以MI300X為例，其擁有 192GB 的HBM3記憶體和 5.3 TB/s 的記憶體

頻寬，相比NVIDIA H100的80GB和3.35 TB/s，分別高出 140% 和 60%。

這使其在處理大型模型推理時具有天然優勢，吸引了Meta和微軟等超大規模客戶的採用。

為了撬動CUDA的程式碼壁壘，AMD祭出了關鍵武器——HIP(異構計算可移植介面)。HIP是一個C++ API，允許開發者編寫可在AMD和NVIDIA GPU上同時運行的程式碼。



同時，AMD提供了「HIPIFY」工具，可以自動將現有的CUDA程式碼轉換為HIP程式碼，轉換成功率通常在80-95%之間。

這個策略非常聰明。它試圖直接解決第三章提到的「程式碼資產引力」問題。AMD在對開發者說：「你不需要拋棄你過去十年的心血，只需要運行一個轉換工具，你的寶貴資產就能在我的平台上發揮價值。」

殘酷的現實，硬體優勢下的軟體困局：

然而，理想與現實之間存在巨大的鴻溝。AMD的硬體優勢，往往被其尚在追趕的軟體生態所拖累。

儘管HIPIFY工具在語法層面提供了便利，但從一個經過千錘百鍊的CUDA生態，遷移到一個仍在快速發展、時有穩定性問題的ROCm生態，對企業而言依然是一項充滿風險和隱性成本的巨大工程。

這使得AMD陷入了一個戰略困境：擁有足以威脅對手的武器，卻缺乏一支能將武器威力完全發揮的成熟軍隊。

事實就是，儘管硬體規格在多個維度上領先，AMD的晶片定價卻遠低於NVIDIA。MI300X的平均售價約為 15,000美元，而H100的平均售價高達 32,500美元。這意味著NVIDIA享有高達 117%的價格溢價。

這個溢價，就是市場為**CUDA**生態系統支付的「**CUDA稅**」。客戶購買的不僅僅是硬體，更是**CUDA**帶來的穩定性，開發效率，龐大的生態支援，以及最重要的，在**CUDA**底下，真正能發揮的**GPU**性能。

儘管步履維艱，AMD的追趕從未停止。憑藉其硬體產品的性價比優勢，以及在一些大型超級計算項目（如美國的Frontier超級電腦）中的成功部署，ROCm正在艱難地縮小與CUDA的差距。但它更像是一個永遠在追逐地平線的旅人。

AMD的追趕，對投資者來說，最大的威脅是引發價格戰。即使ROCm的性能只有CUDA的90%，但如果AMD的晶片價格只有NVIDIA的60%，那麼對成本敏感的客戶（尤其是在推理市場）就會產生動搖。

這將迫使NVIDIA放棄一部分超額利潤來保住市場份額，從而侵蝕其高達70%的毛利率。因此，投資者需要密切關注MI300X等產品的實際市場份額和定價策略。

二、Intel與oneAPI：計算世界的「世界語」



如果說AMD的策略是「模仿」，那麼Intel的策略則是「超越」與「統一」。Intel試圖扮演一個更高維度的角色，它不想再創造另一個「CUDA」，而是想創造一個能統一所有硬體（CPU, GPU, FPGA）的「計算世界語」--oneAPI。

但oneAPI的願景雖然宏偉，但它面臨的挑戰甚至比ROCm更大。

- 「萬能」與「專精」的矛盾：一個試圖適應所有硬體的程式設計模型，能否在性能上匹敵一個為特定硬體「量身定做」的模型？這是一個根本性的疑問。
- 就像一把萬能的瑞士軍刀，雖然功能繁多，但它的每一項功能（如螺絲刀、剪刀）都可能不如一把專用的工具來得高效。在AI這個對性能壓榨到極致的領域，這種「性能折扣」可能是致命的。
- 遲到的硬體玩家：Intel雖然是CPU的霸主，但在高效能獨立GPU市場，它是一個不折不扣的後來者。
- 它在努力推廣一套軟體標準的同時，還需要證明自己的硬體（如Ponte Vecchio和Gaudi系列加速器）能夠與NVIDIA的產品相抗衡。這種「軟硬兩線作戰」的局面，極大地分散了其資源和市場焦點。
- 改變習慣的巨大阻力：oneAPI/SYCL要求開發者學習一種新的程式設計範式，這直接觸碰了第三章提到的「人力資本引力」。相比之下，AMD的ROCm/HIP至少在語法層面降低了遷移門檻。

Intel的oneAPI是一場高瞻遠矚的豪賭，它賭的是未來計算的多樣性和開放標準的最終勝利。但在此刻，它更像是在一片已經被拉丁語（CUDA）統治的大陸上，艱難地推廣一種新發明的人造語言。

歷史的警鐘：英特爾的殷鑑

說起Intel，我們更應該從Intel的困境，去看究竟Nvidia的Worse case scenario。

在2017年至2020年間，當AMD的Ryzen處理器在性能上追上並部分超越Intel時，Intel的護城河（x86架構的兼容性）被證明不足以抵擋衝擊。

- 市佔率侵蝕：Intel的x86市場份額從2016年的 82% 下滑至2024年的 61%。
- 利潤率崩潰：其毛利率從穩定的 60%中段 暴跌至 40%中段，蒸發了近20個百分點。
- 定價權喪失：為了保持競爭力，Intel被迫在伺服器市場進行15-25%的降價。

這也解釋了為何NVIDIA如此瘋狂地進行硬體迭代和軟體優化。它深知，**CUDA**的鎖定效應，必須建立在持續的性能領先之上。一旦失去性能優勢，**Intel**的昨天就可能是**NVIDIA**的明天。

三、開源社區：螞蟻雄兵的游擊戰

除了兩大巨頭的正面衝鋒，一股更靈活、更去中心化的力量正在以「游擊戰」的方式，從另一個維度侵蝕**CUDA**的根基。這就是開源社區。

抽象層的崛起：以**PyTorch**為代表的AI框架是第一層抽象，而更激進的專案如**OpenAI**的**Triton**和**Chris Lattner**的**Mojo**則試圖走得更遠。它們希望讓開發者用統一的、類**Python**的語法編寫高性能程式碼，再由編譯器自動翻譯到不同品牌的**GPU**上。

釜底抽薪的陽謀：這些專案的目標是將硬體徹底「商品化」，從而架空**CUDA**。然而，理想很豐滿，現實很骨感。

目前，這些方案普遍受困於性能折扣、功能不全、跨平台支援不穩定等「不成熟」的陣痛中，更像是一個美好的願景，而非能挑戰**CUDA**霸權的現實威脅。

• 本章總結:

- 挑戰者主要來自三股力量：**AMD**的「鏡像」追趕（**ROCm**）、**Intel**的「統一」標準（**oneAPI**）與開源社區的「抽象」嘗試。
- **AMD**雖有硬體優勢，但其**ROCm**軟體生態的成熟度和穩定性仍是最大短板，導致其產品需以巨大價差競爭，而這正是「**CUDA**稅」的體現。
- **Intel**的歷史警示我們，單純的軟體兼容性護城河在性能被迫平時是脆弱的，這解釋了**NVIDIA**為何必須在軟硬體上都保持高速迭代。

第五章：硬軟體加乘的威力

從剛才**AMD**的例子可以看出，**NVIDIA**的霸權，是源於硬軟體之間產生的強大「加乘效應」。

CUDA如何放大硬體性能？

CUDA不僅僅是讓GPU能跑通用程式，它更是將NVIDIA晶片的潛能壓榨到極致的「性能放大器」。

1. **高度優化的函式庫**：NVIDIA提供的**cuDNN**和**cuBLAS**等函式庫，並非通用代碼，而是由頂級工程師針對每一代NVIDIA硬體的微架構進行了手工級的精細調校。
2. **Tensor Core的無縫整合**：CUDA生態使得開發者可以「自動」且「無感」地使用GPU內置的專用AI硬體單元——**Tensor Cores**，從而獲得數倍甚至數十倍的性能提升。
3. **全棧控制與協同進化**：NVIDIA控制著從晶片設計到上層函式庫的整個技術棧，能夠進行「協同設計」，確保新硬體的革命性功能一經發布，就能立即透過軟體釋放出全部威力。


NVLink：為多GPU性能打造的硬體基石

當單一GPU的性能不足以應對龐大的AI模型時，**NVLink**就成為了NVIDIA的另一張王牌。

在上一期我們已經介紹過NVLink，在這裡則輕輕帶過。

1. **頻寬優勢**：第四代NVLink提供了高達900 GB/s的雙向頻寬，約為最新**PCIe 5.0**的7倍，能為多GPU應用帶來2倍以上的速度提升。
2. **快取一致性的統一記憶體**：NVLink實現了跨GPU和CPU的硬體級「快取一致性」，極大簡化了超大模型的編程複雜度。
3. **NVSwitch帶來的可擴展性**：透過**NVSwitch**晶片，NVIDIA能將多達256個GPU連接成一個「全互聯」的巨大計算結構，使得訓練萬億級參數模型成為可能。

綜效加乘：當CUDA遇上NVLink



真正的威力在於CUDA與NVLink的結合：CUDA的通訊函式庫（如**NCCL**）被專門優化以利用NVLink的全部頻寬；NVLink的統一記憶體架構讓CUDA應用程式能夠輕鬆擴展；Tensor Core的算力與NVLink的高速互聯相結合，使得多GPU訓練能夠實現近乎線性的性能擴展。

這種整合使得NVIDIA系統的整體性能遠超其各個部件性能的簡單疊加。

為何AMD難以複製？

儘管AMD的硬體在某些指標上極具競爭力，但它在複製這種硬軟體綜效方面面臨著幾個根本性的、結構性的挑戰：

1. 軟體與文化的「基因」差異：

NVIDIA的軟體文化是「性能痴迷」與「垂直整合」，他們將函式庫視為與晶片同等重要的產品，投入巨資進行極致優化。這使得CUDA應用通常能發揮硬體40%的理論性能。

相比之下，AMD的ROCm更側重於「開源使能」，其文化基因鼓勵社群參與和跨平台相容性，但這也導致其官方優化和「開箱即用」的體驗遠不如NVIDIA。

因此，ROCm往往只能發揮硬體不到30%的理論性能。這「10%」的軟體效率差距，足以抵銷硬體上的規格優勢。

2. 生態的「時差」與「慣性」：

CUDA生態領先ROCm近二十年，這不僅僅是開發者數量的差距，更是「時間」本身構成的壁壘。

- 時差：每當NVIDIA發布新一代硬體，配套的CUDA軟體也同步就緒。而ROCm對新演算法和框架的支援總是慢半拍，這種持續存在的「時差」讓追求前沿性能的開發者別無選擇。
- 慣性：全球數百萬開發者的肌肉記憶、大學課程的設置、以及數億行現存的CUDA程式碼，共同構成了一股巨大的「生態慣性」。要求整個行業掉頭，其轉換成本是天文數字。

3. 互聯架構的「斷層」：

這是一個關鍵的硬體架構差異。NVIDIA的NVLink + NVSwitch旨在打造一個可平滑擴展的GPU計算矩陣，無論是8個GPU還是在NVL72系統中的72個GPU，都能維持極高的全互聯頻寬。

而AMD的Infinity Fabric技術雖然在單個伺服器（8 GPU）內部提供了高效的環形互聯，但在擴展到多個伺服器時，必須依賴標準的InfiniBand網路。

這在互聯層級上形成了一個明顯的「性能斷層」，使得其在構建超大規模集群時，難以實現NVIDIA那樣的無縫擴展和統一記憶體空間。

這一點，在「上篇」已經深入展開過。

4. 商業模式的兩難：

NVIDIA不僅賣晶片，更重要的是它銷售整合了軟硬體的「解決方案」，如DGX伺服器和SuperPOD集群。這使其對最終產品的性能和優化有著絕對的控制權。

而AMD在資料中心市場，主要扮演「零件供應商」的角色，將晶片出售給伺服器廠商（如Dell、Supermicro）。


這意味著AMD對最終系統的整合與調優控制力較弱，其性能表現會因合作夥伴的整合能力而異，難以保證如NVIDIA般一致的頂級體驗。

這四大結構性差異，解釋了為何**AMD**即使在某些硬體指標上取得領先，也難以撼動**NVIDIA**由硬軟體綜效所構築的深厚壁壘。這場戰鬥的本質，已不僅僅是晶片之間的對決，更是兩種不同商業模式、技術文化和生態戰略的全方位較量。

- 本章總結:

- **NVIDIA**的真正威力來自**CUDA**（軟體）與**NVLink**（硬體）的深度整合與協同設計，創造出**1+1**遠大於**2**的性能綜效。
- **AMD**難以複製此優勢，因其面臨軟體文化基因、生態時差、互聯架構斷層與商業模式（零件供應商 vs. 解決方案提供商）四大結構性挑戰。
- 這場競爭的本質，是**NVIDIA**的「垂直整合解決方案」與**AMD**的「開放生態零件供應」兩種模式的對決。

第六章：雲端諸侯的崛起——ASIC，另一場戰爭



在AMD與NVIDIA進行著一場像素級的「鏡像戰爭」時，一條新的戰線已悄然開啟。

這一次的挑戰者，不再是試圖打造另一款通用GPU的晶片公司，而是NVIDIA帝國最大的客戶——Google、Amazon等雲端巨頭。

他們厭倦了支付高昂的「NVIDIA稅」，決定親自下場，為自己量身打造專用的「專屬利器」。

這就是ASIC（專用積體電路）的戰爭。它不是一場對稱的較量，而是一次從根本上改寫遊戲規則的非對稱打擊。

如果說NVIDIA的GPU是性能強悍、能應對各種複雜路況的「全地形越野車」，那麼ASIC就是只為特定城市、特定路線設計的「高速磁懸浮列車」——它的通用性為零，但在自己的軌道上，其成本與效率無人能敵。

另一種思維：ASIC如何「說話」？

一個自然的問題是：這些ASIC用什麼語言編程？它們有自己的「CUDA」嗎？

答案出人意料：沒有，也不需要。

ASIC的設計者們選擇了一條更聰明的道路。他們沒有試圖去複製一個已有數百萬開發者的CUDA生態，而是採用了一種「編譯器先行」的策略。這意味著開發者幾乎不需要改變自己的習慣。

- **Google的TPU**，其背後的「大腦」是名為**XLA**（加速線性代數）的專用翻譯官。開發者依然用他們熟悉的Python和TensorFlow/JAX框架寫代碼，XLA則像一位精通TPU硬體架構的專家，在程式運行前的一瞬間，將這些高階指令「即時編譯」（JIT）成TPU能理解並最高效執行的機器碼。
- **Amazon的Trainium和Inferentia晶片**，也遵循同樣的邏輯。它們的翻譯官是**Neuron SDK**。開發者寫著標準的PyTorch代碼，只需多加幾行，Neuron編譯器就會接管一切，將模型優化並部署到AWS自家的晶片上。

這種模式的巧妙之處在於，它將複雜性隱藏在了一個「黑盒子」裡。開發者無需學習新的底層語言，但代價是，這個黑盒子是平台綁定的。

XLA的TPU後端是Google的專有資產，只能在Google Cloud上使用。這形成了一種新的鎖定：開發體驗是開放的，但執行平台是封閉的。

專為一件事而生：ASIC的架構與經濟學

雲端巨頭們為何要耗費數十億美元走上這條自研之路？答案藏在ASIC的硬體架構和它所帶來的極致經濟效益裡。

GPU作為一個通用處理器，就像一把功能齊全的「瑞士軍刀」。它有主刀、有剪刀、有開瓶器，能應對各種任務，從圖形渲染到科學計算。但當你只想用主刀切割時，其他工具的重量和複雜性就成了累贅。

ASIC則是一把「手術刀」。它移除了所有與核心任務無關的部件，只為一件事而生：高效地執行AI計算，特別是矩陣乘法。

- 架構上，TPU採用了所謂的「脈動陣列」（Systolic Array），可以將其想像成一個完美編排的晶片級「裝配線」。數據像水流一樣，精準地流過每一個處理單元，沒有一絲一毫的浪費。這使得它在處理矩陣運算時的硬體利用率遠超通用GPU。
- 經濟上，這種極致的專用化帶來了驚人的回報。對於雲端巨頭每天需要處理的數十億次推理請求而言，每一瓦特的電力、每一分錢的成本都至關重要。

- **成本效益：** Google聲稱其TPU v5e的推理「性價比」比同類GPU高出3倍。AWS也表示其Trainium晶片能帶來30-40%的性價比優勢。
- **能源效率：** TPU的能效同樣可以達到NVIDIA H100的3倍。這意味著在提供相同算力的情況下，數據中心的電費和冷卻成本將大幅降低。

當你的業務規模大到一定程度時，這種效率的提升，每年能節省的是數億美元的真金白銀。這就是雲端諸侯們打造自家「手術刀」的根本動力。

戰場劃分：ASIC的勝場與CUDA的堡壘

然而，手術刀雖然精準，卻無法用來砍柴。ASIC的極致專用化也帶來了它的「阿喀琉斯之踵」——缺乏靈活性。這也決定了它與CUDA的戰場將被清晰地劃分開來。

1. 推理市場：ASIC的應許之地

AI推理是一個高度重複、規模巨大的任務，就像工廠裡的標準化生產。這正是ASIC的完美用武之地。在這裡，成本和效率壓倒一切。

隨著越來越多的AI應用落地，推理的計算量將遠超訓練。因此，在大規模推理這個戰場上，ASIC正對NVIDIA構成最嚴峻的威脅。

市場預測也印證了這一點。摩根大通預計，到2028年，自研ASIC將佔據AI加速器市場45%的份額。這意味著NVIDIA在推理領域的絕對統治將被打破。

2. 訓練與研發：CUDA的堅固堡壘

與推理不同，AI模型的訓練和前沿研究充滿了不確定性。新的演算法、新的模型架構（如從CNN到Transformer的變革）層出不窮。

這時，「瑞士軍刀」的價值就體現出來了。NVIDIA的GPU憑藉CUDA生態的靈活性，可以迅速適應任何新的演算法。

研究人員今天想到一個新點子，明天就可以用CUDA實現並在GPU上驗證。而ASIC的設計週期長達1-2年，一旦定型，就很難適應突如其來的演算法革命。

如果為Transformer設計的ASIC問世時，下一個革命性架構已經出現，那它可能瞬間就變成了昂貴的「矽磚」。

因此，在AI訓練，特別是前沿探索領域，CUDA的靈活性和成熟生態系統使其地位依然難以動搖。

潛在的變數：OpenXLA能成為「世界語」嗎？

在這場多方博弈中，還有一個巨大的未知數——OpenXLA。

由Google、AMD、Intel、Meta等巨頭共同發起的OpenXLA專案，其雄心是打造AI編譯領域的「羅塞塔石碑」。

它希望創建一個通用的中間層（StableHLO），讓開發者寫的PyTorch或JAX代碼，可以無縫地編譯到NVIDIA GPU、AMD GPU、Google TPU、AWS Trainium等任何一種硬體上。

- 如果OpenXLA成功，它將從根本上瓦解CUDA的軟體護城河。硬體廠商們將回歸到純粹的「性價比」競爭，開發者可以自由選擇，不再被單一平台綁定。
- 如果OpenXLA失敗，或者只能實現「能運行，但跑不快」的「性能可移植性幻覺」，那麼開發者依然會選擇為性能最好的平台（目前是CUDA）進行深度優化，NVIDIA的生態優勢將得以延續。

目前看來，OpenXLA前路漫漫，但它代表了整個行業對打破單一供應商壟斷的共同渴望。

結論：一個分裂的未來

ASIC的崛起，不太可能「殺死」CUDA，但它幾乎註定會終結NVIDIA一家獨大的時代。

最可能出現的未來，是一個碎片化的市場：

- NVIDIA將繼續在需要靈活性的訓練和通用AI開發領域保持領先，但其總市場份額將從80%-90%的高位回落。
- Google、AWS等雲端巨頭將憑藉其自研ASIC，在大規模推理市場佔據主導地位，並透過垂直整合捕獲巨大的經濟價值。
- AMD等追趕者則在兩者之間尋找機會，試圖在提供一定靈活性的同時，提供比NVIDIA更具吸引力的性價比。

ASIC的戰爭，本質上是一場經濟學的戰爭。它證明了當一個市場的利潤高到一定程度，且應用場景足夠標準化時，最大的客戶就會不可避免地轉變為最強大的競爭對手。CUDA的護城河雖然深厚，但它無法阻擋資本和效率追求的潮水。

帝國的版圖，正在被重新繪製。一個多極化的AI算力世界，即將來臨。

- 本章總結:


- 雲端巨頭（Google、Amazon）正透過自研ASIC（專用晶片）發動一場非對稱戰爭，旨在擺脫對NVIDIA的依賴並降低成本。
 - ASIC透過「編譯器先行」策略繞開了CUDA生態壁壘，並在標準化、大規模的「推理」市場上，展現出遠超GPU的成本與能源效率。
 - 這將導致AI算力市場的分裂：NVIDIA繼續主導靈活性要求高的「訓練」市場，而ASIC將在「推理」市場佔據重要份額，終結NVIDIA一家獨大的局面。
-

第七章：帝國的反擊與潛在的裂痕

面對AMD的模仿、ASIC的釜底抽薪，NVIDIA這座巨像非但沒有動搖，反而以更快的速度進行著自我加固和擴張。它的策略可以歸結為兩點：用絕對的速度拖垮追趕者，用絕對的懷柔吞噬挑戰者。

一、帝國的反擊：速度、懷柔與鐵腕

1. 速度即壁壘：用創新拖垮模仿者



NVIDIA對付AMD ROCm這類「鏡像」追趕者的策略，簡單而粗暴：跑得更快。這背後是巨額的研發投入。在AI熱潮中，NVIDIA的研發支出持續增長，2025財年總額高達129.1億美元。

- 無情的硬體迭代：NVIDIA的GPU架構以驚人的速度更新。從Pascal到Volta，再到Turing、Ampere，以及如今主宰市場的Hopper（H100），再到剛剛發布、性能再次躍升的Blackwell（B200）。每一代架構的更迭，不僅僅是算力的提升，更重要的是引入了針對最新AI演算法的專用硬體單元。
 - **Tensor Core**的演進：從最初支援FP16，到Ampere架構支援TF32、BF16，再到Hopper架構引入專為Transformer模型設計的「**Transformer引擎**」和FP8精度。
 - 這意味著什麼？這意味著AMD的ROCm團隊永遠在做一道追趕題。當他們費盡九牛二虎之力，終於在軟體層面優化、追平了NVIDIA上一代硬體的性能時，NVIDIA的下一代硬體和配套的CUDA新版本已經發布。
 - 新的硬體特性需要新的CUDA函式庫來驅動，這條性能護城河被NVIDIA不斷地向前拓寬、挖深。開發者為了追求極致性能，只能選擇最新的NVIDIA平台。
- 軟體生態的加速擴張：**NVIDIA深知軟體才是最終的鎖。因此，它在CUDA這個核心之上，以前所未有的速度構建著一個龐大的軟體帝國。

- **CUDA-X AI**：這不是一個單一的產品，而是一系列針對不同領域的加速函式庫和工具的集合。涵蓋了從資料科學（cuDF）、機器學習（cuML）、深度學習（cuDNN, TensorRT）到視覺、語音、推薦系統等幾乎所有AI應用場景。
- **NVIDIA AI Enterprise**：將這一切打包成一個企業級的、有官方支援和維護的軟體套件。這直接解決了企業用戶最關心的穩定性和可靠性問題，讓他們更沒有理由轉向ROCm等穩定性稍遜的平台。

NVIDIA用這種「你剛學會走，我已經在飛」的速度，讓**AMD**的模仿策略顯得步履維艱，成本高昂。

營運槓桿：帝國的印鈔機

NVIDIA能夠發動如此猛烈的「速度戰」，其底氣來自於其商業模式中無與倫比的營運槓桿

（**Operating Leverage**）。簡單來說，這就是「營收像火箭一樣飆升，而成本像烏龜一樣慢爬」。從2023到2025財年：

- 營收從269.7億美元暴增至1305億美元，成長了 384%。
 - 營運費用（研發+行政銷售）僅從111.3億美元增長至164.1億美元，僅成長 47%。
- 這創造了高達 8.1倍的營運槓桿——營運費用每增加1%，營收就增長8.1%。這種恐怖的效率，讓**NVIDIA**的營運利潤率從15.7%飆升至 62.4%。這背後的核心就是**CUDA**。一旦這個龐大的軟體平台建成，服務再多的客戶、支持再高的營收，其邊際成本也趨近於零。
- 這台高效的印鈔機，產生了驚人的自由現金流（**Free Cash Flow**）。2025財年，**NVIDIA**產生了 608.5億美元的自由現金流。這筆巨款就是帝國的「戰爭基金」，使其能夠：

1. 維持高速創新：投入百億美元進行研發，拖垮追趕者。
2. 回饋股東，彰顯信心：在2025年8月，**NVIDIA**宣布了高達 600億美元的股票回購計畫。這一舉動無異於向市場宣告：管理層對**CUDA**護城河的持久性充滿信心，認為將現金返還給股東，比囤積起來應對未知的威脅更有價值。

懷柔即吞噬：擁抱、擴展、再鎖定

面對Intel的oneAPI和開源社區的抽象層，NVIDIA採取了更為高明的「懷柔」策略，這是一套類似於微軟當年「擁抱、擴展、消滅（Embrace, Extend, Extinguish）」的現代版本。

擁抱： NVIDIA沒有去對抗PyTorch、TensorFlow、JAX這些高層框架，反而成為它們最大的貢獻者之一。NVIDIA的工程師團隊與這些開源社區緊密合作，確保每一個新版本的框架在NVIDIA GPU上都能獲得最佳的性能和最及時的支援。這使得「PyTorch/TensorFlow + NVIDIA GPU」成為了事實上的黃金組合。

擴展： 在擁抱的基礎上，NVIDIA提供了「額外」的價值。

- **TensorRT：** 這是一個用於高效能深度學習推理的優化器和運行時。開發者用PyTorch訓練完模型後，可以選擇使用TensorRT進行極致的優化，以獲得在NVIDIA GPU上無與倫比的推理速度和效率。
- **Triton的「軟著陸」：** 對於OpenAI的Triton這類試圖抽象硬體的语言，NVIDIA非但沒有抵制，反而積極擁抱。NVIDIA的編譯器團隊努力確保Triton能夠在自家GPU上生成最高效的程式碼。這讓開發者覺得：「既然用Triton在NVIDIA上效果最好，那我為什麼還要費心去考慮其他硬體呢？」

再鎖定： 通過上述兩步，NVIDIA巧妙地瓦解了抽象層的威脅。開發者雖然使用的是看似跨平台的PyTorch或Triton，但在追求極致性能的驅使下，他們會不自覺地使用到TensorRT等NVIDIA專有的擴展工具。

久而久之，他們的開發流程、部署腳本、性能調優經驗，又一次與NVIDIA的生態深度綁定。抽象層本想架空CUDA，結果卻被CUDA的引力捕獲，成為了其生態系統最外圍的衛星。

終極鎖定： NVIDIA最新的殺手鐮是NIMs（NVIDIA Inference Microservices）。這是一系列預先打包好、經過極致優化的「AI模型容器」。

開發者可以直接下載一個NIM（例如，一個用於語言翻譯的NIM），無需關心底層模型優化，就能輕鬆地將其部署到任何NVIDIA的硬體上，無論是雲端資料中心還是邊緣設備。

NIMs的戰略意圖極其深遠。它將鎖定效應從「開發階段」延伸到了「部署階段」。一旦企業的AI應用架構是基於NIMs構建的，那麼未來想要遷移到非NVIDIA的硬體平台，就意味著要重寫整個模型的服務和部署流程，這在運維層面是近乎不可能的任務。

NIMs正在成為CUDA生態最新的、也是最頂層的「引力奇點」。

法律鐵腕：劃下不可逾越的紅線

如果說「速度」和「懷柔」是帝國擴張的陽謀，那麼法律的鐵腕，則是NVIDIA毫不掩飾的、捍衛其統治的終極武器。

它用一紙條款，就足以讓挑戰者們不寒而慄。

- **EULA中的「毒丸條款」**：2021年起，NVIDIA悄悄地在其CUDA工具包的終端使用者授權協議（EULA）中，加入了一條看似不起眼、實則殺傷力巨大的條款（自CUDA 11.6版起，該條款被正式包含在安裝文件中）：

「您不得對使用SDK元件生成的任何輸出部分進行逆向工程、反編譯或反彙編，以將此類輸出產物翻譯到非NVIDIA平台上為目的。」

這條款如同一顆地雷，它的目標極其明確：徹底封殺所有「翻譯層」技術。這意味著，任何試圖讓已編譯好的CUDA程式（即「輸出產物」）在AMD或Intel的GPU上運行的嘗試，都直接違反了NVIDIA的授權協議。

- **ZLUDA的悲歌：一場「殺雞儆猴」的威懾**：這顆地雷的威力，在一個名為ZLUDA的專案上得到了最淋漓盡致的體現。
 - **希望之星**：ZLUDA是一個天才般的開源專案，它的目標正是NVIDIA最忌憚的「二進位翻譯」。它就像一台魔法翻譯機，能讓為NVIDIA GPU編寫的現成CUDA應用程式，無需修改原始碼，直接在AMD的GPU上以接近原生的性能運行。這無疑是對CUDA護城河的直接威脅。
 - **悲劇轉折**：這個充滿潛力的專案，一度獲得了AMD的資金支持。然而，在NVIDIA更新EULA後，情勢急轉直下。2024年，AMD不僅停止了資助，其法務部門更突然要求專案開發者Andrzej Janik將所有受AMD資助期間開發的程式碼從GitHub上撤下。

- **無聲的威懾：**最令人不寒而慄的是，從頭到尾，NVIDIA什麼也沒做。沒有發出一封律師函，沒有任何公開威脅。AMD的退縮，完全是出於對NVIDIA EULA條款潛在法律風險的恐懼。正如開發者在撤下程式碼時無奈地寫道：「程式碼是在得到AMD的郵件批准後發布的。現在AMD的法務部門說那不具法律約束力，所以要求撤銷。」
- ZLUDA的遭遇，成為了NVIDIA帝國面前一場真實的示警。它用一個案例向全世界宣告：CUDA的引力不僅僅是技術和生態，更是由法務部門守衛的、不可觸碰的紅線。任何試圖繞過CUDA生態的「捷徑」，都將面臨來自巨人陰影下的法律威脅。這種「不戰而屈人之兵」的威懾力，遠比任何技術封鎖都更加有效。

二、潛在的裂痕：帝國的三大隱憂

儘管NVIDIA的防禦固若金湯，但歷史告訴我們，沒有永恆的帝國。在看似無懈可擊的表面之下，正潛藏著三道可能動搖其根基的裂痕。

1. 經濟裂痕：「足夠好」革命

- **背景：**AI的應用正在從「訓練」走向「推理」。模型訓練需要最頂級、最昂貴的GPU集群，不計成本。但推理任務則遍布雲端、邊緣設備甚至手機，對成本和能效極為敏感。
- **威脅：**對於大量的推理場景來說，並不需要H100那樣的「性能怪獸」。一個價格只有其十分之一、性能達到其三分之一的晶片，可能就是一個「足夠好」且極具性價比的選擇。這為AMD、Intel、高通，以及眾多AI晶片新創公司（如Cerebras, SambaNova）打開了巨大的市場空間。
- **歷史的鏡子：**這與當年x86架構擊敗更優雅、更強大的RISC架構工作站的歷史何其相似。廉價、量大、生態豐富的PC最終佔領了市場。如果AI推理市場的規模最終遠超訓練市場，那麼由「足夠好」的晶片構成的長尾市場，可能會逐漸侵蝕NVIDIA在高階市場的利潤和話語權。

利潤率壓縮的風險

這條裂痕對NVIDIA的財務模型構成了直接威脅。如果AMD透過ROCm的完善，成功在推理市場實現了「90%的性能」，那麼NVIDIA將面臨艱難的選擇。分析師模型顯示，為了保住市場份額，NVIDIA可能被迫進行20-30%的價格下調。

這將直接衝擊其引以為傲的毛利率。在這種情況下，其毛利率可能從目前的72-75%壓縮至51-58%的區間。

- 雖然這依然是一個健康的數字，但對於習慣了超高利潤的華爾街來說，這將是一個巨大的衝擊，重演當年Intel利潤率崩塌的故事。

2. 範式裂痕：演算法的「黑天鵝」

- 背景：NVIDIA和CUDA的整個帝國，都建立在一個核心的數學運算之上：稠密矩陣乘法。這是當前深度學習演算法的心臟。
- 威脅：萬一下一代AI革命性的演算法，不再依賴於大規模的稠密矩陣乘法呢？
 - 稀疏計算：如果未來的模型變得高度稀疏，那麼專為稠密計算優化的GPU架構可能會失去優勢。
 - 圖神經網路（GNNs）：處理非結構化數據的圖計算，其計算模式與傳統的深度學習有很大不同。
 - 新興範式：如生物啟發的脈衝神經網路（Spiking Neural Networks），或者其他我們今天還無法想像的計算模型。
- 後果：一旦發生這種演算法層面的「範式轉移」，NVIDIA過去二十年積累的硬體優化和CUDA軟體生態，其價值將被大大削弱，甚至可能一夜之間變得過時。所有玩家將回到同一個新的起跑線上，這將是NVIDIA最不願看到的「黑天鵝」事件。

3. 地緣裂痕：主權AI與供應鏈風險

- 背景：AI已經被提升到國家戰略安全的高度。同時，NVIDIA的晶片製造高度依賴台灣的台積電（TSMC）。
- 威脅：
 - 主權AI（Sovereign AI）：出於對供應鏈安全和技術自主的擔憂，世界各國（包括中國、歐洲、印度等）和大型科技巨頭（如Google、Amazon、Microsoft）都在投入巨資研發自己的AI晶片和軟體棧。他們不希望將國家的AI命脈完全寄託在一家美國公司和一家台灣製造商身上。
 - 地緣政治風險：任何圍繞台灣海峽的政治動盪，都可能對全球GPU供應造成毀滅性打擊。這種風險本身就是催化劑，促使各方加速尋找替代方案。

- **後果：**這種由政治和安全驅動的「去NVIDIA化」趨勢，雖然在短期內難以撼動其地位，但從長遠看，它會人為地催生出多個獨立的、不兼容的AI生態系統，從而打破NVIDIA目前所享有的全球統一市場的格局。

與此同時，挑戰者也在快速進化。AMD最新發布的 ROCm 7.0 版本，據稱在推理和訓練性能上相比舊版實現了 3到4倍 的巨大飛躍，並加入了對FP4/FP6等新精度的支援。

這表明，儘管生態差距巨大，但在核心性能上，追趕者正以前所未有的速度縮小差距，這本身也構成了對帝國的潛在衝擊。

• 本章總結:

- NVIDIA的反擊策略是三位一體：用無情的「速度」拖垮追趕者，用「懷柔」策略吞噬開源抽象層，並用「法律鐵腕」（EULA條款）威懾翻譯層技術。
- 其驚人的營運槓桿和現金流，是支撐其發動「速度戰」的經濟基礎，也是其信心的體現。
- 然而，帝國仍面臨三大潛在裂痕：「足夠好」晶片在推理市場的經濟威脅、革命性演算法「黑天鵝」的範式風險，以及主權AI和地緣政治引發的供應鏈風險。

最終章：超越王座——計算的終局與文明的基石

綜合上述的防禦工事與潛在裂痕，從投資角度看，核心問題並非「CUDA是否會被顛覆」，而是「它的統治形態將如何演變，以及這種演變對其財務模型的影響」。

承認護城河的深厚，與預見其市場份額和利潤率的必然回落，兩者之間並不矛盾。

1. 護城河的深度：至少18個月的絕對領先

首先，必須明確：CUDA的護城河是真實且堅固的。從硬體架構的迭代速度、軟體生態的成熟度到開發者的慣性，NVIDIA已經建立了一個至少18到24個月的絕對領先優勢。

這意味著在可預見的未來，NVIDIA將繼續主導市場，特別是在對性能要求最苛刻的AI訓練領域，這是其估值的基本盤。

2. 侵蝕的必然性與擴張的市場：一個更大的蛋糕

然而，歷史上沒有任何一家科技公司能永久佔據一個高增長市場90%以上的份額。

侵蝕是必然的，動力來自於客戶（雲端巨頭）的理性選擇（扶持第二供應商以求議價能力和供應鏈安全）和自研ASIC的精準打擊（在內部大規模推理場景中實現更高性價比）。

因此，最理性的預期是，NVIDIA的市場份額將從目前 80-90% 的巔峰，逐漸回落到一個更為「常態化」的 60-70% 區間。其驚人的毛利率也將面臨壓力，從 70%中段 的高位溫和下修。

但這引出了投資NVIDIA的核心邏輯：即使其市場份額（蛋糕的比例）縮小，但整個AI計算市場（蛋糕本身）的擴張速度更快。一個65%份額的萬億級市場，遠勝過一個90%份額的千億級市場。

3. 最終的投資論述：一個分層的未來

綜合以上分析，AI計算市場的終局，不會是單一贏家通吃，而是一個清晰的分層結構：

- **NVIDIA的王國（高階與主流市場）**：憑藉CUDA生態和最強的硬體性能，牢牢佔據利潤最豐厚的高階AI訓練市場和企業級AI部署市場。
- **AMD的領地（性價比市場）**：憑藉硬體的性價比優勢，在對成本較為敏感的雲端推理市場和尋求第二供應商的客戶中，成為市場上最重要的「第二選擇」。
- **ASIC的自治邦（超大規模內部市場）**：Google、Amazon等雲端巨頭，將主要在其內部標準化的超大規模推理應用中，廣泛部署自研ASIC。

結論是，**CUDA帝國的絕對君主制時代正在走向終結，但NVIDIA王朝的統治遠未結束。**

它將從一個壟斷者，演變為一個佔據市場核心、享受行業最大增長紅利、並擁有健康利潤率的領導者。

未來的關鍵，不在於其市場份額是否會從90%下滑，而在於其能否在60-70%的穩定份額下，持續定義行業的技術走向，並將這種領導地位轉化為強勁且可持續的自由現金流。

遠方的地平線——計算的終局是「隱形」

無論上述最可能的投資前景如何演變，從更長遠的視角看，所有的技術路徑都指向一個共同的終極目標：讓計算本身變得「隱形」。

就像今天我們使用電力一樣，只需將電器插入插座，無需關心電力來自何方。AI計算的終局也必然如此。

未來的開發者，理想中應能在高層次介面上描述意圖，而一個智能的「世界編譯器」會自動將任務分配給全球網路上最適合、最經濟的計算單元去執行。

從這個角度看，CUDA帝國的歷史功績，是它以前所未有的力量，完成了AI計算從「手工作坊」到「工業化發電廠」的建設，並定義了第一代「插座標準」。

而所有的挑戰者，無論是模仿、標準化還是抽象，他們奮鬥的目標，是創造一個能兼容所有發電廠的「萬能插座」，或者乾脆發明一種全新的「無線供電」技術，徹底擺脫插座的束縛。

結語

CUDA帝國的故事，是科技史上一個關於遠見、執行力、生態壁壘和開放性挑戰的經典案例。

它不是一個簡單的「封閉與開放」的二元對立故事，而是一個關於如何在混沌中建立秩序，以及這個秩序又如何激發新的、試圖打破它的力量的複雜敘事。

NVIDIA用CUDA加冕為王，但王座之下，暗流洶湧。經濟規律、科學探索和人類社會對自主與安全的永恆追求，是比任何一家公司都更強大的力量。這場爭奪機器靈魂的戰爭，正從一場殲滅戰，演變為一場劃分勢力範圍的持久戰。

而NVIDIA，依然是這盤棋局上，最強大的執棋者。它的最終程式碼，正由未來親自書寫。

- KP

謝謝你閱讀到這裡，如果你覺得這篇分析為你帶來了價值，請不吝按下一個讚，這是我持續創作的最大動力。

最後，宣傳一下自己，我在各大社交平台都有定期發文。

另外Telegram有頻道，每天早上我會發當天重要新聞摘要。

同時，如果想開戶的話，可以考慮用我的富途/口袋證券獨家推薦碼，會有更多優惠。

全部資訊在以下鏈結：

https://linktr.ee/fomo_soc

另外，如果你已經加入付費會員，不要浪費了群組的功能，進入我們Substack的Chat功能一起討論市場!

- KP

本機離線版本 • 圖片與內文完整

← 回索引

在原站開啟 ↗