

[← 索引](#)[💎 付費](#)2025-12-26 1197 字 [↗ 原站](#)

Groq，LPU到底是甚麼？為甚麼Nvidia必須買下 Groq的靈魂？- 深度分析第27期：Nvidia「收購」Groq



2024 年 2 月 19 日。

對於大多數人來說，這只是一個普通的星期一。但對Groq這家公司來說，卻是非常重要的一天。

一位名叫 Matt Shumer 的用戶上傳了一段僅有 3秒的錄屏影片。沒有花哨的剪輯，沒有激昂的配樂，只有一個簡單的對話框。

他在框內輸入了一個複雜的問題。

在 ChatGPT 建立的「常識」裡，用戶習慣了等待。你會看到游標閃爍，然後文字像老式打字機一樣，一個字、一個字地蹦出來。你習慣了在 AI「思考」時去喝口水。

但在 Shumer 的影片中，事情發生得太快，以至於大腦幾乎來不及處理。

就在他按下 **Enter** 鍵的瞬間，數百個單詞組成的完美答案，包含引用來源和結構化建議，在不到一秒鐘的時間內瞬間刷滿螢幕。

沒有打字機效果，沒有等待，文字出現的速度快到肉眼無法捕捉。

這條推文像野火一樣蔓延。在那一刻，世界突然意識到：

我們過去兩年所經歷的AI延遲，並不是物理定律的限制，而是硬體的限制。

當大語言模型在 **Groq** 的晶片上跑起來時，人們第一次感覺到了那種電影裡才有的、與機器無縫對話的未來。

Groq，這家名字聽起來和Elon Musk 的 **Grok** 僅一字之差的公司，在一夜之間從「默默無聞的晶片新創」變成了「Nvidia的挑戰者」。

時間快轉到 2025 年 12 月 24 日，聖誕夜前夕。

沒有慶功宴，沒有上市敲鐘的歡呼。一則重磅新聞悄然登上了財經版頭條：

Nvidia宣布以 200 億美元的價格「收購」**Groq** 的核心資產與人才。

第一章：TPU 之父的叛逆



在矽谷，Jonathan Ross 這個名字通常與一個縮寫詞連在一起：**TPU**（**T**ensor **P**rocessing **U**nit，張量處理單元）。

2013 年的 Google 正面臨一場看不見的危機。

隨著語音識別、圖像分類等 AI 功能的普及，Google 的數據中心正面臨被算力需求壓垮的風險。

內部的工程師算了一筆帳：如果讓每一位安卓用戶每天只使用 3 分鐘的語音識別，Google 就需要將現有的數據中心數量翻倍。這意味著數百億美元的額外支出，這在商業上是不可持續的。

當時的解決方案通常是購買更多的 CPU，或者開始嘗試使用 Nvidia 的 GPU。但 Jonathan Ross，這位當時還在 Google 廣告部門工作的軟體工程師，有了一個瘋狂的想法。

利用 Google 著名的「20% 自由時間」政策——這項政策曾誕生了 Gmail 和 AdSense——Ross 開始了一個代號隱秘的硬體專案。

他的想法很簡單，卻極具顛覆性：

為什麼我們要在為圖形渲染設計的晶片（GPU）上跑 AI？為什麼不從零開始，設計一顆專門為神經網路數學運算而生的晶片？

這就是 TPU 的雛形。

Ross 不僅僅是提出想法，他親手設計並領導了這個專案。在短短 15 個月內——這在硬體開發史上簡直是神速——他和團隊完成了從設計、驗證到部署的全過程。

當第一代 TPU 插上 Google 的伺服器時，效果是震撼的。它的每瓦運算性能（TOPS/Watt）表現驚人——是當時 GPU 的 29 倍，更是傳統 CPU 的 83 倍。

它拯救了 Google 的運算危機，隨後更是成為了 AlphaGo 擊敗李世石背後的秘密武器。Ross 一戰成名，成為了 Google 內部的傳奇人物，他的發明支撐起了 Google Search、Photos 和 YouTube 幾乎核心命脈的算力。

按理說，Ross 應該在 Google 享受著頂級工程師的榮耀，不斷在組織中升職加薪。但在 2016 年，他卻做了一個讓所有人驚訝的決定：辭職。



為什麼？

因為 Ross 看到了 TPU 的侷限性——不是技術上的，而是哲學上的。

TPU 是強大的，但它被鎖在 Google 的高牆之內，它是一個「封閉的武器」。只有 Google 的工程師，或者購買 Google Cloud 昂貴服務的企業才能使用它。

對於外部世界——那些大學實驗室的學生、車庫裡的創業者、不想被 Google 生態綁架的開發者——TPU 就像是一個遙不可及的神話。

Ross 的野心遠不止於此。他在 Google X（Google 的秘密實驗室）工作期間，深刻地意識到：AI 的未來不應該被少數幾家巨頭壟斷。

「如果算力是新時代的石油，那麼鑽井平台不應該只屬於 Google。」

Ross 在後來的一次採訪中暗示過這種想法。

他看到了一個巨大的市場空白：世界需要一種比 GPU 更快、比 TPU 更開放的晶片。

他想要「民主化」這種超級算力。

2016 年，Ross 帶著一部份他原來團隊的頂級晶片工程師出走，創立了 Groq。

這個名字取自科幻大師海因萊因的小說《異鄉異客》（Stranger in a Strange Land）中的詞彙“Grok”，意為「深刻地、直覺地理解」。

這也隱喻了 Ross 的技術哲學：他要設計一種能讓機器「瞬間理解」人類語言的晶片。

第二章：離經叛道的 LPU



2016 年，當 Jonathan Ross 離開 Google 創立 Groq 時，他給自己的新發明取了一個看似狂妄的名字：**LPU (Language Processing Unit，語言處理單元)**。

在當時，這簡直是行銷上的自殺。那一年，AI 的主流戰場是圖像識別（ImageNet），而不是語言。

大語言模型（LLM）的概念還處於嬰兒期，將晶片命名為「語言處理單元」，就像在汽車剛發明時，宣稱自己造了一架「飛機」一樣，既超前又令人困惑。

但 Ross 並不在乎。他看到的未來與當時的矽谷截然不同。他認為，現有的晶片架構——包括 CPU 和 GPU——都存在一個根本性的基因缺陷。

為了理解 Groq 為什麼被視為「離經叛道」，我們必須先理解它的對手：Nvidia 的 GPU。

繁忙的十字路口 vs. 精密的瑞士鐘錶

LPU vs. GPU

Feature	LPU	GPU
Design Focus	Specialized, sequential processing for NLP	General-purpose, parallel processing
Primary Applications	Natural language processing, AI chatbots, language translation	AI/ML training, gaming, graphics rendering
Efficiency	Lower power consumption, optimized for specific tasks	High power consumption
Flexibility	High efficiency in language-related tasks only	Broad application across various fields

Source: marktechpost.com

Nvidia的 GPU 本質上是一個機率性（**Probabilistic**）的機器。

想像一下，GPU 的內部就像是一個擁有數千條車道的超級繁忙十字路口。數據包就像是一輛輛汽車，它們在記憶體和計算核心之間穿梭。

為了管理這些巨大的車流，GPU 需要大量的「交通警察」——也就是硬體調度器（**Schedulers**）、緩存控制器（**Cache Controllers**）和分支預測器。

這些「警察」的工作是動態指揮交通：「你先停下，讓那輛車先過」、「現在記憶體堵塞了，大家等一等」。

這就導致了一個問題：不可預測性。

你永遠不知道一輛車通過十字路口確切需要多少毫秒。有時是 5 毫秒，有時因為堵車變成了 10 毫秒。這就是為什麼你在玩遊戲或使用 ChatGPT 時，偶爾會感覺到卡頓或延遲的波動。

Jonathan Ross 厭惡這種混亂。

Groq 的 LPU 採用了一種完全相反的哲學：確定性（**Determinism**）。


在 LPU 的世界裡，沒有交通警察，也沒有紅綠燈。所有的數據流動，在晶片開始運作之前，就已經被軟體編譯器（**Compiler**）精確地安排好了。

這就像是一隻機械結構精密的瑞士鐘錶，或者是工廠裡的自動化流水線。編譯器知道每一個電子在每一納秒（Nanosecond）的確切位置。數據在晶片上的流動是完全同步的，就像軍隊閱兵一樣整齊劃一。

因為不需要「交通警察」，Groq 砍掉了晶片上大量用於調度和緩存控制的電路。這帶來了兩個巨大的優勢：

- 1. 極致的效率：更多的晶片面積被用於實際的計算，而不是管理計算。
- 2. 零延遲抖動：LPU 的反應時間是恆定的。這對於需要即時反應的系統（如自動駕駛或即時語音翻譯）來說，是至關重要的特性。

SRAM 的豪賭：法拉利與貨車的抉擇



除了「確定性」，Groq 還做了一個在當時看來極其冒險的硬體決策：拋棄 HBM（高頻寬記憶體），全押 SRAM（靜態隨機存取記憶體）。

這是一個關於「容量」與「速度」的終極取捨。

- **Nvidia的選擇 (HBM)：**這就像是一輛巨大的貨車。它能裝載海量的貨物（數據），一次可以運送 80GB 甚至更多的模型權重。但它的缺點是，貨車裝卸貨很慢，而且倉庫（記憶體）離工廠（計算核心）有一段距離，數據傳輸存在物理瓶頸。
- **Groq 的選擇 (SRAM)：**這就像是一輛法拉利跑車。它的後備箱非常小（單個晶片只有 230MB 容量），裝不了多少東西。但它的速度快得驚人。Groq 將 SRAM 直接鋪在計算核心旁邊，數據傳輸速度達到了驚人的 80TB/s——這是Nvidia HBM 速度的 10 倍以上。

這就是 LPU 速度神話的物理基礎。在 LPU 上，數據不需要在倉庫和工廠之間來回奔波，它就在手邊。

然而，這也是 Groq 早期最大的軟肋。

因為 SRAM 非常昂貴且佔空間，單顆 LPU 無法裝下任何現代的大型 AI 模型。要運行一個大模型，你需要將數百顆 LPU 連接在一起，讓它們像一個巨型大腦一樣協同工作。

在 2016 年到 2022 年間，這被視為一種極其不經濟的架構。

「為什麼我要買 500 顆晶片來跑一個模型，而Nvidia的一顆晶片就能裝下？」這是當時投資人和客戶最常問的問題。

孤獨的先知

在 ChatGPT 爆發之前的歲月裡，Groq 是一個孤獨的異類。

當時的 AI 市場由「訓練」主導。訓練需要的是吞吐量大（Throughput），是讓貨車一次拉最多的貨。Nvidia的 GPU 是為此而生的王者。

而 Groq 專注的是「推理」的延遲（Latency），也就是法拉利送貨的速度。那時，沒有人需要法拉利。

大家都在做離線的數據分析，晚上把數據丟進去，第二天早上看結果，快一秒慢一秒根本沒人在乎。

在這段時間中，根本沒人關心推理。投資人看不懂為什麼要追求極致的低延遲，客戶也不在乎 0.2 秒和 1 秒的區別。Groq 曾數次瀕臨破產，Ross 甚至不得不自掏腰包維持公司運轉。

Jonathan Ross 和他的團隊在沒有掌聲的舞台上堅持了八年。他們被嘲笑為「偏科生」，被質疑技術路線走進了死胡同。他們製造了一把屠龍刀，卻發現世界上只有殺雞的需求。

直到 2022 年底，OpenAI 發布了 ChatGPT。

一夜之間，世界變了。AI 不再是後台的批處理任務，變成了前台的即時對話。用戶開始在乎每一個字的生成速度。延遲成為了新的痛點。

Groq 等待的風，終於來了。

這家「離經叛道」的公司，終於迎來它命運的轉折點。

第三章：速度的證明與資本的狂歡

在很長一段時間裡，Groq 面臨著一個典型的硬體初創公司困境：你的晶片再好，如果開發者拿不到手、不會用，那也是廢鐵。

傳統的銷售模式是將實體 LPU 卡賣給數據中心，但這意味著漫長的交付週期、複雜的硬體適配和高昂的試錯成本。對於那些渴望速度的 AI 開發者來說，這太慢了。

於是，在 2024 年初，Groq 做了一個大膽的決定——如果我們不賣鏟子，而是直接提供挖好的金礦呢？

這就是 **GroqCloud**。



Experience the fastest inference in the world

簡單來說，GroqCloud 是一個推理即服務（**Inference-as-a-Service**）平台。Groq 將數千張 LPU 卡架設在自己的數據中心裡，並封裝成簡單易用的 API 接口。

開發者不需要購買任何硬體，不需要懂底層編譯原理，只需要像調用 OpenAI 的 API 一樣，將模型請求發送給 GroqCloud，就能立刻體驗到 LPU 的極致速度。

這一轉變是革命性的。它將原本需要幾個月的硬體部署週期，壓縮到了幾秒鐘的 API 調用。

碾壓級的基準測試：碾壓 H100

隨著 GroqCloud 的開放，以及那條引爆全世界的推文之後，開發者開始對它進行瘋狂的壓力測試。結果是令人瞠目結舌的。


在知名 AI 評測機構 Artificial Analysis 的榜單上，Groq 的數據點孤零零地懸掛在圖表的左上角——那是代表「極致速度」和「極致低價」的無人區。

Throughput vs. Price

Quality: General reasoning index, Throughput: Tokens per Second, Price: USD per 1M Tokens

Most attractive quadrant

Mistral Perplexity Together.ai Anyscale Deepinfra Fireworks Groq Lepton



- **速度對比：**當時最強大的 Nvidia H100 GPU 在運行 Llama 2 70B 這種主流大模型時，輸出速度大約是每秒 30-50 tokens。而 Groq 的 LPU 在同樣的 70B 模型上跑出了每秒約 270-300 tokens 的速度，是 H100 的 6 到 10 倍。而在運行 Gemma 7B 等輕量級模型時，Groq 更是飆升至每秒 800 tokens 以上。
- **延遲對比：**對於語音對話來說，人類能感知的延遲極限大約是 200 毫秒。GPU 的推理延遲通常在 500 毫秒以上，導致對話總有尷尬的停頓。而 Groq 將這個數字壓到了 100 毫秒以內。

這意味著什麼？這意味著 **AI 終於可以像真人一樣說話了。**

實際應用場景：誰在為速度買單？

這種極致的速度不僅僅是為了炫技，它解鎖了那些 GPU 無法觸及的商業場景。

1. 獨角獸的選擇：

- **Canva：**這家擁有 2.6 億月活用戶的設計巨頭，並沒有選擇傳統雲廠商，而是將其 AI 魔法設計功能的後端推理交給了 Groq，只為了讓用戶在點擊「生成」的那一瞬間無需等待。
- **GPTZero：**擁有 1000 萬用戶的 AI 抄襲檢測工具，利用 Groq 將檢測速度提升了 7 倍，同時保持了 99% 的準確率。

2. 即時語音助手：像 Vapi 和 Retell AI 也在和Groq商討合作。過去，和 AI 打電話像是在用對講機，你說完，等一秒，它再回。現在，AI 可以隨時打斷你，插話，甚至和你吵架，流暢得令人恐懼。
3. 即時翻譯：在聯合國會議或跨國商務談判中，Groq 讓「同聲傳譯」變成了真正的「同步」。

資本的狂歡：從 2.8 億到 69 億到 200 億的飛躍

速度的證明直接引爆了資本市場的熱情。

Groq 的融資歷程是一條完美的指數曲線。早期，只有像 Chamath Palihapitiya 的 Social Capital 這樣大膽的風險投資人敢於下注。但在 2024 年那場病毒式的傳播之後，華爾街的「聰明錢」也開始進場了。

Learn ▼ Pricing About ▼



Use Cases

Groq Raises \$750 Million as Inference Demand Surges

The investment strengthens Groq's role in the American AI Stack, delivering fast, affordable compute worldwide.

Mountain View, CA — September 17, 2025 — Groq, the pioneer in AI inference, today announced \$750 million in new financing at a post-money valuation of \$6.9 billion. The round was led by Disruptive with significant investment from Blackrock, Neuberger Berman, DTCP and a large US-based West Coast mutual fund manager. The raise also included continued support from Samsung, Cisco, D1, Altimeter, 1789 Capital and Infinitum.

Groq powers more than two million developers and Fortune 500 companies with fast, affordable compute and is growing its presence globally, building on existing data centers in North America, Europe, and the Middle East.

2025年9月，Groq 完成了新一輪融資，由 **BlackRock**（貝萊德）領投，估值達到69億美元。這份投資名單堪稱豪華：思科 (Cisco)、三星 **Catalyst Fund**，甚至還有小**Donald Trump**的**1789 Capital**。

這傳遞了一個明確的信號：**Groq** 不再是一個科學實驗，它是被視為能夠挑戰**Nvidia**霸權的戰略資產。投資人看懂了一件事——如果**推理（Inference）**是 AI 的未來，那麼 **Groq** 會在這個未來有一席之地。

孤獨的戰士們：為什麼是 Groq？

Groq 並不是唯一試圖推翻**Nvidia**統治的反抗軍。在矽谷的各個角落，還有其他強大的挑戰者：

- **Cerebras**：他們造出了世界最大的晶片（Wafer Scale Engine），一塊晶片就有一張餐桌那麼大，試圖用暴力美學解決訓練問題。
- **SambaNova**：由史丹佛大學教授創立，主打可重構數據流架構，深受企業級客戶喜愛。
- **Tenstorrent**：由傳奇晶片設計師 Jim Keller 領軍，試圖用 RISC-V 架構重寫規則。

然而，在 2024 年至 2025 年的這段時間窗口裡，**Groq** 顯得最為特別。

為什麼？因為其他挑戰者大多還是在解決「訓練」的問題，或者試圖做一個「更好的 GPU」。只有 **Groq**，極端地、偏執地只解決一個問題：**推理的延遲**。

第四章：200 億美元的聖誕震撼

2025 年 12 月 24 日，矽谷的聖誕夜並不平靜。

當大多數人正準備與家人拆禮物時，一條重磅新聞推送震動了整個科技圈：**Nvidia**宣布以 200 億美元現金，與 **Groq** 達成「戰略合作協議」。

新聞稿的措辭經過了精心雕琢，每一個字都像是在法律的鋼絲上跳舞。

Nvidia發言人強調：「我們正在吸納 **Groq** 的傑出人才並獲得其技術授權，這不是一次傳統意義上的公司收購。」

Groq and Nvidia Enter Non-Exclusive Inference Technology Licensing Agreement to Accelerate AI Inference at Global Scale

Today, Groq announced that it has entered into a non-exclusive licensing agreement with Nvidia for Groq's inference technology. The agreement reflects a shared focus on expanding access to high-performance, low cost inference.

As part of this agreement, Jonathan Ross, Groq's Founder, Sunny Madra, Groq's President, and other members of the Groq team will join Nvidia to help advance and scale the licensed technology.

Groq will continue to operate as an independent company with Simon Edwards stepping into the role of Chief Executive Officer.

GroqCloud will continue to operate without interruption.

但事實上，這名義上是合作，骨子裡卻是一場為了規避監管、披著「授權」外衣的吞併。

這筆交易的金額令人咋舌——200 億美元。這意味著 Groq 的估值在短短三個月內，從 9 月份融資時的 69 億美元暴漲了近 3 倍。

授權（Licensing）的藝術：為何不是收購？

為什麼Nvidia不直接買下 Groq？答案只有三個字母：**FTC**（美國聯邦貿易委員會）。

Nvidia還記得 2022 年的痛苦教訓。當時，他們試圖以 400 億美元收購 ARM，結果被監管機構拖了 18 個月，最終在反壟斷的重壓下宣告失敗。

這一次，黃仁勳不想重蹈覆轍。

於是，他們採用了矽谷最新的「併購新範式」——資產出售與人才吸納（**Asset Sale & Acquire**）。

我們必須回溯過去 20 個月裡，矽谷巨頭們是如何一步步完善這套「掏空式收購」劇本的。

這套劇本的核心邏輯只有一條：買走大腦（人才）和靈魂（IP），留下軀殼（公司實體）以應付反壟斷審查。

1. 原型機：微軟與 Inflection (2024 年 3 月)

Microsoft pays Inflection \$650 mln in licensing deal while poaching top talents, source says

By Krystal Hu and Harshita Mary Varghese

March 22, 2024 6:26 AM GMT+8 · Updated March 22, 2024



這是「偽裝收購」的開山之作。

當時，微軟看上了 AI 獨角獸 Inflection 的頂級人才，但忌憚於 FTC 對巨頭併購的嚴厲紅線。

於是，微軟發明了一種新玩法：微軟不買公司，而是支付了 6.5 億美元的天價「授權費」。

名義上，這是為了使用 Inflection 的模型；實際上，這筆錢是用來安撫並買斷投資人的。緊接

著，微軟直接「僱傭」了聯合創始人 Mustafa Suleyman 和 Karén Simonyan，連同幾乎所有的核心工程師一併打包帶走。

一夜之間，Inflection 從一家明星獨角獸變成了一個只剩下空殼的 B2B 服務商。

FTC 雖然憤怒地啟動了調查，但在法律定義的模糊地帶中，微軟成功證明了：

只要不買股權，就不算「控制權變更」，從而完美繞過了 HSR 反壟斷申報。

2. 進階版：Meta 與 Scale AI (2025 年 6 月)



Meta 在 2025 年 6 月對 Scale AI 的操作，則展示了另一種狡猾的變體——「少數股權滲透」。

Meta 斥資 143 億美元收購了這家數據標註巨頭 49% 的股份。因為沒有達到 50% 的控股線，他們避開了最嚴格的審查程序。

然而，Meta 通過將 Scale AI 的 CEO Alexandr Wang 挖角至內部負責「超級智能實驗室」，實際上已經掌握了這家公司的靈魂。

這種曖昧的關係導致了災難性的副作用：Scale AI 的其他客戶，如 OpenAI 和 Google，因擔心數據安全紛紛出走。

最終，Scale AI 雖然名義上保持獨立，卻被迫裁員 14%，徹底淪為 Meta 的附庸。

3. 殘酷版：Google 與 Windsurf (2025 年 7 月)

OpenAI's Windsurf deal is off – and Windsurf's CEO is going to Google

SUMMARIZE

/ Key researchers from the AI coding startup are also heading to Google.

by **Hayden Field**

Jul 11, 2025, 10:22 PM GMT+1

[Link](#) [Facebook](#) [Twitter](#) | [1 Comment \(1 New\)](#)



Photo: Kevin Dietsch / Getty Images

但最殘酷、也最接近Nvidia今日手筆的預演，發生在 2025 年 7 月。

當時，Google 為了在編程助手領域追趕對手，將目光鎖定了 Windsurf。

Google 支付了 24 億美元，但這筆錢並沒有均勻地流向公司，而是被精確地切割：一半讓風險投資人獲得了 4 倍回報，另一半則作為簽約獎金，只為了帶走那 40 名核心技術人才。

至於剩下的 210 名員工？

他們被徹底遺棄在一個一文不值的「剩餘公司」裡，直到後來被 **Cognition** 收購才勉強獲得安置。

這場交易赤裸裸地向矽谷展示了一個新規則：在資產出售的遊戲中，未被選中的員工與公司資產是可以被剝離的棄子。

隱藏的危機：為什麼 **Groq** 選擇出售？

在外界看來，**Groq** 是一艘正在升空的火箭。但在財務報表的陰影處，危機早已顯現。

就在交易發生的幾個月前，**Groq** 悄悄將 2025 年的營收預測從 20 億美元大幅下調至 5 億美元。

這 15 億美元的缺口，源於一筆關鍵的沙地阿拉伯供應鏈交易的延遲，以及數據中心產能的激烈競爭。

GroqCloud 雖然擁有 200 萬開發者，貢獻了公司近 70% 的營收，但它是一個高運營成本、低利潤率的業務。

對於 **Jonathan Ross** 來說，擺在面前的選擇很殘酷：繼續在資金密集型的雲端戰場上流血，還是將核心技術變現，讓巨頭來承擔風險？

Nvidia 敏銳地嗅到了這股血腥味。

Nvidia的集大成之作

Nvidia在 2025 年聖誕夜的操作，正是吸取了上述所有巨頭的精華，並將其放大到了 200 億美元的規模：

1. 結構復刻微軟：採用「非獨家授權 + 人才吸納」模式，堅稱 **Groq** 依然獨立，試圖繞過 HSR 申報。
2. 規模超越 **Meta**：200 億美元的現金，足以讓 **Groq** 的投資人（貝萊德、三星、思科）閉嘴，甚至歡呼。
3. 製造「殭屍獨角獸」：**Nvidia** 只帶走了 **Jonathan Ross**、總裁 **Sunny Madra** 以及核心 LPU 工程團隊。

被留下的是 **GroqCloud**——這個平台雖然貢獻了公司 70% 的營收並擁有 200 萬開發者，但在失去了大腦（工程團隊）後，它實質上已經變成了一具「殭屍」。

正如分析師所言：「**Groq** 作為獨立競爭對手的日子已經結束了。路線圖隨著人才走了，留下的只是維護模式。」

Nvidia 拿走了未來，卻將運營風險和債務留給了舊殼。

這種結構的精妙之處在於，從法律技術上講，**Nvidia**並沒有「控制」**Groq**，因此理論上可以繞過HSR Act的強制申報和漫長的審查期。

Groq 背負著運營虧損、債務以及高昂的硬體庫存成本。通過「非排他性合作」而非「股權收購」，**Nvidia** 成功將這些財務包袱留給了 **Groq** 的舊股東和債權人，自己則輕裝上陣，只帶走了最具價值的知識產權與人才。

Nvidia賭的是，在Trump政府相對寬鬆的監管環境下，FTC 沒有足夠能力去刁難這筆「收購」。

資本的盛宴與員工的失落

200 億美元的現金流向了哪裡？這揭示了矽谷殘酷的分配法則。

這是一場資產出售（Asset Sale），而非股權收購。這意味著錢首先進入 **Groq** 公司的賬戶，然後由董事會決定如何分配。

贏家是明確的：

- **投資人（The VCs）**：貝萊德（BlackRock）、三星、思科等在 9 月份剛以 69 億美元估值入場的投資人，短短三個月就獲得了近 3 倍的回報。
- **核心高管**：Jonathan Ross 和被選中的核心工程師們，不僅拿到了Nvidia的高薪 Offer，還通過特殊的激勵條款獲得了巨額獎金。

輸家則是沉默的：

那些沒有被Nvidia選中的 **Groq** 員工——大約 150 到 200 人——發現自己處於一個尷尬的境地。他們依然受僱於 **Groq**，但這家公司已經被掏空了靈魂。

沒有了 Jonathan Ross，沒有了核心架構師，剩下的 GroqCloud 只是一個沒有研發能力的空殼服務商。他們的期權價值，完全取決於董事會是否願意將那 200 億美元分紅，以及分紅的比例。


這就像 Google 在 2025 年 7 月對 Windsurf 做的那樣：核心團隊帶著錢走了，留守員工面對的是裁員和股權歸零的風險。

第五章：Nvidia的戰略焦慮

若單看 Nvidia 的股價與財報，這家公司似乎已臻化境。它掌控著全球九成的 AI 訓練晶片市場，Blackwell 架構更是硬通貨，利潤率令人咋舌。

然而，黃仁勳的目光早已越過了當下的繁榮，投向了產業週期的下一個階段。

他清楚地看到，隨著 AI 應用的爆發，市場重心正在發生微妙而巨大的遷移——從「訓練（Training）」轉向「推理（Inference）」。



在 2023 年之前，AI 的主旋律是「建造大腦」——也就是訓練。這是一個比拼蠻力的過程，需要數萬張 GPU 並行運算，吞吐量（Throughput）是唯一指標。在這個戰場上，Nvidia 的 GPU 架構是完美的。

但隨著 ChatGPT 的普及，世界進入了「使用大腦」的階段——也就是推理。這是一個完全不同的戰場。

- **訓練是「批發業務」**：就像工廠進貨，卡車一次拉幾噸原料，沒人在乎卸貨是快一秒還是慢一秒。
- **推理是「零售業務」**：就像便利商店結帳，每一個用戶都在排隊，每一次對話都是即時交易。在這裡，**延遲（Latency）**就是一切。

分析師預測，到 2030 年，AI 推理市場的規模將達到 2550 億美元，遠超訓練市場。而在這個新戰場上，Nvidia引以為傲的 GPU 架構，遇到了一個物理學上的對手：**記憶體牆（Memory Wall）**。

基因缺陷：為什麼 GPU 害怕推理？

想像一下，GPU 就像是一個擁有幾千個廚師（核心）的超級廚房。但這個廚房有個致命設計：冰箱（HBM 記憶體）放在隔壁大樓。

在「訓練」時，這沒問題，因為廚師們一次拿很多食材，切很久。

但在「推理」時，尤其是生成語言模型時，是「切一刀，拿一次食材」。GPU 的核心必須頻繁地等待數據從 HBM 傳輸過來。這就是為什麼你的 ChatGPT 有時會卡頓——那是計算核心在等數據。

Groq 的 LPU 則完全不同。它把冰箱（SRAM）直接搬進了廚房，鋪在了砧板旁邊。

這物理差距，是Nvidia靠軟體優化無法彌補的。通過這筆收購，Nvidia承認了在特定推理場景下 GPU 的局限性，並迅速將解決方案收入囊中。

消滅「瑞士」：防止第二生態的誕生

除了技術焦慮，Nvidia還有一個更深層的戰略恐懼：生態系的失控。

Nvidia最強大的護城河不是晶片，而是 **CUDA**——那個讓全世界開發者離不開Nvidia的軟體平台。只要你用 CUDA 寫代碼，你就被鎖定在Nvidia的硬體上。

Groq 最危險的地方在於，它試圖建立一個「去 CUDA 化」的世界。

Groq 的編譯器直接對接 PyTorch 和 TensorFlow，開發者不需要寫 CUDA 代碼。GroqCloud 的 API 更是讓硬體變得透明。Groq 正在變成 AI 界的「瑞士」——一個中立、高效、不強迫你站隊的基礎設施。

如果讓 Groq 繼續發展，開發者可能會形成一種新的習慣：用Nvidia訓練，用 Groq 推理。

一旦這種模式固定下來，Nvidia的帝國就會被撕裂。推理端的利潤將流向 Groq，而 CUDA 的鎖定效應將在推理端失效。

200 億美元，是Nvidia為了「消滅選項」而支付的保險費。買下 Groq，就是拆掉這座「瑞士」，把開發者重新趕回Nvidia的圍牆花園裡。

整合的挑戰

當然，這筆收購後的整合工作依然充滿挑戰。

首先是技術哲學的融合：CUDA 建立在動態調度的並行計算之上，而 Groq 則依賴靜態編譯的順序計算。

如何將這兩種截然不同的邏輯無縫整合進 Blackwell 平台，而不造成開發者的困惑，是一個巨大的工程難題。

其次是人才與客戶的磨合，Jonathan Ross 這種反壟斷色彩濃厚的創始人能否適應巨頭文化？

以及那些原本為了避開Nvidia鎖定而選擇 Groq 的客戶，是否會因為供應商變更而流失？

這 200 億美元，是Nvidia為下一個十年支付的入場券。


面對 Google TPU 的步步進逼和推理市場的爆發，Nvidia選擇主動出擊，將潛在的變數轉化為手中的王牌。

第六章：供應鏈的蝴蝶效應

在矽谷的慶功宴和華爾街的分析報告之外，這場 200 億美元收購案的漣漪，正以一種更為隱晦卻深遠的方式擴散至太平洋彼岸，最終觸動了韓國京畿道平澤市（Pyeongtaek）的神經。

那裡是三星電子（Samsung Electronics）先進晶圓廠的核心地帶。對於三星而言，Groq 被Nvidia收購，不僅僅意味著一個潛在客戶的流失，更代表著它在晶圓代工（Foundry）戰場上，試圖構建「非台積電生態系」的一次戰略受挫。

三星的雙重算盤：財務勝利與戰略失落



要理解這其中的微妙關係，我們需要回溯到 2024 年。

當時，三星做了一個頗具前瞻性的決定：其風險投資部門（Samsung Catalyst Fund）不僅參與了 Groq 的融資，更在後續輪次中持續加碼。

這在晶圓代工行業雖然並非孤例，但意圖明顯。

在 2024 年的晶片代工版圖上，台積電（TSMC）憑藉其穩定的良率和龐大的產能，幾乎壟斷了 Nvidia、AMD 和蘋果等頂級客戶的 AI 晶片訂單。

市佔率徘徊在第二位的三星，急需尋找破局點。

Groq 對三星來說，曾是一個理想的「戰略支點」。

Groq 規劃採用三星的 4nm (SF4X) 製程來生產其下一代 LPU。這對三星而言是一個雙贏的布局：

1. 資本層面：通過投資獲得股權回報。

2. 代工層面：如果 Groq 能在推理市場崛起，三星將擁有一家能夠證明其 4nm 製程實力的標竿客戶，向市場展示「頂級 AI 晶片並非非台積電不可」。

然而，Nvidia的收購改變了這個劇本。

隨著 Groq 併入Nvidia版圖，三星雖然能從股權退出中獲得可觀的財務回報（預計數億美元的利潤），但在代工戰略上卻面臨尷尬。

Nvidia是台積電最堅定的合作夥伴，其核心的數據中心晶片高度依賴台積電的先進製程與 CoWoS 封裝技術。

這意味著，Groq 未來的晶片訂單極大概率會回歸台積電體系。

三星失去的不僅是一個客戶，更是一個在 AI 時代建立獨立影響力的機會。

產能的現實：為何 Groq 最初選擇了「非主流」路線？

這場變局也揭示了半導體行業一個殘酷但現實的邏輯：產能即話語權。

許多人好奇，既然 Groq 追求極致性能，為何最初選擇了 GlobalFoundries（格羅方德）的 14nm 和三星，而非直接擁抱台積電？

答案在於商業現實中的「優先級」。

在台積電的客戶名單上，產能分配有著清晰的商業邏輯。

- 第一梯隊：如蘋果、Nvidia、AMD。他們訂單量巨大，且願意支付鉅額預付款，鎖定了最先進製程的大部分產能。
- 新創梯隊：像 Groq 這樣的新創公司，儘管技術獨特，但在產能緊缺的週期中，往往難以獲得頂級代工廠的優先排期。

因此，Groq 的選擇是一種務實的生存策略。

GlobalFoundries 提供了美國本土的供應鏈安全，而三星則提供了台積電難以給予的產能承諾與資本支持。

Groq 的 LPU 架構之所以強調「不依賴最先進製程」（利用成熟製程也能跑出高性能），正是為了在巨頭壟斷的產能縫隙中尋求生存空間。

馬太效應的延續

Nvidia收購 Groq，將半導體行業的「馬太效應」（強者恆強）推向了一個新的高度。

1. 台積電的整合優勢：隨著 Groq 技術融入Nvidia的 Blackwell 或後續平台，為了實現 LPU 與 GPU 的高效互連，Nvidia極有可能利用台積電的 CoWoS 先進封裝技術將兩者整合。這將進一步鞏固台積電在高端 AI 晶片製造領域的中心地位。
2. 供應鏈的集中化：這場收購讓全球 AI 算力的供應鏈更加集中。設計端由Nvidia主導，製造與封裝端則高度集中於台積電。這種結構帶來了極致的效率與性能優化，但也讓整個 AI 產業對單一供應鏈條的依賴度達到了前所未有的程度。

在首爾的三星總部，高管們看著財務報表上的投資收益，或許會感到一絲複雜。

他們贏得了投資回報，卻在代工版圖的博弈中暫時退守。而在大洋彼岸，黃仁勳正在將 LPU 這塊關鍵拼圖嵌入Nvidia龐大的技術體系中，準備以更完整的姿態，迎接 AI 推理時代的到來。

第七章：200 億美元的護城河——Nvidia的終極防禦

為什麼Nvidia願意支付近 3 倍的溢價（200 億美元），去收購一家三個月前估值僅為 69 億美元的公司？

如果僅從財務報表看，這似乎是一筆昂貴的揮霍。但若將視角拉高到Nvidia的資產負債表管理與長期生存戰略，這筆交易並非簡單的收購，而是黃仁勳為其帝國買下的一份「生存保險」。

這是一份寫給華爾街的最終答卷，用以回應過去三年懸在Nvidia頭頂的達摩克利斯之劍。

1. 消除隱憂

近來，對Nvidia的一個主要「空頭論點（Bear Case）」是：Nvidia擁有訓練（Training）市場，但隨著 AI 進入大規模應用期，它將失去利潤更豐厚、規模更大的推理（Inference）市場。

投資人擔心，一旦推理市場轉向專用晶片（ASIC），Nvidia的高毛利將無法維持。Groq 的存在，就是這個論點的具象化證明。

通過這筆交易，Nvidia瞬間填補了這個戰略缺口。

現在，Nvidia可以向微軟、OpenAI 和亞馬遜提供一個完美的閉環：用 Blackwell 進行大規模訓練，用整合了 LPU 技術的方案進行超低延遲部署。

這筆 200 億美元的支出，實際上是為了捍衛Nvidia未來十年數兆美元市值的「終端價值（Terminal Value）」。

它消除了客戶尋找替代方案的理由，確保了Nvidia從「AI 軍火商」平滑過渡為「AI 基礎設施壟斷者」。

2. 防禦性併購：人才的稀缺性溢價

Nvidia支付的溢價，很大程度上是為了「防禦性」地鎖定 Jonathan Ross 及其團隊。

只要 Ross 保持獨立，Groq 就是Nvidia競爭對手（如 AMD、Intel）或超級大廠（Amazon AWS、Google Cloud）的潛在獵物。

試想一下，如果亞馬遜收購了 Groq 並將其免費整合進 AWS，那將對Nvidia的雲端統治力造成毀滅性打擊。

因此，這 200 億美元不僅是為了「得到」Groq，更是為了「不讓別人得到」Groq。將棋盤上最危險的一顆棋子私有化，確保下一代非 GPU 架構是為Nvidia而建，而非用來對抗Nvidia，這是極具性價比的戰略阻斷。

3. 扼殺「瑞士選項」：極大化轉換成本

Groq 曾試圖成為 AI 界的「瑞士」——一個中立的、非 CUDA 的替代方案。這對Nvidia的生態霸權構成了結構性威脅。

收購完成後，這個「逃生出口」被封死了。Nvidia強迫那 200 萬名曾經嘗試 Groq API 的開發者回歸 CUDA 的懷抱。

未來的整合極有可能是將 Groq 的編譯器技術融入 CUDA 生態，這將導致企業的轉換成本（Switching Cost）變得無限高。

從投資角度看，這是在極大化客戶的「生命週期價值（LTV）」。

4. 非排他性授權的陽謀

這次交易的設計在於「非排他性授權」。這是一個為了安撫監管機構而設計的完美盾牌，也是一個針對競爭對手的精巧陷阱。

法律上的盾牌：

表面上，Groq 依然擁有將 LPU 技術授權給 Google、AMD 或 Intel 的權利。

這讓 Nvidia 在面對反壟斷審查時可以理直氣壯地說：「看，我們並沒有壟斷這項技術，市場依然是開放的。」這直接規避了當年收購 ARM 失敗的覆轍。

現實中的陷阱：

但晶片架構不是靜態的食譜，而是動態的工程。

Nvidia 帶走了創辦人 Jonathan Ross 和核心工程團隊——也就是那些唯一懂得如何優化、修復並迭代這項技術的人。

留給 Groq（以及潛在競爭對手）的，只是一套無法升級的「靜態代碼」。

沒有了原創團隊，這套技術就如同失去了靈魂的軀殼。Nvidia 掌握了「未來」（下一代架構的研發能力），而競爭對手即便獲得授權，也只能得到「過去」。

通過這種方式，Nvidia 既規避了監管，又實質上鎖死了技術路線。

5. 風險套利的算計：即使「失敗」也是勝利

Nvidia當然知道 FTC（聯邦貿易委員會）會介入，甚至可能提起訴訟。但黃仁勳在賭一場必勝的局：

- 情境 A（最好的結果）：以國家安全為由（將最強推理技術留在美國巨頭手中），遊說成功，交易獲批。Nvidia獲得技術與人才，徹底補完拼圖。

- 情境 B（次好的結果）：FTC 提起訴訟，官司拖延兩三年。

在這期間，Groq 的技術已被內部消化，人才已被同化，其作為獨立競爭對手的勢頭被徹底打斷。

即便最後敗訴需要剝離資產，Nvidia也已經完成了戰略目的——扼殺了一個處於上升期的威脅。

對於Nvidia而言，這 200 億美元哪怕只是買到了競爭對手的「混亂與停滯」，也是值得的。

結語：算力時代的「標準石油」

2025 年的聖誕夜，標誌著 AI 晶片戰國時代的結束，以及一個新帝國的固化。

Nvidia通過這筆交易，證明了它不僅僅是一家技術公司，更是一個精明的資本配置者。

它利用其在訓練時代積累的超額利潤，在推理時代尚未完全爆發前，就買下了通往未來的門票。

這讓人聯想到 19 世紀末的標準石油（Standard Oil）。洛克菲勒不僅僅控制了煉油（訓練），他還通過併購控制了輸油管道和鐵路（推理與部署）。

風險依然存在——整合兩種截然不同的晶片架構（GPU 與 LPU）將是工程上的地獄，且企業文化的衝突在所難免。

但在一個月前，市場還在爭論 TPU 能否挑戰 GPU 的霸權。

而今天，Nvidia 用 200 億美元的支票，直接證明：未來，是可以被買下的。

- KP

本機離線版本・圖片與內文完整

← 回索引

在原站開啟 ↗