

← 索引  2026-01-10 1099 字 ↗ 原站

CES的深度拆解，Nvidia新晶片的「六位一體」？進軍自動駕駛？不需要散熱了嗎？ - KP思考筆記(第24期)

本文目錄

- 1 主題一：當機器人不再只是表演後空翻
- 2 主題二：Panther Lake 的準時赴約，Intel要強勢歸來？
- 3 主題三：「六位一體」的戰爭機器，拆解 NVIDIA Vera Rubin 的系統級宰制力
- 4 主題四：工業宇宙的作業系統，解析西門子與 NVIDIA 的聯盟
- 5 主題五：自動駕駛的「Android 時刻」，Alpamayo 究竟想如何挑戰 Tesla 和 Waymo？
- 6 主題六：Nvidia新架構不再需要散熱了嗎？
- 7 一句話，劃開了新舊時代
- 8 主題七：AMD打算如何追趕Nvidia？
- 9 從「獨角戲」轉向「雙雄爭霸」
- 10 主題八：當算力戰爭打到發電廠，xAI的「能源獨立」大計
 - 11 告別「錄製」，迎來「直播」
 - 12 VLA 模型：從「寫程式」到「教小孩」
 - 13 機器人的群體進化
 - 14 從藍圖到產線
 - 15 混合動力模式：為什麼「遠端操作」不是退步？
 - 16 全球棋局：美國的「大腦」與中國的「規模」
 - 17 讀懂Intel的戰爭語言
 - 18 一場洗刷十年恥辱的執行力革命
 - 19 技術上的「可行性」不等於商業上的「競爭力」

- 20 核心困境：「網路之牆」
- 21 六位一體的協同作戰
- 22 其餘成員：各司其職，協同作戰
- 23 協同設計如何解決真實痛點？
- 24 從賣「零件」到賣「系統」，護城河的再次加深
- 25 工業巨人的全貌
- 26 掙脫 CPU 枷鎖，解放設計與模擬的枷鎖
- 27 物理 AI vs. 數據中心 AI
- 28 從「標本」到「活體」
- 29 一場雙贏的合作
- 30 會「解釋」的 AI (Chain-of-Thought Reasoning)
- 31 NVIDIA 的戰略意圖
- 32 用「模擬」取代「實測」
- 33 一個無法被繞過的生態系
- 34 投資者該如何看這盤棋？
- 35 傳統散熱：在數據中心裡裝一台「巨型冰箱」
- 36 液冷技術 (Liquid Cooling)：把「水冷頭」直接貼在晶片上
- 37 轉型不會一夜發生
- 38 「協同設計」(Co-design) 時代的來臨
- 39 數據中心的全棧式進攻
- 40 真相：Helios使用的並非「完全體」的UALink
- 41 戰略定位：一個「足夠好」的第二選擇
- 42 開闢新局：專業與邊緣AI的側翼騷擾
- 43 不是因為「更好」，而是因為「能買到」
- 44 Megapack，非賣品級的必需品

4.5 實戰驗證



大家好，我是 KP，歡迎來到第 24 期的《週末思考筆記》。

2026 年的第二個星期，有兩件重要大事。

第一件，是關於我個人的小里程碑。早前曾跟大家提過，我收到了 AWS 的邀請，去分享我對這場 AI 競賽的看法。就在前幾天，這場分享會圓滿結束了。

老實說，作為一個出身金融業的人，和不同的人分析投資標的、拆解資本流向是我的老本行，我早已習以為常。

但要站在一群科技人才面前談科技趨勢，心裡確實有點「班門弄斧」的緊張感。不過，我一直對都十分關注科技業的發展，每當看到那些突破邊界的技術，我總會不由自主地幻想：未來的世界到底會變成什麼樣子？

這次能以「跨界者」的身分與科技圈產生連結，對我而言，是榮幸，更是激勵。

而第二件大事，則是正在拉斯維加斯如火如荼進行的 CES 2026 (消費電子展)。

如果你以為 CES 只是個看新電視、新手機的展覽，那可能低估了它的影響力。在科技圈，CES 是一月最重要的「定調之戰」。

原因很簡單，CES 發生在每年的一月，吸引了全球數以萬計的記者，所以各大科技巨頭會在此時發表當年的「年度主旋律」。

CES也是少數能讓「傳統製造業」與「半導體公司」以及「軟體公司」聚在一起的地方。

令到在展場華麗的燈光背後，有無數的「閉門會議」，不同公司，投資人等等坐在一起，商討有沒有合作空間。

因此，本週的《週末思考筆記》內容極其紮實。我整理了 8 個核心主題，其中 7 個都聚焦在 CES 2026 的深度拆解：

主題一：當機器人不再只是表演後空翻

主題二：Panther Lake 的準時赴約，Intel要強勢歸來？

主題三：「六位一體」的戰爭機器，拆解 NVIDIA Vera Rubin 的系統級宰制力

主題四：工業宇宙的作業系統，解析西門子與 NVIDIA 的聯盟

主題五：自動駕駛的「Android 時刻」，Alpamayo 究竟想如何挑戰 Tesla 和 Waymo？

主題六：Nvidia新架構不再需要散熱了嗎？

主題七：AMD打算如何追趕Nvidia？

主題八：當算力戰爭打到發電廠，xAI的「能源獨立」大計

（為新朋友快速說明：我的內容分為兩種：「深入研究」是付費會員專屬的重磅分析；「週末思考筆記」則是你正讀的這篇，是分享市場觀點的投資散文，永久免費。）

話不多說，我們直接進入正題！

進入正文之前會員們可以投下你們的神聖一票，決定兩星期後「深入研究」的主題。

投票將在**3天後**結束。

主題一：當機器人不再只是表演後空翻



CES 2026 : Boston Dynamics' Atlas wins CNET's top robot honor at CES 2026 | AJU PRESS

如果過去十年的機器人產業是一場漫長的「概念演習」，那麼**CES 2026**就是正式的「實戰校閱」。

這次展會傳遞出一個極其強烈的信號：人形機器人已經從「研發預算」轉向了「資本支出（CAPEX）」。這不再是科技大佬們用來展示肌肉的公關工具，而是製造業巨頭們寫入財報、實打實的生產力工具。

告別「錄製」，迎來「直播」

過去我們看波士頓動力（**Boston Dynamics**）的影片，總是在驚嘆後空翻或跑酷，但那些大半是錄製好的程式。

在 **CES 2026**，波士頓動力選擇在展場現場遠端操控 **Atlas**。機器人公司很少在現場演示人形機器人，因為任何一次失誤都會引來災難性的關注。

這向市場傳達了一個訊息：**Atlas** 已經不再是實驗室裡的產品，它具備了進入工廠所需的「工業級穩定性」。只有當供應鏈、維護體系與成本結構都準備好時，一家公司才敢冒著「現場翻車」的風險進行公開展示。

VLA 模型：從「寫程式」到「教小孩」

真正賦予 **Atlas** 「靈魂」的，是與 **Google DeepMind Gemini AI** 的深度整合，突破點是 **VLA（Vision-Language-Action）** 模型的成熟。

當你下達「拿起鍵盤旁邊的紅杯子」時，**VLA** 模型並非在執行一段死板的程式。它從網路規模的訓練中早已學會了什麼是「杯子」、理解「旁邊」這類空間關係、並將「紅色」與視覺特徵關聯起來。

它解決了困擾機器人學數十年的「泛化」（**Generalization**）難題，一個在藍色杯子上訓練過的機器人，現在能理解「藍色」是一個獨立於物體形狀的顏色屬性。

現在的機器人不需要針對特定任務重新訓練，它能聽懂自然語言指令並直接執行。這意味著機器人的部署成本將呈指數級下降，因為訓練週期大幅縮短。

機器人的群體進化

在 **CES 2026** 之前，每一台機器人都是一座孤島。1號機器人學會了繞開障礙物，其餘 999 台對此一無所知。

今年，幾乎所有頭部玩家都推出了「聯邦學習」（**Federated Learning**）系統。這背後的邏輯是：一台機器人跌倒的教訓，會立刻變成一萬台機器人的經驗。當一台 **Atlas** 在現代汽車（**Hyundai**）的工廠裡遇到一個極端案例（**Edge Case**），解決方案會透過 **OTA** 瞬間同步給全球的機隊。

這種「群體智慧」的進化速度，是人類勞動力永遠無法企及的。

從藍圖到產線

如果說技術是前提，那麼資本和產能的承諾，則是拐點的最終確認。

- **現代汽車 + 波士頓動力**：現代在 CES 上宣布，到 **2028 年**實現每年生產 **30,000 台 Atlas** 的目標，並將其部署於喬治亞州的電動車超級工廠。
- **智元機器人 (AgiBot)**：如果說現代的承諾是「未來」，那麼智元的出貨量就是「現在」。該公司宣布已在全球製造並交付超過 **5,000 台**人形機器人。
- **宇樹科技 (Unitree)**：宇樹宣布 **H2 型號**將於 **2026 年 4 月**以 **29,900 美元**的價格開始出貨。

混合動力模式：為什麼「遠端操作」不是退步？

很多人看到機器人背後還有真人遠端操作，就覺得技術還不成熟，這話只對了一半。

事實上，「人機協作」是目前商業落地的最優解。一個熟練的工人可以同時監控並切換操作 **10 台**機器人，機器人處理 **90%** 的重複動作，人類處理 **10%** 的複雜決策。

- **投資回報率 (ROI)** 算得過來：一台機器人 **3-5 萬**美金，**3-5 年**回本。
- **數據閉環**：人類的每一次干預，都是在為 **AI** 提供最高質量的訓練數據。

這解釋了為什麼智元能在還沒實現「完全自主」前，就已經在全球交付了超過 **5,000 台**機器人。市場等不及完全自主，市場要的是現在就能省錢的方案。

全球棋局：美國的「大腦」與中國的「規模」

CES 2026 展現了清晰的競爭格局：

- **美歐陣營 (波士頓動力、Figure、NEURA)**：專注於 **AI 大腦**的深度整合與極致的工業安全標準。

- 中國陣營（宇樹、智元）：展現了強大的供應鏈整合與成本控制能力。宇樹H2 喊出 **2.9 萬美金** 的明確售價與交期，這是在逼著全球製造業做選擇。

目前看來，中國廠商在商業化速度與成本優化上領先了 **1-2 年**。

拐點已至，但驗證尚需時日

雖然人形機器人已經跨過了商業門檻，但投資者需要區分：誰在賣「願景」（如家用機器人，目前仍屬科幻），誰在賣「工具」（如工業與物流機器人）。

CES 2026 證明了生產級硬體、推理級 **AI** 和可行的商業模式已經匯合。然而，這個拐點的真實性，最終將由 **2028 年** 的工廠部署數據和 **2029-2030 年** 的單位產量來驗證。

主題二：Panther Lake 的準時赴約，Intel要強勢歸來？



Intel stock rallies as CES debut of Panther Lake chip marks make-or-break moment

在CES 2026的鎂光燈下，Intel確實打出了一張漂亮的牌。**Panther Lake**的問世，就像一場遲來的及時雨，澆熄了市場對其「四年五節點」路線圖最大的疑慮。

Panther Lake的成功，究竟證明了什麼？又掩蓋了什麼？

讀懂Intel的戰爭語言

在分析之前，我們先來解釋一下Intel的語言。

什麼是 **Panther Lake**？

你可以將「Panther Lake」理解為Intel為2026年筆記型電腦市場打造的新一代「大腦」。

它不是單一晶片，而是一個完整的處理器系列（Core Ultra 3/5/7/X），將成為從輕薄本到高性能筆電的心臟。

它的使命，就是要向世界證明，在AI時代，Intel依然能定義什麼才是一台「好電腦」。

什麼是 18A 製程？

如果說處理器是建築，那「製程」就是建造這棟建築的工藝藍圖與技術水平。

數字越小，代表工藝越先進，可以在同樣大小的晶片上，塞進更多、更小、更省電的電晶體。

18A，可以理解為**1.8奈米**級別的技術，是Intel暫時最頂尖的製造工藝。

一場洗刷十年恥辱的執行力革命

對 **Intel** 而言，**Panther Lake** 最重要的數據不是效能增長，而是 **2026 年 1 月 27 日** 這個上市日期。

從**10奈米**到**7奈米**，**Intel**在過去十年飽受製程延宕的折磨，信譽幾乎破產。**Panther Lake**的如期而至，代表著**Intel**的工廠，終於能再次跟上自家**PPT**的腳步。

這是一場關於「執行力」的自我救贖。

無論是遊戲中的幀數，還是每瓦性能的提升，**Panther Lake**的實測表現基本兌現了**Intel**在發表會上的承諾。

這意味著**18A**製程的兩大基石：**RibbonFET**與**PowerVia**技術，並非實驗室裡的屠龍之技，而是能帶來實質性能優勢的「黑科技」。這重建了市場對其技術路線的信任。

更關鍵的是，**Intel**並非只拿出幾顆「特挑」的黃金樣品，而是在全球同步推出了橫跨**200**多款**OEM**設計的完整產品線。這證明**18A**製程已具備規模化量產的能力，良率正走在一條可預測的爬坡曲線上。這場仗，**Intel**打得有備而來。

總結來說，**Panther Lake**證明了**18A**製程「能用、好用，且能大規模製造」。

技術上的「可行性」不等於商業上的「競爭力」

Panther Lake證明了**18A**「能做」，卻沒證明它「做得便宜」。

60-70%的初期良率，對比台積電**N2**製程仍然有**10-15**個百分點的差距，是一道無法迴避的數學題。它直接轉化為更高的單位成本、更低的產出效率。

這意味著，用**18A**為自己生產晶片或許可以不計成本，但要以此說服蘋果、高通等外部客戶放棄台積電，幾乎是不可能的任務。在晶圓代工的戰場上，成本就是生命線。

更重要的是，**Intel** 證明了 **18A** 能幫「自己」做晶片，卻沒能證明能幫「別人」做晶片。**CES** 上除了已知的微軟合作案，完全沒有 **Apple**、**Qualcomm** 或 **Broadcom** 等重量級外部客戶的簽約消息。

沒有外部客戶，**18A** 就只是一個昂貴的內部玩具，而非真正的代工事業。


同時，他們雖然提到 **14A** 進度領先，但缺乏具體客戶回饋。加上在這場大會中，**Intel** 所有的聚光燈都給了消費級產品，這讓外界懷疑 **Intel** 在高毛利的資料中心市場是否仍處於守勢。

一場止血，而非反攻

Panther Lake 的問世，是一次至關重要的「止血」。它驗證了**Intel**的執行力，穩住了搖搖欲墜的軍心，為自己贏得了喘息的時間與空間。

但要重回巔峰，市場在等待的是在未來幾個季度的財報。屆時，冰冷的良率數字、毛利率變化以及那份「夢寐以求」的外部客戶名單，將會給出最終的答案。在那之前，**Intel** 依然只是一個「正在康復中」的巨人。

主題三：「六位一體」的戰爭機器，拆解 **NVIDIA Vera Rubin** 的系統級宰制力



Nvidia's Vera-Rubin Platform Obsoletes Current AI Iron Six Months Ahead Of Launch

Vera Rubin的出現，宣告了「單顆晶片打天下」的時代正式終結。

在**CES**之後，很多人還在糾結**Rubin**的**PFLOPS**翻了幾倍，但這其實看錯了重點。**黃仁勳**這次真正祭出的殺招，不是更強的**GPU**，而是「極致協同設計（Extreme Co-design）」。

這一次，**NVIDIA**不再只是給你一顆引擎，而是直接把整台**F1**賽車的底盤、傳動、甚至連維修站的補給系統（六顆晶片）全部焊死在一起。

核心困境：「網路之牆」

要理解**Rubin**的設計哲學，必須先理解**AI**基礎設施現在面臨的瓶頸：等待。

簡單來說，**GPU**的算力增長速度遠遠超過了數據傳輸的速度。結果就是，耗資數百萬美元的**GPU**叢集，其真實利用率常常只有**40-50%**。

剩下的時間，這些昂貴的矽晶片都在「空轉」，焦急地等待數據從網路的另一端緩慢爬來。這不僅是效率問題，更是經濟災難。

不斷推進**GPU**的性能其實也無濟於事，只要一天其他部件效率沒有提高，連接的效果沒有變好，真實利用率只會保持在低位。

Vera Rubin的誕生，就是為了用一種極其徹底的「**系統工程**」手段，徹底推倒這堵牆。

六位一體的協同作戰

Rubin平台的靈魂在於「**極致協同設計**」(**Extreme Co-design**)。這意味著平台上的六顆晶片，從設計的第一天起，就不是獨立的零件，而是作為一個統一的機櫃級系統被同時構思、同時優化。

讓我們來認識一下這顆晶片上的每個成員：

1. Vera CPU — 數據總指揮：

在以訓練為主的時代，**AI**是「**計算密集型**」任務。**GPU**利用率高達**85-95%**，而**CPU**僅負責加載數據、調度任務，利用率低至**10-20%**。

當時的共識是：「**CPU**無關緊要，隨便一顆**Xeon**都能用。」

但到了**2025-2026**的「**推理時代**」，情況完全反轉。**AI**推理的第一步（把文字變標記）和最後一步（把標記變文字）都是**CPU**密集型的工作。

GPU處理一個**Token**只要微秒級，但**CPU**進行批次處理（**Batching**）可能要毫秒級。這1000倍的速度差，導致**GPU**有99%的時間在等**CPU**把下一批數據準備好。

當我們進入「**長文本 (Long-context)**」和「**代理型 AI (Agentic AI)**」時代，**CPU**需要管理的**KV Cache**規模呈幾何級數增長。如果**CPU**慢，**GPU**利用率會直接從**90%**掉到**40%**。

這就是**Vera CPU**存在的理由。它並非一顆像**Xeon**那樣的通用**CPU**，而是一顆為**AI**協調而生的**88核**定製化**Arm**處理器。

它的架構被優化，專門用於處理**Token**化、請求批處理、以及在三級記憶體（**GPU HBM4**、**CPU DRAM**、**ICMS**儲存）之間進行複雜的**KV Cache**調度。

它與Rubin GPU之間那條1.8 TB/s的NVLink-C2C高速通道，正是為了實現這種無縫、低延遲的協調而存在。

2. BlueField-4 DPU — 基礎設施總管：

我們先來理解一下黃仁勳口中的「第三運算支柱」：**DPU**（數據處理單元）。它的唯一使命，就是在資料中心內高效地移動數據。

在現代的超大型AI資料中心裡，有一種東西叫「資料中心稅」(Datacenter Tax)：意指CPU有大約**30%~40%**的效能都被浪費在處理網路封包、安全檢查這些「雜事」上，而不是在跑真正的AI程式。

有了**DPU**，它就能把這**30%**的雜事接手過來，**CPU**就能**100%**全力投入在指揮AI運算。一個**DPU**本質上是一個小型電腦，整合了多核**CPU**（負責控制）、高性能網路介面（負責數據處理）和硬體加速引擎。

這正是**BlueField-4**在Rubin體系中的角色。它內建一顆**64核Grace CPU**，專門處理所有與AI計算無關的「髒活累活」：網路封包處理、**ICMS**儲存I/O協調、安全隔離、遙測監控。

這就像為**CEO**配備了一個萬能的執行長辦公室，讓他可以專心於戰略決策。

正是因為**BlueField-4**接管了所有基礎設施工作，**Vera CPU**才得以被徹底解放，**100%**專注於更高價值的AI協調任務。

其餘成員：各司其職，協同作戰

3. Rubin GPU — 算力引擎：

50 PFLOPS的推理性能固然亮眼，但那只是標題。真正的重要在於**22 TB/s**的**HBM4**記憶體頻寬，是**Blackwell**的近三倍。

為何這如此重要？因為當前最前沿的長文本推理（**Long-Context**）和專家模型（**MoE**），瓶頸從來不在於計算，而在於記憶體頻寬。

4. NVLink 6 Switch — 機櫃內神經系統：

如果說**GPU**是肌肉，**NVLink 6**就是連接它們的神經。它將每顆**GPU**的雙向頻寬翻倍至**3.6 TB/s**，在**72**顆**GPU**之間建立了一個真正的「全通訊」(**all-to-all**) 網路。

這徹底消除了**MoE**模型中因數據交換而產生的內部瓶頸，如同為大腦的每個神經元都建立了直連通路。

5. ConnectX-9 SuperNIC — 智慧交通警察：

傳統網卡是被動的。而**SuperNIC**則是一個主動的「交通警察」，它在數據流量產生的源頭就進行整形和擁塞控制。它不是在交通堵塞後去疏導，而是在一開始就杜絕了堵塞發生的可能。

6. Spectrum-6 Ethernet Switch — 跨系統高速公路：

如果**NVLink 6**是機櫃內的「局域網」，**Spectrum-6**就是連接數千個機櫃的「廣域網」。它採用了先進的矽光子技術，以**5**倍的能效提升，將整個資料中心連接成一個無縫的、巨大的**AI**工廠。

協同設計如何解決真實痛點？

還記得我前幾天提過的「推論上下文記憶體儲存平台」(**Inference Context Memory Storage Platform**) 嗎？(還未看的快去看)

這之所以可能，是因為**BlueField**從設計之初就知道**Spectrum-X**的傳輸模式，而**GPU**的軟體也知道何時該預取數據等等。結果是，長文本處理速度提升**5**倍。

而專家模型(**MoE**)需要在大量**GPU**之間進行密集的「全通訊」，**Blackwell**的**NVLink**在超過**60**顆**GPU**後就會達到飽和。

在**Rubin**的架構中**NVLink 6**將頻寬翻倍，並將**SHARP**（網路內計算）功能直接整合進交換器，分擔了大量通信開銷。

這使得訓練同樣規模的**MoE**模型，所需的**GPU**數量僅為**Blackwell**的四分之一，代表效率上升了**4**倍。

從賣「零件」到賣「系統」，護城河的再次加深

Vera Rubin的發布，標誌著**NVIDIA**商業模式和競爭壁壘的重大轉變：

單一晶片的**FLOPS**競賽正在變得次要。**AMD**的**MI500**或許能在原始算力上追平**Rubin GPU**，但它能同時拿出與之完美匹配的**BlueField**、**NVLink**和全套軟體生態嗎？

這套六晶片協同設計的架構，與**CUDA**軟體生態深度綁定，創造了巨大的轉換成本。


客戶購買的不再是一塊**GPU**，而是一整套預先整合、深度優化的「**AI工廠解決方案**」。這種系統級的鎖定，遠比單一硬體的性能優勢更為堅固。

Vera Rubin 宣告了「拼湊零件」時代的結束，和「系統為王」時代的到來。

Rubin平台上的每一項技術單獨來看都是「進化」，但當它們被「協同設計」這個核心理念串聯起來時，其產生的化學反應是「顛覆性」的。

p.s. 這裡沒有細說**NVLink**，但**NVLink**絕對是Nvidia的重要護城河之一，有興趣可以重溫舊文。

主題四：工業宇宙的作業系統，解析西門子與 **NVIDIA** 的聯盟



西門子宣布和**Nvidia**合作擴展為「工業 AI 作業系統（Industrial AI Operating System）」，將 **NVIDIA** 的算力基因，徹底植入全球數十萬名西門子工程師所構築的工業帝國中。

這個聯手開啟了一個新時代的序幕：一個由加速運算定義、**AI** 驅動、虛實完全融合的「物理 AI」（Physical AI）時代。

工業巨人的全貌

在深入探討這場革命之前，我們必須先精準定位西門子在這場聯盟中的角色。

許多人對西門子的印象可能還停留在「德國製造」的家電或工業自動化設備上。這固然沒錯，但這只是冰山一角。

其今日真正的核心與靈魂，是它龐大的「數位工業」軟體組合**Xcelerator**，大家可以將 **Xcelerator** 想像成是專為整個工業世界打造的「作業系統」。

1. 複雜模擬與虛擬測試：

在製造任何實體原型之前，西門子的軟體（如 **Simcenter**）需要在虛擬世界中進行成千上萬次的流體力學、結構強度和電磁模擬。

這些任務的計算量極其龐大，傳統 **CPU** 需要數天甚至數週才能完成，而 **NVIDIA** 的 **GPU** 加速運算能將其縮短到幾小時。

2. AI 驅動的設計與工廠優化：

無論是利用 **AI** 生成最優化的零件結構，還是在數位工廠中預測生產瓶頸並進行排程優化，都需要強大的 **AI** 訓練和推理能力，這恰好是 **NVIDIA AI** 平台的專長。

3. 創建物理級逼真的數位雙生：

要建立一個能與物理世界即時互動、視覺上極度逼真且行為符合物理定律的「活體」數位雙生，需要 **NVIDIA Omniverse** 平台提供的即時光線追蹤和物理模擬引擎。

簡而言之，西門子提供了工業世界的「應用程式和作業系統」，而 **NVIDIA** 則提供了能讓這一切以指數級速度運行的「超級晶片和底層引擎」。

掙脫 CPU 枷鎖，解放設計與模擬的枷鎖

過去數十年，從晶片設計（**EDA**）到飛機的流體力學模擬（**CFD**），整個工業軟體世界都建立在 **CPU** 的基石之上。**CPU** 擅長處理複雜的單線程邏輯，這與工業演算法的循序特性不謀而合。

然而，自 **2010** 年後，**CPU** 性能的「擠牙膏」式增長，早已追不上工業設計複雜度的指數級爆炸。

一個先進製程的晶片驗證，動輒在 **CPU** 叢集上跑上數週；一款新車的風阻模擬，需要耗費數十小時。設計工程師們撞上了一堵無形的牆，產品的迭代速度被運算力死死地卡住了喉嚨。

而 **NVIDIA** 的出現，帶來了 **GPU** 加速運算這把利刃。透過將 **NVIDIA** 的 **CUDA-X** 函式庫、**cuSOLVER** 等加速引擎，引入 **PhysicsNeMo** 這類生成式物理模型，令過去需要數週的設計優化週期，如今可能在一天內完成。

過去，工程師需要運行 **100** 次、每次耗時數小時的模擬來尋找最優解；現在，他們只需在 **GPU** 上運行 **20** 次模擬來訓練一個 **AI** 模型，剩下的 **80** 次探索，**AI** 可以在幾秒鐘內「預測」出結果。

物理 AI vs. 數據中心 AI

事實上，運行在工廠裡的「物理 **AI**」，與我們熟知的、運行在雲端數據中心的 **AI**（如 **ChatGPT**），是兩種截然不同的物種。

- **資料中心 AI（機率導向）**：處理的是資訊位元（**Bits**）。它基於統計機率，偶爾的錯誤（幻覺）在可接受範圍內，且對延遲的容忍度較高。
- **物理 AI（定律導向）**：處理的是實體原子（**Atoms**）。它必須嚴格遵守能量守恆、質量守恆等物理定律。

例如，在生產線上即時檢測瑕疵品並立刻停機。這裡追求的是極致的低延遲與可靠性。正是這種根本性的差異，決定了你不能簡單地把雲端 **AI** 搬到工廠裡。

工業界需要的是一套截然不同的、從晶片到軟體都為「即時、可靠、本地化」而生的專用架構。西門子與 **NVIDIA** 的聯盟，正是為了確保 **AI** 在工廠邊緣端（**Edge**）能實現極致的低延遲、高可靠性與物理準確性。

從「標本」到「活體」

這場聯盟最令人興奮的成果，莫過於賦予了「數位雙生」（**Digital Twin**）真正的生命。那麼，到底什麼是數位雙生？

想像一下，你為你的愛車拍了一套極其精細的 **3D** 寫真集，鉅細靡遺地記錄了它每個零件的樣貌和規格。

這就是過去的數位雙生，一個精美的、高保真的「數位標本」。它可以用於展示、查閱，但它本身是靜態的、被動的。

但今日的自主數位雙生，不只能做到這點。現在，想像你不僅有了這本寫真集，還在虛擬世界中創造了一個和你的實體車一模一樣的「活體」。

這個虛擬活體擁有自己的物理引擎（**Simcenter**），能模擬真實世界的力學和流體；它擁有自己的大腦（**PhysicsNeMo**），能從數據中學習並預測行為；它還擁有自己的神經系統，能與實體車的感測器即時同步。

它不再是一個被動的標本，而是一個永不疲倦、在虛擬世界中進行著持續優化實驗的「自主大腦」。

它能即時分析真實工廠的數據，在虛擬空間中測試數千種改進方案（例如調整產線佈局、更換機器人手臂），然後將被驗證為最優的方案，直接部署回物理世界。

百事可樂（**PepsiCo**）的案例完美地詮釋了這一點。他們在動工前，在虛擬世界中發現了 **90%** 的潛在問題，最終實現了 **20%** 的產能提升和 **10-15%** 的資本支出削減。

一場雙贏的合作

然而，這條通往未來的道路並非坦途。實現這一切的核心技術，NVIDIA Omniverse 平台，正處於一個關鍵的十字路口。

根據不同的報導，儘管 NVIDIA CEO 黃仁勳對其寄予厚望，將其視為價值數億美元的市場機會，但 Omniverse 在過去幾年的商業化進程中卻進展甚微。

據報導，由於需求不足，其 Omniverse Cloud 服務一度關停；開發者抱怨軟體難用、功能不全；工程資源過度投入於無法產品化的演示中，讓黃仁勳本人也感到沮喪。

這使得與西門子的聯盟，不僅僅是一次市場擴張，更成為 NVIDIA 的一場戰略需要。


與其單打獨鬥地向市場推銷一個尚不成熟的平台，不如將其深度嵌入像西門子這樣的工業巨擘的生態系統中。

透過西門子全球數十萬工程師和龐大的客戶基礎，NVIDIA 試圖為 Omniverse 創造一個無法拒絕的應用場景，強行拉動市場需求，從而克服其早期的採用困境。

對西門子而言，這次合作讓他們從一家賣設備、賣軟體授權的公司，轉型為一個靠持續優化和 AI 服務來賺錢的平台公司。他們的 Xcelerator 平台，就像是工業界的 App Store，而 NVIDIA 提供了底層的硬體和作業系統。

工業世界的遊戲規則正在被改寫。競爭的焦點，已從單點的軟體功能，轉向了誰能提供一個從設計到營運、從硬體到軟體、從雲端到邊緣的「全棧式整合平台」。

主題五：自動駕駛的「Android 時刻」，Alpamayo 究竟想如何挑戰 Tesla 和 Waymo？



A look at how Mercedes Benz, Nvidia collaborated on autonomous vehicles | Constellation Research Inc.

在自動駕駛的賽道上，過去只有兩條路：一條是 **Tesla** 的「垂直整合模式」（自己造晶片、造車、寫軟體），另一條是 **Waymo** 的「封閉營運模式」（高成本、地理圍欄）。

Alpamayo 的出現，是第三條路：平台化。

它想做自動駕駛界的 **Android**，讓所有不想被 **Tesla** 甩開、卻又沒能力研發底層 **AI** 的傳統車廠（如賓士、豐田、通用），能直接「租借」**NVIDIA** 的大腦。

會「解釋」的 AI（Chain-of-Thought Reasoning）

首先，**Alpamayo** 究竟是什麼？它並非 **Nvidia** 自己跳下來搞自動駕駛，而是提供一個完整的生態系統，其核心旨在幫助任何汽車製造商（**OEM**）或計程車隊營運商，打造出自己的 **Level 4** 自動駕駛能力。

這個生態系統的核心，是一個名為 **Alpamayo 1** 的視覺-語言-行動（**VLA**）模型。但它與過去的 **AI** 模型有著根本性的區別：它引入了「思維鏈推理」（**Chain-of-Thought Reasoning**）。

這意味著什麼？過去的自動駕駛 **AI**，像一個神秘的「黑盒子」。它看到數據，然後給出一個指令（轉向、煞車），但你無從得知它「為什麼」這麼做，連工程師都難以解釋。這在監管機構眼裡是巨大的安全隱患。

而 **Alpamayo** 則像一個會自言自語的人類駕駛員，它會在做出決策前，生成一步步的、可被人類理解的邏輯鏈。例如，當車輛遇到故障紅綠燈時，系統會產生人類可讀的邏輯軌跡：

「偵測到紅綠燈故障 → 觀察四周無橫向來車 → 判斷安全 → 緩慢通過。」

當保險公司和政府要求解釋事故原因時，**NVIDIA** 的「可解釋性」將成為傳統車廠進入 **Level 4** 的通行證。

但當然，所有東西都不是沒有代價的。思維鏈推理的本質是生成額外的、用於解釋的「思考代幣」（**Tokens**）。

推理模型比傳統模型的功耗高出 **2-3** 倍。對於電動車而言，這意味著每天僅因運算就要多消耗數度電，直接削減了寶貴的續航里程。加上思維鏈的延遲性，也是 **Nvidia** 必需要考慮的事情。

最後，駕駛有時候是本能反應，多於一個精密的思考過程。加入了思維鏈，究竟會令自動駕駛變得更好還是更笨，仍然有待考察。

NVIDIA 的戰略意圖

NVIDIA 投入如此巨大的資源進入這個燒錢無數的領域，背後有三個戰略原因：

1. 尋找下一個萬億級市場：

黃仁勳已明確表示，在資料中心 **AI** 之後，以自動駕駛為代表的「物理 **AI**」（**Physical AI**）是 **NVIDIA** 的第二大增長機會。

當資料中心的 **AI** 晶片市場逐漸走向成熟甚至商品化時，**NVIDIA** 迫切需要一個能將其運算能力從雲端延伸至邊緣、從開發滲透至量產的全新戰場。

2. 成為「賣鏟人」，而非「淘金者」：

與親自造車的**特斯拉**和運營車隊的**Waymo**不同，**NVIDIA**的定位是成為產業鏈上游的基礎設施供應商。

它賣的是一整套解決方案：從車載超級晶片（如 **Drive AGX Thor**，單價約 **3,500 美元**）、作業系統、**AI** 模型，到後端的訓練與模擬平台。

它希望複製在 **AI** 資料中心領域的成功模式：我不是最大的使用者，但我讓所有使用者都離不開我。

3. 終結「重複造輪子」的混亂局面：

當前，幾乎所有車廠都在各自為政地從零開始研發自動駕駛系統，這導致了巨大的資源浪費。

Alpamayo 提供了一個強大的架構，讓車廠可以在此基礎上進行微調和客製化，而不是從頭發明感知、規劃和控制系統。**NVIDIA** 試圖藉此一舉統一這個碎片化的市場。

用「模擬」取代「實測」

不過，大家可能都會明白，自動駕駛最重要的不只是技術，而是數據。這方面 **Tesla** 和 **Waymo** 有大量真實行駛數據，**Alpamayo** 又打算如何追趕？

這就又要說回 **Nvidia** 的 **Omniverse** 了。透過 **Omniverse** 的物理模擬，**NVIDIA** 宣稱能將模擬數據轉化為現實表現的誤差降低 **83%**。

這意味著，在理論上賓士不需要像 **Tesla** 那樣花十年去收集數據，只要在 **NVIDIA** 的數位孿生世界裡「跑」幾個月，就能獲得接近 **Level 4** 的能力。這是一場「以算法換數據」的賭注。

一個無法被繞過的生態系

NVIDIA 的策略在於，它不與任何車廠為敵，而是讓所有車廠都成為它的夥伴。其合作夥伴網絡已經遍佈產業的各個角落：

- **Mercedes-Benz**：作為首個全棧式合作夥伴，賓士將於 **2026 年** 第一季在美國率先推出搭載 **Alpamayo** 技術的 **CLA** 車型，這將是該平台首次大規模的「期中考」。

- **戰略級巨頭 (Toyota, GM)：**全球銷量第一的豐田和美國巨頭通用汽車，都已承諾在其下一代平台中整合 **NVIDIA Drive** 技術。
- **自動駕駛營運商 (Uber, Aurora)：**Uber 計劃在 **2027** 年前部署 **10 萬輛**基於 **NVIDIA** 架構的 **Robotaxi**；**Aurora** 則專注於無人駕駛卡車領域。
- **新興勢力與供應鏈 (Lucid, BYD, Foxconn)：**從豪華電動車品牌到全球最大的電動車製造商比亞迪，再到代工巨頭富士康，都已納入 **NVIDIA** 的生態版圖。

這形成了一個強大的**網絡效應**：當行業內越多的參與者採用 **NVIDIA** 的平台，這個平台的標準地位就越穩固，後進者選擇其他方案的機會成本就越高。

投資者該如何看這盤棋？

NVIDIA 的 **Alpamayo** 巧妙地避開了造車和運營這兩個資本最密集、回報週期最長的無底洞，轉而佔據了產業鏈中利潤最豐厚、最具控制權的一環。

但大家也要明白的是：這是一個正確的、但極其長期的故事。

對於投資者和觀察者而言，必須清晰地認識到：**Alpamayo** 的成功，取決於整個行業的成熟速度，而這個速度充滿了不確定性。

在未來 **2-3** 年內，**NVIDIA** 的核心故事仍然是其在資料中心 **AI** 領域無可匹敵的統治力。

自動駕駛業務將是一個重要的增長期權，但它更像是一場需要耐心等待的長線投資，而非能立即引爆財報的催化劑。

現在，全世界都在屏息等待 **2026** 年，看著賓士 **CLA** 的輪胎在真實道路上滾動時，這盤大棋將迎來它的第一次「期中考」。

主題六：Nvidia新架構不再需要散熱了嗎？

Supercomputers can stay chill with hot water says Nvidia


By Diana Goovaerts · Jan 6, 2026 5:43pm

data center

data centers

liquid cooling

Nvidia



黃仁勳只用了一句話，就讓全球幾家空調與散熱巨頭的市值，在盤中瞬間蒸發了數十億甚至上百億美元。

他說：「我們未來的**Vera Rubin**平台，是用攝氏**45度**的溫水來冷卻的。在這個溫度下，資料中心不再需要傳統的冰水主機（**Chiller**）。」

市場的第一反應是：**NVIDIA**不再需要散熱了！這對整個散熱行業是毀滅性打擊！

於是，恐慌性拋售開始了。但事實上，要了解這個變化，我們要先了解一下數據中心是如何散熱的。

傳統散熱：在數據中心裡裝一台「巨型冰箱」

過去幾十年，數據中心的散熱邏輯是「冷卻空氣」。

你可以把大型冷水機組 (Chillers)想像成一台放在頂樓的巨型冰箱。它的任務是利用電力，強行把水溫降到很低（通常是 **7°C** 到 **15°C**）。

運作流程是這樣的：

1. 冷水機組製造出冷水。
2. 這些冷水流進室內的「空調箱（**CRAH**）」。
3. 空調箱吹出冷風。
4. 冷風吹向伺服器，帶走晶片的熱量。

問題在於，空氣的導熱能力非常差。當 **AI** 晶片像電磁爐一樣燙時，你就算把風扇吹到起火，也來不及帶走熱量。

而且，為了維持那台「巨型冰箱」運作，數據中心有 **30%-40%** 的電費是花在冷水機組上的。這就是為什麼傳統方式既浪費空間，又極度耗能。

液冷技術 (Liquid Cooling)：把「水冷頭」直接貼在晶片上

液冷技術（特別是 **Direct Liquid Cooling, DLC**）跳過了空氣這個低效率的中介，直接用液體去「吸熱」。

運作流程是這樣的：

1. 像賽車改裝一樣，在晶片表面貼上一塊**金屬冷板**。
2. 液體（通常是水或特殊冷卻液）直接流過這塊冷板。
3. 液體直接帶走晶片的熱量，然後流出伺服器。

為什麼這樣更好？水的導熱能力是空氣的 **25 倍以上**。

這意味著你可以用更小的體積，處理更多的熱量。這也是為什麼 **NVIDIA** 的高階機櫃（如 **NVL72**）必須強制使用液冷，因為空氣已經「吹不動」這些怪獸晶片了。

Vera Rubin 革命：為什麼「不要冰箱」，卻更需要「水管」？

讓我們回到**CES**大會上，黃仁勳說到：「我們用 **45°C** 的溫水來冷卻。」

這聽起來很反直覺：**45°C** 的水不是溫的嗎？怎麼冷卻晶片？

事實上，只要晶片表面是 **80°C-90°C**，**45°C** 的水對它來說依然是「涼爽」的，足以帶走熱量。

那麼，既然我們只需要 **45°C** 的水，那我們根本不需要那台耗電的「巨型冰箱（冷水機組）」來製造 **15°C** 的冷水了。

我們只需要把 **45°C** 的熱水排到室外，利用室外空氣（假設是 **30°C**）進行自然熱交換，水溫自然就會降下來。

這就是為什麼 **NVIDIA** 的改變依然需要「液冷技術」：雖然我們不需要「冷水機組（Chiller）」來製造人工冷能，但我們比以前更依賴「液冷循環系統」。

1. 更精密的 **CDU (液冷分配單元)**：既然沒有了冷水機，系統需要更聰明的泵浦和控制閥，來精確控制這 **45°C** 的溫水流量。
2. 更龐大的歧管 (**Manifolds**)：每一台伺服器、每一個晶片都要接水管。這就像是從「中央空調」變成了「全屋地暖+水管系統」。
3. 更高效的熱交換器：雖然不用冰箱，但我們需要巨大的「乾冷器」在室外散熱。

散熱的需求不但沒有消失，反而因為晶片功耗暴增（**Rubin**平台單顆晶片功耗高達**2300W**），散熱問題變得比以往任何時候都更加棘手。

消失的，只是那台笨重、耗電的「車庫大冷氣」而已。

這場變革，清晰地劃分出了兩個陣營：未來的贏家與輸家。

傳統冰水主機（Chiller）巨頭的情況

傳統 HVAC（暖通空調）巨頭，他們的核心業務之一就是製造那些大型的冰水主機。他們就像是世界上最會造「車庫大冷氣」的專家。

當 NVIDIA 這位最重要的客戶直接宣布「我的新設計不再需要你的產品」時，市場的恐慌是完全可以理解的。

他們必須立刻、馬上轉向液冷解決方案，否則在 AI 資料中心這個增長最快的市場裡，他們將被徹底邊緣化。

液冷生態系的玩家

Vertiv 的前身是艾默生網絡能源（**Emerson Network Power**），它不只做散熱。它的業務核心是「數據中心基礎設施」，主要分為兩大塊：

- **電源管理 (Power)**：包含 **UPS**（不斷電系統）、配電櫃、開關櫃。這部分佔了它營收的很大一部分。
- **熱管理 (Thermal)**：包含傳統的精密空調、大型冷水機組，以及現在最火的液冷系統。

Vertiv 旗下一直有液冷產品線（如 **Liebert** 品牌），但過去 20 年，數據中心 **95%** 都是用風冷，所以液冷只是它的一個「小眾實驗室產品」。

雖然 NVIDIA 說「不需要冷水機組（Chillers）」，看似砍掉了 Vertiv 的一部分傳統生意，但實際上，液冷系統的「含金量」比傳統空調高得多。

傳統冷水機組像是一台巨大的工業設備，競爭者眾多，利潤透明。但 **NVIDIA** 要求的液冷系統，是一套「零容忍」的精密工程，這需要如 **Vertiv** 這種專家。

轉型不會一夜發生

儘管黃仁勳的願景很宏大，但投資者需要注意幾個現實邊界：

1. 氣候限制：在亞利桑那州或中東沙漠，**45°C** 的溫水冷卻在夏天依然面臨嚴峻挑戰，機械製冷（**Chiller**）可能還是得作為備援。
2. 存量市場：全球現有的數據中心不可能拆掉重建，混合架構（**Blackwell + Rubin**）會持續很長一段時間。
3. 功耗悖論：雖然 **Rubin** 效率更高，但單顆晶片功耗已達 **2,300W**。這意味著熱密度變高了，散熱的「總預算」其實是在增加的，只是花錢的地方變了。

「協同設計」（Co-design）時代的來臨

過去，資料中心的建構是分工的：**NVIDIA** 賣晶片，**戴爾/惠普** 賣伺服器，**Vertiv** 賣散熱，大家各自為政。

但現在，**NVIDIA** 不再只賣晶片，它賣的是一整套高度整合的「系統」。從晶片、電源、網路到散熱，所有環節都在設計之初就被通盤考慮、緊密耦合。

在「協同設計」的情況下，**NVIDIA** 能夠在其晶片加入了極其精密的「微通道冷板」。這些冷板內部蝕刻了無數微米級的流道，讓冷卻液直接流經晶片封裝的最深處。

這就是這場革命的物理學本質：不是因為 **45°C** 的水本身有多「冷」，而是因為我們把從晶片到水之間的「熱量通道」建得無比寬闊通暢。

散熱不再是事後的補救措施，而是整個架構設計的核心一環。這意味著，散熱公司未來無法再像過去一樣，單純地銷售標準化產品。他們必須成為 **NVIDIA** 生態系中的合作夥伴，能夠參與到前期共同設計中。

誰能與NVIDIA緊密合作，誰就能掌握未來的訂單。


一句話，劃開了新舊時代

所以，讓我們回到最初的問題。黃仁勳的那句話，並不是給散熱行業判了死刑。他其實是劃出了一條線，線的一邊是過去，另一邊是未來。

他用最直白的方式告訴市場：依賴舊有技術、無法適應系統級整合的公司將被淘汰；而那些早已佈局液冷、並能融入新生態系的玩家，將迎來前所未有的增長。

散熱的預算依然存在，只是從購買「冰水主機」，轉移到了購買更精密、更高效的「直接液冷系統」。

主題七：AMD打算如何追趕Nvidia？



OpenAI 站台、李飛飛押注、Blue Origin 登月，AMD 在CES 2026 秀出最強AI 算力| TechNews 科技新報

當 NVIDIA 宣佈了排山倒海的新技術後，我們下一個問題很自然地就會是：**AMD** 還能追上嗎？

在這次 **CES** 大會中，蘇姿丰（**Lisa Su**）用她的演講給出了答案。

雖然 AMD 的口號依然是溫暖的「**AI 無處不在**」（**AI Everywhere, for Everyone**），試圖展示從雲端到邊緣的完整版圖，但明眼人都看得出來，整場演講的靈魂、時間分配與舞台焦點，全都留給了那個最核心的戰場：數據中心。

數據中心的全棧式進攻

AMD 這次發佈了**Helios AI**機櫃，要理解其重要性，必須先明白它與過去的區別。

這並非**AMD**首次推出機櫃，但**Helios**是其第一個從零開始、為**AI**而生、完全整合的「機櫃級平台」。

在**Helios**之前，AMD的**MI300/MI350**機櫃，更像是將一堆高效能的樂高積木（GPU）堆疊在一個標準化的架子上。它們採用了行業標準的「通用基板」（**UBB**），追求的是模組化的彈性，而非極致的整合效能。

其內部互連技術XGMI在超過8個GPU後擴展性不佳，使得整個機櫃更像是「128個獨立GPU節點的集合體」，而非一個統一的超級電腦。

這一切轉變的催化劑，是AMD在2025年3月的一項關鍵收購：**ZT Systems**。

這次收購為AMD帶來了超過1000名頂尖的數據中心系統工程師。這次收購讓AMD完成了從「零件組裝廠」到「整體架構設計師」的蛻變，賦予了他們從頭打造一個整合平台的能力。

在此之前，AMD在面對NVIDIA的NVL72/NVL144等真正一體化的機櫃級系統時，並沒有對等的武器。**Helios**的出現，意味著AMD終於能夠在「架構整合」的維度上與NVIDIA正面對決，而不僅僅是在單顆GPU的規格上追逐。

真相：Helios使用的並非「完全體」的UALink

聽起來 AMD 已經具備與 NVIDIA 一戰的實力了，對嗎？我們得看看細節。

在 **Helios** 中，雖然 GPU 透過全新的 **UALink** 架構互連，號稱能像單一引擎般協同工作。但深入探究會發現，AMD 目前採用的是 **UALink Over Ethernet (UALoE)**。簡單來說，這是一個「過渡版本」，底層跑的依然是乙太網路。

AMD之所以這麼做，只有一個原因：時機。

真正能與**NVLink**在物理層面抗衡的「原生**UALink**」交換機晶片，需要由**Marvell**和**Astera Labs**等合作夥伴提供，但它們要到2026年底甚至2027年才能準備就緒。

相比之下，**NVIDIA** 擁有自家的 **NVSwitch** 和原生 **NVLink** 的 **Co-design** 優勢。這導致 **Helios** 在延遲與集體運算效率上，短期內依然無法完全等同於 **NVIDIA** 的頂級表現。

戰略定位：一個「足夠好」的第二選擇

這個技術妥協，清晰地定義了**Helios**的市場定位。它並非旨在全面擊敗**NVIDIA**，而是要成為一個極具競爭力的「第二選擇」。

當 **OpenAI** 總裁 **Greg Brockman** 親自登台與蘇姿丰並肩而立時，信號已經很明確了：**AMD** 已經是頂級 **AI** 巨頭認可的、可信賴的基礎設施供應商。

- 對於訓練（**Training**）市場：這是 **NVIDIA** 的利潤堡壘。對於追求極致效率、分秒必爭的頂級實驗室，**NVLink** 系統仍是首選。
- 對於推論（**Inference**）市場：這才是 **AMD** 的主戰場。當模型訓練完成進入大規模部署，市場對延遲的容忍度會提高，但對成本、供應鏈多樣性、記憶體頻寬的需求會激增。

Helios 在這裡表現得「足夠好」，加上開放標準帶來的靈活性，使其成為 **Oracle**、**Azure** 等雲端巨頭構建推論基礎設施時，最能制衡 **NVIDIA** 的利器。它讓客戶擁有在 **NVIDIA** 之外的真正選擇權，從而打破壟斷，這本身就是重要的。

開闢新局：專業與邊緣AI的側翼騷擾

如果數據中心是正面戰場，那麼「實體 **AI**」（**Physical AI**）就是 **AMD** 開闢的側翼陣地。**AMD** 推出的 **Ryzen AI Embedded P100/X100** 系列，直接瞄準汽車、工業自動化與機器人。這些產品具備寬溫工作能力（-40°C 至 +105°C）與 **ASIL-B** 汽車安全認證。

Blue Origin 亦宣佈，其月球著陸器將搭載 **AMD** 晶片，證明了 **AMD** 在邊緣 **AI** 受到一定的認可。

在這些需要極高穩定性與特殊環境適應力的領域，**NVIDIA** 尚未建立絕對的統治力，這給了 **AMD** 極大的發揮空間。

從「獨角戲」轉向「雙雄爭霸」

黃仁勳讓全球看到了 **AI** 的「天花板」，而蘇姿丰則正在鋪設 **AI** 的「地板」。

AMD 在 **CES 2026** 展示的不再是挑戰者的姿態，而是一個成熟供應商的形象。這場變革對產業是健康的：當市場不再只有一種聲音，創新的成本才會下降，**AI** 的應用才會真正爆發。

這塊蛋糕增長得夠快，每個人都能分一杯羹。

主題八：當算力戰爭打到發電廠，xAI的「能源獨立」大計

Elon Musk confirms xAI's purchase of five 380 MW natural gas turbines

The deal, which was confirmed by Musk on X, highlights xAI's effort to aggressively scale its operations.



Published 16 hours ago on January 7, 2026

By Simon Alvarez X



Credit: xAI/X

好了，終於到最後一個主題，也是唯一一個不是CES中的主題。

電力是AI下一個瓶頸，相信大家已經有一定的了解，每家巨頭現在都正在努力尋找充足的電力供應。

在最近，**xAI**斥資數十億美元，繞過傳統電網，直接採購近**2 GW**（吉瓦）的天然氣渦輪發電機組，在**孟菲斯（Memphis）**等地自建燃氣發電廠。

不過，這一次的主角，卻不是我們熟悉的**GE**，**西門子**等等，而是一家叫**斗山**的韓國公司。

不是因為「更好」，而是因為「能買到」

這次採購名單中的主角**斗山 DGT6-300H.S2**，是韓國首款自主研發並出口美國的**H級燃氣輪機**。這是一個極具象徵意義的時刻。

過去這個領域被**GE**、**西門子**、**三菱**等老牌巨頭壟斷，但**斗山**用**11年**的時間走完了別人幾十年的路。這台機器的技術指標令人驚嘆：它能在**12分鐘**內快速啟動，每分鐘增加**55 MW**的出力。

斗山的渦輪機在效率上與**GE**的旗艦型號相差無幾。**GE**在空氣動力學設計上或許更激進，但**斗山**也有**PCHE**（印刷電路板式熱交換器）等巧妙的創新，特別適合空間有限的資料中心部署。

但重點是，**GE**和**西門子**手握**3-5年**的訂單，產能早已排到**2029年**之後。它們是典型的「賣方市場」，根本無法滿足**xAI**對速度的渴求。

而**斗山**，作為一個急於打入國際市場的後起之秀，產能相對充裕，能夠承諾在**2026年底**就交付。

於是，**Elon Musk**選擇了那個能立即到貨的「優良」武器，而不是那個需要等待兩年的「完美」武器。

Megapack，非賣品級的必需品

如果說渦輪機是心臟，那麼**特斯拉**的**Megapack**儲能系統絕非「配件」，而是維持心跳穩定的「心臟節律器」，是整個架構中不可或缺的一環。

原因在於**AI訓練負載**的獨特物理特性：

- **極端波動**：**AI**叢集在運算和通訊狀態間切換時，功耗會在毫秒內從基線暴增或暴跌**±90%**。

- **高頻振盪**：這種波動頻率高達**30赫茲**（每秒30次）。

想像一下，讓一台精密的噴射引擎每秒鐘在「怠速」和「全速」之間切換**30次**。其結果必然是災難性的機械損傷。對於燃氣渦輪機也是如此，這種高頻振盪會引發葉片共振、壓縮機喘振，使其預期壽命從**40,000小時**驟降至不到**15,000小時**。

Megapack的作用就是一個巨大的「電力減震器」。它以毫秒級的速度吸收和釋放能量，將這種毀滅性的高頻「噪音」過濾掉，只把平滑、緩慢變化的負載曲線傳遞給渦輪機。這讓渦輪機可以始終運行在最高效、最穩定的「舒適區」。

甚至，它能部份取代傳統資料中心昂貴的柴油備用發電機，節省了數億美元的資本支出和燃料費用。

在閒置時，**Megapack**還可以參與電網的頻率調節服務，產生額外收入。

它解決了一個物理學上的根本難題，讓大規模 **AI 訓練**與傳統發電設施的結合成為可能。

實戰驗證

市場上不乏電池供應商，但**Megapack**的核心競爭力在於軟體。

硬體是商品，但控制演算法是技術壁壘。特斯拉的**VSM**（虛擬同步機）軟體能讓電池模組在數學上模擬巨大旋轉渦輪的慣性，其頻率響應時間小於**50毫秒**，比競爭對手快數倍。

這種「預測性負載建模」能預判**GPU**訓練的脈衝模式，提前調整充放電，讓系統所需的電池容量減少**15-25%**，直接節省上億美元的資本支出。

這套「渦輪 + **Megapack**」的混合架構並非實驗室產物，而是已經在全球範圍內大規模運作：

- **xAI 孟菲斯集群**：已部署**156-168台 Megapack**，總容量超過**1.2 GWh**，正活躍地平滑**GPU**訓練產生的波動。
- **Tesla Cortex 集群**：在德州部署了**500 MWh**的**Megapack**，支撐**10萬片 H100**的電力運作。
- **Google Oberon 項目**：同樣部署了**1 GWh**的儲能系統來繞過電網瓶頸。

當「電力」成為新的護城河

當Google收購Intersect Power，SoftBank不惜一切都要將DigitalBridge收入囊中，GE Vernova的訂單排到2028年，大家就明白，如何確保自家的電力，是現時巨頭們最煩惱的事情了。

能源獨立，將會是2026年基礎設施最重要的一環。

謝謝你閱讀到這裡，如果你覺得這份筆記為你帶來了價值，請不吝按下一個讚，這是我持續分享的最大動力。

另外我在Telegram有頻道，每天早上我會發當天重要新聞摘要。

同時，如果想開戶的話，可以考慮用我的富途/口袋證券獨家推薦碼，會有更多優惠。

全部資訊在以下鏈結：

https://linktr.ee/fomo_soc

另外，如果你已經加入付費會員，不要浪費了群組的功能，進入我們Substack的Chat功能一起討論市場!

- KP

本機離線版本 • 圖片與內文完整

← 回索引

在原始站開啟 ↗