

← 索引  公開 2026-06-06 1417 字 ↗ 原站

今年要加息了？記憶體需求減半？AI PC時代到來？ - KP思考筆記(第45期)

本文目錄

- 1 主題一：當 Windows 遇上 CUDA，AI PC 如何權力重組？
- 2 主題二：當 AI 走向「代理人」時代，Intel 如何用 CPU 奪回系統調度權？
- 3 主題三：從回購王變成融資王，Google 為什麼突然募資 850 億美元？
- 4 主題四：拒絕賺快錢，從 Build 2026 看微軟的策略
- 5 主題五：Nvidia 對記憶體需求減半？
 - 6 微軟與 NVIDIA 的共生博弈
 - 7 CUDA 的生態滲透
 - 8 協同設計時代的開端
 - 9 128GB 統一記憶體的現實與未來
 - 10 營收的「雜音」，生態的「強音」
 - 11 「編排層」的論述
 - 12 Perplexity 的動態調度學
 - 13 Intel 與 SambaNova 的「解耦式推理」
 - 14 18A 節點落地與 x86 的防禦反擊
 - 15 紙上談兵終覺淺，市場數據定乾坤
 - 16 為什麼我們無法在 Computex 得到答案？
 - 17 接下來該看什麼？
 - 18 標題黨的盲點：那筆被誤解的「300 億員工稅金」
 - 19 公開市場的速度優勢

- 20 股神的背書
- 21 逼迫所有人提前攤牌的「軍備競賽」
- 22 我們正處於物理基建的「重工業時代」
- 23 拒絕「嫉妒型創新」：微軟不做下一個 Zune
- 24 企業的終極護城河：專屬的「爬山機」
- 25 這解釋了 Build 2026 發表的一切
- 26 從「重壓合作」到「建立選擇權」：微軟與 OpenAI 的關係演變
- 27 商業模式的轉變：當人頭計費失效
- 28 仍要時間觀察
- 29 不當完美主義者，先通車再說
- 30 記憶體階層的演進
- 31 對記憶體產業的實際影響
- 32 標題之外
- 33 商周專欄解禁版(付費會員專享)



大家好，我是 **KP**，歡迎來到第 45 期的《週末思考筆記》。

星期五，市場風雲突變，基本上呈現了全線下挫的態勢。這種下跌是典型的「**Beta** 式下跌」，高 **Beta** 的標的跌幅深一些，低 **Beta** 的則相對抗跌。

這種「無差別下跌」顯然是由宏觀因素驅動的。由於非農就業數據異常強勁，市場情緒迅速轉向，開始對年底可能發生的「加息」進行定價。

提到**加息**，最近期的肯定是慘烈的 2022 年。

但我們要明白，2022 年之所以是災難性的，是因為**加息**的幅度與持續時間都超出了預期。

這裡我們需要做一個邏輯拆解：

如果你判斷這將是另一場漫長且劇烈的**加息**週期，那麼 2022 年的教訓就是最好的教科書。

但如果你認為這可能只是一次性的微調，甚至根本不會發生，那麼下一個問題就是：

你覺得市場會怎麼想？而你打算如何反應？

在市場處於超買區間這麼長一段時間後，任何風吹草動都可能引發劇烈的短期回撤，很多資金都在尋找一個合理原因獲利了結。如果要我猜的話，進一步下探尋找支撐的機會確實不小。

這時候，投資者最常面臨的抉擇就是：到底要不要「擇時（Timing the market）」？還是選擇「硬扛」？

「擇時」聽起來很美好，如果你精準逃頂，確實能避開跌幅。但現實是，「何時重新進場」往往比「何時離場」更難。

如果你判斷錯誤，市場只是經歷了一個極短暫的小回撤就迅速 V 轉，你很可能會陷入更痛苦的 **FOMO**（恐懼錯過）情緒中，最終被迫在高位追回來。

事實上，**波動（Volatility）**是每一位權益投資者必須支付的「入場券」。

這是投資股票的本質，你不可能在拒絕接受 10% 甚至更多回撤的同時，卻期待獲得 50% 甚至 100% 的回報。

如果你持倉相對集中，那麼過去兩個月你應該斬獲頗豐，目前的回調不過是將部分利潤「還給」市場。這很正常，無需恐慌，關鍵是決定下一步怎麼走。

關於下一步，你必須先釐清自己的「投資身分」：你是一個交易者（**Trader**），還是一個投資者（**Investor**）？

如果你是交易者，你的核心是趨勢、動能與止損。當宏觀邏輯改變、技術面破位時，嚴格執行紀律、保護本金是你的首要任務。

但如果你定義自己為投資者，那麼現在正是你進行「深度體檢」的最佳時機。你必須認真重新審視你的部位：

- **集中度**：你的心臟是否能承受目前集中度帶來的淨值波動？
- **信念感**：你對這家公司的信心，是來自於它上漲的股價，還是來自於你對它業務競爭力的理解？
- **估值與安全邊際**：在利率可能更高、環境更嚴峻的假設下，現在的股價是否依然具備吸引力？
- **因果邏輯**：你是否真的清楚它過去為什麼漲，現在又為什麼跌？

對於我自己的部位，我暫時的選擇是硬扛，但收縮戰線，將資金從「衛星標的」撤出，轉而加碼到「高信念」的核心標的上。（這不是投資建議，之後可能也會根據情況調整哈哈）

之所以有底氣留在場內，是因為我的核心持倉大多擁有足夠的獲利緩衝，且我確保手中沒有槓桿，而我對每一個持倉都十分清楚背後投資邏輯。

在動盪時期，留在場內（Stay in the market）是為了不遺漏長期的複利，但留在哪些標的裡，決定了你是否能睡得好覺。

只要你的公司基本面依然強勁，且你的財務結構是健康的，那麼短期的股價回撤不過是帳面上的數字跳動。

當然，那些預言家又紛紛現身了。你會聽到很多聲音說：「看吧，我就說會跌。」

但事實是，即便經歷了這波回撤，許多股票的價格也只是回到了大約兩三週前的水準。除非你能在過去幾天精準地預測到頂部並全身而退，否則這些「事後諸葛」式的預言，對於真正的財富增長並沒有實質幫助。

投資是一場關於「勝率」與「賠率」的遊戲，更是一場關於「心理韌性」的考驗。

FOMO研究院的Substack Chat每天有很多高質的交流，在不確定的時刻，尤其歡迎大家一起來參與討論。

在宏觀不確定的情況下，倒不如繼續花時間思考基本面。這個星期的思考筆記將會有5個主題，包括：

- 主題一：當 **Windows** 遇上 **CUDA**，**AI PC** 如何權力重組？
- 主題二：當 **AI** 走向「代理人」時代，Intel 如何用 **CPU** 奪回系統調度權？
- 主題三：從回購王變成融資王，**Google** 為什麼突然募資 **850** 億美元？
- 主題四：拒絕賺快錢，從 **Build 2026** 看微軟的策略
- 主題五：**Nvidia** 對記憶體需求減半？

不妨考慮先讚後看，我們立刻進入主題！

主題一：當 **Windows** 遇上 **CUDA**，**AI PC** 如何權力重組？



Nvidia launches PC chip to bring AI directly to personal computers | MarketScreener

黃仁勳在 Computex 台北正式揭曉了 RTX Spark 平台（搭載 N1/N1X 晶片）。Dell、Lenovo、ASUS、MSI、HP，甚至傳聞中的 Surface 都會在今年秋天到 2027 年初推出搭載這顆晶片的筆電。

大家可能會想，發佈看起來很強，但這對 NVIDIA 未來幾季財報有什麼貢獻？

答案是：幾乎沒有。

N1/N1X 的筆電要到今年秋天才會上市，初期出貨量小、定價高、目標客群窄。如果你期待這顆晶片在 2026 或 2027 年的財報上看到爆炸性的收入貢獻，你會失望的。

但這個發佈真正的意義，是 PC 產業的「時代分水嶺」可能正在發生。

微軟與 NVIDIA 的共生博弈

在過去，PC 產業的規則非常簡單。微軟定義作業系統，Intel 與 AMD 提供晶片，NVIDIA 則是強大的配件。但進入 AI 時代，這個行之有年的邊界開始模糊。

微軟執行長 Satya Nadella 公開宣示要把無限制的智慧帶到每個家庭與每張桌面，黃仁勳則強調雙方深度的技術整合。兩家公司聯合喊出「PC 的新時代」，從 Prism 模擬器的優化、異質架構的調度，到專為 **AI Agent** 設計的全新 Windows 安全機制，微軟正在為 NVIDIA 的硬體量身雕琢作業系統。

這是一場雙方在戰略上高度互補、彼此需要的雙向奔赴。

微軟非常需要 NVIDIA。微軟對未來 PC 的終極願景是 **Agentic AI**，讓每台電腦都能在本地球端流暢運行自主的 AI 代理。

高通的 Snapdragon X 雖然證明了 **Windows on Arm** 的可行性與省電優勢，但在面對真正吃重、需要極高算力與記憶體頻寬的本地端大模型時，高通的 GPU 與生態依然顯得力不從心。

為了對抗 **Apple Silicon** 的強勢威脅，微軟急需一個在硬體與軟體生態上都能一拳定音的盟友。

與此同時，Apple 已經用 M 系列晶片搭配統一記憶體與 macOS，建立了一個讓微軟羨慕的整合典範。蘋果用戶在自己的 MacBook 上跑大型語言模型已是日常，微軟如果不能在 Windows 陣營端出對應的方案，它在 AI PC 這個品類的話語權將會被結構性侵蝕。

反過來，NVIDIA 同樣深切地需要微軟。

如果 NVIDIA 不跟微軟合作，它在消費端幾乎沒有其他具備規模的舞台。macOS 是蘋果的禁地，不允許第三方晶片；Linux 雖然技術上可行，但消費端桌面市佔常年低於百分之五，若只在 Linux 上推 NIX，這顆晶片只會變成資料科學家的小眾玩具；至於 ChromeOS 與 Android，則完全不適合 NVIDIA 鎖定的高階 AI、創作與遊戲市場。

NVIDIA 想把 **CUDA** 從資料中心延伸到客戶端，**Windows** 是唯一能提供足夠規模的舞台。沒有微軟的配合，這顆晶片在大眾市場將失去影響力。

CUDA 的生態滲透

在這場看似雙贏的合作背後，產業的權力天平有可能會被悄悄重組。

微軟依然是作業系統的所有者，定義著安全模型、API 與開發者規則。但是，當 **CUDA** 成為 **Windows on Arm** 上 AI 工作負載的事實標準時，未來幾年 Windows 上的 AI 創新，將會越來越深地綁定在 NVIDIA 的軟體棧上。

當所有的 AI 開發者都在 CUDA 上寫程式，所有的 AI 應用都在 **TensorRT** 上做推論優化，所有的開源模型都優先支援 NVIDIA GPU 時，微軟未來的轉換成本就會變得極高。

如果 **Agentic AI** 真的變成 PC 的主要互動介面，用戶不再頻繁點開個別軟體，變成了與一個 AI Agent 對話，那麼傳統作業系統體驗的能見度有可能會下降。

作業系統可能會變成 AI Agent 的底層基礎設施，而不再是用戶感知的主體。在這個情境下，作業系統是什麼牌子變得不再那麼關鍵，跑在上面的 AI Agent 用的是誰的算力與模型反而變得更重要。

這就是 NVIDIA 真正在玩的長線遊戲。

它不是要取代 Windows，是要在 Windows 之上，建立一個由 CUDA 定義的 AI 計算層。

微軟依然是房東，但 **NVIDIA** 變成了所有租客都必須打交道的水電公司。

雖然 AMD 的 Strix Halo 已在 unified memory 與 iGPU 性能上展現實力，但其軟體生態與開發者習慣仍與 NVIDIA 有明顯差距。

這與 NVIDIA 在資料中心的策略本質上是一樣的，它從不取代雲端業者，但所有雲端業者要做 AI 都繞不開它。現在，它想在 PC 端複製這個模式。

協同設計時代的開端

傳統的 PC 模式是鬆散模組化的。Intel 與 AMD 做 CPU，NVIDIA 做 GPU，微軟做作業系統，大家相對獨立地演化，靠標準介面拼湊起來。這個模式在 PC 的成熟期非常有效率，任何一塊都可以被單獨替換與升級。

但這個模式在 AI 時代正在失效。

AI 工作負載對整個系統協同運作的要求遠高於傳統工作。記憶體頻寬、延遲與容量必須跟 GPU 算力匹配；作業系統排程器要懂得怎麼分配 AI 工作給 CPU、GPU 與 NPU；安全模型要重新設計，因為 Agent 是會自主執行的；電源管理也要懂得 AI 工作負載的爆發特性。

這些事情都需要硬體、作業系統與軟體棧一起設計才能做好。鬆散模組化的結果，往往是每個元件單獨看都不錯，加起來體驗卻不盡人意。

蘋果靠垂直整合解決這個問題已經做了許多年。Windows 陣營過去一直無法走這條路，因為微軟必須照顧多個硬體夥伴。

但現在 NVIDIA、微軟與聯發科的組合，提供了一個有趣的折衷方案。

接下來幾年，我們應該會看到 Qualcomm 與微軟、AMD 與微軟、Intel 與微軟也會出現類似深度的協同設計關係，每個組合針對不同的市場區隔。鬆散模組化的時代不會完全結束，但高階 AI PC 這個品類，會明顯地走向更緊密的協同設計。

鬆散模組化的時代不會完全結束，但高階 AI PC 這個品類，會明顯地走向更緊密的協同設計。

這對整個 PC 供應鏈的意義很深遠。過去 OEM 廠商只要會組裝就能賣機器，未來能不能提供真正好的 AI PC 體驗，會越來越取決於它跟晶片商、作業系統商的整合深度。有能力做深度客製化的廠商會受益，純組裝廠的價值則會被進一步壓縮。

128GB 統一記憶體的現實與未來

除了軟體生態的角力，RTX Spark 採用的統一記憶體架構也是一項結構性變革，最高支援達 128GB 的 LPDDR5X。

這在技術上是一次巨大的飛躍，但也伴隨著極高的物理挑戰。為了讓 CPU、GPU 與 NPU 共享超高頻寬與極低延遲，記憶體顆粒必須極度靠近 SoC。

這意味著傳統插槽式記憶體在高端 AI PC 上將不復存在，取而代之的是極其複雜的封裝技術。當容量拉高到 64GB 甚至 128GB 時，散熱、訊號完整性與良率控制的難度呈指數級上升。

這無疑為高階、高密度的 LPDDR5X 乃至未來的 LPDDR6 市場注入了強心針。對於在先進封裝與高密度記憶體領先的廠商如三星與 SK 海力士而言，這是一個長期的結構性藍海。

但我們必須保持理性，這不會在一夜之間改變記憶體市場的供需與價格。

在 2026 到 2027 年的初期階段，搭載 128GB 統一記憶體的旗艦級 AI 筆電，售價極可能突破兩千美元。這注定是一個屬於極客、專業開發者與創作者的小眾高階市場，出貨量在短期內難以與主流 PC 相比。

因此，當前的記憶體價格循環依然由資料中心的 HBM 需求主導。**RTX Spark** 對記憶體產業的實質營收貢獻，更像是一顆埋在 2027、2028 年之後的種子，當這種架構逐漸下放到主流價位帶時，才會迎來真正的爆發。

營收的「雜音」，生態的「強音」

退一步從商業現實來看，我們必須理解一個事實：在當前的 AI 狂潮中，消費級 PC 的市場規模，在 NVIDIA 龐大的資料中心版圖面前，不過是滄海一粟。

今天推動 NVIDIA 股價與千億美元營收的，是資料中心裡成千上萬顆、單價數萬美元的 Hopper 與 Blackwell 晶片。

相比之下，筆電晶片的客單價與利潤率根本不在同一個量級。這也是為什麼，**RTX Spark** 平台在短期內絕對無法成為左右 NVIDIA 財報的關鍵因子。

那麼，我們為什麼還要高度關注這件事？

因為這是一場關於「防禦」與「延伸」的長線佈局。

資料中心的算力是「集中式」的，它解決的是大模型的訓練與雲端大規模推論；但 AI 的終極形態，必然會走向「分佈式」的邊緣端（Edge）。

如果 NVIDIA 只守在雲端，那麼當未來的 AI 應用逐漸向終端轉移、當輕量化模型（SLM）在個人裝置上就能流暢運行時，NVIDIA 就有可能失去對終端生態的控制權。

PC是Nvidia將 **CUDA** 生態系「實體化」到每個人桌面上的特洛伊木馬。

這是一個需要慢火細熬、甚至需要數年時間去觀察的指標。我們不該用「這季賣了幾顆晶片」來衡量 **RTX Spark** 的成功，我們要觀察的是：

- 開發者是否開始習慣在 **Windows** 筆電上，直接調用本地端的 **TensorRT** 進行日常開發？
- 微軟的 **Copilot** 與各類 **AI Agent**，是否在搭載 **NVIDIA** 晶片的系統上運行得最為流暢？
- 這種「軟硬一體」的體驗，是否逐漸拉開與傳統 **x86** 筆電的差距，進而重塑消費者的購買決策？

NVIDIA 與微軟在 **PC** 上的聯手，更像是在為五年、甚至十年後的運算生態買一張「保險票」。

它現在不負責賺大錢，但它負責確保在未來的某一天，當雲端算力向終端分流時，**NVIDIA** 依然是那個唯一的遊戲規則制定者。

主題二：當 **AI** 走向「代理人」時代，**Intel** 如何用 **CPU** 奪回系統調度權？



Intel CEO unveils AI innovations and partnerships at COMPUTEX 2026 - The HinduBusinessLine

在 **Computex 2026**，**NVIDIA** 的 **RTX Spark** 搶走了大部分頭條。

但**Intel** 想告訴市場的是：隨著 AI 從簡單的「單次問答（Single-turn Q&A）」進化到複雜的「多代理人協作（**Agentic AI**）」，**CPU** 正在重新奪回系統的核心主導權。

這不僅僅是關於 **18A** 先進製程量產、設計定案（Tape-out）超過 300 個、或是 **Xeon 6+**（Clearwater Forest）與新一代 **Core Ultra** 的硬體發表；這是一場關於 AI 系統架構的重新定義。

「編排層」的論述

過去幾年，在 GPU 主導的生成式 AI 時代，**CPU** 常常被邊緣化為一個「即插即用（Plug-and-Play）」的通用組件，彷彿只要負責把數據「餵」給 GPU，它的任務就完成了。

但 **Intel** 正在打破這個膚淺的定位。

傳統的聊天機器人，其瓶頸在於高密度的矩陣運算，這確實是 GPU 的天下。然而，當企業開始部署 **Agentic AI**（代理人系統）時，運算邏輯發生了根本性的轉變。

一個能夠自主完成複雜任務的 **AI Agent**，必須經歷「目標拆解 → 制定計畫 → 呼叫外部工具與 API → 跨系統擷取上下文 → 在多次互動中維持狀態 → 處理錯誤恢復與分支邏輯」的繁複過程。

這些任務本質上並非矩陣乘法，其高度依賴分支邏輯判斷、記憶體管理、狀態維護與任務調度。

在一個 **agentic** 系統裡，你需要一個「大腦」來協調 GPU、記憶體、網路和分散式推論之間的工作。這個大腦最適合由 **CPU** 來扮演。特別是 **Xeon**。

Perplexity 的動態調度學

為了讓這個論述更具體，Intel 把 **Perplexity** 的 CEO **Aravind Srinivas** 請上台做了一個現場示範。

Perplexity 展示了其「**Perplexity Computer**」作業系統，在處理敏感的企業槓桿收購（LBO）財務模型時，系統如何進行動態調度：

1. 本地處理（隱私與速度）：敏感的財務數據與初步分析，直接在搭載 **Intel Core Ultra 3** 的本地裝置上運行，確保數據不出關。它自動標記出哪些內容是敏感的、需要保持隱私，然後把這些保留在設備上。
2. 雲端協同（深度推理）：當遇到需要極大參數模型進行深度邏輯推理的步驟時，調度器會自動將去隱私化的任務發送至雲端。

這種「端雲協同」的架構，打破了過去「全面上雲」或「純端側運行」的極端二分法。**Intel** 的晶片（端側的 **Core Ultra** 與伺服器端的 **Xeon**）正是為了這種動態路由設計的。這不僅大幅降低了企業調用昂貴雲端 GPU 的成本，更在物理層面解決了數據合規與隱私的痛點。

Intel 與 SambaNova 的「解耦式推理」

如果說 **Perplexity** 展示的是端與雲的協同，那麼 **Intel** 與 **SambaNova** 的深度合作，則是對資料中心異質運算（**Heterogeneous Computing**）的實踐。

在雙方展示的「**Vector Core Compute**」企業推理雲與機櫃級（**Rack-scale**）系統中，**Xeon** 處理器展現了其獨特價值。這套系統呈現了高度的解耦（**Disaggregated**）特徵：

- **Xeon 6+ (18A)** 擔任主機與調度大腦，負責工作負載調度、加速器之間的數據移動、網路與記憶體協調，以及全局系統編排。
- **SambaNova SN-50 RDU** 負責推理中高頻率的「解碼（**Decode**）」階段。
- 甚至在部分環節中，還能協同 **NVIDIA Blackwell GPU** 處理「預填充（**Prefill**）」階段。

Intel 不再強求客戶在每一個環節都使用 **Intel** 的晶片。相反地，他們承認異質運算（混合使用不同晶片）才是未來的常態。

Intel 的戰略是：「不論你用誰的加速器（**SambaNova** 或是 **NVIDIA**），你都需要一個最優秀的協調者來把這些硬體完美縫合在一起。而 **Xeon** 就是那個最完美的黏著劑。」

18A 節點落地與 x86 的防禦反擊

Intel 表示，現在有多個產品（客戶端的 **Core Ultra Series 3** 和伺服器端的 **Xeon 6+**）正在 **18A** 上出貨或 ramp up。設計定案數超過 300 個。良率在改善中。

如果 **18A** 真的如他們所說的那樣成功，這對整個「編排層」敘事是很大的加分。因為這意味著 **Intel** 可以在自己的先進製程上製造高效能、低功耗的 **CPU**，而不是依賴外部代工。

但這也是一個大「如果」。市場見過太多 **Intel** 的 roadmap 在執行中出問題。現在的態度基本上是「先看到持續交付再說」。

同時，面對 **NVIDIA** 積極推動 **Arm** 架構（如 **Grace** 處理器）進入資料中心與客戶端，**Intel** 選擇用 **x86** 的生態積澱進行回擊。

他們的定位是，數十年來優化的企業級程式碼、編譯器與安全協議，在 **x86** 架構上運作最為穩定。在導入 **AI Agent** 時，它必須與企業既有的資料庫、ERP、安全性協議深度整合。這正是 **Intel Xeon** 展現「系統指揮官」價值的舞台。

紙上談兵終覺淺，市場數據定乾坤

Computex 2026 雖然為我們描繪了兩種截然不同的未來藍圖，但它並無法為「**x86** 與 **Arm** 誰才是 AI 時代的終極解答」給出標準答案。

- **NVIDIA** 的 **Arm** 路線：試圖證明透過高度整合的 **Arm CPU** 與 **GPU**，能打破傳統架構的記憶體瓶頸，實現前所未有的能效比，並藉此徹底顛覆 **Windows PC** 與資料中心的既有格局。
- **Intel** 的 **x86** 路線：則極力證明在複雜的「多代理人 (**Agentic AI**)」時代，系統的穩定度、軟體相容性以及 **CPU** 作為「編排層大腦」的調度能力，才是決定 **AI** 落地成本與效率的關鍵，而這正是 **x86** 累積數十年、無法被輕易動搖的護城河。

為什麼我們無法在 **Computex** 得到答案？

在展會期間，兩家公司所公布的基準測試 (**Benchmarks**) 與展示，都是在最有利於自家架構的特定場景下進行的。

- **NVIDIA** 展示的，是跑特定本地 **LLM** 時，**Arm** 晶片那令人驚艷的每瓦 **Token** 輸出率。
- **Intel** 展示的，是面對複雜企業工作流時，**x86** 系統那行雲流水般的異質硬體調度與相容性。

這些「紙面性能」都非常優秀，但它們都屬於「完美實驗室」裡的產物。

接下來該看什麼？

要判斷這場架構之爭的真正勝負，我們必須將目光移開展會，在接下來的數個季度中，持續監控以下三個核心的後續實質數據：

1. 企業與 **OEM** 的實際拉貨與出貨量；
2. 軟體生態系的實際相容性與遷移成本：
 - 企業在將現有的 **IT** 基礎設施、資料庫與安全性軟體遷移到 **Arm** 架構時，是否遇到了預期之外的阻礙與隱性成本？
 - **x86** 陣營在執行新一代 **AI Agent** 軟體時，是否真的能如 **Intel** 所說，展現出無縫接軌的調度優勢？

3. 雲端服務商（CSPs）的資本支出與採購比例。

Computex 2026 只是這場馬拉松的起跑槍聲。**NVIDIA** 證明了 **Arm** 的無限潛力，**Intel** 則用 **x86** 的深厚底蘊來反擊。真正的贏家，將由接下來幾季的出貨報表、企業財報與軟體生態系的真實回饋來決定。

主題三：從回購王變成融資王，Google 為什麼突然募資 850 億美元？

In 28 years, Google / Alphabet has tapped primary equity markets in only seven of them. Six were small. The seventh, announced in 2026, is larger than every prior raise combined — by more than 10x.



SOURCES: GOOGLE PRESS RELEASES · GOOG S-1 / 10-K FILINGS · ALPHABET 2026 OFFERING ANNOUNCEMENT. PRIMARY EQUITY ONLY — EXCLUDES SBC, ACQUISITION STOCK, SPLITS, INSIDER SALES, AND DEBT.

Image

Alphabet 這個星期宣布並完成了一筆高達 **847.5 億美元** 的歷史性股權融資。

這是什麼概念？它打破了 2010 年巴西石油（Petrobras）創下的 **700 億美元** 紀錄，成為人類企業歷史上規模最大的單一增資案。

對於這筆天文數字，市場上充斥著各種聲音。

有人質疑：「**Google** 不是富可敵國、手握大把現金流嗎？為什麼還要跟市場要錢？」甚至有人放大招股書中的細節，質疑這筆錢是用來「幫員工繳稅」而非發展 AI。

一家過去十五年一直在回購自己股票的科技公司，為何要大舉融資？

標題黨的盲點：那筆被誤解的「300 億員工稅金」

首先，我們來釐清一個在社群媒體上被瘋傳的「偽命題」：

「**Alphabet** 融資是為了幫員工繳稅，而不是為公司發展」。

這完全是只看硬幣一面的斷章取義。這次 847.5 億美元的融資結構，其實分得很清楚：

- 約 **447.5 億美元**：透過公開發行、可轉債與巴菲特旗下 **Berkshire Hathaway** 的私募，這筆錢是鐵打的「AI 基礎建設與算力擴張基金」。
- 約 **400 億美元的 ATM（市價發行）計劃**：其中預計有 300 億美元，確實是用來處理 2026 年員工股權激勵（RSU）歸屬時的稅務問題。

讓我解釋一下這個操作實際上是什麼。

過去，當員工的股票到期歸屬時，**Alphabet** 通常會「扣留一部分股票」作為稅金，並直接動用公司自有的自由現金流（FCF）幫員工向政府繳納這筆龐大的稅款。

這種做法雖然保護了股東（因為扣留的股票不會流入市場，稀釋效應較低），但卻會直接抽走公司數百億美元的真金白銀。

現在，面對 2026 年高達 1,800 億至 1,900 億美元的瘋狂 AI 資本支出（CapEx），**Alphabet** 選擇了不同的財務策略：

他們改用 **ATM**（按市價發行新股）的方式，在公開市場上募集資金來支付這筆 **300 億美元** 的員工稅金，從而把公司原本寶貴的「自由現金流」完好地保存下來，全力投入 **AI 戰場**。

雖然這意味著現有股東必須承受股本被進一步稀釋的代價（這也是為什麼過去幾年靠「股票回購」防稀釋的 **Alphabet**，這次會引起市場短暫恐慌），但從資金效率的角度來看，「用融資付稅，把自有現金省下來蓋資料中心」，與「用融資蓋資料中心」在實質效果上是一樣的，都是為了在最關鍵的 **AI 軍備競賽** 中，確保手頭有最充裕的現金彈藥。

Alphabet 2026 年 的資本支出（**CapEx**）指引高達 **1,800 億至 1,900 億美元**（幾乎是去年的兩倍），根本不是沒有發展。**Alphabet** 真正的考驗仍然是大規模資本支出是否能產生回報，而不是這 **300 億美元** 稅務項目的具體資金來源。

公開市場的速度優勢

這筆歷史性融資，最有趣的地方在於，它展示了「已上市科技巨頭」對比「未上市 **AI** 新創」在資金獲取速度上的降維打擊。

當前，像 **OpenAI**、**Anthropic** 這些明星獨角獸，為了應付龐大的模型訓練與算力成本，同樣在尋求百億美元級別的融資或 **IPO** 計劃。

然而，未上市公司的融資之路無比漫長，要經歷無數輪的談判、繁瑣的 **SEC** 審查、路演、估值博弈，動輒耗時數月甚至一年。

反觀 **Alphabet**：

- 6 月 1 日：宣布計劃融資 **800 億美元**。
- 6 月 2-3 日：因為市場認購太過踴躍，直接超額認購，最終定價 **847.5 億美元**。
- 6 月 4-5 日：資金全部交割入帳。

前後僅僅用了不到五天。

這就是身為萬億級上市公司、擁有極致流動性與信用紅利的終極優勢。

當新創公司還在排隊等待 IPO、為估值爭論不休時，**Alphabet** 已經把 **850 億美元** 的真金白銀裝進口袋，直接去向 **台積電** 搶產能、向 **NVIDIA** 搶晶片、向電力公司搶電網配額了，為 **Gemini** 提供更多資金發展。

在「天下武功，唯快不破」的 **AI** 軍備競賽中，這種「光速吸金」的能力，本身就是一道無法逾越的護城河，也是為甚麼其他獨角獸要盡快上市的原因。

股神的背書

這次融資的錨定投資者中，出現了一個熟悉的名字：**Berkshire Hathaway**，他們直接認購了 **100 億美元**。

這是繼承班底 **Greg Abel** 掌舵後的重大決策之一。**Abel** 公開說過，**Berkshire** 不會「為了 **AI** 而做 **AI**」，必須是增值的。在這裡投入 **100 億美元** 是一個具體的投票，表明 **Alphabet** 在 **AI** 基礎設施上的執行達到了那個標準。

他們願意在 **Alphabet** 股價並不算便宜的當下，砸下 **100 億美元**，釋放了一個極其強烈的信號：

即使在最保守、最注重價值投資的巨頭眼中，**Alphabet** 的 **AI** 基礎建設投資，估值相對有吸引力，依然具備極高的長期回報率（**ROIC**）與安全邊際。

這給了市場一顆定心丸，它證明了這場軍備競賽有著扎實商業邏輯支撐的未來基建。

逼迫所有人提前攤牌的「軍備競賽」

這次 **850 億美元** 的歷史性融資，確實為整個 **AI** 生態系帶來了顯著的正面效應。當頂級資本願意在此刻為天文數字的資本支出背書時，它實際上是用真金白銀向市場證明：

AI 的商業變現絕非空中樓閣。這不僅給了高喊泡沫化的空頭一記響亮耳光，也為 **NVIDIA**、**台積電** 等半導體巨頭，以及電網、核能與冷卻系統等供應鏈，提供了一張極其珍貴的「長期未來訂單保證書」，間接降低了整個板塊的系統性風險。

然而，這也是在迫所有人加速行動。

這筆錢砸下去，意味著 **Alphabet** 正在用史無前例的資金體量，提前鎖定並壟斷未來幾年最稀缺的晶片與電力資源，極限擠壓其他玩家的生存空間。

更關鍵的是，它正在逼迫所有人以最快速度跟進融資。

2026 年，四大超大規模運算商（Hyperscalers）的集體資本支出指引已來到驚人的 **7,250 億美元**。在如此恐怖的燒錢速度下，即便是強如亞馬遜、**Meta** 這樣的巨頭，其自由現金流也面臨被榨乾的壓力，被迫轉向股權融資。

然而，全球資本市場的承接力始終會有上限。當每家巨頭都試圖在市場上募集成百上千億美元時，先動手的 **Alphabet** 已經拿走了最便宜、最充裕的第一桶金。

那些動作慢、還在猶豫是否要稀釋股權，或是還在為估值爭論不休的競爭對手（包括 **OpenAI**、**Anthropic** 等新創），一旦錯過了這個短暫的黃金窗口，未來將不得不面對更挑剔的投資人與更昂貴的融資成本。

我們正處於物理基建的「重工業時代」


站在歷史的節點回看，這筆 **850 億美元** 的融資，是我們理解當前 **AI** 週期定位的終極信號。

我們正在見證一個前所未有的、資本極度密集的「重工業階段」。在這個階段，物理世界的基礎建設（算力、電力、資料中心）必須先行，隨後才能迎來軟體層面的全面變現。

公開市場用超額認購的熱情、波克夏用 **100 億美元** 的錨定、評級機構用正面的信用評估，共同為這個偉大的週期投下了信任票。

這筆融資之所以值得我們每一個人高度關注，是因為它清晰地告訴了我們：這場 **AI** 之戰，最終將屬於那些能夠在資本市場長袖善舞、高效部署並展現極致執行力的終極玩家。

主題四：拒絕賺快錢，從 Build 2026 看微軟的策略



Microsoft Build 2026 Preview: The AI Takeover of Windows Has Officially Begun | PCMag

剛剛落幕的 **Microsoft Build 2026**，表面上是一場眼花繚亂的「**Agent**（智能體）大秀」。

如果你只看大會的標題，會看到一堆讓人興奮的新名詞：七個新的 **MAI** 自研模型、一個叫 **Scout** 的「自動駕駛」個人工作代理、一台塞了 **NVIDIA RTX Spark** 晶片的開發者夢幻機器、一個不是 **Windows** 的全新平台 **Solara**，以及一顆在量子運算領域取得重大突破的 **Majorana 2** 晶片。

你可能會問：既然市面上已經有 **OpenAI**、**Anthropic** 這些強大的模型，微軟為什麼還要大費周章自己做 **MAI** 模型？

幾天後，微軟執行長 **Satya Nadella** 接受了 **Stratechery** 創辦人 **Ben Thompson** 的專訪。這場對話，才是我們理解微軟真正在做什麼的關鍵鑰匙。

拒絕「嫉妒型創新」：微軟不做下一個 Zune

專訪中，**Thompson** 問了一個很多人都想問的問題：在 **AI** 這場競爭中，微軟到底是領先還是落後？

Nadella 的回答很有意思。他沒有直接給出答案，而是退一步，重新定義了競爭。

「大多數人衡量競爭地位時，彷彿這是一場完全零和的遊戲，但從來都不是這樣。雲端時代不是，當年的用戶端伺服器時代也不是。對我來說，『微軟在這個新世界中能獨特地做什麼』，這才是我們必須先回答的問題。」

接著，他坦誠地說了一句非常清醒的話：「我們最糟的時候，就是因為『嫉妒』而去做某些事。只因為別人做出了很酷的熱門產品，不代表我們就該跟風。」

他甚至主動自嘲了微軟當年的黑歷史 **Zune**（當年為了對抗 iPod 而推出的播放器）：

Zune 是個好裝置，但這世界根本不需要微軟做 **Zune**。

這番話，其實是 **Nadella** 在向市場釋放一個明確的訊號：微軟不打算加入「誰的模型最聰明」這場無止境的軍備競賽。

微軟的基因從來就不是做出世界上最強的單一產品，他們的強項是成為一個平台，讓所有人都能在上面創造價值。在 PC 時代是 Windows，在雲端時代是 **Azure**，而在 **Agent** 時代，微軟要做的，是企業 AI 生態的作業系統。

企業的終極護城河：專屬的「爬山機」

既然不爭最強模型，那微軟要做什麼？

Nadella 提出了一個非常生動的概念，叫做「爬山」（Hill-climbing）。

「爬山基本上是這樣的：當你想『AI 能做什麼？』，AI 就是拿一個目標，持續學習如何預測和創造代表那個目標的輸出，而且是持續不斷地做。」

「私有輸出、評估，我認為這可能是一家公司創造的最重要的智慧財產權，就是這些私有的基準和評估。在那裡，你有品味地去識別什麼是好的輸出、什麼是高品質。」

這就是微軟對 **AI** 時代企業競爭優勢的核心判斷：最關鍵的不是你用的基礎模型有多聰明，而是你能不能把公司的隱性知識、專屬資料與工作流程，持續地餵給模型，讓模型在你的業務場景裡不斷「爬山」，變得越來越懂你。

微軟要建的，就是一個讓這台「爬山機」能夠安全、規模化、受治理地運作的平台。

這解釋了 Build 2026 發表的一切

一旦理解了「爬山機」這個框架，**Build 2026** 那些看似眼花繚亂、各自獨立的產品發表，瞬間就拼成了一幅清晰的拼圖。微軟其實是在為企業打造一整套組裝工具箱：

首先，是 **MAI** 模型與 **Frontier Tuning**。

微軟不跟別人拼誰的模型更強，他們給企業一個大小適中、極具成本效益的 **MAI** 自研模型。

透過 **Frontier Tuning**，企業可以用自己的專屬資料來訓練它。這就像是讓引擎適應自家門前的山路，用最低的 **Token** 成本，爬出最好的效果。

其次，是 **Microsoft IQ**。

Microsoft IQ（包含 **Work IQ** 和 **Web IQ**）把原本埋在 **Microsoft 365** 底下、平常沒人注意的企業內部資料庫挖出來，變成 **Agent** 可以直接調用的智慧層。

這等於是給了 **Agent** 一張企業內部的活地圖，讓它知道每項工作的前因後果。

接著，是 **Microsoft Scout**。

過去的 **AI** 像是一個等著你發號施令的副駕駛，而 **Scout** 則是真正的 **Autopilot**。

它不需要你一直跟它聊天，它會在背景默默運作，主動幫你準備會議、處理費用報告。這正是 **Nadella** 所說的，**AI** 從「被動工具」走向「自主工作」的關鍵一步。

再來，是 **RTX Spark** 開發機與 **Solara** 平台。

為了讓工程師能在本地順暢地測試這台爬山機，微軟推出了配備強大晶片的 **Surface RTX Spark** 開發機。

同時，他們也推出了全新的 **Solara** 平台。這是一個完全不依賴 **Windows** 的新系統，專為穿戴式裝置或智慧硬體設計。

這展現了微軟的務實，當舊有的 **Windows** 道路不適合新一代的 **Agent** 體驗時，微軟寧可直接鋪一條新路，也不硬套舊框架。

最後，是 **MXC** 沙盒與 **Agent 365 SDK**。

當 **Agent** 開始在背景自主幫你開車、處理業務，企業最怕的就是它失控撞車。**Microsoft Execution Containers (MXC)** 安全沙盒與治理工具，就是為了在系統底層拉起安全防護網，確保 **Agent** 的一舉一動都在合規且安全的範圍內。

這些發表並不是零散的技術更新，微軟的意圖非常明確：他們要幫企業把安全防護、內部資料、自主代理和底層硬體全部縫合在一起，讓企業能毫無後顧之憂地運作自己的「爬山機」。

從「重壓合作」到「建立選擇權」：微軟與 OpenAI 的關係演變

Nadella 在專訪中對 **OpenAI** 的態度相當務實。他承認早期與 **OpenAI** 的合作是微軟在 **AI** 賽道上快速取得領先地位的關鍵，也坦言「每天 **OpenAI** 做得好，微軟也做得好」。

雙方合約關係至少持續到 2032 年，微軟仍會是 **OpenAI** 的重要客戶與基礎設施提供者。

然而，從微軟積極推出 **MAI** 自研模型、**GitHub Copilot** 導入多模型選擇（甚至可以用 **Claude** 來互相檢查），以及在算力分配上展現的紀律來看，微軟正在從「早期重度依賴單一合作夥伴」，轉向「建立重要但非獨占的夥伴關係」。

更關鍵的是，**Nadella** 清楚表達了微軟在資本配置上的取捨：

「在今天這個時代，如果你想要短期的 **Azure** 營收，這很容易，你只需要把 **GPU** 賣給某個投機的 **AI** 新創（**Neolab**）就行了。」

他明確表示微軟不會這麼做。原因很簡單：前沿 **AI** 實驗室最終會建立自己的基礎設施。

與其把寶貴的算力大量押在少數幾個模型公司身上，不如把產能分配給三個更長期的桶子：超大規模雲端服務、微軟自己的應用業務（**M365**、**GitHub**、**Security**），以及自研模型的研究計算。

這背後反映出 **Nadella** 對未來的判斷：真正的長期價值，不會來自追逐最熱門的模型公司，而是來自那些願意為安全、治理、企業整合，以及持續優化付出代價的客戶。拒絕「容易賺的錢」，正是微軟把算力留給真正能產生長期複利的地方。

商業模式的轉變：當人頭計費失效

然而，這場變革也帶來了一個根本性的商業難題：當 **Agent** 可以 24 小時在背景不間斷工作時，傳統 SaaS「按人頭計費（Per-Seat）」的模式就失效了。

如果一個自動駕駛的 **Agent** 能幫五個人完成工作，企業為什麼還要買五個帳號？

微軟給出的解法是「混合定價模式」（基本人頭費 + 彈性算力消耗費）。

這是一場考驗耐心的轉型。對企業客戶來說，這意味著他們會非常精明地計算每一筆 **AI** 消費的 ROI，這會帶來優化成本的壓力；而對微軟來說，這逼得他們必須把安全沙盒（**MXC**）、觀測性與治理工具打包成無可取代的套裝服務，讓企業在享受 **Agent** 便利的同時，不得不為這些底層的安全防禦買單。

仍要時間觀察

微軟在 Build 2026 展現的姿態，反映出一個歷經多個平台週期後，選擇以長期結構性優勢為優先的成熟公司。

它沒有急於證明自己的自研模型在通用能力上超越 **GPT** 或 **Claude**，而是把重點放在如何把安全沙盒、企業上下文、治理工具與底層硬體，系統性地結合在一起。

這種做法背後的邏輯，在 **Nadella** 與 Ben Thompson 的對話中表露得相當清楚：微軟認為，**AI** 時代企業真正的護城河，來自於能否把自身的隱性知識持續轉化為模型優勢，而非單純依賴最強的基礎模型。

Build 所展示的，正是微軟試圖在這個方向上建立平台級能力的嘗試。

然而，這條路徑仍存在明顯的執行挑戰。**Agent** 的實際採用速度、企業是否願意為持續運作的 **Agent** 支付可觀的消費費用，以及這些消費何時能對財報產生實質貢獻，都是市場在接下來幾個季度會密切觀察的重點。

目前 **Scout** 仍處於 **Frontier** 客戶小規模驗證階段，混合定價模式的市場接受度也尚未完全明朗。

換句話說，微軟正在為 **Agent** 時代的長期遊戲規則布局，但這場轉型需要時間驗證。

短期內，市場仍會以 **Azure** 成長品質、內部應用與研究算力的使用效率，以及早期 **Agent** 產品的採用跡象，來評估這套策略的進展。

主題五：Nvidia 對記憶體需求減半？

Memory: SemiAnalysis Says Rubin NVL72 DRAM Capacity per Rack Cut ~50%, Lowering System Cost

SemiAnalysis reports NVDA is reducing Rubin NVL72 SOCAMM DRAM capacity from ~55TB to ~28TB per rack, with most Rubin systems expected to use 96GB SOCAMMs rather than 192GB modules. The change lowers estimated rack cost from \$7.6M to \$6.8M and reduces total cost of ownership from \$4.16/hr/GPU to \$3.90/hr/GPU.

Recall, NVDA has said SOCAMM is \$300B TAM. Given shortages, not unreasonable for them to manage the specs

Image

SemiAnalysis 發了一份報告，提到 **Nvidia** 的 Vera Rubin NVL72 機櫃在出貨時，系統記憶體的配置比原本規劃的少了大約一半。

很快地，市場上就出現了鋪天蓋地的熊市鬼故事：「Nvidia將記憶體需求砍半！」、「記憶體大廠的超級週期要終結了！」

這類點擊率極高的陰謀論，完美展現了什麼叫「去脈絡化的斷章取義」。

不當完美主義者，先通車再說

首先，我們要釐清一個關鍵：被「砍半」的，是 CPU 側的系統記憶體（**LPDDR5X**），而不是 GPU 側那顆最核心、最昂貴的 **HBM4**（高頻寬記憶體）。

在 Rubin 晶片上，負責承擔海量矩陣運算、注意力機制等核心算力的 **HBM4**，規格與需求完全沒有受到任何影響。

那為什麼要動 CPU 側的 **LPDDR5X**？答案很簡單：供應鏈卡住了，但客戶等不及了。

目前，要達到原先規劃的超高容量，必須使用極高密度的 16 層堆疊 **LPDDR5X** 模組，而這種模組目前的良率與產能極其受限。

如果 **Nvidia** 堅持「規格不攻頂不出貨」，那 Rubin 的量產時程勢必會被嚴重拖累。

於是，黃仁勳做了一個非常務實的商業決策：

- 降規加速出貨：改用產能成熟的 **96 GB** 模組，避開供應鏈瓶頸，讓 Rubin 機架能以最快速度送進微軟、Meta 等雲端巨頭（Hyperscalers）的資料中心。
- 幫客戶省錢（降低 TCO）：這一降規，直接讓每台機架的成本暴省了 **80 萬美元**（從約 **760 萬美元** 降至 **680 萬美元**）。
- 保留升級後路：Blackwell 世代（如 GB300 Ultra）使用的是直接鐸死在主機板上的 LPDDR 記憶體；但 Vera Rubin 平台改用了插槽式（Socketed）的 **SOCAMM2** 模組設計。

這種「熱插拔、可現場更換」的設計，意味著 **96GB** 只是供應鏈極限下的「過渡性配置」。如果客戶未來真的有極致需求，且高密度模組產能跟上了，隨時可以像插拔電腦記憶體一樣，在機房裡直接升級。

很明顯，這根本不是 **Nvidia** 覺得不需要這麼多記憶體了，只不過是一個工程上的妥協。

這根本不是需求下滑，只不過是一個「先上車、後補票」的彈性策略。

記憶體階層的演進

系統記憶體配置降低，反而可能加速另一個趨勢：把更多工作負載推向儲存層。

在即將到來的 **Agent**（智能體）與長文本（**Long-Context**）時代，**AI** 不再只是回答一個問題就結束，而是要進行多輪對話、調用工具、協同運作。這會產生天文數字般的 **KV 快取（KV Cache）**。

這些暫存資料如果全部塞在最貴、最稀缺的 **GPU HBM** 裡，成本會高到不合理；但如果全部丟到傳統硬碟，速度又慢到讓人無法忍受。

於是，**AI** 工廠正在演進出類似傳統電腦 **CPU** 快取（**L1/L2/L3**）的「**三階層記憶體架構**」：

- 熱層（Hot Tier）— **HBM4**：速度最快、最貴。只用來處理最核心的即時運算。
- 溫層（Warm Tier）— **LPDDR5X（SOCAMM）**：速度中等、具備高頻寬與 **CPU** 一致性。用來暫存「準備要用」的 **KV Cache** 與 **Agent** 調度狀態。
- 冷層 / 容量層（Cold/Capacity Tier）— 高性能 **SSD** 與 **AI** 原生儲存：容量極大、成本最低。用來存放長期的對話記憶與歷史資料。

當系統記憶體配置降低，這個三層架構的價值反而更明顯。軟體需要更聰明地管理資料在不同層級之間的流動，而 **Nvidia** 的全端控制（從晶片到軟體堆疊）讓他們有能力做這種最佳化。

對記憶體產業的實際影響

從這個變化，我們可以再嘗試往下推兩個結論。

1. 儲存層（SSD / NAND Flash）變得更重要

當 **CPU** 側的 **LPDDR5X** 容量降低，系統為了維持整體流暢度，勢必會更積極地把「半熱」（Warm）狀態的 **KV Cache** 與 **Agent** 上下文，透過軟體堆疊（**Nvidia Dynamo**、**BlueField-4**、**NIXL** 等）更頻繁地調動到高性能儲存層。

對記憶體大廠來說，這意味著原本「配角」的 **NAND Flash** 業務，在 **Agent** 時代反而成為不可或缺的戰略拼圖。**Samsung**、**SK hynix**、**Micron** 同時擁有 **DRAM** 與 **NAND** 事業的廠商，在這個演進中反而具備更完整的 **exposure**。

2. 機架變便宜，出貨量暴增（總量效應大於單機減少）

每台機架省下 **80 萬美元**，加上出貨速度變快，會刺激雲端巨頭下單更多數量的 **Rubin** 機架。

從數學邏輯來看，全球 **LPDDR5X** 的總產能目前就這麼多。**Nvidia** 將單機配置減半，意味著原本只能組裝 100 台機櫃的記憶體，現在可以分給 200 台機櫃使用，讓整體 Rubin 平台以雙倍速度鋪開。

對記憶體大廠來說，產能依然是滿載被消耗掉的，總體位元（Total Bits）需求根本沒有縮水。

相反地，每一台多賣出去的機架，裡面搭載的 **HBM4** 可是一點都沒少。更別提未來產能緩解後，客戶回頭採購 **192GB** 模組進行二次升級的「售後拉貨潮」。

標題之外

SemiAnalysis 的創辦人 **Dylan Patel** 在社群媒體上的回應很直接：「有件事我一直覺得有趣，分享我們報告的人經常漏掉大部分內容。」

事實上，複雜的供應鏈分析，在傳播過程中幾乎必然會被簡化。簡化本身不是壞事，但當簡化變成扭曲，當「**Nvidia** 為了加速出貨而調整系統記憶體配置」變成「記憶體需求腰斬」，訊息的本質就完全走樣了。

這次的 **SOCAMM** 故事是個縮影。相比起記憶體需求的崩潰，這更是 **AI** 基礎建設正在走向一個更成熟、更分層、更軟體定義的記憶體架構。

在這個架構裡，熱資料、溫資料、冷資料有各自適合的載體，而整體的矽需求和儲存需求會隨著 **AI** 部署的規模持續上升。

記憶體超級週期的邏輯沒有改變。瓶頸會在不同層級之間移動，但總需求的方向是清楚的。

下次看到「XX 需求腰斬」這種標題時，或許可以先問一句：腰斬的是哪一層？為什麼？這對其他層級有什麼影響？答案通常比標題有趣得多。

商周專欄解禁版(付費會員專享)

謝謝你閱讀到這裡，如果你覺得這份筆記為你帶來了價值，請不吝按下一個讚，這是我持續分享的最大動力。

我在**Facebook**和**Threads**都有每天發佈當天對市場的觀察，大家也可以考慮追蹤我的社交媒體。

另外我在**Telegram**有頻道，每天早上我會發當天重要新聞摘要。

同時，如果想開戶的話，可以考慮用我的富途/口袋證券獨家推薦碼，會有更多優惠。

全部資訊在以下鏈結：

https://linktr.ee/fomo_soc

另外，如果你已經加入付費會員，不要浪費了群組的功能，進入我們**Substack**的**Chat**功能一起討論市場!

· KP

本機離線版本 • 圖片與內文完整

← 回索引

在原地開啟 ↗