

← 索引 FREE 公開 2026-07-25 1226 字 ↗ 原站

CUDA護城河被削弱？黃仁勳在X首次發文？Gemini真的不行了嗎？- KP思考筆記(第52期)

本文目錄

- 1 主題一：AMD用Helios反攻Nvidia？
- 2 主題二：Nvidia CUDA護城河在消退？
- 3 主題三：黃仁勳的第一條推文，叫美國「開放」一點？
- 4 主題四：從Google財報看Gemini的策略
- 5 主題五：Elon Musk 為什麼破天荒公開感謝美光？
- 6 主題六：Intel的業績應該怎樣看？



KP
FOMO研究院

大家好，我是 KP，歡迎來到第 52 期的《週末思考筆記》。

第 52 期，是十分特別的一期。因為我每個星期都會寫一篇思考筆記，風雨不改。去到第 52 期，這代表著我在 **Substack** 寫了整整一年。

真的，來到了一週年，很衷心地感謝大家。

一年前開始寫**Substack**的時候，我沒有想過會發展成今日這個地步。更不要提兩年多前，我開始在 **Facebook**、**Threads** 分享的時候，那更不是現在這個模樣。

那時候的我，連自己到底要寫甚麼、寫給誰看，都還在摸索。

在資訊越來越氾濫的年代，輸出已經變成了很容易的事情。最難的，反而是得到每個人的專注力。

一條簡單的喊單推文，一條講述「10 隻最受惠 AI 概念股」的短影音，半分鐘就能看完，就能獲得股票代碼，就能打開股票 APP 下單。為甚麼要花上一個小時去閱讀一篇長文？

我沒有標準答案。或者說，如果你讀到了這裏，你大概已經有自己的答案。

半分鐘給你的是資訊，一個小時給你的，是思考的框架。資訊會過期，框架不會。

下週那 10 隻股票可能換了另外 10 隻，但你理解一門生意的邏輯、你拆解一個宏大敘事的能力，是跟著你走的。

趁著一週年，我想誠實地向大家坦白一件事：在投資與產業的領域裡，還有太多太多我不知道的事情。

你以為我寫每一個題目之前，都已經是完全的專家嗎？當然不是。很多時候，我在動筆前也只掌握了冰山一角。

但做研究這件事，我是真的享受。把一堆散亂的資訊，梳理成一篇你讀得下去、讀得明白的分析，這件事我是真的享受。

而更讓我感到無比驕傲的，是我們共同建立起來的這座「**FOMO** 研究院」社群。

這是一個非常「反常」的社群。在喧囂的投資世界裡，這裡幾乎沒有人會問我「現在能不能買？」、「目標價看多少？」這種簡單粗暴的投機問題。

相反地，這是一個會認真讀完，然後跟我說：「KP，你第三段的邏輯我不同意，因為.....」的社群。

(繼續鼓勵大家多到討論區逛逛，即使不發表意見，每天也有很多精彩討論，下面是連結)

寫這種硬核、不帶報牌性質的內容，永遠拿不到市場上最高的流量。在這個「流量即正義」的時代，這看起來似乎不太聰明。

但獲取最高的流量，從來就不是我的目標。

找到對的人，坐在一起，形成一個正向的循環。你因為讀了而多想了一層，我因為你的反饋而下次寫得更準，這才是我最大的目標。

邁向第二年的我們

比起一年前的我，我敢說自己進步了不知多少倍。

而我也敢說，如果你有一直和我們前行，今天的你，比起當初剛剛按下訂閱的你，也肯定進步了不知多少倍。

所以，謝謝你。

謝謝你願意在一個甚麼都求快的世界裏，花上你寶貴的時間，跟我一起思考和進步。

下一年，我希望我們繼續。不會每次投資都贏錢，但求對的時候多對一點，錯的時候少錯一點。每個星期，都比上個星期的自己，進步那麼一點點。

第 52 期，我們繼續。

這個星期有6個主題，包括：

主題一：**AMD用Helios反攻Nvidia？**

主題二：**Nvidia CUDA護城河在消退？**

主題三：黃仁勳的第一條推文，叫美國「開放」一點？


主題四：從Google財報看Gemini的策略

主題五：**Elon Musk** 為什麼破天荒公開感謝美光？

主題六：**Intel**的業績應該怎樣看？

不妨考慮先讚後看，我們立刻進入主題！

主題一：**AMD**用**Helios**反攻**Nvidia**？



要了解 Helios 機櫃的重要性，我們要先理解，過去幾年 AMD 和 Nvidia 最大的差別在哪。

MI300X、MI325X 時代的 AMD，本質上在做一件事：把一顆顆效能不錯的 GPU 交給客戶，然後說：「剩下的，你自己搞定。」

伺服器怎麼組、網路怎麼接、散熱怎麼做、軟體怎麼調，統統是買家自己的事。

這就像你去買車，經銷商把引擎交到你手上，然後微笑著說：「底盤、變速箱、空調系統，麻煩您自行組裝。」

同一時間，Nvidia 在幹什麼？從 NVL72 開始，黃仁勳賣的早就不是 GPU 了。

他賣的是一整個機櫃，72 顆 GPU 透過 NVLink 綁成一個巨大的運算域，網路、散熱、電源、軟體棧全部打包好，插上電就能跑。客戶要做的決定從「怎麼整合」簡化成「要不要買」。

差距在哪裡？三個字：**摩擦力**。

AMD 的客戶要自己解決 8 顆 GPU 以上的擴展瓶頸，要自己跟 ROCm 的成熟度搏鬥，要自己搞定液冷和高速網路。

每一層整合工作，都在消耗客戶的工程資源和耐心。而 Nvidia 的客戶？開箱即用，**CUDA 生態**現成，72 顆 GPU 像一顆一樣運作。

商業模式的重大演進

Helios 是 AMD 歷史上第一個真正的機櫃級 AI 平台。

一個標準 Helios 機櫃裡裝了 72 顆 MI455X GPU、18 顆第六代 EPYC Venice CPU、31TB 的 HBM4 記憶體，加上 Pensando 的網路晶片和全套液冷系統。整個機櫃被設計成一個統一的運算域，具備明確的系統級架構意志。

這項設計的真正價值在於路線選擇：

- **規格標準**：基于 Meta 主導的 Open Rack Wide (ORW) 開放規格。
- **Scale-up**：採用 UALink-over-Ethernet。
- **Scale-out**：使用 Ultra Ethernet。

雲端巨頭可以自由選擇 Broadcom 或 HPE Juniper 等不同廠商的網路交換器，擺脫 Nvidia 專有 InfiniBand 與 NVSwitch 的生態綁定。

對於極度抗拒被單一供應商鎖定的巨頭而言，這項開放特性具有極高的戰略吸引力。

技術的妥協：首代 Helios 的潛在瓶頸

然而，開放標準在現階段也伴隨著技術妥協。

第一代 Helios 系統將 UALink 封裝並運行在標準乙太網路交換器上，尚未採用原生的 UALink 特殊應用晶片（ASIC）。

這會帶來額外的協定開銷（Protocol Overhead），導致延遲增加，並降低小封包傳輸的效率。

相較之下，Nvidia 專有的 NVLink 軟硬體棧在通訊效率上依然保有優勢。在超大型模型訓練任務中，Nvidia 的架構理論上更為出色。

原生的低延遲 UALink 交換器預計要到 2027 年左右才會問世。2026 年出貨的首批 Helios 系統，本質上是一個兼顧時效與開放性的折衷方案。

輕資產商業模式：AMD 的算力變現路徑

在商業落地上，AMD 與 Nvidia 的利潤捕獲方式有明顯差異：

Nvidia 傾向於高度控制整套系統的設計與規格，GPU、Grace CPU、NVLink 交換器、網路晶片全部自家出品，合作夥伴主要負責組裝與交付。

Nvidia 對整體架構的掌控力極強，系統利潤的分配也由其主導。

AMD 則負責定義並設計開放式機櫃藍圖（Helios），實際的硬體組裝與銷售交由 Supermicro、HPE 等系統合作夥伴執行。

AMD 的營收來源是機櫃內的高價值矽晶片：MI455X GPU、Venice CPU、Pensando 網卡。

這種模式讓 AMD 以較低的資產投入，專注於晶片銷售，同時迴避了整機製造與庫存的沉重風險。

搭售率：AMD 跟自己的過去算帳

Helios 對 AMD 最直接的財務意義，在於解決了一個困擾多年的老問題：搭售率（Attach Rate）。

在商業世界中，搭售率就像速食店的經典策略。你點了一份主餐漢堡（GPU），店員順口問一句「要不要加購薯條和可樂（CPU 與網路晶片）？」

GPU 是吸引客戶上門的招牌主餐，CPU 與網路晶片則進一步提升整體營收貢獻。

過去，客戶單獨購買 AMD 的 GPU 後，很可能轉頭去買 Intel 的 CPU 或 Broadcom 的網路卡。AMD 的晶片只佔了系統成本的一小部分，搭售率長期受限。

Helios 改變了這個局面。AMD 直接在機櫃藍圖上把自家最頂級的 Venice EPYC 處理器和 Pensando 網路晶片「預先畫好」。

當客戶決定採用 Helios 架構時，AMD 的全套晶片就是預設配置。搭售率從「碰運氣」變成「寫在設計圖裡」。

這跟 Nvidia 的高搭售率有本質區別。Nvidia 靠的是封閉生態的強制綁定，你別無選擇。AMD 靠的是開放架構下的預設最優解，你理論上可以換，但換了效果會變差。

關於價格的迷思

市場上流傳一種說法：「Helios 比 Nvidia 還貴。」這個結論聽起來很有衝擊力，但經不起推敲。問題出在比較基準的錯亂。

多數人喊貴，是拿 Helios（估計約 500 萬美元以上）去跟上一代的 GB200/GB300 NVL72（估計約 300-400 萬美元）比。

這就像拿 2026 年的旗艦車去比 2025 年的中階款，然後驚呼「怎麼變貴了」。當然貴了，你比的根本不是同一代產品。

如果拿 Nvidia 真正的下一代 Vera Rubin NVL72（摩根士丹利預估約 780 萬美元）來比較，Helios 會比上一代貴，但比下一代便宜，而且記憶體容量還多了大約 50%。

如果我們把三代產品放在同一張桌子上，真實的價格排序其實是：

GB200/GB300 $\leq$ Helios $<$ Vera Rubin NVL72

AMD 的定價邏輯很清楚：用更激進的價格和更充裕的記憶體，在 **Nvidia** 世代交替的窗口期搶下市占。

市占率現實與客戶投票

戰略轉型的最終檢驗標準是訂單。截至 2026 年 7 月：

- **Microsoft** 確認將 Helios 用於 Azure 前沿模型推理。
- **Meta** 簽下高達 6GW 的多年期大單。
- **Anthropic** 確認部署 2GW 的 MI450 系列系統。
- **Oracle** 與 **OpenAI** 亦深度參與。

這些訂單將直接推動 **AMD** 市占率的結構性改變。過去幾年，**AMD** 在 AI 加速器市場的營收市占率始終徘徊在 3% 至 8% 的個位數，**Nvidia** 則穩佔 80% 以上。

Helios 的出貨，很可能將幫助 **AMD** 在 2027 至 2028 年間突破雙位數門檻。

Helios 無法瞬間推翻 **Nvidia** 的絕對主導地位，**CUDA** 生態系的護城河依然深厚。但 **AMD** 已成功拿到高階機櫃級市場的入場券，從邊緣玩家晉升為具備實質威脅的替代選項。

最後的洞察

AMD 過去的困境源於客戶總擁有體驗的缺失。**ROCm** 軟體生態的追趕固然重要，完整的基礎設施解決方案才是決勝關鍵。


Helios 的出現，讓我們評估 **AMD** 時不能再只看「**GPU** 效能與市占率」。

它同時改變了收入結構（更高的 CPU 與網路晶片搭售）、競爭定位（從性價比替代變成完整第二系統選項），以及長期毛利率的潛力。

如果 Meta、Anthropic、Microsoft 等 GW 級承諾能如期落地，市場過去給 AMD AI 業務的「軟體與生態折扣」應該適度收斂。

合理的估值框架，已經從「週期性 GPU 供應商」往「具備系統級架構能力的平台型公司」移動了一步。

主題二：Nvidia CUDA護城河在消退？



一個工程師，一個週末，一個全新的機櫃。

Anthropic 共同創辦人 Tom Brown 分享了一個故事：他們拿到一台 AMD MI355 機櫃，工程師只對 Claude 下了句「幫我把這台機器搞起來」，丟著跑過週末，結果竟跑出了連續改善的效能圖表。

前沿模型在全新硬體上的表現，就這麼被 AI「自己」拉了起來。

過去要讓一塊新硬體從開箱到跑得順，得靠專職團隊花上數週甚至數月。你得懂驅動載入、記憶體分層、卡跟卡之間的溝通，還要熟知各種文件裡沒寫的東西。這十年累積的調優知識，過往正是 **CUDA** 生態真正的護城河。

同一時間，AMD 與 Anthropic 宣布深度合作，Anthropic 將部署高達 2GW 的 AMD Instinct MI450 系列 GPU，並明確寫下要用 Claude 來優化 Instinct 的工作負載與 ROCm 開發。

模型不只是跑在晶片上，模型正在替晶片寫軟體。

護城河還在，但水在退

CUDA 今天依然擁有結構性優勢。NVIDIA 把晶片、互連網路與系統軟體整套綁在一起賣，那種深度整合的效率，絕非一個週末就能複製。

再加上極度成熟的除錯工具，以及整個開源生態「CUDA 優先」的強大慣性，當你燒掉幾百萬美元跑幾週訓練時，你依然會選「已知的好」，而不是「理論上可以的好」。

但護城河的性質正在改變：

- 兩年前：CUDA 的護城河是「不可進入」。你根本不知道從何開始，光移植一個核心運算就夠小團隊折騰半天。
- 今天：它正在變成「偏好性」。你可以離開了，只是離開之後的巔峰性能和穩定性還差一截，而且你現有的工程習慣仍長在 CUDA 上。

從「不可能」變成「麻煩但可行」，這中間的距離，才是 AI 硬體格局重新洗牌的真正空間。

不只一個人在這麼說

DeepSeek 創辦人梁文鋒也在流出的投資人會議內容中直言：「NVIDIA 的 CUDA 護城河正在快速崩解。」

他的理由如出一轍：AI 已經能寫程式，大幅降低了建立軟體生態系的人力門檻。他甚至樂觀地認為，中國晶片在軟體上的問題一年內能基本解決，真正的瓶頸反而落在製造產能。

DeepSeek 自己已跑了上萬張華為 Ascend 950，並認為其 SuperNode 在性價比上能替代 GB200/GB300 的工作負載。

話術會否有點誇大，大家可以自行判斷，但方向上，他和 Anthropic 指向的是同一件事：強大的 Coding Agent 正在將「建立替代軟體棧」的難度，從多年大型工程壓縮成可快速迭代的日常任務。

真正的新瓶頸：寫得出，和信得過

軟體護城河被 AI 填平了嗎？對，但只對了一半。競爭的缺口已悄悄轉移到「能不能信得過」。

模型能在幾小時內生出高效能程式碼，通過單元測試與中等規模基準。

但你未必知道它在極端條件下會不會安靜地出錯，也許訓練跑到第三週數值開始微幅漂移，也許擴展到兩千張卡時觸發了隱藏 bug。這些都是在昂貴的生產環境中才會發生的鬼故事。

AI 打下了生產程式碼的成本，卻沒有降低「信任這段程式碼」的成本。團隊容易累積大量跑得快、但無人深讀的程式碼，維護與除錯成了新黑洞。

稀缺資源從「會寫程式的人」，變成了「能嚴謹驗證、壓力測試，並敢為機器程式碼扛責任的人」。而這種人更為稀有。

CUDA 的殘存優勢，就在於你在最關鍵的任務上，依然「不敢完全離開」。

NVIDIA 會怎麼接招？

NVIDIA 真正在做的，是把黏性往更高的地方搬。

如果把寫程式比喻成「砌磚頭」，AI Agent 確實能幫你快速把牆砌好。但 NVIDIA 現在賣的，已經不只是磚頭，而是整座「智慧大樓」——地基、高速電梯、中央空調、物業管理一次到位。

低階程式碼愈來愈容易被 AI 搬到別的平台，但整棟樓怎麼蓋得又穩又快、各樓層怎麼高效溝通，這種深度整合的能力，目前還是 NVIDIA 明顯領先。別人可以很快蓋出能住的房子，但要蓋出同樣高效運轉的大樓，難度依然很高。

更關鍵的是，AI Agent 寫程式已是大勢所趨。當開發者發現：叫 Agent 優化 CUDA，十分鐘搞定；換到其他平台卻要折騰一小時，那股本來在削弱舊護城河的力量，反而變成幫 NVIDIA 加固新護城河的水泥。

- 舊護城河：「你的程式碼離不開我。」
- 新護城河：「你的整套 AI 營運，最後還是最想待在我這棟樓裡。」

真正在發生什麼？

十八個月前，AI 公司的算力採購是單選題：買 NVIDIA，或者慢慢等。


今天它變成了多選題：NVIDIA、AWS Trainium、AMD、自研晶片等。每一條路的軟體轉移成本都在下降，因為模型本身成了施工隊。

這甚至形成了一種奇妙的循環：**Claude** 正在讓未來跑 **Claude** 的硬體更高效，高效的硬體又養出更強的下一代模型。

這並不意味著 NVIDIA 會被輕易取代。壟斷的力量雖然軟化，但系統整合的領先溢價依然存在。多數公司會為了產能與成本分散供應商；但當預算充足且任務極度關鍵時，我相信大家依然會走那條信心最高的路。

CUDA 的護城河沒有乾涸。它只是從一座不可逾越的城堡，變成了一條你可以涉水而過、只是鞋子會濕的河。

主題三：黃仁勳的第一條推文，叫美國「開放」一點？



2026 年 7 月 24 日，黃仁勳發了他人生中的第一條推文。

不是新晶片發布，不是簽下了一個新客戶，他卻在談一件事：開放模型（Open-weights model）。

一個市值四兆美元公司的 CEO，社交媒體的處女秀，不是推銷自己的產品，而是替「別人可以免費拿走、修改、部署的 AI 模型」背書。

那封標題為〈Open Weights and American AI Leadership〉的聯署信，簽名欄讀起來像矽谷的復仇者聯盟：Microsoft、Meta、IBM、Hugging Face、Palantir、a16z、Y Combinator.....洋洋灑灑，幾乎把半個科技圈都拉上了船。

信裡到底說了什麼？

信的核心論述，用一句話概括：美國 AI 要贏，不應該靠幾家閉門造車的 AI 公司，而是鋪天蓋地的開放生態。

它開頭就拉出了一個歷史類比：1980 年代的開源軟體運動。

就像 80 年代的開源軟體撐起了今天的網際網路一樣，只有讓每個人都能拿去改、拿去用，美國的技術標準才會成為全球標準。

對手一定會用 AI 攻擊你，如果你把防衛能力都鎖在 OpenAI 或 Google 身上，一旦他們被攻破，全美國就集體癱瘓。讓廣大社群一起檢視程式碼，才是最堅固的盾。

對於爭議最大的「蒸餾技術」（用大模型輸出幫小模型升級），黃仁勳說：這是站在前人肩膀上的合法演進，該用法律解決的是惡意偷竊，而不是用一刀切的禁令扼殺技術。

但如果你只讀到這裡就點頭稱是，那你大概還沒看懂黃仁勳想做甚麼。

鏟子商的生存焦慮

NVIDIA 不賣模型。NVIDIA 賣的是讓模型跑起來的那塊矽、那台機器、那整座資料中心。

它是 AI 時代的鏟子商，不挖金礦，但每一個挖金礦的人都得找它買鏟子。問題是：如果金礦只有三座呢？

當 AI 的世界被壓縮成 OpenAI、Anthropic、Google 幾家封閉巨頭的遊戲，使用場景被侷限在 API 調用，算力需求再大也是「幾家公司的採購預算」。

更致命的是，這些巨頭每一個都在偷偷磨自己的鏟子：Google 有 TPU，Amazon 有 Trainium，Meta 在搞 MTIA。今天你是他們唯一的供應商，明天你就是他們最想擺脫的依賴。

但如果模型開放呢？

生態會瞬間從「幾家巨頭」變成「一百萬個玩家」：從微調模型的新創、做研究的大學、部署本地影像診斷的醫院，到為了資料主權自建機房的中東政府。每一家都需要 GPU，每一家都需要 CUDA，每一家都變成了 NVIDIA 的客戶。

黃仁勳在採訪裡說得幾乎是赤裸裸的：

「免費的 AI 對硬體是好事。免費的 AI 對晶片是好事。免費的 AI 對資料中心是好事。」

翻譯成人話：你們儘管把模型免費撒出去，撒得越廣越好。因為每一個「免費」的背後，都站著一個需要買我晶片的人。

那封信真正的讀者

表面上，這封信寫給政策制定者。

它用「國家安全」「主權」「競爭」「創新擴散」這些大詞把自己包裝成一份愛國文件，呼籲不要過早限制開放模型，不要把創新趕到海外。

因此，我們會看到聯署名單裡有 Palantir、有 CrowdStrike，這些名字出現在「國家安全」語境裡，最合理不過了。

它在告訴華盛頓：限制開放權重，不是保護美國，是削弱美國。黃仁勳把商業利益和國家利益綁在一起，把「我想賣更多晶片」翻譯成「美國不能輸掉 AI 競賽」。

更深一層，這封信是寫給投資人的。

它在說：不要怕開放模型，不要怕效率提升，不要怕「免費」。開放不是 **NVIDIA** 的威脅，是 **NVIDIA** 的增長引擎。模型越開放、越免費、越無處不在，跑這些模型所需要的算力就越是天文數字。

而最實際的一層：全球有多少政府和受監管行業，出於隱私、合規、地緣政治的原因，不可能把資料送進美國公司的雲端 API？他們要的是「模型在我自己的機房裡跑」。

開放權重加 **NVIDIA** 全棧方案，是目前這個命題唯一成熟的答案。每一座「主權 AI 工廠」的背後，都是一排排閃著綠光的 **GPU** 機架。

最危險的位置，和最安全的位置

黃仁勳比誰都清楚：在 AI 時代，最有利的不是「擁有最好的模型」，而是「成為所有人跑模型時繞不過去的那一層」。

模型會過時，架構會迭代，今天的頂級模型，明天就會變成免費的大路貨。但基礎設施層，一旦成為預設選項，就有了近乎永恆的黏性。

封閉讓少數人強大，但開放，才能讓所有人對你產生依賴。

主題四：從Google財報看Gemini的策略



最近社群媒體上嘲笑 Gemini 的梗圖越來越多了。

說實話，他們沒說錯。在純粹的前沿模型能力上，在長鏈條工具調用上，在 **agentic coding** 的指令遵循上，Gemini 確實落後於 Claude 和 GPT，甚至可能已經比不上其他的後來居上者了。

Pichai 自己在財報電話會上都承認了，Google 在 **agentic coding** 上「有點落後」。Gemini 3.5 Pro 從 I/O 大會承諾的六月時間表一路滑到「合作夥伴測試中」，這種跳票模式已經變成了一種敘事慣性。

所以，是的，**Gemini** 的前沿模型確實不夠強。這件事沒什麼好辯護的。

但事實上，**Google** 的精力並不完全在於產出最前沿的模型。

市場問錯的問題

華爾街和科技媒體最執著的問題是：「**Gemini** 是不是絕對的第一名？」每次 **Pro** 版本延遲，這個問題就被重新拿出來鞭一次。

這個問題本身沒有錯，但它預設了一個前提：純模型能力的排名決定商業勝負。

Google 內部顯然已經不這麼想了。翻開 **Q2** 財報電話會的紀錄，你會發現一個非常清晰的訊號。

Pichai 談論 **Gemini 4** 的預訓練時用了「十分進取」這個詞，態度認真，資本支出也確實砸下去了（全年指引上調到 1950 至 2050 億美元）。但整場電話會的重心，全部指向另一個方向：產品整合。

AI Overviews 和 **AI Mode** 合併成無縫的搜尋體驗，月活突破 10 億。**Gemini App** 達到 9.5 億月活，日活在一年內翻了三倍。**Ask YouTube** 在六月觸及 1.4 億用戶。搜尋營收年增 17%，達到 633 億美元。

Google 正在做的事情，用一句話概括：把模型變成調味料，撒進十億人每天已經在用的產品裡。模型是食材，搜尋、**YouTube**、**Workspace**、廣告系統才是那盤菜。

Flash 才是真正的中心

當大家都在盯著 **3.5 Pro** 什麼時候發布時，**Google** 卻在瘋狂地迭代、發布各種 **Flash** 變體（包括 **3.6 Flash**、**3.5 Flash-Lite**，以及針對網絡安全的 **Flash Cyber**）。

Pichai 在電話會議上直言：**Flash** 已經成為 **Google** 的「中流砥柱」。

- 前沿模型（**Pro**）：年薪百萬、能寫底層架構的「首席科學家」。
- 大眾模型（**Flash**）：月薪幾千、任勞任怨、隨叫隨到的「實習生」。

在 Google 眼中，真正驅動營收和用戶規模的，從來不是跑分最高的那個模型。是那個夠好、夠快、夠便宜、能塞進每一次搜尋查詢和每一次 **App** 互動裡的模型。

每分鐘 220 億 tokens 的 API 吞吐量（上一季是 160 億），這個數字背後跑的主要是 **Flash**，不是 **Pro**。9 百萬開發者每月在用 **Gemini** 建構應用，他們要的是性價比，不是排行榜上的小數點。

市場把注意力放在「**Gemini 3.5 Pro** 是否能追上 **Claude**」，但 **Google** 的營運重心放在「**Flash** 能不能讓每一次搜尋都多產生一個廣告曝光機會」。

當然，這不意味著前沿能力無足輕重。

Pro 的意義更多在於品牌光環與市場信心：它讓企業客戶在簽下多年合約時相信 **Google** 仍在牌桌上，讓頂尖研究員有理由留下來，讓華爾街不把「落後」兩個字寫進估值模型。

前沿模型是展廳裡那台概念車，負責讓人走進門。但每天真正開出停車場、產生營收的，是 **Flash**。

Gemini 的變現邏輯

很多人問：**Google** 的 **Gemini** 到底要怎麼收回這幾千億的投資？

在我看來：**Google** 從來沒打算把 **Gemini** 當成一個獨立商品來變現。

OpenAI 的商業模式是賣 **ChatGPT** 訂閱，賣 **API** 調用，賣企業方案。**Anthropic** 也是。他們需要公布 **ARPU**，需要追蹤付費轉化率，需要證明每一個用戶願意為模型本身掏錢。

Google 不需要。

Google 已經擁有一台每年印鈔超過兩千億美元的機器，叫做搜尋廣告。**Gemini** 在這台機器裡的角色，不是新產品，是升級包。

就像你不會問「**iOS** 更新怎麼單獨變現」，因為它的價值體現在讓整支 **iPhone** 更好用、讓你更離不開蘋果生態。

- **AI Overviews**：讓搜尋結果更豐富，用戶因此多搜了幾次，多點了幾個廣告。

- **AI Mode**：讓複雜查詢有了對話式入口，商業意圖更明確的提問變多了，廣告主的轉化率跟著上升。
- **Performance Max 與 AI Max**：讓投放更精準，ROAS 穩住了，廣告主願意加預算。

每一個環節，**Gemini** 都在幕後把搜尋廣告這台引擎的轉速往上催。它不需要自己出現在收銀台前。

直接的變現路徑確實存在：**Google One AI** 付費方案、開發者 **API** 用量、企業解決方案。但它們的體量和戰略優先級，跟「讓搜尋多賺一百億」比起來，是零頭。

這套邏輯有效嗎？搜尋營收 +17%，**Cloud** 營收 +82%（248 億美元，營業利潤翻三倍），後備訂單堆到 5140 億美元。初步答案是肯定的。

但市場想要更鋒利的證據：

- **AI** 到底帶來了多少「增量」查詢？
- 有多少傳統自然結果的點擊率被 **AI** 摘要吃掉了？

Google 的回應是「每週仍有數十億點擊流向網站」，語氣輕鬆，但這個張力在公開數據中始終沒有被完全化解。外部數據持續顯示，當 **AI Overviews** 出現時，傳統有機結果的點擊率的確在下降。

Google 說整體餅在變大，但切餅的刀法變了，有些人的那塊確實小了。

結語

Google 正在打一場跟市場認知不同的戰爭。

市場認為這是一場模型排名賽：誰的 **benchmark** 最高，誰的 **coding agent** 最強，誰就贏。在這個框架下，**Gemini** 確實落後，**Pro** 的延遲確實難看，人才流失確實令人擔憂。


但 **Google** 正在打的是一場分發與整合的戰爭。他們的賭注是：當模型能力持續壓縮、前沿差距逐漸收窄時，真正的護城河會回到「誰能把模型無縫嵌入十億人的日常行為中」。

搜尋、**YouTube**、**Android**、**Chrome**、**Workspace**，這些是 **OpenAI** 和 **Anthropic** 在短期內無法複製的分發基礎設施。

所有人都在問「**Gemini** 什麼時候追上 **Claude**？」

Google 真正在回答的問題是：「當模型能力變成水電煤，誰擁有最大的管網？」

主題五：Elon Musk 為什麼破天荒公開感謝美光？



Elon Musk 在 Q2 財報電話會上做了一件很不「Musk」的事：他公開感謝了美光（**Micron**）。

他說美光「在未來幾年為 **Tesla** 騰出了空間」，在記憶體價格「瘋狂到離譜」的環境下，以「合理的條件」保留了相當規模的產能分配。

Musk 是什麼人？是那個在供應鏈會議上把供應商罵到哭、動不動就威脅要自研取代的人。

這告訴你，**Elon Musk** 覺得需要公開維繫這段關係。

百年洪水，不是修辭

AI 訓練叢集和超大規模資料中心正在吞噬原本屬於消費電子和汽車的產能。

Hyperscaler 的採購量級讓所有其他買家都變成了小客戶。價格曲線的陡峭程度，Musk 自己的形容是「我見過任何東西裡最大的漲幅」。

在這種環境下，「拿到產能」和「拿到合理價格的產能」是兩件完全不同的事。後者需要關係、需要承諾、需要讓供應商相信你的未來量體值得他為你留位子。

Tesla 歷來不是 Micron 的頂級客戶。能在這種市場裡拿到優先長期分配，說明雙方在洪水來臨前互相綁定了：**Micron 賭 Tesla 的成長曲線，Tesla 賭 Micron 的產能承諾。**

Optimus 現在在哪裡

現實是，Optimus 目前的量體極小。

Fremont 的 Model S/X 產線已完全拆除，正在安裝 Optimus 第一代產線，「預計很快開始生產」。但首批產品不會賣給外部客戶，而是送入內部的「Optimus Academy」做訓練數據收集和軟體迭代。

德州 Gigafactory 的第二個量產點正在建設中。有意義的放量，更現實的時間點是 **2027 年夏天**。

Musk 反覆強調 Optimus 有將近一萬個獨特零件，幾乎所有東西都是新的，供應鏈要從零建起。他描述的是一條經典的製造業 S 曲線：前期漫長、平坦、令人沮惱。

換句話說，今天全球可能只有幾十台到幾百台 Optimus 存在。放在全球 DRAM/HBM 的需求圖景裡，這個數字連四捨五入的誤差都算不上。

沒有人在建這個模型

早陣子，Micron CEO 公開說過一個數字：一台人形機器人的記憶體需求，大約是一台 **L2+ 自動駕駛車的 10 倍**。

今天，沒有任何一家記憶體公司的分析師，在 2026 或 2027 年的需求模型裡放了一條「人形機器人」的項目。

為什麼？因為量體太小了，不值得建模。幾百台機器人乘以 10 倍記憶體，在全球 HBM 產能面前是一個可以忽略的數字。

但如果 S 曲線開始彎呢？

如果 2028 年是幾萬台，2029 年是幾十萬台，2030 年 Tesla 真的在談幾百萬台呢？

那個 10 倍乘數會把一個被忽略的變數，突然放大成一個跟 AI 訓練叢集和高階消費裝置爭搶同一塊產能的需求類別。

到那個時候，需要更新模型的不只是 Tesla 的單位成本表。整個記憶體產業的需求假設，可能要因為一個今天還不存在的市場而被重寫。

Terafab：連記憶體都想自己造

更值得注意的是 Tesla 的長期佈局。

Terafab（與 SpaceX、Intel 合作的自有晶圓廠計劃）的目標不僅僅是邏輯晶片。根據目前的公開資訊，記憶體製造也在其射程範圍內。

這才是關鍵。Tesla 過去對電池做過完全相同的事：先外購，同時自建產能，等到自研的 4680 電池成熟後逐步提高自給率。他們現在對記憶體採取的，是同一套劇本。

短期鎖 Micron 的外部產能，長期建自己的記憶體產線。這不是一家認為「記憶體短缺會隨景氣循環消退」的公司該有的姿態。

這是一家已經把先進記憶體視為長期結構性約束的公司，才會同時做兩件事。

真正的訊號

多數人把 Optimus 量產的漫長爬坡歸因於軟體成熟度、致動器可靠性，以及那一萬個全新零件。這些都是真的。


但 Tesla 的行動透露了另一層判斷：他們已經把先進記憶體，視為與上述問題同等重要的約束。

Musk 在產量還只有幾十台的時候，就公開感謝美光；同時又把記憶體放進 Terafab 的射程。這兩個動作合在一起，說明的不是「今天缺貨」，而是「我們預期這條曲線彎起來之後，產能會不夠分」。

當 S 曲線真的開始爬升，早一步鎖定長期分配的公司和臨時去搶現貨的公司，差別不會只是成本高低。在一個訓練叢集、高階消費裝置、實體 AI 同時爭奪同一塊矽的市場裡，差別是「有貨」還是「要等」。

Musk 很少公開感謝供應商。當他這樣做的時候，值得問一句：他到底在鎖定什麼？

主題六：Intel的業績應該怎樣看？



CPU 在 AI 基礎設施裡越來越關鍵，這件事市場已經消化了好幾個月。

代理式工作負載、複雜推理編排、大規模數據調度，讓 CPU 從 GPU 的配角重新變成有實質戲份的角色。大家都懂。

不過，懂是一回事，Intel 剛交出來的數字是另一回事。

2026 年第二季，單季營收 161 億美元，年增 25%，十五年以來最強的成長，比華爾街預期高出約 12%。數據中心業務年增 59%。Xeon 6 被管理層稱為 Intel 歷史上爬升最快的產品之一。

分析師已經把「AI 會拉動 CPU 需求」寫進模型，並調高預期，結果實際數字還是把那個調高過的預期再打穿了一截。

緊到什麼程度？

這次財報最關鍵的轉變，是 Intel 徹底擺脫了過去幾年「晶片賣不賣得出去」的生存質疑，直接進入「產能跟不上需求」的狀態。

執行長陳立武與財務長在法說會上明確表示：「強勁的需求，已經遠遠超出了我們不斷增長的供應能力。」

超出預期幅度達到 12%，在我看來，代表市場對需求強度的假設仍然偏保守：

AI 對 CPU 的拉動比預期更猛：

市場知道 AI 會帶動 CPU 需求，但 CPU 對 GPU 的比例到底會怎麼移動，假設仍然偏保守。

隨著代理式工作負載和推論編排複雜度上升，某些架構裡 CPU 的權重增加得比模型預估更快。Xeon 6 的爬升曲線陡到連 Intel 自己都說是歷史級的。

執行面跑贏了自己的計畫：

良率比預期好，生產週期比預期短，工廠產出超過原本指引的中位數。就算需求跟預期一樣多，光是「做出來」這個環節就貢獻了額外的量。

產品組合往上走：

高階 Xeon 配置賣得比低階多，專用矽晶片（包括客製化 ASIC）年增接近三倍。同樣賣一百萬顆，賣的東西變貴了，營收就自動多出一截。

多線業務全面超標：

客戶端（AI PC 帶動，年增 13%）和代工業務（年增超過 30%）也同時超標。當所有業務一起往同一個方向偏，超出預期的幅度就會疊加。

管理層因此把 2026 CapEx 上修到超過 200 億美元，2027 還會再明顯增加。

當然，市場現在看到「加速投資」就會反應負面，但在我看來長期協議與需求訊號已經夠明確，讓他們願意提前鎖定設備與無塵室。

Q3 指引：看起來像煞車，其實是油門踩到底了

Q3 營收指引落在 158 到 168 億美元，中位數約 163 億，跟 Q2 的 161 億幾乎持平。

乍看之下像動能放緩，但管理層講得很清楚：持平的原因是做不出更多。這條指引的上限，就是產能的天花板。

Intel 現在的指引邏輯是「我確定能交多少貨」，而不是「市場願意買多少」。

不過，在我看來，供給緊到這個程度，平均售價天然就有上移空間。

當客戶搶著要貨、交期拉長、長期協議在排隊，就算 Intel 刻意不大幅漲價，產品組合也會自動往高處走：高階配置賣得比低階多，折扣自然收掉，平均售價就被動上移。

我不認為 Intel 會大幅加價，因為他們還在轉型中段，還在撿回丟掉的市佔和客戶信任。

但我相信就算只是「適度」，在量被產能鎖死的季度裡，平均售價哪怕只往上走幾個百分點，營收就會跑贏那條看起來持平的指引。

這不需要需求再加速，也不需要產能突然爆發，只需要供需張力維持在 Q2 的水準。

Foundry：最諷刺的好消息

代工業務則呈現最諷刺的好消息。從技術與營運來看，進步是實打實的：

- 虧損收斂至 21 億美元。
- Panther Lake 生產成本今年內砍掉約 50%。
- 18A 製程出貨量季增超過 50%，良率與週期時間均超出內部預期。

然而，尷尬的地方也正在於此。目前 Intel Foundry 的營收中，外部客戶貢獻的比例依然只有可憐的 5% 左右（約 2.93 億美元）。

為什麼外部客戶遲遲無法放量？除了驗證需要時間，另一個隱性原因正是內部產能的排擠效應。

因為 Xeon 6 等 AI 伺服器 CPU 的需求實在太過火爆，Intel 必須把絕大多數的先進製程產能，優先拿來滿足自家。

這雖然用實績向外界證明了「**18A 製程跑高產量晶片完全沒問題**」，但同時也極大地限制了他們能分給外部代工客戶的產能空間。

大家要明白的是，Intel其實是兩家不同公司組成的，如何給它估值，視乎你怎樣看這兩家「公司」

這次財報在我看來，「產品公司」的地板明顯抬高，「代工公司」的時間表卻仍充滿不確定性。投資人現在必須決定，自己到底是在買一個已經被需求拉回來的 CPU 巨頭，還是在買一個還需要好幾年才能證明外部商業模式的代工挑戰者。

如何平衡「自家晶片賣翻」與「吸引外部代工客戶」，將是 Intel 下一階段最微妙的考驗。

溢出的需求會去哪裡？

Intel 交不出貨的時候，客戶自然看向第二來源。AMD 的 EPYC 在核心數、每瓦效能、記憶體頻寬上本來就有競爭力，Intel 交期一拉長，那些本來就在評估 AMD 的客戶就有了更多理由加速。

2026 年第一季，AMD 伺服器 CPU 的營收市佔接近 **46%**，創下新高。營收市佔遠高於單位市佔，代表 AMD 吃到的恰恰是高核心數、高單價的那一塊，也就是 AI 基礎設施裡最值錢的部分。

Intel 的數據中心業務年增 **59%**，說明他們在大口吃這塊餅；溢出來的部分，AMD 很可能會吃到更多。

Intel已經不是一年前那家公司

這個財報季最值得記住的，不是「CPU 在 AI 裡有角色」這件事。市場幾個月前就知道了。重點是程度。

就算你已經把 AI 對 CPU 的需求寫進了預期，實際數字還是能把預期打穿 **12%**。供給已經在跑贏自己的計畫了，需求還是追著跑。

一個被看衰了好幾年的公司，突然要煩惱的是產夠不夠、**capex** 該不該再加、定價籌碼要不要忍住不用。

一個被看衰好幾年的公司，現在最煩惱的已經從「有沒有人要買」變成「產能夠不夠、**CapEx** 該不該再加、定價籌碼要不要忍住不用」。

產品端的地板被這次財報實質抬高了；代工端則仍是一場需要時間與紀律的長跑。

謝謝你閱讀到這裡，如果你覺得這份筆記為你帶來了價值，請不吝按下一個讚，這是我持續分享的最大動力。

我在**Facebook**和**Threads**都有每天發佈當天對市場的觀察，大家也可以考慮追蹤我的社交媒體。

另外我在**Telegram**有頻道，每天早上我會發當天重要新聞摘要。

全部資訊在以下鏈結：

https://linktr.ee/fomo_soc

另外，如果你已經加入付費會員，不要浪費了群組的功能，進入我們**Substack**的**Chat**功能一起討論市場!

· KP

本機離線版本 · 圖片與內文完整

← 回索引

在原站開啟 ↗