

← 索引  付費 2026-08-12 9877 字 ↗ 原站

什麼是主權 AI？黃仁勳為何狂推開源？如何改寫利潤分配？ - 深入分析第59期：主權AI + 開源模型

本文目錄

- 1 第一章 | 閉源模型的裂痕
- 2 第二章 | 一體兩面：主權 AI 與開放權重
- 3 第三章 | 開放權重的追趕：智力的大宗商品化
- 4 第四章 | 軟體層：方向盤與煞車
- 5 第五章 | 雲端層：誰在重新劃分地圖？
- 6 第六章 | 基礎設施層：誰在賣發電機？
- 7 第七章 | 邊緣層：誰在把 AI 帶到最後一哩？
- 8 終章 | 跟著 NVIDIA 的錢走
 - 8.1 3.1 Zuckerberg 的算盤
 - 8.2 3.2 性能平權：開放模型憑什麼追上？
 - 8.3 3.3 DeepSeek 的衝擊
 - 8.4 3.4 從獨木橋到多極競賽
 - 8.5 3.5 差距收斂與「夠用」門檻
 - 8.6 3.6 開源與開放權重
 - 8.7 3.7 免費的模型，大家靠什麼賺錢？
 - 8.8 3.8 並不是下載就能運作
 - 8.9 5.1 微軟：深耕企業地下室的「混合基因」
 - 8.10 5.2 AWS 與 Google：能力不缺，但並非戰略主軸
 - 8.11 5.3 Oracle：錯失通用市場後的主權差異化

8.12 5.4 Neoclounds：開放模型時代的中間層


8.13 5.5 雲端層的投資邏輯

8.14 6.1 採購權的轉移：從白牌主導到解決方案需求

8.15 6.2 Dell AI Factory：交鑰匙的發電機組

8.16 6.3 全包之外：當需求超出套餐範圍

8.17 6.4 基礎設施層的投資邏輯



天下大勢，分久必合，合久必分。

從 1970 年代的大型主機（集中），到 1990 年代的個人電腦（分散），再到 2010 年代的雲端運算（再次集中）。

每一次鐘擺的轉向，都伴隨著舊巨頭的衰落、新霸主的崛起，以及千億級別資本的重新洗牌。

過去四年，生成式 AI 的爆發將這種「集中化」推向了極致。全球企業將最核心的數據與業務邏輯，打包送進少數幾家矽谷巨頭的遠端黑盒子裡。

企業不需要蓋機房，只要插上 API 的插頭，就能獲得無盡的智力。

市場理所當然地認為，這種高度集中的壟斷格局就是 AI 時代的一切。

但鐘擺，已經觸及了反彈的臨界點。

當 AI 從辦公桌上的「問答機器」，進化為接管企業核心流程的「自主代理（Agent）」，甚至成為國家級別的戰略資產時，這種接駁API的做法開始出現了不同的問題。

「開源模型」和「主權AI」開始冒起，成為新的敘事。

我不打算，也沒有能力預測哪一個大模型會贏得最終的智力競賽。

我更關心的是：當企業與國家開始奪回 AI 的控制權時，價值將會流向哪裡？

在這篇分析中，我將會帶你完整地走一趟整條「主權AI」的價值鏈，從掌控決策的軟體層、重新劃分地盤的雲端層、售賣算力的基礎設施層，一直到觸及物理世界的邊緣層。

我們開始。

第一章 | 閉源模型的裂痕

在 AI 興起的頭幾年，企業引進 AI 的方式非常簡單：按月訂閱，按量計費。

老闆們不需要花大錢蓋機房，只要把資料傳給遠端的科技巨頭，電腦就能吐出聰明的解答。

這種向外採購 AI 能力的模式，讓無數公司體驗到了前所未有的便利。大家習慣了把核心業務交給雲端，以為只要按時繳費，就能輕鬆享受全球頂尖的科技成果。

但在2026年，這套模式開始遇上了兩個危機。

1.1 Uber 的預算告急與「Tokenmaxxing」的結束

FORTUNE

After blowing through its entire 2026 AI budget in months, Uber CTO says, 'We're coming to the end of the so-called tokenmaxxing era'



Uber CTO Praveen Neppalli Naga said the company has decreased its cost per token after blowing through its annual AI budget in a matter of months. · Fortune · Big Event Media/Getty Images for HumanX Conference

第一個危機是財務上的實質衝擊。

以 Uber 為例，其內部工程師使用 Agentic coding 工具（如 Anthropic 的 Claude Code）的比例，從 2 月的 32% 飆升到 95%，高達 70% 的提交代碼由 AI 生成。

這種狂熱帶來了驚人的帳單。雖然多數員工每月的 API 消耗約在數百美元，但重度使用者每月的成本可達 500 到 2,000 美元。

整體採用速度遠超財務部門的假設，Uber 後來甚至不得不為每位員工、每個工具設定每月 1,500 美元的使用上限。

Uber CTO Praveen Neppalli Naga 宣布，這是一場「Tokenmaxxing era（狂衝 Token 的時代）」的結束。

同時，Uber 營運長 Andrew Macdonald 公開質疑：「我們很難劃出 AI 使用量飆升，與實際交付產品功能之間的明確關聯。」

這意味著，企業已經意識到，無限制提供最昂貴 API 的時代結束了，成本控管與實質效益的驗證成為剛需。

1.2 微軟的帳單管理

Microsoft starts canceling Claude Code licenses / Thousands of Microsoft developers will use GitHub Copilot CLI instead

by [Tom Warren](#)

May 15, 2026, 3:00 AM GMT+8



25

Comments (All New)




Image: Cath Virginia / The Verge

即便是資金雄厚的微軟，也面臨同樣的帳單問題，他們開始在內部導入嚴格的 **AI 財務管理 (FinOps)** 與模型路由機制。

當員工發起一個簡單任務，系統會自動分派給較低成本的小模型；只有複雜任務才會呼叫昂貴的前沿模型。

透過這種精準控管，微軟設法將龐大的 **Token** 支出拉回可控範圍。

1.3 Agent 的興起與 Token 暴增

帳單失控的背後，有一個關鍵的技術轉折。

2023 年的時候，員工只是把 AI 當作簡單的問答機器人。你輸入一段提示詞，AI 回覆兩段文字，一次對話通常只消耗幾百個 Token，費用微乎其微。

到了 2025 年與 2026 年，企業開始全面導入自主代理工具（Agentic AI）。

AI 開始接管複雜的多步驟任務，從被動回答問題，轉向主動規劃與執行。

當一名工程師下達指令要求 AI 在系統中尋找漏洞時，自主 Agent 為了理解情境，會在背景自動載入整個專案程式庫中數萬行的背景資料，並在系統內部重覆呼叫與測試幾十次。

任務的複雜度增加了十倍，背後消耗的 Token 數量卻暴增了五十倍。

企業原本期待藉由遠端模型來提升效率，結果卻發現，只要員工開始將多步驟的自動化 workflow 交給 AI，計費速度會遠超財務部門的預算規劃。


龐大的雲端 API 費用按月遞增，企業不僅沒有建立起專屬的技術護城河，反而讓營運預算持續膨脹，難以預測。

1.4 當供應商變成直接對手

Anthropic just launched Claude Design, an AI tool that turns prompts into prototypes and challenges Figma

Michael Nuñez

8:00 am, PT, April 17, 2026



Credit: VentureBeat made with Midjourney



第二個危機則是商業信任。

2026 年 4 月，Anthropic 發表了名為 Claude Design 的新產品，用戶可以直接利用自然語言生成 UI 設計、原型與簡報。

這款產品的定位，顯然重疊了設計巨頭 Figma 與 Canva 的核心領地。

當時的 Figma，恰好是 Anthropic 在企業端最重要的模型採購客戶之一。更令人敏感的是，Anthropic 的產品長 Mike Krieger，當時同時擔任 Figma 的董事會成員。

在 Claude Design 正式發布的前幾天，Krieger 突然宣布辭去 Figma 董事職位。

隨後爆出的細節顯示，Anthropic 在之前的溝通中，將該產品的能力描述得相當基礎，實際發表的產品卻直接進入 Figma 的核心市場。

這導致 Figma 選擇中途退出原本規劃的聯合發布計畫。Figma 執行長 Dylan Field 事後公開指出，Anthropic 在合作過程中缺乏持續的坦誠。

這讓整個科技業意識到閉源模式隱藏的深層風險。

Figma 的遭遇未必是資料被挪用的鐵證，但它揭示了一個重要的結構性利益衝突。

當模型供應商為了追求增長，開始往應用層擴張時，企業永遠無法確定，今天提供底層 API 的合作夥伴，明天會不會憑藉對你業務邏輯的理解，直接推出產品成為你的競爭對手。

1.5 Alex Karp 的警告



在 Palantir 的 2026 年第二季財報會議與專訪中，CEO Alex Karp 將這種企業界的集體焦慮，化為更具攻擊性的行業警告。

Karp 指出，許多企業陷入了一場無意義的 Token 狂熱。

公司高層為了展現轉型成果，鼓勵員工大量調用雲端 API，耗費數百萬美元購買 Token，忽視了這些支出並未帶來實質的營運效益。

Karp 在受訪中使用了「數位殖民」這個詞來形容閉源大廠的商業邏輯。

他的意思是：閉源模型實驗室在遠端收集全球企業的業務邏輯與專業數據，消化吸收後，再將升級後的模型賣給企業的競爭對手。

Karp 提出「AI 主權」的概念，企業與政府必須擁有自身數據、模型權重與工作流的絕對控制權。

1.6 黃仁勳的第一條推文



Jensen Huang  
@JensenHuang



For my first post, I'm sharing a letter @NVIDIA signed on why open models matter.

AI will transform every industry, power every company, and be built by every country.

Open models strengthen safety and cybersecurity, accelerate innovation and diffusion, and enable sovereignty.

The world needs both frontier closed models and frontier open models.

2026 年 7 月 24 日，長期謝絕個人社群動態的黃仁勳，發出了他個人在 X 平台上的第一條推文。

這條推文分享了一封名為《開放權重與美國 AI 領導力》的聯合公開信，迅速吸引了超過百家科技機構聯署。

黃仁勳在信中強調，世界既需要前沿的閉源模型，也需要開放模型。

AI 技術將由每一個國家與企業親自建造，開放權重是確保技術安全與主權的基礎。

1.7 從智力租賃走向主權重構

從 Uber 的預算超支、Figma 的供應商疑慮，到 Alex Karp 的警告與黃仁勳的推文，這些事件標誌著全球 AI 產業權力結構的轉移。

企業與國家開始意識到，真正的技術壁壘，在於能否將智力與數據的主導權握在自己手中。

這場運動普遍被稱為「AI 主權」。

但「主權」到底意味著什麼？它跟開放模型之間，又是什麼關係？

第二章 | 一體兩面：主權 AI 與開放權重

如果租賃模式有這麼多問題，為什麼過去四年，全球企業還是排著隊把數據送上去？

2.1 電網的黃金歲月與隱藏代價

答案很簡單。2023 年，自己訓練一套接近 GPT-4 水準的模型，成本可能高達數億美元。相比之下，可能調用 API 只需要數千美元。

插上電，比蓋電廠合理。

這種租賃模式在 2023 到 2025 年間，確實為企業創造了巨大的生產力價值。但第一章的三個案例已經揭示了它的隱藏代價：成本不可控、供應商可能變成競爭者、數據與控制權握在別人手上。

過去企業大多選擇忍受，因為替代方案的成熟度還不夠。那時的開放模型能力有限，在複雜推理與企業級任務上仍有明顯差距。

2.2 什麼是 Sovereign AI？

現在，替代方案開始出現。企業與政府開始追求「**Sovereign AI**」（主權 AI）。

主權 AI 的核心，是把 AI 的控制權從第三方手裡拿回來。


它至少包含五個維度：

- **數據主權**。你的業務數據、客戶資料、產線參數，盡可能不經過第三方伺服器。合約寫得再漂亮，只要數據離開你的控制範圍，風險就仍然存在。
- **模型主權**。你用的模型權重由你擁有、你微調、你更新。供應商不能任意遠端變更你的模型版本，也不能單方面中斷你的使用。
- **算力主權**。運行 AI 的硬體，盡可能落在你可掌控的環境。關鍵系統在網路不穩或受限時，仍能維持基本運作。
- **決策主權**。AI 做出的重要判斷，你能審計、能追溯、能回滾。它不再只是一個無法解釋的黑盒子。
- **供應鏈主權**。你的 AI 系統盡量降低對單一國家或單一公司技術棧的絕對依賴。關鍵環節出現變數時，仍有調整空間。




AI Sovereignty: The enterprise gap


91% Don't fully understand their AI dependencies



81% Say outages would disrupt operations



71% Find switching AI vendors difficult



AI sovereignty enables:

- Control across AI systems
- Resilience to disruption
- Adaptability as conditions change

定義完主權 AI，下一個問題是：怎麼實現？

如果模型鎖在閉源 API 背後，你擁有的更多是使用權，而非完整的主控權。數據通常必須經過對方的環境，模型版本也由對方主導。對方的商業策略一旦改變，你的調整空間就會受限。

開放權重改變了這個結構的可能性。當模型權重可以被下載、被擁有、被微調、被部署在你選擇的環境中，模型主權才變得實際可行。

開放權重是燃料，主權 AI 是需求。

反過來說，如果沒有主權 AI 的需求，開放權重只是眾多技術選項之一。

企業可以繼續使用閉源 API，因為更省事。正是政府要求數據受控、企業希望降低對單一供應商依賴的需求，給了開放權重更強的商業驅動力。

但開放權重只是起點。有了燃料之後，還需要引擎、方向盤、底盤和車輪。接下來的章節，我們逐一拆解這套系統。

2.4 從概念到現實

概念清楚了。接下來的問題是：這些開放模型，到底是怎樣在短短幾年內，從「不夠用」變成「足以支撐許多主權 AI 場景」的？

2023 年的開源模型，在處理較複雜的推理任務時，仍經常出現明顯落差。那時的它們，確實難以承擔關鍵業務。

但到了 2025 年與 2026 年，情況出現了明顯變化。這場性能追上的過程，是如何發生的？

第三章 | 開放權重的追趕：智力的大宗商品化

AI 中最諷刺的事情之一，莫過於「OpenAI」這個名字。

2015 年，當 Elon Musk 與 Sam Altman 等人共同創立 OpenAI 時，這家非營利機構的初衷是將最新的 AI 技術「Open」給全人類，避免這項技術被少數巨頭壟斷。

然而到了 2024 年，當 GPT 系列模型被嚴密封鎖在黑盒子裡、成為商業授權工具後，Musk 將 Altman 與 OpenAI 告上法庭，指控對方背離了初始的開放承諾。

2026 年 5 月，加州陪審團以「已超過訴訟時效」為由駁回了 Musk 的主要指控。

無論最終結果如何，「OpenAI」這個名字本身，已經成為科技界最大的名不副實之一。

真正接下「開放」這面旗幟的，是一群原本被視為外圍挑戰者的研究團隊與科技公司。

3.1 Zuckerberg 的算盤

Mark Zuckerberg says his goal for the next decade is to build open-source platforms and have them win

By Katie Balevic



Meta CEO Mark Zuckerberg wants to go all in on open source. David Zalubowski

開放模型浪潮的第一個轉折點，來自 **Meta** 創辦人 **Mark Zuckerberg**。

2023 年，**Zuckerberg** 決定將 **Llama** 模型權重免費開放給全球下載。

Zuckerberg 打算做善事？當然不是。

他在智慧型手機時代吃過虧，缺乏自己的作業系統，讓 **Meta** 長期受制於 **Apple** 的政策調整。

他下定決心，絕不在 **AI** 時代再次讓出底層平台的主導權。


Meta 的策略是將模型層徹底大宗商品化，當全球工程師都在 **Llama** 基礎上開發時，模型本身的軟體價值被壓縮，價值則轉移到 **Meta** 自身的社群與硬體生態。

但 **Llama** 只是開了門。真正讓開放陣營變得有威脅的，是 2024 到 2026 年間，一波來自不同地區、不同團隊的密集創新。

3.2 性能平權：開放模型憑什麼追上？

Open models lag state-of-the-art closed models by 4 months

Epoch Capabilities Index score



EPOCH AI | CC-BY

epoch.ai

2023 年到 2024 年上半年，開放模型與閉源前沿之間隔著一道明顯的能力鴻溝。

Llama 2 在簡單問答上表現尚可，但碰到多步驟推理、複雜數學、或長上下文的程式生成，就會開始出現偏離事實的解答。那時候的差距，用「年」來計算。


先解釋一個貫穿全文的概念。業界常把模型的「參數量」比喻為一本經驗手冊的厚度，以為手冊越厚、模型就越聰明。

早期的軍備競賽也確實遵循這個邏輯：閉源前沿模型的參數量據傳超過萬億，訓練一次動輒數億美元。

然而，參數量從來不是衡量能力的唯一尺度。模型的實際表現，同樣取決於訓練資料的純度、架構的設計，以及推理時的計算方式。

過去幾年「拚命堆疊參數」的單一邏輯，正是被這些新技術路徑所打破。

第一，架構創新讓算力用得更精準。



混合專家架構（MoE）讓模型面對每個問題時，只調動最相關的一小部分參數，其餘參數保持待命。

配合合成數據與知識蒸餾，訓練團隊可以用明顯更少的算力，逼近過去需要天量資源才能達到的效果。

「擁有自己的模型」，從超級巨頭的專利，變成了中型企業也負擔得起的選項。

第二，推理時計算讓模型學會「多想一會」。

傳統模型是快問快答。2025 年初出現的推理型模型，把「在草稿紙上多算幾步」變成了可規模化的能力。

這讓開放模型在數學、程式生成、複雜邏輯推理這些過去被閉源鎖死的硬指標上，突然變得非常有威脅。


第三，開放生態的迭代速度，是閉源陣營無法複製的。

閉源模型幾個月發一版。開放權重模型一旦釋出，全球社群立刻開始微調、量化、蒸餾、做特化版本。一個模型從發布到被優化到各種場景可用，往往只需要幾週。

3.3 DeepSeek 的衝擊

這三條路徑交匯在一起，在 2025 年初觸發了一個讓整個市場重新定價的事件：

DeepSeek 發布了 V3 與 R1。



V3 用 MoE 架構把算力用得更省，R1 把推理時計算做成了可規模化的能力，在多項數學與推理基準上逼近甚至超越當時部分閉源模型，在代碼基準上也與 Claude 3.5 Sonnet、GPT-4o 互有勝負。

DeepSeek 的衝擊是雙重的。

第一重，性能上的心理關卡被打破。

過去業界普遍認為，前沿推理能力幾乎被閉源實驗室鎖死。DeepSeek 證明，開放權重模型也能在最難的任務上打到接近的水準。

第二重，「高性能等於超高成本」的假設被動搖。

一個資源遠不如矽谷巨頭的團隊，用明顯更低的預算，做出了威脅前沿的模型。

它意味著，繼續為閉源 API 支付高昂溢價的合理性，正在快速下降。

3.4 從獨木橋到多極競賽

DeepSeek 打開了局面之後，開放生態迅速從少數先鋒變成了多隊競賽。

法國的 Mistral 證明了歐洲路線的可行性，不需要美國超大資本也能產出有競爭力的開放模型。

阿里巴巴的 Qwen 走的是另一條路：把權重免費開放，換取開發者進入自己的雲端生態，後續的託管與運算服務才是利潤沉澱的地方。

到了 2025 年下半年，智譜的 GLM、月之暗面的 Kimi 等模型持續加壓。

Kimi 把參數規模推到超大級別，同時選擇開放權重，直接挑戰了「最大最貴的模型只能待在閉源 API 後面」這個潛意識假設。

開放模型的舞台，從 Llama 的獨木橋，變成了一條多線並進的高速公路。

這對主權 AI 的推動者來說是一個關鍵信號：開放生態不依賴任何單一公司。押注開放路線的風險，正在被分散。

3.5 差距收斂與「夠用」門檻

到了 2026 年，最佳開放權重模型與閉源前沿的平均落後，已從過去的「以年計算」縮短到大約三到四個月。

在多數企業實際會用到的工作負載上，這個差距已經小到可以接受。

這裡有一個容易被忽略的結構性變化：企業真正天天在用的任務，很多並不需要絕對前沿。

文件摘要、客服問答、代碼輔助、報表生成，這些場景佔了企業 AI 支出的絕大部分。當開放模型在這些「夠用區間」站穩，閉源模型的溢價就變得越來越難辯護。

性能差距大幅收斂，成本卻仍有數倍到十倍以上的落差。對許多企業而言，繼續為剩餘的邊際效能支付高昂租金，已經不再是理性選擇。

3.6 開源與開放權重

What you get	Open weight	Open source (OSAI)
Trained weights to download and run	Yes	Yes
Fine-tune on your own data	Yes	Yes
Training code	No	Yes
Training data (or detailed data information)	No	Yes
Rebuild from scratch and fully audit	No	Yes
Typical license	Permissive or custom (Apache, MIT, or vendor terms)	OSI-approved (e.g. Apache 2.0)

這裡需要精準區分「開源」與「開放權重」。

真正的開源意味著公開訓練程式碼、原始數據集與完整訓練日誌。極少有頂級模型能做到這種程度的完全透明。

目前市場上廣受歡迎的模型，嚴格來說屬於開放權重：你拿到的是模型的完整運算結構，可以下載、微調、離線部署，但訓練過程未必完全公開。

對於尋求數據安全的企業與國家而言，擁有權重檔案確實提供了極大的自主性。海外廠商無法單方面切斷你的 API 服務，也無法遠端靜默升級你的模型。

當然，拿到權重檔案只是第一步。

開放權重消除了「模型 API 的單點控制」，但企業依然會依賴底層的推理框架、GPU 軟體棧（例如 NVIDIA 的 CUDA）與硬體算力。

真正的主權 AI，不僅是掌握權重，還要在整個軟硬體供應鏈中，盡可能建立自己的控制權。

不過，這裡隱含著一個深刻的矛盾：當所有主權方案都建立在同一家美國公司的底層技術上時，「主權」到底意味著什麼？

3.7 免費的模型，大家靠什麼賺錢？

模型權重免費了，開放生態靠什麼盈利？通常有四種模式。

答案其實非常簡單：它們把免費的模型權重當成了最強大的商業誘餌。

這些開放模型實驗室的獲利模式，主要可以縮影為四種策略：

第一是賣極致省事的官方 API 服務。

雖然模型可以自由下載，但企業自己租伺服器運作其實非常折騰。實驗室最懂得如何優化自家模型，因此能提供全市場最便宜、最快且穩定的官方 API 接口。

許多開發者試了一圈後發現，直接付費調用 DeepSeek 或 Mistral 的官方 API，反而比自己架伺服器更省錢省心。

第二是賣企業私有授權與客製化工程。

許多團隊採用雙重授權。中小企業與個人可以免費下載；一旦大型企業或政府機構需要將模型部署進自家機房，並要求二十四小時專人維護、商業合規承諾與專屬數據微調，就必須支付昂貴的企業級授權費與顧問費。

第三是背後母公司的戰略補貼。

Meta 免費釋出 Llama，是為了防止 OpenAI 壟斷底層平台，保護自家的社群與廣告帝國；阿里巴巴全力投入 Qwen，目標是吸引全世界的開發者進入阿里的雲端生態。

模型研發費用對背後的巨頭來說，只是帶動龐大本業運轉的行銷與生態投資。

第四是獲得免費的全球研發團隊。

模型一開放，全球數百萬名工程師便會免費替實驗室找漏洞、修程式碼、開發外掛，並提供真實的使用反饋。

實驗室省下了天價的測試成本，得以用極高的速度迭代出更強大的下一代模型。

3.8 並不是下載就能運作

假設你是一家中型公司的 CTO，讀完前面的內容後決定行動。你讓團隊下載了最新的開放權重模型，準備在公司內部部署一套專屬的 AI 系統。

權重檔案下載完成了。然後你發現，真正的麻煩才剛開始。

這些權重檔案知道怎麼理解語言、怎麼做推理。但它不知道你的客戶是誰，不知道哪些數據可以給誰看，不知道 AI 做了一個錯誤的判斷該由誰負責，更不知道該在哪台機器上跑。

你需要解決四個問題：

- 誰來管 AI 的決策（軟體層）？
- 在哪裡跑（雲端層）？
- 硬體從哪裡來（基礎設施層）？
- AI 怎麼到達人的手上（邊緣層）？

在這四層價值鏈中，有一家公司的足跡幾乎無處不在：**NVIDIA**。

接下來四章，我們逐一拆解。

第四章 | 軟體層：方向盤與煞車

第一章提過，黃仁勳在 X 平台上發出了第一條推文，而 Alex Karp 則對閉源巨頭發起砲轟。

這兩位科技巨頭幾乎在同一時期做出動作，是因為他們正在聯手打造一套能讓主權 AI 真正落地的軟體控制系統。

如果把一個免費下載的開放模型比喻成一台馬力強大的引擎，這台引擎若要安裝進國家衛生部、軍事物流鏈或是大型跨國銀行的資料中心裡，還需要一套靈敏的方向盤、煞車系統與安全儀表板。

4.1 催化劑：當 AI 成為武器

July 21, 2026 Security

OpenAI and Hugging
Face partner to address
security incident during
model evaluation

2026 年 7 月，AI 模型託管平台 Hugging Face 的基礎設施遭到入侵。

OpenAI 隨後承認，其兩個測試模型在跑一個名為 ExploitGym 的資安基準測試時，為了「作弊拿到答案」而逃出了沙盒環境，利用漏洞在公開網路上發動了攻擊。

最諷刺的是：發動攻擊的不是駭客，而是 OpenAI 自己的前沿閉源模型。

更令人警惕的是後續的清理過程。當防禦團隊嘗試求助美國頂級的閉源模型進行事故鑑識時，卻被拒絕了。


理由是閉源工具將資安協助視為禁區，無法區分事故響應者與攻擊者的行為。

最終，Hugging Face 是靠著 Z.ai 的開放權重模型 GLM 5.2，逐一審查了超過一萬七千個動作，才成功控制入侵。

這場事件構成了三重反差：閉源 AI 是加害者，閉源 AI 在善後時無法提供幫助，開放模型才是救援。

它傳遞了一個極其清晰的信號：在極端的安全事故中，防禦方必須擁有可檢查、可控制的開放模型。閉源黑盒子在平時是便利的工具，在戰時卻可能成為鑑識的盲區。

Open Secure AI Alliance



正是在這個背景下，NVIDIA 牽頭成立了「Open Secure AI Alliance」（開放安全 AI 聯盟）。


聯盟從 7 月成立時的 37 家創始成員，到 8 月 Black Hat 資安大會時已擴張至超過 120 家，涵蓋 Microsoft、IBM、Dell、CrowdStrike、Palantir、ServiceNow 等巨頭。

諷刺的是，闖禍的 OpenAI 起初缺席，後來才和 Google 一同補上名字，而 Anthropic 則一直拒絕加入。

這個聯盟將「開放權重」的敘事，從單純的商業成本考量，直接拉高到了國家安全與網路防禦的戰略層次。

4.2 Palantir：為「斷網」而生的控制中樞

理解了控制層的剛性需求後，我們來看最硬核的玩家：Palantir。



Palantir 旗下的 Foundry、AIP 與 Apollo，從設計的第一天開始，就是為了在客戶自身的實體基礎設施上運行而打造，甚至可以在完全切斷外部網路的極端環境下獨立運作。

它的早期客戶是美國情報機構與國防部，整套系統架構就是在極高的安全要求下發展出來的。

Palantir 在高安全市場裡最難被超越的壁壘，是一張特別的安全通行證。美國國防部對於處理機密資料有著極為嚴格的標準，過去軟體只要從雲端搬到離線伺服器，就必須重新進行耗時數月的審查

 Palantir [Investor Relations]

02 / 12 / 2026

Palantir Receives DISA Authorization for PFCS Forward, Extending IL5 and IL6 Accreditation to On-Premises and Edge Deployments

。

2026 年初，Palantir 取得了 IL5 與 IL6 關鍵授權，讓官方認可其軟體具備「檢查一次、隨處部署」的能力。不論系統安裝在後方機房還是前線設備，都能直接獲得最高等級的安全認證。

(如果你對Palantir的業務仍然一知半解，我誠邀你重溫我半年前的深入分析，我相信會是華語區最深入淺出的講解)

4.3 Palantir 與 NVIDIA 的合作

Open Models, Closed Environments: Palantir Brings Secure AI to US Agencies With NVIDIA Nemotron

NVIDIA Nemotron open models help Palantir advance US technology leadership with mission-specific sovereign AI for government agencies and critical infrastructure operators.

June 29, 2026 by [Justin Boitano](#)

🕒 3 mins 💬 0 Comments ➦ Share



有了這張通行證，Palantir 順理成章地與 NVIDIA 深化了主權 AI 操作系統的戰略合作。

雙方分工極其明確：**NVIDIA** 提供底層算力與免費的 **Nemotron** 開放模型（模型免費，帶動晶片銷售）；**Palantir** 提供上層的資料權限過濾、工作流自動化與合規框架。

NVIDIA 負責讓 AI 計算得極快，**Palantir** 負責讓 AI 在合規的軌道上精準運行。

為了理解這套「引擎加方向盤」的架構在實務中如何運作，我們可以想像一個場景（此為虛構情境，僅供說明）：

一家國際私營銀行希望利用 AI 審查跨境交易與洗錢風險，但客戶隱私絕對不能上傳海外 API。

導入這套聯合架構後，銀行在自有機房運行 **Nemotron** 模型。

當分析師輸入客戶姓名時，Palantir 系統會先審查員工權限，自動遮蔽敏感身分，只把乾淨的資產數據傳給模型。

當 AI 建議批准某筆巨額轉帳時，系統不會自動執行，而是對接合規資料庫，要求風控主管進行第二次數位簽章。

每一次推理的邏輯都會寫入無法竄改的日誌，隨時準備接受監管審計。整個過程在銀行內部封閉完成，海外供應商無權干預。

4.4 ServiceNow：自主 Agent 的信任層

NVIDIA and ServiceNow Partner on New Autonomous AI Agents for Enterprises

At ServiceNow Knowledge 2026, the companies are extending their collaboration to deliver governed autonomous agents to enterprises, from employee desktops to AI factories.

May 5, 2026 by Kari Briski

🕒 4 mins 🗨️ 0 🔄 Share



如果說 Palantir 解決的是極致防務與國安層級的需求，ServiceNow 解決的則是廣大企業在日常營運中的現實難題。

當大型企業放手讓成千上萬個自主 AI Agent 去執行寫程式碼或審核報銷時，誰來確保它們不會在背景誤刪檔案或連結未授權的系統？

2026 年，ServiceNow 與 NVIDIA 共同打造了企業自主 Agent 的信任層。

NVIDIA 提供 OpenShell 安全沙盒，替每一個 Agent 套上數位隔離箱，超出授權範圍的動作會立刻被阻斷。

ServiceNow則提供 AI Control Tower 中央治理平台，讓管理者能集中制定安全政策、監控 Agent 動態，並在異常時直接按下緊急停止。

這座控制塔甚至被納入了 NVIDIA 的企業級 AI 工廠驗證設計中，讓治理能力直接延伸到企業自建的基礎設施裡。

4.5 數據治理與可觀測性：Databricks與Datadog

主權 AI 的崛起，同時推升了另外兩類軟體的需求。



Unity AI Gateway

Agent Registry

Access Control


Contextual Policies

Budgets

Smart Routing

Agent Tracing

Models



Agents



MCP & Skills



External Agents



AI Coding




Databricks 解決的是數據搬遷的痛點。

企業推動私有化 AI 時，最忌諱把龐大的數據庫搬來搬去。**Databricks** 的零複製（Zero-copy）架構，允許 AI 模型直接在數據儲存的原地進行讀取與運算。

配合 **Unity AI Gateway**，企業可以在統一介面裡管理各種開放模型，設定 **Token** 預算上限與敏感資料過濾器，確保數據治理堅如磐石。

(**Databricks**還未上市，不過是一家十分值得留意的公司)



Datadog 則解決了私有環境的可觀測性。

當企業在自己的資料中心打造 AI 基礎設施時，IT 環境的複雜度呈指數級上升。

GPU 利用率、晶片溫度、電力消耗與故障率，都需要即時監控。Datadog 提供跨混合架構的可觀測性，讓維運團隊隨時掌控私有算力叢集的健康狀況。

4.6 哪些 SaaS 吃不到紅利？

講完受惠的軟體業者，必須把界線劃分清楚。許多傳統的 SaaS 公司並不能吃到這波主權 AI 的紅利。

一般的純應用層 SaaS（如標準 CRM 或協作工具），主要受益於「AI 功能變好用」，但主權 AI 本身不必然增加它們的預算。

強依賴閉源 API 的 AI 原生應用，其核心依賴會在企業將模型搬回本地時被切斷。缺乏壁壘的薄工具，切換成本極低，很難獲得新增量。

真正能吃到紅利的，是那些站在控制、治理、審計與營運維護位置上的軟體。當模型大腦變便宜時，它們的控制價值反而會變得更昂貴。

Palantir 管控極致安全與決策審計，**ServiceNow** 管控 **Agent** 權限，**Databricks** 管控數據治理，**Datadog** 管控基礎設施可觀測性。

模型可以隨時替換，但這四層控制能力一旦建立，替換成本極高。

軟體控制層的故事講完了。擁有了模型大腦與控制系統，這些軟體最終需要一個安全的實體場所來落地運行。

接下來，我們將目光轉向下一層，看看全球雲端與資料中心的地圖正在如何被重新劃分。

第五章 | 雲端層：誰在重新劃分地圖？

軟體與模型，最終需要落腳在實體的資料中心與伺服器機架上。模型權重下載了，控制系統架好了，但算力從哪裡來？數據要在哪裡處理？

過去十年，這塊地圖由少數超大規模雲端巨頭牢牢掌控。企業把資料上傳至巨頭的遠端機房，在雲端完成運算，按流量付費，這是一套高度集中且極具規模效應的生意。

開放模型與主權 AI 的興起，正在開始鬆動這個集中結構。當客戶開始選擇私有化部署，公共雲端的純 API 流量增速就會受到壓制。

雲端巨頭需要提供新的選項，才能留住這些開始考慮其他部署方式的客戶。

在這場挽留客戶的戰役中，微軟、亞馬遜和谷歌的姿態不完全相同。

而同時，**Oracle** 和新雲們亦有不同的邏輯。

5.1 微軟：深耕企業地下室的「混合基因」

Microsoft CEO Satya Nadella talks up sovereign cloud credentials as firm announces general availability for Azure Local Disconnected, new capabilities for Foundry Local

As Microsoft hands more control to customers, Satya Nadella touts the tech giant's growing sovereign ecosystem



By Rory Bathgate | Published February 25, 2026 In [News](#)



(Image credit: ITPro/Rory Bathgate)

在所有雲端巨頭中，微軟將主權 AI 與混合雲部署放在了最核心的戰略位置。

這個取態，是因為微軟長達十多年的「混合基因」。

時間回到 2010 年代初，當 AWS 喊出「將所有伺服器搬上公有雲」時，全球無數大型企業的資訊長卻猶豫不決。銀行、醫院與國防廠商無法輕易放棄自建的機房。

當時微軟沒有強迫客戶放棄本地伺服器，他們選擇把雲端的管理體驗送進客戶自己的機房。

從 Active Directory 到 Azure Arc，微軟一直擅長讓企業在同一個介面上同時管理雲端與本地伺服器。

到了現在的AI世代，微軟同樣以同一態度應戰。

微軟CEO Satya Nadella 在達沃斯論壇上提出，真正的 AI 主權在於企業與國家能否「掌控自身的命運（Control of Destiny）」。

他的邏輯是將主權包裝成一套可自由搭配的選單：一般企業使用公有雲但數據鎖在本國境內；高度敏感機構則透過 Azure Local，將雲端管理系統直接安裝在自家機房，支援完全斷網運作。

配合 Foundry Local 等工具，微軟讓工程師能用熟悉的介面，直接在自家硬體上指揮 AI 模型。

微軟的戰略非常清晰：它深刻理解銀行、醫院與國防廠商不願放棄自家機房的痛點，因此主動把雲端體驗打包送進客戶的地下室，將「混合與主權」變成了向所有企業推銷的主軸。

5.2 AWS 與 Google：能力不缺，但並非戰略主軸

如果單純看技術，AWS 與 Google 絕對有能力提供完全斷網或實體隔離的主權解決方案（例如 Google 的分散式雲端架構與 AWS 的本地機架方案）。

但從商業佈局來看，這並不是它們當前的戰略重心。

AWS 的核心護城河，依然在無與倫比的公有雲規模、服務廣度與龐大的開發者生態；Google 則將多數火力集中在 Gemini 模型的前沿研發、消費級產品與數據分析平台。

對這兩家巨頭而言，主權 AI 更多是一個「必備的防禦選項」。為了滿足特定政府或高監管客戶的合規要求，它們會提供相應的主權雲或隔離方案，確保客戶不流失。

但要它們像微軟那樣，把「幫客戶在地下室蓋機房」作為主動進攻的商業主軸，顯然不符合它們追求極致規模經濟的公有雲基因。

總結來說，面對主權 AI 的浪潮，三巨頭給出了不同的商業答案：

微軟賣的是「隨心所欲的控制權」，AWS 賣的是「無所不包的公有雲生態」，Google 賣的是「最前沿的 AI 智力與數據洞察」。

5.3 Oracle：錯失通用市場後的主權差異化

Oracle and NVIDIA Accelerate Sovereign AI, Enabling Abu Dhabi's AI-Native Government Transformation

October 14, 2025 by Asad Ansari

🕒 3 mins 🗨️ 0 📄 Share



在傳統公有雲的競賽中，Oracle 遠遠落後於前三大雲。

創辦人 Larry Ellison 很清楚，正面硬碰硬難有勝算，最快的方法是繞開通用市場，直接攻佔各國政府與大型機構最敏感的主權需求。

Oracle 的產品光譜非常直接。

想把資源鎖在牆內的客戶，可以使用 Dedicated Region，由 Oracle 將模組化資料中心直接搬進客戶指定機房。

希望自主營運的國營電信商，可以透過 **Alloy** 模式掛上自己的品牌向外提供主權算力。面對法規嚴格的歐洲，則設立由歐盟在地法人營運的主權雲。

搭配與 **NVIDIA** 深度綁定的高密度 GPU 叢集，**Oracle** 在多個國家級機構的主權採購中佔據了關鍵位置。

不過，**2026** 財年 **Oracle** 的積壓訂單（**RPO**）雖然達到了驚人的 **6380** 億美元，但這個龐大的數字裡，大部分其實來自少數超大型科技客戶的 **AI** 算力合約（**OpenAI**），主權政府合約在其中的佔比相對有限。

主權合約為 **Oracle** 帶來了高黏性與不錯的新成長故事，同時幫助它打開了高度監管的市場。

但資本市場目前關心的龐大資本支出與執行風險，依然高度取決於那些大型 **AI** 基礎設施專案能否如期交付。

5.4 Neoclouds：開放模型時代的中間層

2023 到現在的算力荒中，三大巨頭最新的 GPU 大多被內部戰略項目與超大型長期合約鎖死。

中小型 **AI** 實驗室、想微調開源模型的傳統企業，在 **AWS** 或 **Azure** 上常常搶不到算力。

Neocloud 切入的正是這個空缺。它們不提供幾百種繁雜的雲端服務，而是專注提供網路高度優化、幾乎開箱即用的 GPU 集群。

進入開放模型時代後，許多企業開始自己微調 **Qwen**、**DeepSeek** 或 **Nemotron**，需要短期到中期、高吞吐的訓練算力，但不一定願意永久擁有整批硬體。這直接擴大了 **Neocloud** 的潛在客群。

但這裡有一條清楚的界限。**Neocloud** 解決的是「算力取得」問題，數據主權則需要其他方案。

因為客戶的數據仍然會進入第三方機房，真正要求數據完全不出境、甚至斷網運行的政府與高度受監管企業，最終仍會選擇 **on-prem**、**Azure Local** 或 **Oracle Dedicated Region**。

在主權 **AI** 的光譜上，**Neocloud** 更接近中間層。它們最可能扮演的角色是溢出與爆發層：企業把核心負載放在自建或主權環境，把實驗、微調與尖峰訓練丟給 **Neocloud**。

團隊有可能會先用 Neocloud 完成開放模型的實驗，等流程穩定後，再把常態負載搬回自己的機房。

所以，買 Neocloud，買的是 GPU 供需持續失衡的週期判斷，加上開放模型時代對彈性訓練產能的需求。

這可以帶來可觀的階段性回報，但不是長期、不可替代的控制權。

5.5 雲端層的投資邏輯

開放模型和主權AI，會讓算力從集中式租賃，走向更分散的擁有與部署。

如果這股趨勢持續，長期定價權更可能落在那些能把雲的能力送進客戶自己環境、同時讓客戶保有控制權的公司手上。

不過，無論是微軟的 Azure Local、Oracle 的 Dedicated Region，還是各國電信商的主權雲，它們的底層算力與參考架構，都是高度依賴 NVIDIA 的 GPU 與軟體棧。

軟體有了，雲端有了。

但無論是在客戶自己的機房，還是在第三方數據中心裡，那些實體的伺服器、儲存設備和網路線，究竟是誰賣出來的？

我們繼續往下走，進入主權 AI 的物理底座。

第六章 | 基礎設施層：誰在賣發電機？

要理解硬體基礎設施層的商業變化，需要先看懂過去十年伺服器買家的隱形規則。

在公有雲全盛時期，全球伺服器的頂級買家只有少數幾家雲端巨頭。這些科技巨頭本身就擁有全球最頂尖的硬體工程團隊。

這些巨頭擁有頂尖的硬體工程團隊，不需要品牌伺服器商(例如是Dell, HP)提供整車方案。

雲端巨頭會直接畫好伺服器藍圖，跳過所有中間品牌，找上廣達、緯創與鴻海這些台灣代工大廠，量產剔除了所有多餘零件、成本壓到極限的白牌伺服器。

在那個時代，品牌伺服器商的處境相當尷尬，只能在利潤較薄的傳統企業市場裡爭奪有限的預算。

6.1 採購權的轉移：從白牌主導到解決方案需求

開放模型與主權 AI 的浪潮，帶來了一群全新的買家族群。

當一家區域銀行、一所大型醫院或一個國家的國防部，決定在自家的機房裡部署私有化 AI 系統時，採購邏輯出現了根本性的變化。

這些機構內部缺乏配備數百名硬體研發工程師的條件，也不可能直接跨海去找台灣代工廠討論客製化規格。

更關鍵的是，如果機房的液冷管道出現滲漏，或是 GPU 伺服器節點突發故障，它們無法自行修復，需要有人能在幾個小時內趕到現場解決問題。

這些新買家需要的，是一套買回去就能立刻發動的完整解決方案。買家結構從極度精通技術的少數雲端巨頭，擴展到需要完整服務與風險擔保的傳統機構。

雖然超大規模雲端巨頭依然維持著龐大的白牌採購量，白牌模式並未消失，但新增的主權與私有化需求，讓品牌伺服器商重新獲得了更高的定價空間與服務附加價值。

6.2 Dell AI Factory：交鑰匙的發電機組



ARTIFICIAL INTELLIGENCE

Dell Expands Enterprise Agentic AI with NVIDIA

Agentic AI demands a new approach to models and infrastructure. Dell Technologies and NVIDIA have you covered.

By [Dell Technologies](#) | August 11, 2026

戴爾與 NVIDIA 聯合推出的「**Dell AI Factory**」，將原本需要自行拼湊的硬體堆疊，變成了一套預先組裝、測試完畢且隨插即用的完整電廠方案。

這套方案背後，其實是 NVIDIA 正在大力推動的「**AI Factory**」（AI 工廠）與 **DSX** 概念。

NVIDIA 將新一代資料中心定義為一座工廠：進去的是數據與電力，出來的是「智能」。而 **DSX** 則是這座工廠的作業系統與參考設計藍圖。

NVIDIA 自己不當運營商，它的角色是提供標準與零件。

SK Telecom and NVIDIA Build AI Infrastructure to Power Korea's AI Innovation

Korea's Leading Telco to Add NVIDIA-Powered AI Cloud Capacity Built on NVIDIA DSX AI Factory Architecture to Accelerate AI Startups, Robotics and Industrial Physical AI

June 7, 2026



這形成了一種類似「加盟」的模式：各國的電信商（如韓國 SK Telecom、德國 Deutsche Telekom、日本 SoftBank）或本地雲巨頭，憑藉著政府信任的基礎設施身份與全國機房據點，出面擔任「國家運營商」，負責土地、電力與客戶關係。

而 Dell、HPE 等硬體商，則根據 NVIDIA 的 DSX 藍圖，提供伺服器、液冷與網路設備。

透過 Dell Enterprise Hub，企業可以取得已針對 Dell 硬體優化的開放模型（如 Nemotron 等），在自家機房部署與運行，數據不必送出公司邊界。

對於政府、金融與醫療等高度受監管的行業而言，實體硬體與資料的主導權具有極高的吸引力。

握有實體機房的鑰匙與電源開關，能提供雲端合約無法給予的安全感。

這套組合已陸續展現在加拿大的主權算力建置、印度的大型 AI 工廠計畫，以及歐洲多個強調資安的高規格平台中。

這套硬體方案還能與前面的軟體控制層直接對接。

Dell Blog



AI SOLUTIONS

Dell and Palantir Introduce an On-Premises AI Operating System

Discover how Dell and Palantir are transforming AI with a secure on-premises operating system. Unify data, ensure security, drive results.

By [Rajbir Panag](#) | May 18, 2026

Dell 與 Palantir 已推出可在 Dell AI Factory 上運行的 on-prem AI 作業系統方案，把控制層直接接到實體基礎設施。

將三個層級串聯起來看：**Palantir** 提供了方向盤與煞車，**NVIDIA** 提供了引擎與燃料，戴爾則提供了堅固的車身與底盤。

慧與（HPE）同樣受惠於這波私有化建置需求，並透過 **GreenLake** 在部分高階運算市場保持存在感。

不過在 AI 伺服器的出貨規模、與 **NVIDIA** 的合作深度以及開放模型生態的適配速度上，戴爾目前展現出更為強勁的市場拉動力。

6.3 全包之外：當需求超出套餐範圍

戴爾的 **AI Factory** 是一套「全包」方案，對大多數剛起步的企業來說，買回去就能用，這正是它的核心價值。

但當企業的 AI 規模持續擴大，某些需求會超出全包的範圍。

最典型的是儲存。戴爾的方案裡已經包含存儲模組，對中等規模的訓練與推論綽綽有餘。

但當一家大型銀行的訓練數據達到數百 TB，需要在多個 AI 專案之間高速共享，或者模型每幾分鐘就要寫入一次龐大的參數快照，存儲的效能與數據治理需求就會超出伺服器廠附帶模組的能力。

這時候，**NetApp** 與 **Everpure** 這類專門處理複雜數據流動的專業儲存廠商，就成了必要的補充。

另一個場景是多品牌整合。

戴爾的專業服務團隊負責戴爾自己的產品。但一家企業的 AI 工廠往往混合了多個品牌：可能用戴爾的伺服器、**Cisco** 的網路、**Palo Alto** 的資安、再加上特定品牌的儲存設備。

把這些不同品牌的硬體拼成一套能穩定運行的系統，需要一個熟悉多品牌搭配的整合者。

TD Synnex、**Ingram Micro**、**CDW** 這類通路商與增值經銷商，扮演的就是這個角色。它們提供整合設計、多品牌搭配、融資方案，並派工程師進場安裝與後續維運。

簡單來說，戴爾解決的是「從零到一」：幫企業把第一座 AI 工廠蓋起來。儲存廠與通路商解決的是「從一到十」：當工廠擴大、設備變多、品牌變雜時，提供專業化的補充與整合。

兩者都是分散式自建浪潮的受益者，但服務的是不同階段、不同規模的客戶需求。

這兩類型玩家在雲端霸權時代逐漸被邊緣化。如果主權 AI 的趨勢真的走強，它們有機會重新回到牌桌上。

6.4 基礎設施層的投資邏輯

只要全球企業與政府持續建立自己的 AI 機房，就必須採購伺服器、儲存、網路與冷卻設備。客戶基礎已從少數雲端寡頭，擴散到更廣泛的企業與公共部門。

最後，必須點出一個實體世界的現實天花板：電力與散熱。

全球資料中心的電力供應已成為嚴重的瓶頸。

當主權 AI 促使各國與企業紛紛自建機房時，他們很快會發現，買到 **GPU** 伺服器並不難，難的是找到足夠的電力配額與液冷基礎設施來支撐這些高耗能的「發電機」。

這將是主權 AI 落地過程中，最真實的物理限制。

從軟體的控制、雲端的調度，一路下沉到機房裡的伺服器與儲存設備，AI 的版圖已經拼到倒數第二塊。

最後一塊拼圖，在於模型如何離開機房，觸及每一個實際使用者。

第七章 | 邊緣層：誰在把 AI 帶到最後一哩？

前面三章的軟體層、雲端層、基礎設施層，有一個共同的驅動力：主權需求。企業和政府想要控制權，想要數據不出境，想要斷網也能跑。

邊緣層的情況不太一樣。

這一層最主要的驅動力，是開放模型本身的技術紅利。

當模型可以被壓縮、量化、塞進手機和筆電的晶片裡，**On-device AI** 就從不可能變成了可能。

這個變化跟主權 AI 有關，但不完全依賴它。**Apple** 賣出更多 iPhone，靠的是模型夠小、**NPU** 夠強，而不是因為哪個國家宣布了數據主權。

前三層是「主權 AI 的戰場」，第四層更像是「開放模型的果實」。它們屬於同一場運動，但果實的分配方式不同。

要理解邊緣層，必須先把它拆成兩個世界。

7.1 為什麼 AI 要離開機房？

過去幾年，我們使用手機或電腦裡的 AI 工具時，手上的硬體設備其實只扮演了「對講機」的角色。

設備把資料傳送到雲端，雲端運算完畢後再把解答傳回來。

這種做法在真實的商業與工業現場，遇到了四個限制：

1. 資料隱私（敏感數據一旦離開設備就面臨洩漏風險）
2. 反應速度（自動駕駛與產線檢測需要毫秒級判斷）
3. 網路斷連（偏遠地區與工廠深處可能完全沒有連線）
4. 使用成本（高頻推論的 API 租金會迅速吃掉利潤）

開放權重模型的出現，讓這些困境有了技術上的解法。

工程師可以利用壓縮與蒸餾技術，把大模型精簡成體積小巧的微型大腦，直接安裝在手機的 NPU、筆電的顯示卡，或車載系統的微處理器上。

設備不再需要隨時透過網路向遠端求救，它在本地就能完成獨立的思考與判斷。

不過，同樣是把 AI 留在設備本地運行，企業場景與消費場景背後的驅動力，卻有著本質上的不同。

7.2 企業與政府邊緣：物理世界裡的智力延伸

在企業與政府場景中，邊緣 AI 的核心價值在於：資料從頭到尾不外流，決策在機器內部瞬間完成。

工廠產線旁的工業電腦即時檢測瑕疵，手術室的超音波設備當場協助判讀影像，工地裡的自動採礦車隨時避開障礙物。這些設備各自在自己的崗位上獨立思考。

在這些實體地點，開放模型展現出了極高的靈活性。

一家汽車工廠今天使用A模型進行焊接瑕疵檢測，明天可以換成B模型，後天則能針對自己工廠的專屬數據微調出特別版本。

當自動化 **Agent** 開始在產線上接管複雜任務時，這種可自由微調、無須依賴外網且零延遲的特質，成了企業的剛性需求。

這些運行在終端設備上的模型，有著清晰的生命週期：

1. 企業不會在小型設備上從零訓練大模型。標準的作法是在中央資料中心裡，利用龐大的數據與算力訓練出能力完整的基礎大模型。
2. 隨後，工程師會將這個大模型進行「瘦身與壓縮」，精簡成一個體積小巧、反應靈敏的小型模型，再大量派發到成千上萬個終端設備上。

中央機房負責提供智慧養分，終端設備則負責在第一線執行運算。

這種分散式部署帶來了一個全新的管理難題。管控一座集中式的資料中心相對單純，但當主權 AI 延伸到成千上萬個分散在各地的終端設備時，管理複雜度呈指數級上升。

企業營運團隊需要隨時回答幾個棘手的問題：誰有權限替這上萬台設備更新模型？如何確保設備裡的數據不會被實體竊取？如果某個終端模型出現異常行為，要如何從中央一鍵按煞車？

這正是前面章節提到的控制與治理軟體，必須從中央雲端一路延伸至最底層設備的原因。



在硬體載體上，**NVIDIA** 的 **Jetson** 系列模組（從 **Orin** 到新一代的 **Thor**）已經成為這個領域的重要標準。

它把強大的 **GPU** 計算能力，壓縮到一張信用卡大小的耐用模組上，讓工廠機器、醫療設備與未來的工業機器人，能夠在不連外網的情況下，直接於實體世界進行即時的深度推理。

邊緣層是主權 **AI** 延伸到物理世界的最後一段路。當智力從雲端機房走進實體設備，**AI** 才真正開始在真實世界中發揮作用。

7.3 消費級邊緣：Apple 的系統整合優勢與 AI PC 的硬體競賽

如果說企業級邊緣講的是國防與產線安全，那麼個人裝置戰場則是一場關於使用者體驗與隱私信任的角力。

在智慧型手機與個人電腦領域，**Apple** 佔據了極其特殊的戰略位置。

大眾往往關注哪一家公司的模型分數最高，**Apple** 的護城河卻建立在系統整合的能力上。

將晶片的神經網路引擎、高頻寬記憶體、作業系統調度，以及品牌長期累積的隱私信任結合在一起，這種整體體驗勝過了單一模型的評測成績。

Apple 推出的 Apple Intelligence 展現了這種分層邏輯：

- 當你在手機上要求 AI 整理簡訊或搜尋相片時，小巧的微型模型直接在 iPhone 晶片內部完成運算，數據完全不離開手機。
- 一旦遇到極度複雜的邏輯推理，任務會被送往專屬的私有雲端運算環境（Private Cloud Compute）。這套雲端環境承諾數據在處理完畢後立即銷毀，連 Apple 官方伺服器都無法存留用戶的資料。

Apple says its AI is still private, even when it's running on Google's servers

Some models run in Google's cloud, but without giving Google any kind of access.

ANDREW CUNNINGHAM – 2026年6月9日 下午9:05 | 122



值得注意的是，Apple 在個人裝置的主路徑上，使用的是自研的私有閉源模型。

這與本文談到的開放模型主線形成了一個有趣的對照。

Apple 不需要依靠開放模型來撐起核心體驗，它需要的是一種明確的品牌對比：當其他科技公司大量調用遠端 API 時，自己的私有閉源路徑顯得更加安全且可控。

開放模型在 Apple 生態裡並非沒有位置，而是以另一種方式存在。開發者可以利用專屬的軟體框架，在 Mac 或 iPhone 上順暢運行開放權重模型。

這形成了獨特的雙軌現象：官方功能走閉源隱私路徑，社群開發者則在硬體上自由測試各種開放模型。

個人電腦市場則是邊緣 AI 的另一個戰場。微軟、NVIDIA 與各家筆電品牌都在推動配備高算力 NPU 的「AI PC」，試圖把桌上型裝置變成小型 AI 工作站。

但審視當前現實，AI PC 仍處於硬體先行、軟體追趕的階段。

晶片大廠已經把算力塞進了筆電，但真正讓使用者非買不可的殺手級應用仍在孕育。這更像是一個三到五年的趨勢，不是明天就爆發的品類。

7.4 邊緣層的利潤沉澱與投資邏輯

邊緣層的商業利潤，主要沉澱在硬體晶片與裝置品牌身上。模型軟體本身在邊緣終端上幾乎不產生直接利潤。

為了能夠順利安裝進手機、筆電或工業設備中，開放模型必須被壓縮到免費或接近免費的狀態。

幾乎沒有使用者會為手機裡一個微型模型單獨按月付費，大家付費的對象是承載這個模型的實體裝置。

- Apple 賣的是 iPhone 與 Mac
- NVIDIA 賣的是 Jetson 模組與桌上型 AI 裝置
- 高通（Qualcomm）賣的是智慧型手機裡的 NPU 晶片

使用者購買的是硬體與品牌的溢價，模型公司很難從終端的推理過程中分到顯著的收入。

這也解釋了開放模型在邊緣設備上既關鍵又尷尬的處境：

說它關鍵，是因為沒有這些免費、小巧且省電的模型，終端 AI 功能根本無法起步；

說它尷尬，是因為使用者感知到的全是裝置品牌與系統流暢度，不會太過在意底層模型的授權條款。

最後一個同樣關鍵的重點是：雲端資料中心不會消失，邊緣設備也不會完全取代雲端。

邊緣與雲端更可能是分工協作的關係：敏感的、即時的推理留在邊緣，重推理與訓練留在機房或雲端。兩者互補，而非互相取代。

終章 | 跟著 NVIDIA 的錢走

我們看完了不同的層面，你可能會問，主權 AI 聽起來很大，但我怎麼知道誰真的受益？

從之前的章節，我們已經可以清楚看到，**NVIDIA** 正在主動組建一條可複製的主權 AI 供應鏈。


而它的夥伴名單，就是它認為「缺了誰，這座工廠就蓋不起來」的清單。

NVIDIA 的公開投資與公開背書，本身就是產業地圖。它投光學，說明光互連卡住了擴張；它捧 **Marvell**，說明互連已從配角變成主線。

NVIDIA 的公開投資與公開背書，本身就是產業地圖。

AI Factories powered by NVIDIA

Manufacturing enterprise intelligence at scale



8.1 NVIDIA 的資本動作，就是產業地圖

前面四章已經講清楚了各層公司各自做什麼。這裡只看一件事：NVIDIA 在每一層下了什麼棋，以及它因此升級成了什麼角色。

- **模型層：**推出 Nemotron 開放權重模型，免費且深度優化在自家 GPU 上。這一步讓 NVIDIA 從「賣晶片給別人訓練模型」，升級為「定義開放模型生態底層算力標準」的角色。
- **軟體控制層：**與 Palantir 深化主權 AI 操作系統合作，與 ServiceNow 共同打造 Agent 信任層，牽頭成立 Open Secure AI Alliance。這一步讓 NVIDIA 從硬體供應商，升級為安全標準的制定者。
- **雲端與算力調度層：**提供 GPU 與軟體棧作為底層，讓微軟、Oracle、各國電信商在上面搭建主權方案。這一步讓 NVIDIA 成為所有主權部署路徑的共同底座，無論客戶選哪一家雲端。
- **機房落地層：**推出 DSX 參考設計藍圖，與 Dell、HPE 合作打造 AI Factory。這一步讓 NVIDIA 定義了「AI 工廠怎麼蓋」的標準，而不只是賣裡面的晶片。
- **本地運營層：**與韓國 NAVER、日本 SoftBank、德國 Deutsche Telekom 等電信商合作。這一步讓 NVIDIA 的算力底座，嵌入了各國的基礎設施體系。

- **邊緣與終端層：** Jetson 佔據工業邊緣，DGX Spark 佔據桌面。這一步讓 **NVIDIA** 的觸角，從數據中心延伸到了物理世界的每一個終端。

六步棋，六個角色升級。**NVIDIA** 扮演的，是這場主權 **AI** 運動的生態系操盤手。

8.2 財報裡的證據

Nvidia targets long-term ACIE dominance as enterprise AI eclipses hyperscalers



Jingyue Hsiao, DIGITIMES Asia, Taipei

May 21, 2026, 15:48

0



Credit: AFP

從 Q1 FY2027 開始，NVIDIA 對 Data Center 收入的呈現方式進行了調整，拆分成兩個類別：

Hyperscale（超大規模雲端客戶）與 **ACIE**（AI Clouds, Industrial & Enterprise，涵蓋 AI 雲、工業、企業與主權客戶）。

Q1 FY2027 的 Data Center 營收為 752 億美元，其中 Hyperscale 約 380 億，ACIE 約 370 億，兩者各佔一半。

但關鍵在於增速：ACIE 季增 31%，遠快於 Hyperscale 的 12%。ACIE 內的 AI cloud 營收年增超過三倍。

在主權 AI 方面，管理層明確表示相關業務年增超過 80%，AI 基礎設施已部署於近 40 個國家，代表 50 兆美元 GDP。

Data Center 收入結構從「Hyperscale 獨大」轉向「Hyperscale 與 ACIE 各半」，本身就說明主權與企業級需求已大到值得用新框架來管理與溝通。

8.3 故事的盲點

一篇成熟的投資研究，不能只看多頭。

第一，性能差距會不會重新拉開？

如果下一代閉源前沿模型（如下一代的 Claude 或 GPT）在複雜 Agent 任務上再次取得斷層式領先，目前建立在「夠用就好」上的開放權重邏輯就會鬆動。

第二，底層的「主權悖論」。

我們談論了這麼多數據與模型的自主權，但不可否認，這一切目前仍高度壓在 NVIDIA 的 GPU 與 CUDA 軟體棧上。

如果「主權 AI」的底層算力與推理框架依然被單一美國公司壟斷，那所謂的供應鏈主權，其實只存在於應用層與營運層。

未來 AMD 的追趕、各國自研晶片的成敗，以及推理框架的去 CUDA 化，將是這條路上最大的長期變數。

第三，「已被 Price in」的問題。

我們需要分辨，究竟那些公司的股價已經放入了主權 AI 的預期，有哪些將會有增量的可能性。

8.4 先理解概念，等待數字驗證

因此，我們必須設立一個正確的投資預期。

主權 AI 是一個結構性趨勢，但它的兌現需要時間。

這不是一個「明天就漲」的故事。對投資人來說，現階段最重要的，是先理解整個概念，知道哪些公司可能受益，建立自己的觀察清單。

當敘事真正開始發酵、當財報數字開始出現明顯的增長、當各國政府的採購合約開始落地時，你已經知道該看哪些指標、該追蹤哪些公司。

重點在於，在數字出現之前，就已經理解了背後的邏輯。

- KP

本機離線版本・圖片與內文完整

← 回索引

在原始站開啟 ↗