


← 索引 FREE 公開 2026-08-29 5975 字 ↗ 原站

Warsh鷹派發言？NVIDIA收購Hugging Face？Salesforce不被AI取代了？ - KP思考筆記(第57期)

本文目錄

- 1 主題一：Warsh鷹派發言，準備升息了嗎？
- 2 主題二：NVIDIA打算買 Hugging Face？為了甚麼？
- 3 主題三：OpenAI 的推出新辣椒晶片，要拋棄NVIDIA了嗎？
- 4 主題四：Salesforce 暴漲 20%，不再被AI殺死了？
- 5 主題五：市場在不滿Marvell的甚麼？
- 6 主題六：混合鍵合（Hybrid Bonding）又被推遲了？



大家好，我是 KP，歡迎來到第 57 期的《週末思考筆記》。

這期的前言稍微短一些，因為本週我準備了足足 6 個主題，內容資訊量相當大。

本週大家應該已經收到第二篇「財報解剖」，這次我們聚焦在 NVIDIA。由於這個系列剛推出不久，我想順道向大家梳理一下目前《FOMO 研究院》的內容架構：

- **週中【深入分析】**：研究院的核心主菜。每篇動輒萬餘字，適合深度閱讀。許多讀者反饋，光是一篇的價值就超越了一個月，甚至一整年的訂閱費。此系列為付費會員專屬內容。
- **週末【思考筆記】**：也就是你現在閱讀的這篇。內容完全免費，每期由 4-6 篇短評組成，整理我對過去一週市場關鍵事件的觀察與思考。
- **不定期【財報解剖】**：作為付費會員的專屬 Bonus。只有當出現極具拆解價值的財報時，我才會特別撰寫。

不論你是免費訂閱者還是付費會員，都希望你能在這裡找到有價值的洞見。

另外提醒大家，付費會員在 Substack 設有專屬討論區（這也是全網唯一的官方社群，其餘皆為詐騙），歡迎大家多來交流，裡面有非常多的精彩洞見。

這個星期有六個主題，包括：

主題一：Warsh鷹派發言，準備升息了嗎？

主題二：NVIDIA打算買 Hugging Face？為了甚麼？

主題三：OpenAI 的推出新辣椒晶片，要拋棄NVIDIA了嗎？

主題四：Salesforce 暴漲 20%，不再被AI殺死了？

主題五：市場在不滿Marvell的甚麼？

主題六：混合鍵合（Hybrid Bonding）又被推遲了？

不妨考慮先讚後看，我們正式開始!

主題一：Warsh鷹派發言，準備升息了嗎？



千呼萬喚始出來。

上週美財長Scott Bessent操作，導致市場對美長債利率十分關注後，市場都變得十分關注Fed主席Kevin Warsh講話。

這番講話結束後，市場的解讀幾乎是一面倒的：「極度鷹派」。

反映在數據上，FedWatch顯示的九月升息機率，在短短數小時內從35%飆升至近60%。緊接著，美國長債利率應聲回落，短債利率則迅速推高。原本緊繃的債市警報，看起來暫時解除了。

但，事實真的如此簡單嗎？

Warsh說了甚麼？

在這場備受矚目的演說中，Warsh其實從頭到尾都沒有講過「九月必須升息」這六個字。

然而，他卻用極其嚴密的邏輯，向市場解釋了「為什麼Fed有可能要升息」。

- **引擎依然強勁：**企業在設備與無形資產上的投資，年增率達到了**9%**，其中超過一半的動能來自人工智慧（AI）的軍備競賽。
- **就業並未失溫：****4.1%**的失業率，意味著勞動力市場依然處於充分就業的健康狀態。
- **資金依然充沛：**當前的金融環境，根本談不上「緊縮」。

而在天平的另一端，通膨的陰霾並未散去。**PCE** 通膨年增率仍有**3.7%**，近六個月的年化數據甚至回升到了**4.1%**，更糟的是，超過一半的消費品價格漲幅依舊高於**3%**。

Warsh的潛台詞很清晰：既然經濟依然強壯，而通膨還在持續，**Fed**就沒有任何理由降息，甚至，不排除升息。

在政策框架上，他重申**2%**是不可動搖的鐵律，聯準會應該專注於調整短期利率，而不是頻繁動用資產負債表等非常規武器。

同時，他繼續主張一個「保持沉默」的聯準會。少做承諾，少給市場畫未來的路線圖。

但事實上，這不是**Warsh**第一次表達這些觀點。

他為什麼非鷹不可？

要理解**Warsh**為何必須表現得如此強硬，我們必須把時鐘撥回上週。

當時，財政部長**Bessent**宣布，將**10至30**年期公債的流動性回購上限翻倍。在三十年期美債殖利率創下**2007**年以來新高的敏感時刻，財政部的這項舉動，在市場眼中無異於「出手干預長端利率」。

「財政主導（**Fiscal Dominance**）」，變成了過去一週，討論度最高的詞。

市場在問，聯準會的貨幣政策，會否也被迫配合財政部的發債需求，甚至幫政府的融資成本「護盤」？

在這種質疑聲浪下，**Warsh**沒有退路。

如果他在這次演說中表現出任何一絲溫和或妥協，市場就會坐實這個猜想，反而可能繼續拋長債、推高期限溢價。

因此，**Warsh**反覆強調**2%**目標、強調短率才是主要工具、強調非常規措施必須退場，都是在向市場宣告：聯準會依然是獨立的，我們不會為財政部的債務壓力買單。

這場鷹派演說，是聯準會為了維護自身信譽，而不得不付出的代價。

那應該怎麼看這件事？

我認為，與其說這是一場升息預告，不如說這是 **Kevin Warsh** 對 **Fed** 的一次信譽修復。

在那個處境下，不論他內心真正的想法是什麼，他都必須擺出這個姿態。這場演說，是寫好的劇本，也是他別無選擇的對手戲。

我認為，不升息、維持現狀，大概率依然是 **Warsh** 心底最真實的偏好。

畢竟在實體經濟尚未失控、**AI** 投資正熱的當下，沒有人想在沒有絕對必要的情況下，主動重啟緊縮，去承擔戳破資產泡沫或壓抑成長的風險。

更不要提**Kevin Warsh**是**Donald Trump**親自欽點的主席了，他大概率不想一開始就被不斷炮轟。

但九月升息確實因為這番話，被重新擺上了檯面，成了一個真實選項。這不代表聯準會已經下定決心要動手，只是這個選項不再能被完全排除。

這場演說的本質，是 **Warsh** 用強硬的言詞築起了一道防波堤。從結果來看，第一階段的防禦成功了。


但最終要不要真的灌下升息這劑猛藥，主動權不在他的口才裡，而在接下來的數據手中。未來的 **CPI** 是否再度抬頭、失業率是否守在 **4.1%** 不動。

這些數據，才是決定九月命運的真正裁判。

關於Kevin Warsh的立場，整個宏觀經濟的狀況，我在兩個月前曾經深入分析過，現在走向暫時仍然符合我的劇本。

如果想對宏觀了解更多的，誠邀你重溫文章。

主題二：NVIDIA打算買 Hugging Face？為了甚麼？



市場傳出 NVIDIA 願意用大約 129 億美元收購 Hugging Face。

Hugging Face 據報年化收入約 1.5 億美元。若交易成真，NVIDIA 等於付出超過 80 倍收入。

若把 Hugging Face 當成普通軟體公司，這個價格實在十分昂貴。

重點在於：它能給 NVIDIA 什麼戰略價值？

Hugging Face 是做什麼的

假設你是軟體工程師，老闆要你幫公司做 AI 客服。你通常不會從零訓練模型，會先找現成模型：

- 哪一個中文較好？
- 哪一個較小、較便宜？
- 哪一個能部署到公司伺服器？
- 哪一個適合 NVIDIA GPU？
- 要怎麼接進自己的程式？

Hugging Face 就是解這個問題的平台。

它像 AI 模型的 App Store 加 GitHub：開發者可以搜尋模型、查看評價與下載量、測試效果、下載模型，也能找到資料集與工具，進一步微調、測試和部署。

目前平台約有 1,300 萬名使用者、超過 200 萬個公開模型、50 萬個公開資料集。這代表它已經成為許多 AI 專案的起點。

買的是 AI 開發的「入口」

Hugging Face 上的模型絕大多數是公開模型，屬於Meta，Mistral，DeepSeek等上傳者。

NVIDIA 收購後，也不會直接擁有這些模型權重。它想掌握的，是開發者選模型、試模型、決定部署方式的地方。

這就像 Amazon 不需要自己生產所有商品，它的價值在於它是消費者找東西的起點。對開發者來說，Hugging Face 就是那個起點。

當開發者在這裡搜尋、比較、測試模型時，搜尋結果的排序、部署的難易度，都會潛移默化地影響模型最終會跑在哪套硬體上。

NVIDIA 目前已經掌握了 AI 產業最核心的「生產設備」（GPU、伺服器架構與加速軟體），但唯獨缺乏開發者「決定用哪個模型」之前的入口。收購 Hugging Face 正好補上這塊拼圖。

如果雙方整合順利，整個 AI 專案的流程就會變成一個完美的變現漏斗：在 Hugging Face 找模型 → 測試 → 調整 → 部署 → 最終順理成章地使用 NVIDIA 的 GPU 與雲端算力。

事實上，這個漏斗早就開始運作了。雙方從 2023 年就合作雲端訓練與推論服務，NVIDIA 也在 Hugging Face 的 D 輪募資中進場成為股東，這一切都為了讓這條「從模型到算力」的路徑變得更無縫接軌。

為什麼 NVIDIA 需要「開放模型」？

封閉前沿模型那一層，客戶是 OpenAI、Anthropic、Google 這類大型公司。

當客戶足夠大的時候，它們就有能力跟 NVIDIA 議價，甚至自己開發晶片。

但開放模型不是這樣。它背後可能是幾萬家公司、研究機構、政府和開發者。

需求非常分散。NVIDIA 不需要和每一個模型討價還價，它只需要讓大家覺得：「如果我要跑這些模型，用 NVIDIA 最方便。」

平台掌握的是開發者開始找模型、比較模型、決定部署路徑的那一步。

誰排在前面、哪條部署路徑最順，最後都會影響 GPU 和算力賣給誰。

資安變得重要

當 AI 越來越強大，企業在導入時最擔心的問題之一是：「我用的模型安全嗎？有沒有被惡意竄改過？」

今年 7 月，OpenAI 在內部做資安測試時，一批本應被隔離的 AI Agent 逃出沙盒，侵入 Hugging Face 的正式環境，拿到憑證、進入伺服器，還下載了內部程式碼。

Hugging Face 在這裡扮演了 AI 模型「履歷中心」的角色。它詳細記錄了每個模型是誰上傳的、使用了什麼資料、經歷過哪些版本更新。

未來，當企業為了避免供應鏈攻擊，而願意為「安全、可追溯的模型來源」付費時，Hugging Face 的商業價值將會進一步提升。

中立性的問題

這筆交易最大的風險跟它最大的價值來自同一個地方。

Hugging Face 今天之所以受到開發者歡迎，是因為大家相信它是一個相對開放、中立的平台。AMD 可以用，其他雲端可以用，各種不同公司的模型也可以放在上面。

2025 年底，NVIDIA 曾經提出再投 5 億美元、把估值做到 70 億美元，Hugging Face 拒絕了。當時的理由很直接：它不想讓單一投資人左右這座被視為中立基礎設施的平台。

不到一年，市場傳出的卻是同一家公司可能把整間公司買走。

對開發者來說，這正是緊張的來源。少數股權都怕被左右，百分之百控股之後，平台還能不能維持現在大家習慣的開放程度？

如果 NVIDIA 收購之後開始明顯偏袒自己的 GPU，改變模型曝光方式，或讓開發者很難把模型搬去其他平台，社群可能就會離開。

而開發者也不是沒有其他選擇，GitHub、ModelScope，以及各大雲端公司自己的模型平台，都可能承接這些需求。

所以這筆收購最有趣的地方是：NVIDIA 花大錢買下 Hugging Face 之後，最好的策略可能反而是不要太用力控制它。

保留獨立品牌、管理團隊和多硬體支援，再讓 NVIDIA 靠產品本身的效能和便利性，把更多工作量自然吸引到自己的平台。

怎麼看這筆交易？

只看 Hugging Face 目前收入，129 億美元很難合理化。

但若把它看成 AI 開發者的入口，邏輯就清楚了：NVIDIA 想把開發者從「找模型」到「跑模型」的路徑，盡量接回自己的軟體、GPU 和雲端算力。


最樂觀的情況是，Hugging Face 保持中立，社群持續成長，越來越多模型最終透過 NVIDIA 的軟體、GPU 和算力平台運行。

即使 Hugging Face 本身難以支撐 129 億美元的收入估值，只要它能避免開放模型入口落入 AMD、雲端廠商或其他競爭者手中，對 NVIDIA 就具有戰略價值。

關於NVIDIA，我剛剛深入分析了這份財報，這篇分析不會只告訴你「需求很好」。我會帶你逐項拆解這份財報裡，最重要的訊號。

你看完就會知道，甚麼才是接下來兩季真正會影響股價的東西。

主題三：OpenAI 的推出新辣椒晶片，要拋棄NVIDIA了嗎？



8月25日的 Hot Chips 大會上，OpenAI 端出了他們的第一顆自研推理晶片 Jalapeño(墨西哥辣椒)。

這顆 700W、搭載 HBM4 的晶片，在 SemiAnalysis 的第三方測試中，不僅在 tokens/W 與低延遲上擊敗了現役的 Blackwell (GB300)，甚至在部分指標上，連 NVIDIA 剛開始出貨的下一代 Vera Rubin 都感受到了威脅。

跑分確實很漂亮。但在你跟著一起興奮之前，我們需要先拆解這場「勝利」的含金量，以及它背後真正正在發生的結構性變化。

一場不公平的對決

先講結論：**Jalapeño 打贏 Blackwell**，某種程度上是「應該發生的事」。

為什麼？因為記憶體世代不對等。

Jalapeño 用的是最新的 HBM4；而它對標的 Nvidia GB300，用的是上一代的 HBM3E。

在推理（尤其是逐字吐出的 **decode** 階段）這個極度依賴記憶體頻寬的場景裡，換一代 HBM，效能曲線本來就會整段上移。

更何況，Jalapeño 的額定功耗是 700W（實測甚至壓在 550W 以下），而 GB300 動輒 1400W。用更低的功耗、更新的記憶體去打上一代的量產貨，數字好看是很合理的事情。

紙面勝利 vs. 量產護城河

當我們在 2026 年 8 月談論這場對決時，NVIDIA 的 HBM4 旗艦 Vera Rubin，已經在向各大雲端客戶出貨了。

而 Jalapeño 呢？它目前還只是實驗室裡的工程樣品。預計 2026 年底才會極少量進 OpenAI 自家的機房，真正有意義的放量要等到 2027 年，全力運轉甚至要到 2028 年。

這正是 NVIDIA 最難被撼動的地方：強大不僅在架構，更在於它能把極其複雜的系統，穩定做出來、交到全球客戶手上。

等到 Jalapeño 終於在 OpenAI 機房裡大規模運轉時，對面不會還是今天的 GB300，而是軟體已經挖過一輪的 Rubin 艦隊，以及 NVIDIA 下一組推論組合（包含把低延遲吐字分出去的 Groq 路線）。

科技產業的時鐘不等人。Jalapeño 在 2026 年的實驗室裡打贏了上一代 Blackwell，但等它真正走上戰場，面對的會是已經迭代過軟體棧、產能全開的新世代艦隊。

所以，跑分確實證明了 OpenAI 的技術實力。但要說這能立刻動搖 NVIDIA 的根基？子彈還得再飛一會兒。

架構的賭注：AI 運算到底要不要「搬家」？

要看懂這顆晶片的設計，我們得先用最簡單的方式，理解 AI 吐出回覆時的兩個步驟：

「讀題」階段（**Prefill**）：當你丟給 AI 一大段文章，AI 必須一次性把整段文字讀進去、理解上下文。這個階段就像是「開卷考試」，非常消耗腦力（算力密集，也就是GPU）。

「答題」階段（**Decode**）：理解完之後，AI 開始一字一字地把答案吐出來。這個階段不需要太複雜的思考，但需要大腦極快地從記憶庫裡提取下一個詞（記憶體頻寬密集）。

面對這兩個截然不同的步驟，NVIDIA 今年的策略是「極致分工」。

他們把需要大量腦力的「讀題」交給 Rubin GPU，把需要快速反應的「答題」交給 Groq 3 這種專門快速吐字的晶片。

但 OpenAI 偏不拆。

Jalapeño 是一顆「平衡晶片」。它就像是一個全能型選手，把讀題的算力、答題的記憶體，全部整合在同一個晶片上，並且把答題時需要用到的「臨時記憶（KV cache）」牢牢鎖在晶片本地。

為什麼要這樣做？因為 OpenAI 賭的是未來 AI Agent 的行為模式。

未來的 AI 代理人會像真人一樣，一會兒讀資料、一會兒講話、一會兒又去調用工具，任務切換極其頻繁。

如果按照 NVIDIA 的做法，把讀題和答題拆給兩種不同的機器，AI 的「記憶和狀態」就必須在不同的機器之間搬來搬去。

想像一下，你每寫一個字，就得把整疊參考資料從一樓抱到五樓，寫完再抱回一樓。這個「搬家稅」在 Agent 時代會變得極度昂貴。

OpenAI 的選擇是：蓋一棟夠大的辦公室（本地 128 顆，全域 2048 顆聯網），讓請求盡量待在同一張網裡，少付跨異質機器的搬家稅。

域內當然還是要傳資料，重點是不要在讀題、答題切換時，把記憶搬去另一種矽。

這是一場關於「未來 AI 工作長什麼樣」的哲學分歧。

NVIDIA 賭的是極致分工，OpenAI 賭的是狀態不搬家。誰對誰錯，要等 2027 年的電費單和延遲數據來判決。

打破了客製晶片的冷啟動詛咒

Jalapeño 最特別的，其實是它的開發過程。

傳統上，自己做晶片（ASIC）有兩大問題：

硬體研發太慢：從設計到晶片做出來，通常要花兩三年。等晶片做出來，AI 模型早就換代了。

軟體翻譯太難：晶片做出來只是塊石頭，你得花好幾年寫「翻譯軟體（編譯器與底層代碼）」，AI 模型才能在上面跑。

這也是 NVIDIA CUDA 護城河最深的地方，不是沒人想換，是懶得、也來不及重新適應一套翻譯層。

但 Jalapeño 從設計到送去製造（Tape-out），只花了 9 個月。

OpenAI 怎麼做到的？他們用自己的 AI 模型，去幫自己設計晶片、寫翻譯代碼。

為了測試跑分，原本晶片上缺少的運算語法（如 DeepSeek R1 用的 MLA 算子），工程師直接叫 AI 現做。

他們直接用內部的 AI（Codex）在短短兩週內，從零「搜尋並自動編寫」出可運行的程式碼。

現場他們甚至用 AI 提示詞，直接把經典遊戲《毀滅戰士》（Doom）移植到了這顆晶片上，證明這套系統不是只能跑自家的模型。

這意味著，「第一代自研晶片一定不好用、軟體一定要開發兩年」的冷啟動難題，被 OpenAI 自己用 AI 打破了。

這並沒有殺死 CUDA，在需要超大規模訓練的戰場上，NVIDIA 依然是絕對的霸主。

但它動搖了一個核心假設：未來其他 AI 實驗室如果想做自己的推理晶片，軟體開發的門檻已經被 AI 降得極低。

供應鏈的影響

這場局裡，帳面最清楚的贏家是 **Broadcom**。

它拿下客製 ASIC 的落地、Tomahawk 6 的網路，也鎖進 OpenAI 後面幾代的設計案。

在 Google 開始嘗試分散供應商的時候，Broadcom 急需一個新的增長故事。

回到最現實的問題：Jalapeño 會減少對 Nvidia 的需求嗎？

短期幾乎不會，OpenAI 依然掛著到 2030 年約 12GW 的 Nvidia 算力承諾。訓練盤、全球 API 節點、多模態任務，短期還是 Nvidia 的天下。

Jalapeño 不能外賣，它是 OpenAI 用來壓自家推理電費的工具。

總體來看，這顆晶片短線幾乎不會動到 NVIDIA 的出貨量與營收；雙方合作與制衡仍是主旋律。被碰的，是中期推論還能不能繼續按平台價賣。

它更像風向標，預示基礎設施會怎麼演。

第一，若未來的 Agent 真的頻繁切換讀題與答題，「狀態要不要搬家」會變成架構變數；

第二，用 AI 設計、編排 AI 晶片的時代，已經開始了。

說起Agentic AI，也不妨重溫Cloudflare的分析。裡面詳細分析了為何Cloudflare會是Agent時代的重要玩家。

主題四：Salesforce 暴漲 20%，不再被AI殺死了？



Salesforce 財報公布後股價大漲，是因為營收或獲利比預期好很多嗎？

老實說，只是還好。

營收只是小勝，EPS看起來很漂亮，主要是兩件事疊在一起。

第一，公司持有 Anthropic，墊高了每股盈餘約 2.43 美元。

第二，今年 3 月發行 250 億美元公司債，幾乎全數用來回購股票，稀釋後股數少了近 15%，大約再把每股盈餘抬高 0.6 美元。

兩件事都跟這季多賣了多少軟體沒有太大關係，把 **Anthropic** 持股重估拿掉之後，本業每股盈餘只是略勝預期，甚至略低於去年。

我認為，市場這次重新定價的核心，完全在於「敘事」的翻轉：

從「**AI** 會不會取代 **Salesforce**」，變成「**Salesforce** 看來不是受害者」。

AI 無法取代的企業底層邏輯

過去一年，軟體公司的最大疑慮之一，就是 **ChatGPT**、**Claude** 這類 **AI** 工具會不會逐漸取代傳統企業軟體。

因為如果未來員工不用再打開 **Salesforce**，而是直接對 **Claude** 說：「幫我找出這季最可能流失的客戶，整理原因，再準備一份續約方案。」

那 **Salesforce** 原本最重要的入口，不就消失了嗎？

而今季的**Salesforce**，嘗試改變大家的理解。

他們說：**AI** 擅長理解問題與整理資料，但缺乏企業內部的「規則與上下文」。

當業務員詢問 **AI**「最多能給客戶多少折扣」時，**AI** 無法自動得知該業務員的查閱權限、公司的折扣上限規定、主管簽核流程，以及後續的跨部門通知機制。

這些高度客製化的企業邏輯與權限控管，深植於 **Salesforce** 系統中，大型語言模型本身無從得知。

退讓前端入口，守住後端系統

因此，**Salesforce**選擇與**Anthropic**聯手，推出 **Claudeforce** 以及內建 37 項銷售技能的 **Salesforce in Claude** 外掛。

簡單來說，**Salesforce**已經接受了一件事：

未來員工很可能只會打開**Claude**或其他 **AI**，而不會每天打開**Salesforce**。

因此，他們的新策略不再跟 **Claude** 搶使用者入口。

他們轉而選擇確保 **AI** 在讀取客戶資料、修改訂單或批准折扣時，必須嚴格遵循 **Salesforce** 的底層資料、權限與流程。

前端對話介面可以隨時從 **Claude** 切換到 **ChatGPT** 或其他模型，但企業累積十幾年的客戶數據、權限架構與業務流程極難遷移。

Salesforce 新的定位變成了：它無需成為企業 **AI** 的「大腦」，只要穩固成為 **AI** 執行任何商業動作前，必定會經過的「神經中樞與執行引擎」。

AI 甚至可能讓 **Salesforce** 更容易賣

在這次財報中，CEO **Benioff**邀請了一個嘉賓進行分享，是**Ohalo** 公司的CEO **David Friedberg**。

Ohalo 起初打算利用 **AI** 自行開發客戶管理系統，因為建立前端頁面的門檻確實很低。

但實際動手後，他們發現真正的挑戰在於繁瑣的後台治理：帳號管理、資料保護、離職權限收回與系統維護。

最終，**Ohalo** 仍選擇以 **Salesforce** 為底層，僅自行開發農業領域的特殊應用。

更有意思的是，他們利用 **Claude** 和 **Cursor** 幫忙設定 **Salesforce**，不到一個月完成；**Benioff** 則說，以前這種導入可能要半年到一年。

這反而提供了一個跟「**AI** 殺死軟體」完全不同的角度。**Salesforce** 過去最大的問題之一，就是貴、複雜，而且導入時間很長。

如果 **AI** 可以把這些設定工作大量自動化，那它消滅的可能不是 **Salesforce**，而是 **Salesforce** 原本的導入摩擦。

以前一家中小企業可能會想：「導入 **Salesforce** 太複雜了，我們用不起。」

未來可能變成：「反正 **AI** 幾個星期就可以幫我設定好，那我乾脆直接用 **Salesforce** 當底層。」

如果這件事情真的發生，**Salesforce** 的市場反而可能變大。

大漲的邏輯可以延續嗎？

這季最大的進展，是 **Salesforce** 開始回答「**AI** 會不會把我取代」這個問題。

目前答案看起來是：至少沒有市場之前想得那麼悲觀。

而且管理層對下半年營收重新加速相當有信心。新增訂單成長快於既有業務、客戶流失率接近歷史低點，合約期限也拉長。

公司甚至還準備繼續增加銷售人員，代表管理層認為目前還可以有更強的成長。

但另一個更重要的問題還沒有解決：**AI** 該如何實質轉化為 **Salesforce** 的營收？

過去的訂閱制非常直觀：1,000 名員工使用，就購買 1,000 個帳號。

若未來大量工作由 **AI Agent** 自動完成，人類使用者可能減少至 700 人，但系統呼叫量與算力消耗卻暴增十倍。

Salesforce 必須重新設計商業模式：究竟該按人頭、**AI Agent** 數量、**API** 呼叫量，還是按創造的商業成果來收費？目前公司仍在測試多種方案。


這次價值重估如果要能長久延續，**Salesforce** 必須證明 **AI** 能夠為公司帶來實質的營收躍升。

接下來 **Dreamforce** 大會公布的最新定價策略、**Claudeforce**的客戶付費意願，以及下一年度的有機成長指引，將會是比單純追蹤 **Agentforce** 客戶數量更關鍵的觀察指標。

SaaS從年初的谷底，到現在已經反彈不少。但究竟是反彈，還是真的轉勢？我認為仍然需要一個清楚的框架。

之前寫過的關於**SaaS**的框架，仍然十分適用。如果你想了解甚麼**SaaS**公司才是真正有價值的，不妨重溫這套框架。

主題五：市場在不滿**Marvell**的甚麼？



Marvell 繳出一份很好的季報。第二季營收年增 **37%**，資料中心業務強勁，公司甚至把 **2028** 財年的營收指引上修至 **180** 億美元。

財測上修，股價卻下跌，這合理嗎？

如果你聽了財報會議後的 Q&A，管理層被不斷追問同一個問題，就會理解投資人在糾結什麼。

老實說，大家最關心的，是那個充滿想像空間的 Google 大單。

1,200 億美元屬於採購上限，大頭其實落在 2029 年

在財報前幾天，Marvell 與 Google 宣佈了一項高達 1,200 億美元的合作案，令市場十分興奮，投資人原本滿心期待，這筆大單會大幅推升 2028 財年的營收。

然而管理層在電話會議給了個相當乾脆的答案：**2028 年的客製化業務確實包含部分 Google 訂單**，但真正能帶來顯著規模貢獻的大頭，得等到 **2029 財年** 及以後。

這個時間差讓市場感到失望。Google 訂單的作用，是拉高 2029 年之後的成長天花板，並沒有全面改寫 2028 年 180 億美元的指引目標。

此外，這份商業協議實質上屬於認股權合約（Warrant Agreement）：Google 的累計採購金額達到特定門檻，才能分階段解鎖對應股權。

所以 \$1,200 億是合作框架推演出來的上限，不能直接當積壓訂單（Backlog）塞進估值。

撐起 2028 年財測的真正主力

既然 Google 訂單的大頭在 2029 年，Marvell 將 2028 年營收上修至 180 億美元的底氣究竟從何而來？

管理層講的是資料中心全面加速：光互連與 DSP、交換、客製化本身在 FY28 仍會逾倍，scale-up 光學的 FY28 展望也明顯上修。

目前 800G DSP 需求依然強勁，1.6T 開始接棒放量，51.2T 交換晶片今年營收更預計成長超過一倍。

這些標準化產品擁有更廣泛的客戶群與清晰的可視度，穩穩撐住了 **2028** 年的基本面。

Google 買的是周邊晶片

市場另一個常見誤解，是以為 Marvell 搶下了 Google TPU 的主晶片。

事實上，這次合作聚焦於 **TPU** 生態系的周邊晶片，包括推論加速器、儲存控制器、網卡與記憶體介面。

這類晶片深深鎖進系統架構，客戶黏著度極高，但產品結構會直接拉低利潤率表現，因為客製化 **ASIC** 晶片本身的毛利率顯著低於標準化產品。

隨著下半年客製化晶片開始放量，Marvell 第三季毛利率指引已小幅回落至 57.5% 至 58.5%。

未來隨著 Google 訂單佔比擴大，產品組合將持續向低毛利區間傾斜，公司必須完全依靠營收規模放大帶來的營業槓桿（**Operating Leverage**），來維繫整體營業利益率。

同時，若 Google 的認股權全數行使，將產生約 7% 的股本稀釋。這意味著營業利益率擴張並不等於每股盈餘（EPS）能同步提升，公司後續必須展現足夠的股票回購力道，才能真正回饋到股東口袋。

接下來該看什麼？

整體而言，**Marvell** 的基本面依舊健全，但估值跟不上想像空間。

市場目前的定價，是在提早拉回並消化 **2029** 年 Google 訂單的想像空間；而公司給出的，則是 **2028** 年由標準化產品堆疊出的實打實底氣。

接下來 10 月 6 日的 Investor Day，市場觀察重點將聚焦在三個具體數據：

- **2029** 年客製化營收的實際增量：取得具體預估總額，避免市場繼續粗暴地將 1,200 億美元上限直接年化計算。


- 周邊晶片與 XPU 本體的營收佔比結構。
- 客製化業務放量後的毛利率中樞，以及認股權稀釋後的每股實質效益。

唯有這些變數塵埃落定，市場才能對 Marvell 的下一步給出更精準的估值模型。

很多人不清楚Marvell的業務，還認為它是一家純ASIC公司。但事實上，他們的資料中心業務分為三大塊：互連，交換器，然後才是ASIC。

理解了他們的業務，你才能更容易看懂他們的財報。

主題六：混合鍵合（Hybrid Bonding）又被推遲了？



隨著 AI 晶片需要處理的資料量爆發，記憶體（HBM）的堆疊層數也從 8 層、12 層一路往 16 層甚至 20 層邁進。

外界原本認為，傳統用來連結晶片的「微凸塊（Microbump）」技術很快就會碰到散熱與厚度極限，產業必須全面改用新一代的「混合鍵合（Hybrid Bonding）」技術。

這項技術轉型，曾被市場視為新一代設備廠（如 Besi、應用材料）業績大爆發的核心引擎。

然而，SK 海力士在 Hot Chips 大會上宣佈：混合鍵合不會用在 HBM4E 上，現有的 MR-MUF 技術將繼續沿用。混合鍵合的登場時間點將順延至 HBM5（約 2029 到 2030 年）。

為什麼這項新技術又被延後了？

規範放寬，空間夠用了

負責制定標準的 JEDEC 協會放寬了 HBM 的高度上限（從 HBM3E 的 720 微米放寬到 HBM4 的 775 微米）。

多出來的空間意味著，只要把晶片磨得更薄、將間距縮小，舊工法依然能塞進 16 層晶片，不必急著換新技術。

客戶目前不需要 20 層

目前 12 層已進入量產、16 層正處於驗證階段。Nvidia 下一代 Rubin 架構晶片並不需要 20 層堆疊。

只要需求停在 12 至 16 層，現有的工法（MR-MUF 與 TC-NCF）就還撐得住。

良率與成本考量

混合鍵合設備的價格是傳統設備的 2 至 3 倍，且現階段良率仍未成熟。

只要堆疊過程中有一層損壞，整顆高昂的 HBM 就宣告報廢。

在 HBM 供不應求且價格昂貴的當下，廠商自然不願冒良率掉入崖邊的風險。

不要把「所有混合鍵合」混為一談

在解讀這項產業變化時，必須將 HBM 與邏輯晶片的 3D 混合鍵合區分開來：

邏輯晶片端（Logic）進度不變：

台積電用於處理器與 AI 晶片的 SoIC 技術（如 AMD 3D V-Cache、MI300 及蘋果未來的 M5 Pro）依然按計畫擴產，並未受到影響。

記憶體端（HBM）確實延後：

這次被推遲的，僅限於 HBM 記憶體晶片彼此之間的垂直堆疊。

HBM 的稀缺性會持續更久

原本市場預期新技術上線後能迅速提升產能與產量，進而緩解價格壓力。

如今新技術推遲，代表未來兩年 **HBM** 的供給瓶頸仍卡在晶圓分配與 **12/16 層** 的製造良率上，高單價（**ASP**）也將獲得支撐。

由於廠商用舊工法製作 12 層與 16 層的良率偏低，**Nvidia**為了確保 **2027 年**的 **Rubin Ultra** 晶片能順利出貨，現在也在積極考慮調整策略，推出容量較小（如 **8 層**）的版本，以避免陷入記憶體斷貨的風險。

設備供應商消長

- **受益者**：現有的封裝設備廠（如 **Hanmi**、**ASMPT**）及擁有一線製造護城河的廠商（**SK 海力士**、**三星**），其現有技術和設備的生命週期延長了 **2 到 3 年**。
- **延後者**：**Besi** 與應用材料（**Applied Materials**）在 **HBM** 混合鍵合的量產敘事時間點延後。不過需要注意，**Besi** 在邏輯晶片封裝的業務並未受影響，並不代表其長期價值改變。

整體而言，這並不是「**3D 封裝**被取消了」，也不代表記憶體傳輸瓶頸消失。

16 層 HBM 依然會陸續出貨，只是製造商選擇繼續使用熟悉但挑戰更高的舊工法來過渡這段時期。

混合鍵合雖然聽上去十分複雜，但卻是未來解決HBM問題的重要方案。3D封裝是一個必然，問題只是時間線。

推薦大家都重溫一下之前寫過關於混合鍵合的分析，雖然技術性，但我寫的方法應該會讓大家看懂。

謝謝你閱讀到這裡，如果你覺得這份筆記為你帶來了價值，請不吝按下一個讚，這是我持續分享的最大動力。

我在Facebook和Threads都有每天發佈當天對市場的觀察，大家也可以考慮追蹤我的社交媒體。

另外我在Telegram有頻道，每天早上我會發當天重要新聞摘要。

全部資訊在以下鏈結：

https://linktr.ee/fomo_soc

另外，如果你已經加入付費會員，不要浪費了群組的功能，進入我們Substack的Chat功能一起討論市場！

· KP

本機離線版本 · 圖片與內文完整

← 回索引

在原站開啟 ↗