← 索引 💎 付費 2026-10-27 22501 字 ↗ 原站

KP商周專欄(第2017-2028期)

本文目錄

1 第二十三期專欄(出刊日期： 2026-07-08)

2 蘋果傳被迫求助中國長鑫存儲，「記憶體超級週期」還有多久？

3 第二十四期專欄(出刊日期： 2026-07-15)

4 iPhone殺了諾基亞、AI卻沒殺死資安，關鍵差在「補充性資產」重估

5 第二十五期專欄(出刊日期： 2026-07-22)

6 被嚴重低估的AI算力要角，快閃記憶體為何迎來最強翻身？

7 第二十六期專欄(出刊日期： 2026-07-29)

8 亞洲最大上市案長鑫存儲掛牌，記憶體中長線前景全解答

9 第二十七期專欄(出刊日期： 2026-08-05)

10 當輝達變成OpenAI的影子銀行…怕的不是借錢，是這三件事

11 第二十八期專欄(出刊日期： 2026-08-12)

12 從微軟到Anthropic六大AI巨頭，一兆美元「隱形融資」正在成形

13 第二十九期專欄(出刊日期： 2026-08-19)

14 算力租賃商財報打臉AI泡沫：舊世代GPU租金居然還在漲

15 第三十期專欄(出刊日期： 2026-08-26)

16 黃仁勳藉一場大缺貨改寫比賽規則，記憶體廠紅利沒預期那麼高了

17 第三十一期專欄(出刊日期： 2026-09-02)

18 輝達財報透露一個新訊號，為何AI三巨頭都攻開源模型？

19 第三十二期專欄(出刊日期： 2026-09-09)

20 新財富備忘錄約稿

21 輝達最新的NVHBM代表了甚麼？

22 第三十三期專欄(出刊日期： 2026-09-16)

23 iPhone18漲100美元還不夠　蘋果新舵手首仗成敗看3指標

24 第三十四期專欄(出刊日期： 2026-09-24)

25 二〇二七年AI產能6成還沒開工　滅絕論之外，投資人該算「時差帳」

歡迎來到 FOMO研究院的特別內容。

這幾篇文章是我受邀於《商業周刊》發表的獨家專欄。

根據協議，專欄文章在刊登滿一個月後，我會將完整內容解禁，專屬分享給研究院的付費會員。

(本來是這樣安排的，結果我這幾個月研究做過頭，居然把它們完完全全給忘了，所以這次一次過發多期給大家。反正這個星期的財報解剖要到星期四才能給大家，這兩天也可以讀回過去幾個月的文章。

所以這次挺誇張的，一口氣放了過去12篇舊文，不需要都看完，選有興趣的來看就好。)

8成生意賠錢，還要顧百萬股東！中鋼「次好哲學」拚翻身

商業周刊

BUSINESS WEEKLY



美歐日同步升息全解讀》

未來3年，從買房到選股，遊戲規則全改寫

便宜資金再見！

錢變貴了！過去最聰明的算盤，現在最危險

- 小心房貸投資變債務炸彈、經營好習慣成現金流殺手
- 你該開始考慮買債！升息期，2款債、4類股吃香



下載商周App
閱讀換好禮

2028

記憶體40年最大海外購併
揭華邦電隱形冠軍戰法

iPhone 18買氣冷殃及鴻海、大立光？
變局在明年，供應鏈旺季將重排

2026.9.28-2026.10.4
定價180元

💡 **閱讀前的小提醒：**

1. **原汁原味的「導演剪輯版」：** 商周刊登的版本經過了編輯部的精簡與潤飾，而我發布在這裡的，是未經刪減的原始草稿。即使你已經看過雜誌版本，這篇原稿保留了更多我個人的推演過程，讀起來會有截然不同的風味。

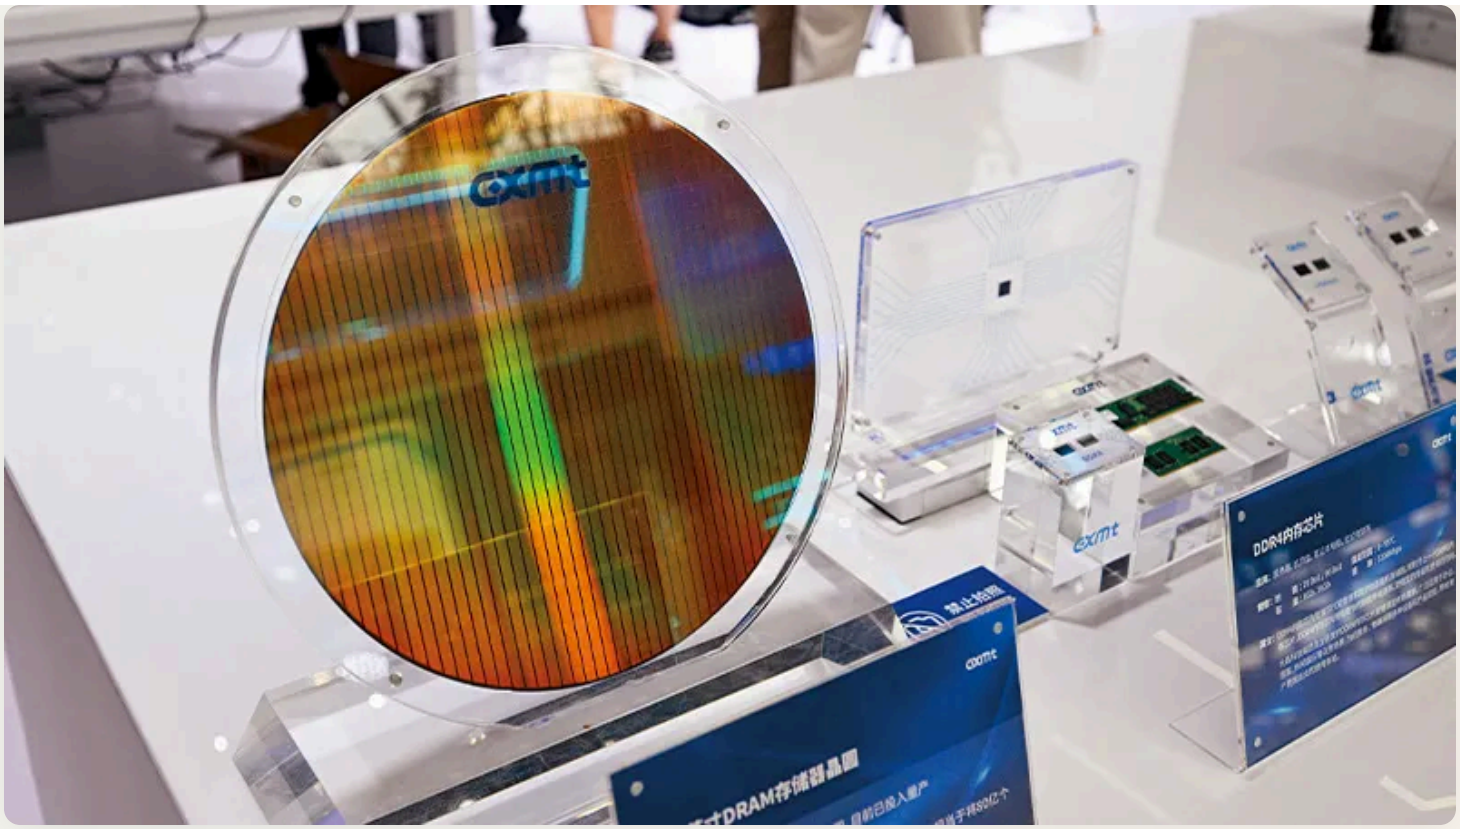
2. **底層邏輯，不怕過時：** 你可能會想：幾個月前的文章現在看會不會太遲？熟悉我的老讀者都知道，**新鮮的是股價，耐看的是邏輯**。

   我寫作的核心始終是拆解產業鏈的結構性本質，而非追逐隔夜即忘的短線新聞。帶著「後見之明」重讀當時的推演，拿來對照今天的市場現實，這不僅不會過期，反而是一次最完美的覆盤與認知升級。

祝大家閱讀愉快！👇

第二十三期專欄(出刊日期： 2026-07-08)

蘋果傳被迫求助中國長鑫存儲，「記憶體超級週期」還有多久？



https://www.businessweekly.com.tw/archive/article?strid=7014417

美光交出了一份堪稱「比完美更完美」的 Q3 財報：營收飆升至 414 億美元（年增 346%），毛利率更是達到了不可思議的 85%。美光甚至高調宣布，他們已經與客戶簽署了 16 個「不提貨也得付錢（take-or-pay）」的長期霸王條款。

這份財報一出，有人歡呼，但有人卻氣得跳腳。

一向以「供應鏈大師」自居的蘋果罕見地公開抱怨，指責記憶體廠商的定價「高到不合理、完全不可持續」。因為記憶體成本的瘋狂暴漲，蘋果已經被「逼入牆角」，為了維持利潤率，蘋果將不得不迎來歷史性的全面漲價。

為了擺脫被美光、三星、SK 海力士三大巨頭「卡脖子」的命運，市場盛傳，蘋果正破天荒地遊說美國政府，希望能獲准向被列入黑名單的中國 DRAM 大廠長鑫存儲（CXMT）採購晶片。

究竟記憶體的盛世還能維持多久？巨頭們是否可以轉向中國來解決記憶體問題？

▉ 蘋果的「長鑫鬼故事」

我先說結論，蘋果靠長鑫存儲就能解決記憶體成本問題，這個絕對是偽命題。

當前全球 DRAM 晶圓產能極度吃緊。長鑫自身也正將大量產能轉向 HBM3 以支援中國本土的 AI 晶片需求。在整體產能受限下，根本沒有一個「又便宜、量又大」的記憶體池等著蘋果去撈。

長鑫確實用低價搶市佔，但一旦把良率、可靠性、長期支援成本算進去，蘋果拿到的實際優惠並不驚人。**而蘋果對「總持有成本」的敏感度遠遠高於「單價」，一個小 bug 導致的召回可以吃掉多年的採購節省。**

更重要的是，長鑫作為中國半導體的國家隊，在當前美中科技戰的張力下，其首要任務必然是優先保障華為、騰訊等本土戰略客戶（例如長鑫近期剛與騰訊簽署大單）。在供應緊張時，蘋果必然是第一個被犧牲的對象。

這說明了，蘋果的動作更多是面對三星、SK 海力士與美光三大巨頭漲價時的談判籌碼，而非一個真正具備可行性的戰略替代方案。

最關鍵的是，蘋果已經不是那個「最搶手的客戶」了。

過去二十年，記憶體大廠都把蘋果當成頂級客戶。但在 AI 時代的記憶體超級週期裡，願意付最高價、簽最長合約的，是 NVIDIA +雲端公司。

他們是為了搶 AI 軍備競賽的門票，價格彈性遠遠低於蘋果。

> 蘋果找長鑫這件事的真正意義，在於蘋果在這場記憶體遊戲裡的定價權，已經被 AI 巨頭排擠到很後的位置。蘋果必須開始做以前不需要做的事，包括去找一家他們原本連正眼都不會看的中國供應商，然後動用政治關係申請豁免。

當我們把鏡頭從 Cupertino 拉遠，你會看到一個更大的圖像，整個記憶體產業的定價邏輯正在被重寫。

▉ 「省記憶體」技術，是壓抑還是引爆需求？

過去一年，AI 圈湧現許多「省記憶體」技術（如優化快取、模型壓縮），號稱能將記憶體佔用減少數倍。

直覺上這會壓抑硬體需求，但事實恰恰相反，這觸發了經典的「傑文斯悖論（Jevons Paradox）」：**當資源使用效率提升、成本下降，總消耗量反而會呈指數級暴增**。

這背後有三個商業傳導邏輯：

當每個用戶佔用的記憶體減少時，雲端廠商並不會關掉伺服器，而是會在同一張顯示卡上塞入數倍的併發用戶，讓硬體繼續 100% 滿載以極大化收益。

同時，成本暴跌解鎖了原本「貴到無法商用」的場景。當百萬字長文本分析、多模態即時互動變得便宜，企業便會瘋狂導入，激發出數十倍的全新業務量。

而當記憶體不再是瓶頸，開發者更會毫不猶豫地把省下來的空間，拿去運行參數更大、結構更複雜的 AI 模型與 Agent 代理。

因此，軟體效率的突破，每次都成了硬體需求擴張的燃料。這解釋了為什麼 NVIDIA Blackwell B200 單卡搭載高達 192GB HBM3E（是 H100 的 2.4 倍），也解釋了為什麼 HBM 市場規模預計在 2028 年將跳升至 1000 億美元。

▉ 記憶體需求早已經不止一個

過去二十年，DRAM 產業是 PC、手機與傳統伺服器共用一個大水池。需求同頻共振，一旦消費端走弱，價格便面臨雪崩。

但這一次不同，記憶體需求已分裂為兩個結構完全不同的池子：

- **1. AI 與資料中心池（HBM、高階 DDR5）：** 定價權極高，需求極度強勁。
- **2. 零售與消費池（手機、PC 記憶體）：** 定價權中等，目前因產能被擠壓而處於「暫時壓抑」狀態。

由於 AI 記憶體的單片晶圓收益是傳統記憶體的 3 到 5 倍，晶圓廠正將大量產能轉向 AI。TrendForce 數據顯示，HBM 已吃掉約 23% 的 DRAM 總晶圓產出。這導致手機、PC 甚至蘋果（Apple）都面臨嚴重的記憶體荒。

這對投資邏輯帶來了深遠的改變，形成過去未曾有過的「雙緩衝機制」：

若 AI 持續強勁，零售需求繼續被壓抑，上升週期將進一步拉長。

即使若 AI 需求走弱，產能轉回普通記憶體，被壓抑的零售需求將釋放，有效緩衝下行風險。還未算上未來會有自動駕駛、機器人等新池子陸續加入。

Agentic AI：被低估的系統記憶體第二戰場

當市場緊盯顯示卡上的 HBM 時， AI 代理的興起，正在引發系統記憶體（CPU DRAM）的結構性需求。

傳統推理是「無狀態」的，問完即丟。你發送一個 prompt，拿到回覆，結束。快取在顯示卡上短暫存在，然後被丟棄。

AI代理人完全不是這樣運作。一個真正的AI代理人可能跨越數百個推理步驟，維持一個持續運作的草稿本，呼叫工具、觀察結果、更新計劃、循環迭代。它在跨會話、跨天甚至跨週的時間尺度上維持記憶，與其他AI代理人協作，並處理多模態輸入。

這種工作負載的記憶體特徵，跟傳統聊天機器人完全是兩種生物。

除了顯示卡上的高速記憶體需求暴增，當 Agent 暫停、等待工具回應、釋放顯示卡給其他任務時，大量的資料必須卸載到主機記憶體（CPU DRAM）與硬碟中。Agent 的思考歷史、對話紀錄、工具輸出與長期記憶，全部都高度依賴系統記憶體。

> 過去只存在於顯示卡上的短暫記憶體，在代理人世界裡變成了跨顯示卡與系統記憶體的持久狀態。

市場報告指出，代理人部署將使每台 AI 伺服器的系統記憶體需求暴增數倍，達到 300-400GB 的高規格配置。

這個「第二戰場」目前尚未被市場定價，原因有三：AI代理人部署仍處早期、市場目光被 HBM 短缺綁架、以及需求量目前難以精準估算。

但邏輯是確定的：當AI代理人從 Demo 走向核心生產，系統記憶體將迎來階梯式的結構性跳躍。

真正的變數在供給端

將 AI、被壓抑的零售需求、AI 代理人的系統記憶體，以及未來的自動駕駛與人形機器人結合來看，記憶體市場的底層邏輯確實正在從「單一需求池的週期波動」轉向「多池共振的結構性成長」。

然而，需求端擁有多個引擎，並不代表價格能永遠一路上漲。**決定這輪盛世長度的關鍵，在於供給端追趕的速度與節奏**。

短期內，供給緊繃是明確的事實。因 HBM 排擠了傳統 DRAM 的晶圓產出，2026 年 DRAM 供給年增率預期僅約 16%，遠低於過去 20% 至 30% 的歷史常態。

各大廠的新廠，包括 SK 海力士清州與美國廠、三星平澤廠、美光新加坡與台灣廠，皆需要數年才能達到滿載，這讓市場預期 2028 年前難有喘息空間。

但拉長維度來看，情況並非毫無懸念。三大廠的資本支出正在快速加碼：三星目標在 2026年底將 HBM 月產能提升至 25 萬片，擴張幅度達 47%；SK 海力士與美光在 2026 年的資本支出合計超過 540 億美元，其中美光更投資 70 億美元在新加坡新建 HBM 封裝廠。

供需缺口的維持，取決於需求成長是否持續快於供給。如果需求年增 30%、供給年增 16%，價格會繼續強勢；一旦需求成長率放緩至 20%，而供給端因新產能開出跳升至 25%，市場天平就會翻轉。

「短缺持續到 2028 年」是目前的市場共識，但 DRAM 產業歷史上從未維持過 5 年以上的緊平衡。任何一家供應商擴產速度超出預期，定價彈性都可能在一夜之間消失， 2027 年上半年將是關鍵的觀察窗口。供給端終究會追上，只是時間與方式會超出市場預期。

這次真的「不再週期」了嗎？

如果需求結構真的變成這樣，加上美光那 16 個「不提貨也得付錢」的合約，記憶體是不是真的告別週期了？

我認為週期依然存在，只是會變得更長、更溫和，且底部不會像過去那麼痛苦。

「這次不一樣」的論點確實有其依據：三家寡佔的產業結構降低了非理性擴產的機率，多池需求為市場提供了天然緩衝，長約（LTA）覆蓋率上升平滑了短期波動，AI 效率改進也不斷解鎖新需求。

即便如此，LTA 僅是延緩症狀的止痛藥。它無法改變產業的三大硬傷：兩到三年的產能投資滯後性、技術演進帶來的自然產出增長、以及終端需求的不確定性。這三根循環骨架依然完好。

當市場嚴重供過於求時，LTA 的保護效果會急速衰減，並引發兩種被市場忽略的次級風險。

首先是庫存暗流累積。客戶受限於合約無法砍單，導致客戶端庫存異常上升。此時原廠財報雖維持亮眼，但客戶倉庫已悄悄堆滿消化不掉的貨，合約到期後原廠將面臨訂單斷崖。

其次是價格扭曲與合約決裂。當一線大廠被迫履行高價 LTA，而競爭對手卻能在現貨市場取得廉價晶片時，巨大的成本劣勢會逼迫大廠透過品質爭議、灰色市場轉單或重新議價等手段毀約。**在嚴重的供過於求面前，沒有一份合約是神聖不可侵犯的**。

觸發這些風險並不需要極端的崩盤情境。只要供給端擴產速度略快於預期（例如 HBM4 良率突破或中國廠商產能跳升），或是需求端成長率從高速放緩至中速，兩者交會之時，共識預期的 2028 年緊平衡就會提前打破。

我的觀察

拆解完所有變數，這輪記憶體週期最誠實的描述是：變數比以往任何一次都多，但短期方向仍然十分明確。

需求端有 AI 訓練、推理、代理人系統記憶體、被壓抑的手機與個人電腦、以及未來的自駕與機器人，多個引擎同時運轉。

供給端則有三大廠的資本支出加碼、HBM4 良率競賽、長鑫存儲（CXMT）的產能跳升與地緣政治干擾。

雖然長約（LTA）覆蓋率、庫存水位、現貨與合約價差等變數單獨看都可能改變結局，但將其綜合評估，未來四到六個季度的答案幾乎沒有懸念，亦即需求遠大於供給，定價權在賣方手上，毛利將繼續維持亮眼表現。

因此，我的建議是該享受的時候就享受。

三家寡佔的結構、多池緩衝的需求、以及長約的部分保護，確實讓毀滅性崩盤的機率大幅降低。

記憶體大廠正迎來歷史上最舒服的日子，高毛利、高能見度與 AI 光環三重疊加，這是實實在在的超級週期。

然而，參與派對的正確姿勢，是一邊跳舞一邊記得出口在哪裡。

當所有人都相信這次不一樣的時候，往往就是週期最狡猾的地方。它不會用市場熟悉的方式回來，可能是系統記憶體的階梯跳升不如預期、可能是長約重談潮突然爆發、也可能是某個週二早上現貨價無預警下跌一成。

投資人不需要現在就離場，但需要知道自己在看哪些訊號。

> 庫克（Tim Cook）現在的表情，就是這場遊戲的第一個訊號。當連蘋果都得低頭去敲一家上了黑名單的中國廠商大門，代表這個產業的定價權已經徹底換了主人。

至於這位新主人能坐多久，誰能知道？

第二十四期專欄(出刊日期： 2026-07-15)

---

iPhone殺了諾基亞、AI卻沒殺死資安，關鍵差在「補充性資產」重估



https://www.businessweekly.com.tw/archive/article?strid=7014448

還記得幾個月前的「軟體末日論」嗎？

當時市場的論調是，在AI出現後，大部份軟件公司都會被消滅，因為AI可以輕鬆寫出代碼。於是，華爾街開始無差別地拋售軟體公司。

我在當時的專欄，曾經寫過：

> **「未來的贏家，不是那個『最能簡化流程』的 AI，而是那個『數據就在它家、流程就在它家完成、且擁有獨家行為洞察』的軟體。」**

幾個月後的今天，雖然市場目光集中在半導體公司，但資安板塊已經默默創下新高。**大家以為 AI 會摧毀軟體應用層，事實上，AI 正在重新定義並轉化它。**

▉ 資安股從「AI 受害者」到市場逆轉

2026 年 2 月底，Anthropic 發布 Claude Code Security 相關工具，市場有不少聲音認為，這代表着 AI 將取代傳統資安。

當時的邏輯在於，AI 能自動掃描漏洞、分析並修補程式碼，還能偵測威脅，因此終端、網路與漏洞管理等傳統廠商將被邊緣化。

市場隨即恐慌拋售，不少資安公司單季跌幅超過 30%。Nasdaq ISE 資安指數第一季下跌近7%，表現落後標普 500 指數。

這與 2023 年市場擔憂「ChatGPT 摧毀 Google 搜尋」的邏輯相似。**每當強大新技術出現，市場往往先關注「誰會被消滅」，忽略了「誰會迎來新需求」**。

直到 4 月初，Anthropic 發布 Project Glasswing，局勢徹底扭轉。

▉ 理解 AI 的「五層蛋糕」架構

要看懂這場逆轉，得先跳出「AI 對某某產業好不好」這種線性思考。

NVIDIA 執行長黃仁勳曾提出 AI 的「五層蛋糕」架構：能源、晶片、基礎設施、模型、應用。每一層都依賴底層支持，且每一層的擴張都會對底層施加壓力。

這個框架的最大價值，是它逼你不要把 AI 當成一個「軟體功能」在想，而是把它當成一個完整的產業堆疊在想。

目前市場討論多集中在最頂層的「AI 應用是否會取代 SaaS」。雖然部分應用層 SaaS 確實面臨壓縮，但若僅看這一層，便會忽略整體產業的變化。

當整個 AI 蛋糕規模擴大十倍，五個層級都會產生全新的風險、複雜度與失效點，這些都轉化為資安市場的潛在市場規模（TAM）擴張。

▉ 為什麼 AI 無法取代資安？

先前的恐慌邏輯存在盲點：過於關注「AI 能做什麼」，忽略了「AI 讓世界變成什麼樣子」。**數據顯示，AI 增加的安全漏洞與攻擊面，遠大於其能自動化解決的問題**。

第一，AI 生成的程式碼，本身就是資安災難。

Veracode 的 2025 年生成式 AI 程式碼安全報告指出，45% 的 AI 生成程式碼包含 OWASP Top 10 漏洞，Java 的資安失效率更達 72%。

CodeRabbit 的分析也顯示，AI 生成的 Pull Request（PR）漏洞數量是人類的 2.74 倍。 在 Y Combinator 2025 年冬季班中，有 25% 的新創公司其 95% 的程式碼由 AI 生成，研究人員在其中發現了數千個漏洞與外洩金鑰。

開發速度提升數倍的代價，是資安問題的指數級增長。

第二，AI 讓攻擊者變得比防禦者更快。

世界經濟論壇（WEF）2026 年全球資安展望顯示，94% 的組織認為 AI 是資安變革的核心驅動因素，87% 認為 AI 相關漏洞是增長最快的風險。

根據 KnowBe4 的數據，目前 86% 的釣魚攻擊由 AI 驅動，深偽（Deepfake）詐騙嘗試較 2022 年增長了 2,137%。面對被壓縮的攻擊時間，防禦端必須被動升級。

過去，發動一次複雜的「魚叉式網路釣魚」需要駭客花幾天研究目標並模仿語氣；現在，駭客只需讓 LLM 讀取目標 CEO 的公開演講，並在幾秒內生成極具說服力的詐騙郵件。

更棘手的是「多態性惡意軟體」，AI 能讓病毒在每次傳播時自動重寫代碼，改變外觀卻保留攻擊功能，如同通緝犯每過一個路口就自動整容。**面對被壓縮到毫秒級的攻擊時間，防禦端必須被動升級，只有 AI 才能打敗 AI。**

第三，AI Agent 本身就是全新的攻擊面。

企業內部的非人類身分（如 API、機器人、AI 代理）數量已達人類身分的 5 到 100 倍。

這些 AI Agent 會自主與 API、數據庫及其他系統進行認證，傳統的身分與存取管理（IAM）系統難以因應。

Palo Alto Networks 收購 CyberArk 正是為了保護這些機器與 Agent 的身分安全，這代表業界正將「Agent 身分安全」視為未來十年的核心市場。

第四，AI 系統本身就變成新的資安支出類別。

模型、訓練數據、推論端點與 Prompt 等新元素都需要防護。模型中毒、提示詞注入（Prompt Injection）、模型萃取及 AI 供應鏈風險，都是全新出現的風險類別。

這並非單純在傳統資安中加入 AI 功能，而是完全新增的一整層支出。

Project Glasswing 為什麼是敘事的轉折點

真正的轉折點，是 4 月 7 日 Anthropic 發布 Project Glasswing。

Anthropic匯集了 Apple、Amazon、NVIDIA 等關鍵基礎設施巨頭，更重要的，是名單當中也有CrowdStrike和Palo Alto Networks兩家資安巨頭。

計畫的核心是將 Anthropic 擅長偵測漏洞的 Mythos 模型，防禦性地嵌入合作夥伴的資安基礎設施中。

這代表著Anthropic選擇的路徑不是「自己做一個資安產品去打 CrowdStrike」，而是「把我的模型嵌進 CrowdStrike 裡」。

這個選擇本身，就是一份公開聲明：

> **「連我們（一個頂尖 AI 實驗室）都認為，光靠 AI 無法有效保護關鍵軟體。我們需要現有資安平台的資料、遙測、偵測引擎和回應能力。」**

雖然 AI 模型能快速找出漏洞，但要轉化為實際的安全防護，必須依賴 CrowdStrike 等平台提供的即時遙測數據、企業級優先級判定，以及與既有維運流程的整合。

事實是，一個孤立的 AI 模型，無論它多麼聰明，是無法保障企業安全的。

要讓 AI 的安全能力落地，它必須與現有的資安基礎設施融合，它需要終端遙測數據來提供上下文，需要網路防護網來執行即時攔截。

這正是「應用層轉型」的縮影：AI 沒有消滅既有的價值鏈，而是透過與基礎設施的深度整合，讓整個生態系的價值倍增。

將大型語言模型（LLM）單獨用於資安的效果有限，但若將其嵌入已累積龐大端點數據的平台，價值將大幅放大。

事實是，從 4 月到 6 月，CrowdStrike 和 Palo Alto Networks都分別漲近 100 %，兩檔股票皆創下單季歷史最佳表現。**市場從 2-3 月的恐慌性拋售，轉為對 AI 時代資安需求的重新定價**。

▌兩個更深層的商業啟示

啟示一：AI 產業的價值分配，永遠要看「補充性資產」（Complementary Assets）

新技術是否能取代既有玩家，取決於既有玩家累積的資產在全新時代中是成為資產還是負擔。

當年 iPhone 讓 Nokia 死掉，是因為 Nokia 的補充性資產（實體按鍵製造、傳統通訊協定）在觸控時代變成負擔。

但資安不是這樣。CrowdStrike 累積了十年的端點行為資料、Palo Alto 累積了十年的網路遙測，這些補充性資產在 AI 時代不是負擔，是放大器。

回到我幾個月前寫的那句話，「數據就在它家、流程就在它家完成、且擁有獨家行為洞察」的軟體，才是贏家。資安公司剛好完美符合這三個條件。

> **所以判斷一個 AI 應用會不會取代既有廠商，正確的問題不是「AI 能做什麼」，而是「既有廠商的補充性資產，在 AI 時代變得更值錢還是更不值錢」**。

啟示二：AI 能解決很多問題，但也會創造很多新問題

每次 AI 能力躍遷，它同時在做兩件事：

一，讓一部分既有工作自動化（這是市場看到的）。二，創造一大堆從來不存在的新問題（這是市場忽略的）。

AI 生成代碼帶來更多漏洞，AI 攻擊加速推升了即時偵測的需求，AI Agent 的部署則催生了新的身分治理需求。

這個框架不只適用資安。把「資安」換成「合規」、「治理」、「稽核」、「觀測性」，同樣邏輯全部成立。**所有在 AI 之上、負責「管理 AI 造成的複雜度」的產業，長期需求都是被 AI 放大的，不是被吃掉的。**

寫在最後

回到 AI 的五層蛋糕架構。AI 應用層的擴張雖然會壓縮部分傳統 SaaS 的價值，但同時也放大了每一層的資安需求。這兩者共存於同一個發展趨勢中，只是市場通常先注意到壓縮的一面，隨後才意識到擴張的機會。

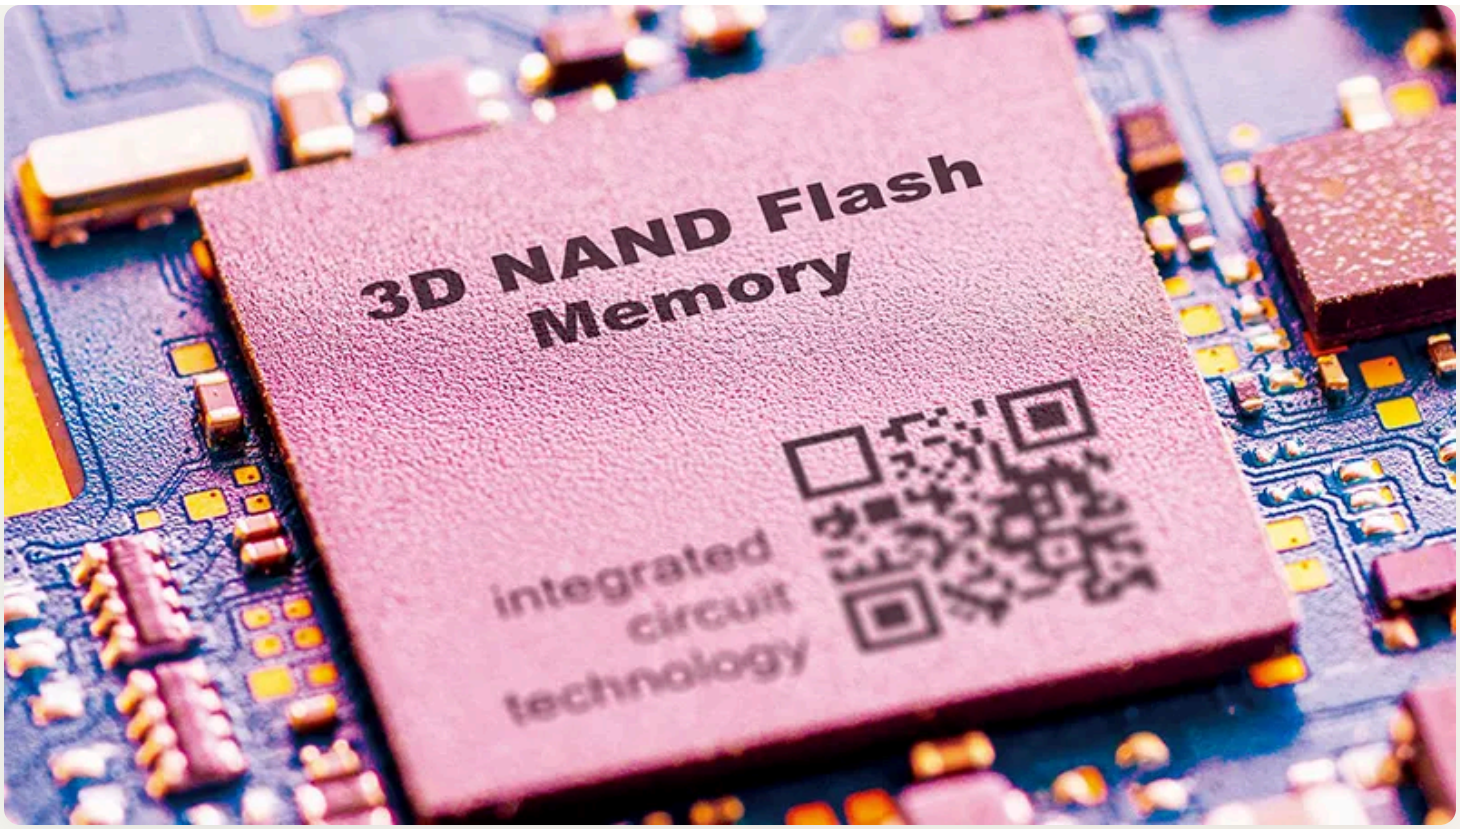
所以幾個月前那句話，我今天想再說一次：

> **未來的贏家，不是那個「最能簡化流程」的 AI，而是那個「數據就在它家、流程就在它家完成、且擁有獨家行為洞察」的軟體。**

下次市場再度出現「AI 將取代某個產業」的言論時，可以先思考一個問題：**該產業累積的補充性資產，在 AI 時代是變得更值錢，還是更不值錢？若答案是更值錢，那麼當下的取代論，或許就是下一次市場反轉前的布局良機。**

第二十五期專欄(出刊日期： 2026-07-22)

被嚴重低估的AI算力要角，快閃記憶體為何迎來最強翻身？



https://www.businessweekly.com.tw/archive/article?strid=7014470

HBM 和 DRAM，可以說是過去一年半導體產業討論度最高的兩個詞。而 NAND Flash 和 SSD，雖然價格也在不斷上漲，但在多數人心中，它們最多只是「順便」被帶動起來的配角。甚至許多人會將「記憶體（Memory）」與「儲存（Storage）」混為一談，把儲存視為記憶體宏大敘事中的一個小小註腳。

然而，市場數據正在打破這個刻板印象。根據 TrendForce 的數據，2026 年第二季，NAND Flash 的合約價預計將環比暴漲 70% 至 75%，漲幅破天荒地超越了傳統 DRAM 的 58% 至 63%。這是本輪半導體週期中，NAND 的價格動能首次超越 DRAM。

美光近期公布的財報也反映了同一個趨勢：其 DRAM 營收環比增長 67%，而 NAND 營收環比增長高達 99%。用絕對金額來看，DRAM 依然是營收老大；**但若從邊際增速來看，AI 儲存層的爆發強度顯然更為驚人**。

AI 推理架構的典範轉移

過去我們談 AI 儲存，講的都是「AI 需要更多資料」，這是一個非常籠統的敘事。

在 2026 年的今天，**儲存晶片（NAND Flash）正在發生一場更本質的變革：它開始直接參與 AI 的「推理（Inference）」計算過程**。

這背後的關鍵，在於 AI 模型在回答問題時，必須動態生成的 KV 快取（KV Cache）。

簡單來說，當你和 AI 進行一場很長的對話，或者丟給它一本數十萬字的小說時，AI 每產生下一個字，都必須「記得」前面所有的對話內容。

為了避免每產生一個新字，就要把整段歷史對話重新讀取、重新計算一次，AI 會把前面已經計算好的對話特徵（在技術上稱為 Key 和 Value）暫存下來，這就是 KV 快取。

問題在於，這個快取的體積非常龐大。它會隨著對話長度以及同時在線的使用者人數呈線性暴增。

在過去，這些即時計算的數據必須全部塞在最靠近 GPU 的 HBM（高頻寬記憶體） 或伺服器的 DRAM（主記憶體） 中。

但 HBM 雖然速度極快，容量卻非常稀缺且昂貴（通常單顆 GPU 只有 80GB 到 141GB 左右）。**當成千上萬個用戶同時向 AI 提問，且每個人都輸入超長文本時，GPU 的 HBM 空間會在瞬間被 KV 快取徹底擠爆**。

如果只靠購買更多昂貴的 GPU 來擴充記憶體容量，成本將高到難以想像。這就是為什麼輝達在 2026 年初推出了 CMX（Context Memory Storage）平台。

CMX 的核心邏輯是：既然 HBM 和 DRAM 的空間不夠，那就把讀寫速度極快的 NVMe SSD 納入記憶體架構中，作為「溢出層（Overflow Tier）」。

當用戶在進行長對話時，系統會把當下最緊急、正在處理的 KV 快取留在 HBM 中，而把暫時沒用到、但等一下會讀取到的歷史對話快取，先「溢流」存放到 SSD 裡。需要時，再透過高速通道快速調回。

這種架構的轉變，直接重塑了 AI 伺服器的硬體配置：

在訓練階段，伺服器主要需要讀取固定的數據集，單台伺服器的 SSD 配置大約從 4TB 增加到 8TB 即可。

但在推理階段，因為要同時應付無數用戶的長對話與即時快取，**單台推理伺服器的儲存需求直接從過去的 64TB 暴增至 122TB 甚至更高**。

▉ Agentic AI 的崛起：開啟全新的 I/O 模式

如果說 CMX 平台解決了當前的記憶體不足問題，那麼代理式 AI（Agentic AI）的普及，則從根本上改變了數據讀寫與處理的方式。

過去我們與 AI 的互動採用「離散提示」模式，也就是你問一句、它答一句，當對話結束時，系統暫存的資料就會釋放。

現在我們進入了「持續代理式工作流」的時代，AI 智能體會主動在背景規劃任務、調用各種外部工具，並進行自我反思與修正，整個過程可能會連續運行數小時甚至數天。

這種新型態的工作模式對儲存系統帶來了新的要求。首先，AI 智能體在長達數天的運作過程中，必須隨時記住先前的決策與狀態，這代表大量的中間運算資料需要被長期且安全地保存在儲存空間中。

其次，AI 智能體在思考與執行任務時，需要頻繁且反覆地從硬碟中讀取先前的歷史紀錄與相關知識。

為了因應這種高頻率的讀寫需求，AI 基礎設施中誕生了一個全新設備，稱為 SSD POD。這是一種透過超高速網路直接與 GPU 集群連接的專屬儲存池，突破了傳統硬碟插在單一伺服器上的限制。

在代理式 AI 時代，如果沒有這種儲存節點提供極低延遲與高頻寬的隨機讀寫支持，GPU 就會因為等待數據傳輸而頻繁「空轉」，進而大幅降低運算效率。

▉ 傳統硬碟缺貨：加速 SSD 替代效應的連鎖反應

除了 AI 計算直接帶來的記憶體需求外，另一個推動儲存晶片（NAND Flash）需求暴增的幕後推手，來自於傳統機械硬碟（HDD）的嚴重缺貨。

在大型資料中心裡，資料通常會分類存放：

- 熱數據（Hot Data）：需要頻繁且快速讀取的資料，使用速度快的 SSD。
- 數據（Cold Data）：不常存取、用來備份的歷史資料，通常儲存在成本極低、容量極大的傳統機械硬碟（Nearline HDD）中。

然而，AI 應用的爆發讓全球對儲存容量的需求集體噴發，導致企業級機械硬碟的產能供不應求。

Seagate 和 Western Digital 等硬碟大廠指出，2026 年全年的企業級機械硬碟產能，幾乎已被微軟、Google 等大型雲端服務商（CSP）提前搶光，部分高容量硬碟的交貨時間甚至被拉長到52 週以上。

面對機械硬碟買不到、交期太長的困境，各大資料中心被迫做出改變：直接用高容量的 QLC SSD（固態硬碟）來替代傳統機械硬碟。

這個無奈之舉，卻意外帶來了顯著的營運優勢。根據產業分析，用高容量 QLC SSD 取代傳統機械硬碟，可帶來數倍空間效率提升與顯著 TCO 改善。

此外，Meta 等科技巨頭也指出，在 AI 的工作流程中，傳統機械硬碟的讀寫速度實在太慢，已經成為拖累 AI 運作的瓶頸，升級到 SSD 勢在必行。

然而，這種「用 SSD 替代 HDD」的趨勢，卻引發了連鎖反應。由於高階的 NAND 晶圓產能同時還要供應給前述的 AI 推理使用，導致 QLC SSD 的產能也開始出現供不應求的缺口。

為了解決機械硬碟短缺的瓶頸，資料中心轉向購買 SSD，結果反而進一步推升了整個 NAND Flash 產業的供給緊張與價格壓力。

▉ 供給側也難以跟上需求

在市場的正常邏輯下，當需求出現爆發性成長，產業龍頭便會開始擴產，進而結束這波供需失衡的週期。然而，當前的實際情況是，各大記憶體龍頭短期內並沒有大幅擴充 NAND 產能的計畫。

三星與 SK 海力士在產能策略上，明確將資源優先分配給利潤率更高的 HBM與先進 DRAM，而非 NAND。

理由非常現實：HBM 的每位元營收與利潤率遠高於 NAND。在無塵室空間、設備與工程人力有限的情況下，大廠自然會選擇獲利空間更大的產品。

根據市場調查機構 Omdia 的數據，SK 海力士甚至在2026年調降了 NAND 晶圓的投片量；三星也將部分廠區的混合產線調整為 DRAM 生產，目標在年底前大幅提升先進 DRAM 的月產能。

即使大廠有意建置新的 NAND 廠房，也無法在短期內提供支援。例如美光在新加坡的新 NAND 廠，以及 SK 海力士的 M17 新廠，預計的量產時程分別落在 2028 年與 2029 年。

> 這意味著在 2028 年之前，全球幾乎沒有大規模的全新 NAND 產能可以真正投入市場。從目前的建廠時程來看，NAND 產業的供給緊繃狀態將至少維持到 2027 年底。

在主流韓美大廠集體「分心」或延後建廠的背景下，市場上僅有極少數玩家在積極擴產，但這並不足以緩解全球的供給缺口。

鎧俠和閃迪作為純粹的 NAND 廠商，它們沒有將資金與精力轉移去研發 HBM 的包袱。其 2026 年資本支出年增 41% 至 45 億美元，且北上（Kitakami）二廠已經投入營運。**這使得它們成為目前純 NAND 投資標的裡，估值邏輯最乾淨、最專注於享受這波企業級 SSD 紅利的玩家**。

而中國的長江存儲雖然其市佔率在一年內從 8% 快速跳升至 13%，展現了強大的技術追趕能力。

然而，受限於美國的出口管制，海外主流客戶無法對其產品進行認證與採用。YMTC 的產能主要用於吸收中國龐大的內需市場，但對於緩解全球（尤其是西方大型雲端服務商）的供給緊繃，幾乎起不到任何實質作用。**它是地緣政治的變數，而非全球市場的解方**。

除了產能擴充受限，現有技術的升級難度也大幅增加。目前 NAND 的擴產高度依賴堆疊層數的提升（從 200 層向 300 層、400 層推進）。

然而，隨著堆疊層數越來越高，晶圓在製造過程中極易產生彎曲與變形，導致良率提升的難度倍增，爬坡期從過去的幾個月拉長到一年以上。

因此，廠商技術藍圖上宣稱的規格，往往需要 12 到 18 個月的滯後期，才能真正轉化為市場上的實際產能。

重新定義 NAND：從「廉價商品」到「AI 關鍵拼圖」

我並非要宣稱「NAND 的重要性已經超越了 DRAM」。在 AI 的世界裡，DRAM 與 HBM 作為「算力核心」與「運算頻寬」的地位依舊無可動搖，它們依然是整個半導體重工業的皇冠。

> 然而，我們必須意識到，過去被視為「便宜、隨時可替代、產能嚴重過剩」的 NAND Flash，如今正經歷一場深刻的「去商品化」。它不再只是單純用來存放冷數據的廉價容器，而是成

> 為了直接參與 AI 推理、決定 GPU 運作效率的關鍵算力拼圖。

更值得注意的是，**NAND 面臨的結構性缺貨，其嚴重程度甚至可能超越 DRAM**。

在 DRAM 領域，雖然 HBM 擠壓了產能，但三大巨頭依然將其視為核心戰場，資本支出與技術升級從未停歇。但在 NAND 領域，韓美巨頭因為 HBM 而集體「分心」，這導致全球 NAND 的有效供給，在面對 AI 推理的需求暴增時，顯得極其脆弱。

> 在我看來，近期相關記憶體與儲存概念股的股價波動，本質上，這些波動大多只是市場沿用舊有「消費電子週期」思維去解讀新時代的「雜音」。而在這片市場雜音中，NAND Flash 的處境尤其顯得格格不入且被嚴重低估。

第二十六期專欄(出刊日期： 2026-07-29)

亞洲最大上市案長鑫存儲掛牌，記憶體中長線前景全解答



https://www.businessweekly.com.tw/archive/article?strid=7014505

六月，一群來自華為關聯設備商的工程師，在沒有預警的情況下被請出了長鑫存儲的核心研發無塵室。他們原本負責設備維護，但從此門禁收回，不再允許進入。

與此同時，長鑫存儲對華為的DRAM報價持續上調。華為要求價格減讓。長鑫存儲的回應是：不。

更有趣的是：在64GB DDR5伺服器模組這個品類上，長鑫存儲的報價已經超過了三星。三星大約1,240美元一條，長鑫存儲比這個數字還高。

你上一次聽到一家中國公司對華為說「不」，是什麼時候？

答案是：應該極少。

> **一家成本結構仍然落後龍頭超過30%的公司，正在對它最大的客戶行使定價權，態度是「我開這個價，你愛買不買」。**

7月27日，長鑫存儲在中國科創板掛牌，募資約579億人民幣（約86億美元），是2026年迄今亞洲最大的IPO。

技術還是落後一點

2026年第一季，長鑫單季營收73到75億美元，年增超過700%。一個季度，幾乎等於2025年全年。營業利潤率約70%。

到2026年底，長鑫的晶圓產能預計達到約35萬片／月，美光約38.5萬片。數字上幾乎接近，中國也將成為僅次於韓國的全球第二大DRAM生產基地。

這個數字會被很多媒體拿來做標題：「長鑫存儲產能逼近美光！」

但這裡有一個大多數表面分析會犯的錯誤：**晶圓不等於位元**。

晶圓可以想像成一張直徑30公分的圓形矽餅，所有記憶體晶片都是從這張餅上切出來的。一張餅能切出多少顆晶片、每顆能裝多少資料，取決於製程有多先進。

三星、SK海力士、美光目前使用的是1a、1b世代，正在推進1c。長鑫的主力製程G4大約相當於1z世代，約17到19奈米。差一個世代，同一張餅上能切出的有效晶片數量，通常會少20%到30%。

再看良率。成熟廠商大約能讓85%到90%的晶片通過測試。長鑫的DDR5良率已經明顯改善，但還未達到這個水準。同樣切出100顆，能賣的好晶片會比較少。

把製程密度和良率疊在一起，結果很清楚：35萬片長鑫晶圓，最終能產出的記憶體總量（產業稱為「位元產出」）比美光少一截。每一顆能用的晶片，長鑫的生產成本也比三星、SK海力士、美光高出三成以上。

> **長鑫接近美光的是生產線數量，不是生產線的實際能力。這是產能規模的接近，不是技術與成本的接近。**

也因此，目前約70%的營業利潤率，主要來自供給稀缺。客戶選擇有限，即使價格較高也必須購買。一旦供給不再那麼緊張，成本上的劣勢就會直接反映在利潤上。

在圍牆裡當國王

但稀缺只是條件，真正讓溢價成立的，是這個市場的結構。

在一個完全開放的全球商品市場中，高成本生產者幾乎不可能長期維持溢價。客戶會套利到更便宜的供應商，高成本者被迫降價或丟掉份額。

但當市場是相對封閉的，外部供應被配額和管制限制、政策偏好推動國產化、買家沒有可靠的大規模替代選項，那個邏輯就失效了。

華為被出口管制卡死，先進HBM和高端DRAM的海外供應基本斷絕。騰訊、字節、阿里雖然沒有被直接制裁，但在三巨頭的分配優先序裡，微軟、Google、Meta、Amazon和NVIDIA生態永遠排在前面。

中國買家拿到的配額更少、交期更長。再加上中國產業政策對戰略基礎設施國產化的持續推動，中國超大規模買家被系統性地推向了長鑫存儲。

六月底，長鑫與騰訊簽下了一份三到五年的伺服器DRAM供貨協議，金額超過兩百億人民幣。字節跳動更誇張，五年合約超過七十億美元。客戶名單還包括阿里雲、聯想、小米。

這些合約帶有量價承諾和價格區間，恰恰是三星、SK海力士、美光在上行週期鎖定經濟性的標準玩法。

長鑫現在用的是同一本劇本，只不過只在中國這個閉環市場裡演。

> **長鑫存儲只需要是「最好的、可用的、大規模的國產選項」。在2026年的中國，這個描述只指向一家公司。**

蘋果也別想拿到折扣

早前有報導稱蘋果正在測試長鑫存儲的DRAM，主要用於中國市場銷售的設備，同時在遊說華府爭取更廣泛的使用許可。動機不難理解：全球記憶體短缺推高了蘋果的採購成本，它需要更多供應來源。

但如果你以為蘋果能拿到一個「友情價」，你大概還沒看懂長鑫現在的姿態。它連華為都敢收溢價、敢把工程師趕出去。它為什麼要便宜賣給蘋果？

蘋果的經典策略是讓供應商互相競爭，用三星壓美光，用美光壓三星，自己坐收漁翁之利。

但在這個半封閉的市場裡，長鑫的角色不是「美光的便宜替代品」。它是唯一的大規模國產選項。你沒辦法用一個壟斷者去壓另一個壟斷者的價。

蘋果能從長鑫拿到的條件，大概不會比華為拿到的更好。

對外面意味著什麼

這個封閉市場對全球短缺的影響其實十分有限。

長鑫的新增產能，短期內不會顯著緩解全球供給緊張。大部分產能被中國本土需求吸收；良率和密度差距意味著實際位元貢獻低於晶圓數字所暗示的；全球真正的瓶頸在HBM，而長鑫的HBM還在早期。

但它做了一件重要的事：它減少了中國需求對全球商品型DRAM的爭搶。沒有長鑫存儲，中國買家會更猛烈地競價三星、SK海力士、美光的配額，把全球價格推得更高。

換句話說，長鑫的存在讓兩個市場各自緊張，但互不加重。

逃離囚徒困境

記憶體行業幾十年來的經典劇本：每一家都有強烈動機擴產或降價搶份額。當三家同時這麼做，行業利潤崩塌。繁榮、蕭條、再繁榮、再蕭條，合作（產能和定價紀律）極難維持。

這是教科書級的囚徒困境。

但長鑫存儲並不完全在這個遊戲裡。

它的核心客戶和需求增長在中國，它沒有在跟三巨頭搶同一批西方超大規模買家的錢包。國產化偏好和在地化壓力，降低了它純粹靠價格競爭的需要。中國AI和雲端需求目前強勁到長鑫可以滿產滿銷、同時維持高價，不需要把產能傾倒進全球市場。

結果是，**長鑫存儲可以表現得像一個理性的國內寡佔者（在某些細分市場甚至是近似獨佔者），鎖定多年期高價合約、拒絕降價、優先利潤率**。

這些行為在一個開放的全球商品市場中，對一個高成本生產者來說是自殺。但在一個半封閉的市場裡，它們是理性最優解。

不過，這個優勢有保質期。長鑫計劃每年新增70到85千片晶圓產能直到2028年。

如果中國國內需求增長放緩，多餘的產能終究需要出口，長鑫會重新被拉回全球商品市場的囚徒困境裡。

這是中國半導體的經典劇本：先吸收中國國內需求，再向全球價格施壓。問題只是「什麼時候」。

HBM的良率問題，反而加固了DDR5的定價權

中國正在進行一場平行的AI基礎設施建設：華為昇騰生態、其他國產加速器、字節、騰訊、阿里的雲端擴張、政府支持的項目。

AI工作負載極度依賴記憶體。這是一場政策驅動的、多年期的產能建設，規模和持續性都遠超正常的週期性需求復甦。

而HBM，恰恰是長鑫存儲最弱的環節。

根據SemiAnalysis 2026年中的模型，長鑫存儲的早期HBM3（尤其是8層堆疊，更不用說12層）整體良率大約只有25%左右。

這意味著：為了生產一定數量的可用HBM堆疊，長鑫存儲必須投入遠多於成熟生產者的晶圓。而那些被HBM「吃掉」的晶圓，是從商品型DDR5的池子裡直接抽走的。 於是迴圈形成了：

強勁的AI需求同時推高DDR5和HBM的需求 > 長鑫存儲把更多晶圓轉向HBM以滿足國產AI晶片需求 > 因為HBM良率極低，這個轉移的幅度遠大於成熟生產者 > 中國國內商品型DDR5供給進一步收緊 > **長鑫存儲在剩餘DDR5上的定價權進一步增強**。

這就是為什麼當前的溢價和對華為的強硬姿態，不僅僅是一個臨時性的短缺現象，它正在被HBM量產的困難自我強化。

至少在長鑫存儲的HBM良率顯著改善、或者出現第二個國產HBM產能來源之前，這個緊繃狀態可能會持續得比正常記憶體週期所暗示的更久。

鐘聲之後

7月27日，中國科創板的鐘聲會響起。579億人民幣入帳。亞洲年度最大IPO。

地緣政治和產業政策已經不可逆地創造了一個「高成本但政治正確的中國DRAM閉環」。這個閉環裡的定價邏輯、競爭動態、客戶關係，跟全球市場越來越脫鉤。長鑫存儲不需要在成本上追平三星，因為它的客戶別無選擇。

但在我看來，分裂是真實的，卻不是永恆的。

長鑫存儲每年70到85千片的新增產能，終究會遇到中國國內需求增長的天花板。那一天到來時，多餘的產能會像水一樣尋找出口，而全球市場的囚徒困境會重新把它拉回殘酷的現實。

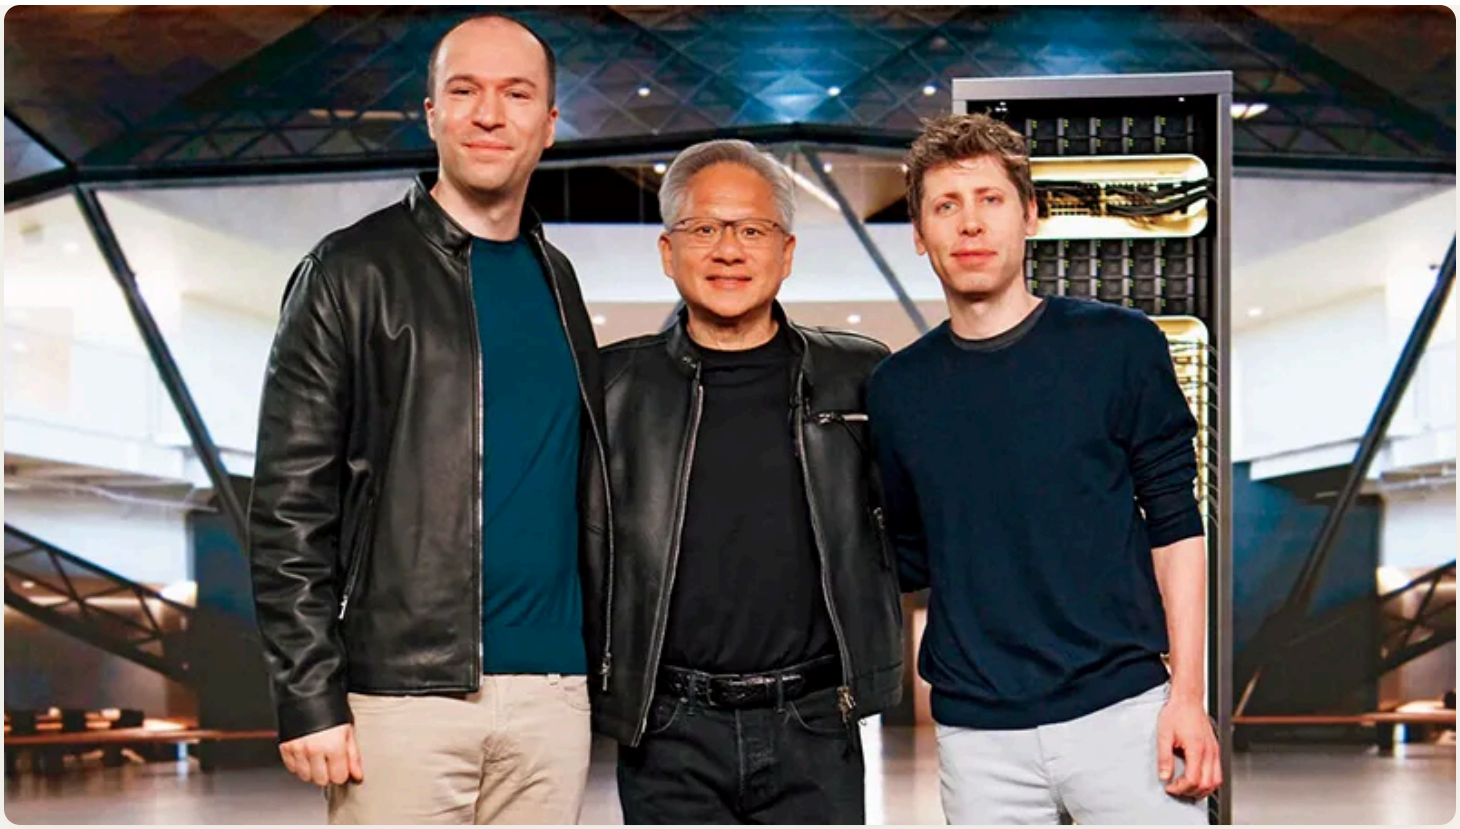
但那一天不是今天，也不會是今年。

> **今天，一個曾經虧損的「國產替代品」，把華為的工程師趕出了無塵室，對比三星收了溢價，讓騰訊和字節簽下了百億美元的多年期合約，然後以亞洲最大IPO的姿態敲響了鐘。**

2026年，中國記憶體產業第一次不再需要「便宜」作為存在的理由。它開始用稀缺性、用不可替代性、用「你沒有別的選擇」來定價。

第二十七期專欄(出刊日期： 2026-08-05)

當輝達變成OpenAI的影子銀行…怕的不是借錢，是這三件事



https://www.businessweekly.com.tw/archive/article?strid=7014530

Nvidia正考慮為OpenAI提供約兩千五百億美元的融資擔保，讓SoftBank在俄亥俄州那座十吉瓦的數據中心能夠借到錢、動得了工。

兩千五百億美元是什麼概念？這幾乎是一個中等國家的年度GDP。

消息一出，市場質疑聲浪鋪天蓋地。很多人指責黃仁勳是在「左手換右手」、虛增AI需求。但我認為這種指責太過簡化。

黃仁勳並非在製造假需求，他是真心在拼盡全力扶持AI生態圈、幫產業打破資本瓶頸。

然而，兩種事實可以同時成立：他確實是在全心推進AI社群的發展，但這種「影子銀行」的做法，也無可避免地拉大了整個產業的泡沫風險。

▌先處理那個最流行的詞

是的，結構上它確實是一筆「循環融資」。

Nvidia提供信用擔保 → 項目因此能借到錢 → 數據中心蓋起來 → OpenAI搬進去、塞滿Nvidia的GPU → 芯片銷售收入流回Nvidia。錢繞了一圈，回到起點。

很多人看到這裡就下結論了：循環融資，泡沫，完蛋。 但在恐慌之前，有一個技術上的區分值得搞清楚。搞清楚之後，你會發現真正該關注的重點完全不同。

> **「擔保」和「直接貸款」在會計與法律上截然不同。**

當年Lucent做的是賣方融資（Vendor Financing），真金白銀借出去，貸款躺在資產負債表上，客戶一倒閉立刻變成呆帳。1999年Lucent已撥出16億美元，那是實打實的信用暴險。 輝達今天提供的是「或有負債」。今天不花一分錢，不增加資產負債表上的債務，也不影響損益表。只有當OpenAI真的違約、擔保被觸發時，它才會變成真金白銀的問題。

▉ 輝達撐得住嗎？

以輝達今天的財務體質，答案非常明確：撐得住。

單季自由現金流將近500億美元，淨現金720億，總債務85億，股東權益1,955億。這是一張堡壘級的資產負債表。**就算2,500億擔保中有相當比例被觸發，以輝達目前的現金產生速度，完全有能力在一兩年內消化。**

與當年Lucent「融資承諾佔營收兩成、自由現金流還在燒」的脆弱狀態相比，輝達根本是另一個物種。

資產負債表上的故事可以放心，真正值得持續追蹤的是資產負債表「外面」的東西。

擔保的形式很輕、不影響當季數字，因此在心理與制度上比直接貸款更容易獲批與堆疊，容易在不知不覺中累積到可觀規模。

若輝達要開一張2,500億的支票直接貸款，內部資本配置委員會、董事會、分析師與評等機構都會施壓，數字的能見度會帶來紀律。但擔保只是財報腳註裡一行「最大暴險總額」，不改變當季數字，讓所有人更容易點頭，因為今天不用掏錢。

這本身是用信用撬動更大的經濟活動，邏輯上完全合理。但正因為容易，所以容易被加碼：2,500億的俄亥俄項目、CoreWeave 60 多億容量回購、Lambda 15 億、OpenAI 300 億股權投資、其他設施租賃擔保。

每一筆單獨看都合理，加在一起卻構成快速膨脹的或有負債網絡。

Lucent的賣方融資危險但可見。今天的擔保結構更分散、難以加總成單一數字。這代表它需要不同的關注方式：**你盯的不應該是某一季的報表，而是這個網絡的累積速度與總量**。

輝達的資產負債表今天完全不需要擔心，但表外的東西值得每個季度多看兩眼。

而表外風險會不會真的被觸發，最終取決於一個更基本的問題：需求到底是不是真的？

真正的問題：晶片賣不動了嗎？

很多人直覺以為輝達出來做擔保是因為晶片賣不動了，恰恰相反。

輝達最新一季數據中心收入為752億美元，年增92%。四大巨頭在2026年的資本開支加起來超過6,000億美元，GPU依舊供不應求。

OpenAI仍需要擔保，是因為產業瓶頸已經轉移。

兩年前瓶頸是GPU不夠，後來變成電力、土地與散熱，今天最大的限制是資本。一座大型AI工廠需要幾百億甚至上千億美元，這是超級重工業。

而OpenAI身處在一個極其殘酷的跑步機上。它有實打實的付費用戶，營收成長驚人。

但為了不被對手超越，它必須在下一代模型和基礎設施上投入呈指數級增長的資金。賺得快，花得更快。

二零二五年收入大約一百三十億，同一年燒了八十到九十億。它有生意，有客戶，有增長，但它拿不到「投資級」的信用評等。

當它想擺脫對微軟的單一依賴、自己聯手軟銀去蓋超大型數據中心時，保守的債務市場和銀行根本不敢放貸給一家信用評等不夠的科技新創。

> **黃仁勳扮演的是「影子銀行」與「信用包裝」，他憑一己之力用輝達的信用替AI社群背書，把金融機構的錢引進來讓項目動工。**

這是他在為產業做事的必要之舉，但這客觀上也確實把槓桿疊得更高、把泡沫吹得更大。

從賣晶片到賣「能力」

把近期新聞串聯起來：輝達推出數據中心租賃方案、提供長期雲端合作、建立AI工廠解決方案，現在又傳出提供財務擔保。黃仁勳正在系統性降低「擁有AI算力」的門檻。

過去輝達的模式很純粹：設計最好的GPU，一手交錢一手交貨，不需要管客戶把晶片拿去哪或借不借得到錢。但當AI工廠規模膨脹到一座要幾百億美元時，客戶一次性買不起。輝達若堅持只做設備商，天花板就會受限於客戶的資產負債表。

輝達開始幫客戶解決「錢從哪裡來」的問題。

這類似GE當年成立GE Capital幫航空公司做引擎租賃融資，或勞斯萊斯按「飛行小時」收費。當產品貴到客戶無法直接購買時，企業要麼降價，要麼降低購買門檻並承擔風險。輝達選擇了後者。

這是一把雙面刃。若AI工廠最終成為企業必備的基礎設施，輝達協助客戶跨過資本門檻，就像銀行貸款蓋電廠，前期投入大，後面能形成長期的生態系需求，估值邏輯將改寫。

但若AI模型公司無法建立自我造血的商業模式，今天的融資擔保就會變成明天的信用風險，把整個行業的系統性風險綁在自己身上。

▉ 跟電訊泡沫到底像不像？

一九九十年代末電信泡沫中，Lucent瘋狂向新創提供賣方融資，額度達營收20%以上，泡沫破裂後吞下巨大呆帳崩潰。Cisco也參與了賣方融資，雖然憑藉資產負債表活了下來，但股價暴跌後花了近二十年才重回高點。

今天的輝達更像當年的Cisco，且實力更為強大。

輝達淨現金高達720億美元，幾乎沒有債務。2,500億擔保是或有負債，即使未來發生最壞情況，以輝達每季產生近500億自由現金流的速度，完全能消化損失。

> **真正風險不在於破產，而在於「估值壓縮」。**

當市場意識到輝達正在用自己的信用催化全產業的需求，投資人會質疑需求背後的風險含金量，進而調降本益比。黃仁勳越是用力拉動產業向前，市場對潛在泡沫的疑慮就越深。

▉ 起數據中心，比賭模型安全

不過，這次輝達與OpenAI的交易裡，還有一個非常重要的細節：這筆兩千五百億的擔保，是用來蓋數據中心的。土地、廠房、電力、冷卻系統。它不覆蓋晶片採購，也不覆蓋模型研發。

在金融邏輯上這叫「前置基礎設施融資」，風險性質不同。借錢研發模型，一旦技術落後，研發費用就變成沒有殘值的空氣。

擔保蓋數據中心，數據中心是硬資產。即便OpenAI倒閉，位於俄亥俄州10 GW 的數據中心依然存在，輝達可轉租給其他巨頭。輝達下注的是整個算力賽道，而非單一公司。

▌那什麼情況下會真的出問題？

最危險的劇本是以下幾件事同時發生：

1. **變現落後**：OpenAI和Anthropic的推理收入增長放緩，但訓練與基礎設施支出降不下來，現金流缺口擴大。
2. **信貸收緊**：信貸市場對AI基礎設施定價更謹慎，CDS利差擴大，融資成本上升。
3. **工程延誤**：大型數據中心因土地、電力或資金問題拖慢進度，增加融資燒錢時間。

當這些情況同時發生，擔保就會從紙面風險變成真實風險。電信泡沫中最激進的融資階段僅持續兩到三年，信貸一旦收緊，解體速度非常快。

▌所以，怎麼辦？

我不覺得現在是恐慌的時候。需求是真的，黃仁勳想把AI生態系做大做強的心也是真的。

但我們必須承認，當賣鏟人開始承擔金融銀行的角色、借錢給顧客買鏟時，哪怕他的動機再純粹，客觀上也確實把整體金融槓桿拉得更緊，增加了泡沫破裂時的衝擊力。

未來我們需要追蹤的，不只是AI工廠蓋得有多快，更包含：OpenAI的推理收入能否跑贏資本開支、GPU租賃價格是否下滑、巨頭是否下調資本開支。

> **黃仁勳是用極大的熱忱與實力在推動一個時代進步。但正如歷史無數次證明的那樣：偉大的願景與膨脹的泡沫，往往本來就是同一個故事的兩面。**

第二十八期專欄(出刊日期： 2026-08-12)

從微軟到Anthropic六大AI巨頭，一兆美元「隱形融資」正在成形



https://www.businessweekly.com.tw/archive/article?strid=7014558

AI 技術越複雜，金融工程就得跟著升級。

最近，Anthropic 在同步做兩件事。

六月時，他們先用350 億美元的 SPV 結構，鎖定 Google TPU 產能，解決眼前的算力瓶頸。八月初，Blackstone 又開始跟投資人談第二筆類似結構，傳聞規模在 360 億左右。

同時，他們的自研晶片團隊已經開始招人，從 OpenAI 挖來做過推理晶片的工程師，同時跟 Samsung 探索二奈米製程合作。

因為算力是約束條件，必須用一切手段去優化。

> **但如果你去翻 Anthropic 的資產負債表，你不會看到 350 億美元的晶片資產。你也不會看到對應的債務。你只會看到一筆租賃費用，每季按時支付，在損益表的營運成本裡。**

那 350 億的晶片在哪裡？在一個叫 SPV（特殊目的載體）的東西裡面。那 350 億的債務在哪裡？也在那個 SPV 裡面。

這筆交易到底是怎麼運作的？

Apollo 旗下的一個結構化融資團隊成立了一個 SPV，然後 SPV 用私募集債的錢去買 Google 和 Broadcom 共同開發的 TPU。買完之後，SPV 把晶片租給 Anthropic，Anthropic 的租賃付款就是這筆債務的還款來源。

Broadcom 為優先級債券提供了殘值擔保：如果 Anthropic 停止付款，而那些 TPU 在二手市場上賣不出足夠的錢來償還優先級債務，Broadcom 會補上差額，大約 300 億的優先級債務都有這層保護。

有了這層保護，優先級債券的定價幾乎達到投資級水準。60 億的超級優先級（A1）賣給銀行，定價大約是美國國債加 100 個基點；240 億的優先級（A2）定價大約 5.75%。

相反，最底層沒有 Broadcom 保護的 45 億初級債券，利率跳到 8.5%。

換句話說，同一個借款人、同一批抵押品、同一個 SPV 裡面，一旦拿掉 Broadcom 那層擔保，資本成本明顯高出一截。

這不是一筆一次性交易

Apollo 在官方新聞稿裡把這個結構稱為「Broadcom AI XPV Platform」。

注意，是「平台」，不是「Anthropic 專屬融資方案」。

Broadcom CEO Hock Tan 在財報電話會議上明確表示，這個平台的目標是到 2028 年部署超過 20 吉瓦的算力。**以每吉瓦大約 350 到 500 億美元的資本強度粗估，這是一個接近甚至超過一萬億美元的工業化融資流水線，350 億只是頭盤。**

結構已經被設計成可重複使用：發起 SPV → Broadcom 提供殘值擔保 → 打包賣給保險與機構資金。未來只要有新的大客戶或新的產能需要鎖定，就可以再跑一輪。

看到這個規模，就會理解為什麼 Apollo 和 Blackstone 這麼積極了。

華爾街的角色

Apollo 設計了整個 SPV 結構，而它的保險部門提供了長期限的資金來源。Blackstone 的信貸和保險部門是核心共同錨定方，它們的網絡把大約一半的債務分銷給了銀行、保險公司和其他機構投資人。

更重要的是，Blackstone 在 Anthropic 的關係裡同時出現在三個層面：股權（大約 10 億美元的持股）、信貸（這筆 350 億的 SPV 融資）、以及企業服務（合資公司，幫 Anthropic 把模型落地到企業客戶）。**它在 Anthropic 整個商業閉環裡，早已不是一個單純的債權人。**

而它們搶著做這件事，原因也很直接。Apollo 和 Blackstone 旗下的保險資金需要長期限、有抵押、有穩定現金流的資產來匹配負債。

AI 晶片的租賃結構恰好全部符合：有硬件做抵押、有 Broadcom 做殘值擔保、有 Anthropic 的租賃付款做現金流、久期夠長、單筆規模夠大。

> **這是目前市場上少數能同時提供規模、收益、相對安全墊，又能綁定高增長 AI 客戶的資產類別。**

為什麼 Anthropic 要做這些金融操作？

因為它在跟時間賽跑。

Anthropic 的終局目標是垂直整合：自己設計晶片，針對 Claude 的推理模式做優化，降低單位算力成本，擺脫對任何單一供應商的長期依賴。當模型架構越來越穩定、工作負載越來越可預測的時候，用通用晶片跑所有東西就開始變得不經濟。自研是必然的方向。

但自研晶片從設計到量產至少要三到五年。

而 Anthropic 等不了三到五年，他們2026 年的收入已經超過數百億，Claude 的用戶在快速增長，它需要吉瓦級的算力，而且需要現在就有。

> **所以這些操作的本質是「買時間」。用結構化融資把現有的、最好的晶片先鎖住，確保未來**

> **兩三年的算力供應，讓自研團隊有窗口把晶片做出來。**

Anthropic 需要這些晶片，但它不想用股權的錢去買。它今年五月剛融了 650 億美元，估值接近一萬億。但如果用股權的錢去買 350 億的晶片，那等於把寶貴的資本鎖在了一堆會快速折舊的硬件裡。

那些錢本來可以用來招最好的研究員、訓練下一代模型、做產品、準備 IPO。

而且，把 350 億的硬件資產和對應的債務放在自己的資產負債表上，會讓它看起來像一家重資產的硬件租賃公司，而不是一家高增長 AI 平台公司。這對 IPO 的估值敘事相當不利。

所以 SPV 結構同時解決了三個問題：讓 Anthropic 拿到算力、讓它的資產負債表保持「乾淨」、讓它的資本成本遠低於純靠自身信用能拿到的水平。

▉ 全行業都在這樣做

不要以為這是Anthropic這些未上市公司的專利。

微軟有 3,290 億美元的「尚未開始」的租賃承諾。這些租賃合約已經簽了，但因為數據中心還沒蓋好、還沒交付，所以它們還沒有出現在資產負債表上。已經確認的租賃負債大約 885 億。**也就是說，微軟真實的長期租賃承諾，是報表上那個數字的將近四倍。**

Meta 的 Hyperion 數據中心項目，用了 Blue Owl 的 SPV 結構，大約 270 到 300 億美元的私募集債放在 SPV 裡，Meta 的合併報表上不會直接顯示這筆債務。

五大雲端巨頭（微軟、Meta、Amazon、Alphabet、Oracle）加在一起，已經披露了大約 1.1 到 1.2 萬億美元的「尚未開始」的未來租賃付款，這個數字是它們資產負債表上已確認租賃負債的三到四倍。

而微軟剛剛把數據中心的估計使用年限從 15 年延長到 25 年，讓更多未來的租賃從「融資租賃」（計入 CapEx）變成「營業租賃」（不計入 CapEx），CapEx 指引從 1,900 億降到 1,750 億，但其實底層的投資計劃一分沒變。

> **整個行業都在做同一件事：把原本會以「CapEx」形式出現在報表上的巨大支出，盡量轉化為租賃、SPV、或有擔保、表外承諾。**

錢還是那些錢，數據中心還是會蓋，晶片還是會買。但報表上的數字，盡量看起來沒那麼嚇人。

這到底是好事還是壞事？

很多人看到這裡可能就會說，這就是AI泡沫。

我會說，某程度上是的，但也不完全是。

AI 基礎設施的建設規模和前置資本需求，已經超出了傳統企業資產負債表和銀行貸款能吸收的速度，而純股權融資會造成巨大稀釋。

純無擔保公司債對非投資級企業來說太貴或根本拿不到。私募集債加上殘值擔保加上 SPV 結構，讓 Anthropic 這樣的公司能夠以合理的成本拿到它需要的算力，跟那些資產負債表更強的巨頭競爭。

這是私募集債在做它最擅長的事：為真實的資產（晶片、電力、數據中心）提供靈活的大規模資本，在公開市場和銀行反應不過來的時候填補缺口。

其實，這和我們上星期談過的Nvidia 為 OpenAI 談大型融資擔保，本質上是一樣的。

這些「供應商用信用支撐客戶融資」的結構，讓整個生態系能夠比純靠市場自發融資更快地擴張。

當然，它也不是無風險的「金融創新」。它創造了一個規模巨大、部分不透明、高度相互依存的槓桿層。

這裡有一個根本的天期錯配，SPV 債券通常 5 到 10 年，數據中心租賃承諾動輒 15 到 25 年，而 AI 需求的能見度可能只有 18 到 24 個月。

Anthropic 每季都要付租金給 SPV，SPV 拿去還債，這筆錢跟 Claude 的用戶成長速度沒有直接掛鉤。如果單位算力價格下降、模型商品化、或出現更有效率的新架構讓現有 TPU 的價值大幅折損，Anthropic 還是得繼續付錢。

當然，如果增長持續，這些結構就是天才般的資本配置。如果增長放緩，它們就是被鎖死的長期義務，而殘值擔保會從「信用增強」變成「真實損失」。

這個趨勢不會停止

公司們正在變得越來越擅長讓支出「看起來」沒那麼可怕。延長使用年限、轉換租賃分類、用 SPV 隔離債務、用殘值擔保降低融資成本。

這些都是合法的、透明的、符合會計準則的。

但作為投資人，你需要意識到，巨頭每季報表上那個「CapEx」數字，其實已經越來越不是全貌了。

評級機構Moody's 多次公開警告，這些未開始的租賃承諾加上表外擔保，已經達到甚至超過巨頭的調整後債務水平，構成「實質信用惡化」。但 S&P 在 Meta 的 Beignet 結構上選擇了接受不併入母公司的處理方式。評級機構之間的分歧，本身就給了公司繼續操作的空間。

會計準則給了空間，公司就會用足那個空間。評級機構在事後追趕，試圖把經濟實質重新納入信用評估。這場「報表數字 vs 真實義務」的拉鋸，將會一直持續。

> **帳單沒有消失，它只是學會了隱身。**

第二十九期專欄(出刊日期： 2026-08-19)

算力租賃商財報打臉AI泡沫：舊世代GPU租金居然還在漲



https://www.businessweekly.com.tw/archive/article?strid=7014588

著名的大空頭 Michael Burry 一直在看空 AI，他最常講的一點，是整個 AI 產業正在上演「現代史上最大的會計騙局」。

微軟、亞馬遜這些巨頭，還有新崛起的算力雲，在帳本上把 Nvidia GPU 的折舊年限拉到 5 到 6 年。

但 Burry 認為，Nvidia 產品迭代太快，這些晶片的實際經濟壽命只有 2 到 3 年。**刻意拉長折舊，等於在掩蓋數千億美元的折舊費用，把公司利潤灌水。**

的確，根據摩爾定律，晶片的升級速度十分快。新架構一出，舊卡就該被淘汰。

這就像iPhone 出了 17，誰還會去買 13？在消費電子的世界裡，舊款就等於廢鐵。

▉ 會計槓桿的具體數字

為了搞清楚這場爭論，我們先看清折舊假設對利潤表的實質影響。

以一台價值 30 萬美元的 8 卡 GPU 伺服器為例。如果採用 6 年直線折舊，每年的折舊費用大約是 5 萬美元。如果採用 4 年折舊，每年的費用則是 7.5 萬美元。

兩者之間，是每台伺服器每年 2.5 萬美元的純利差。

> **將這個數字乘以幾萬甚至十幾萬張 GPU 的龐大機隊，每年的損益表差距就會達到數億甚至數十億美元，而實際的現金流、營收和硬體狀態沒有發生任何改變。**

這純粹是成本確認的時間差。

▉ 現實數據怎麼說

在 CoreWeave 2026年第二季財報電話會議中，執行長透露了一個細節。

他們最近簽下了一份 A100 的租賃合約，租期一直延伸到 2029 年。

A100 是 2020 年 Ampere 架構的產品。中間 Nvidia 已經推過 Hopper、Blackwell，後面還有 Rubin。

一張三手舊卡，居然還能簽出長約，管理層還說價格很有吸引力。**舊世代產品的定價維持在甚至高於幾年前的水平，產能幾乎全滿。**

另一家 AI 新雲公司 Nebius 的數據也同樣反映相似的情況。

他們在最新的商業更新中提到，舊世代 GPU 的租賃價格比上一季上漲了超過 30%。H100 的一年期合約租金，也從 2025 年底的低谷反彈了大約 40%。

舊卡沒有變成廢鐵，它們依然在機房裡全速運轉，租金甚至還在漲。

▉ 算力市場的「瀑布效應」

為什麼會這樣？是空頭們的模型錯了嗎？

分別是，他們把 GPU 當成了消費電子產品，但 AI 算力正在演變成企業級基礎設施。

在企業 IT 的歷史中，有一個非常成熟的模式叫做階層化需求，或者我們可以稱之為瀑布效應。

當年的 IBM 大型主機、Cisco 的企業級路由器、Dell 的 x86 伺服器，都遵循著同樣的生命週期。

當最新一代產品推出時，它確實會搶走最高階的客戶。**但舊產品並沒有瞬間歸零，它們會順著需求瀑布往下流，找到對價格更敏感、對極致性能要求沒那麼高的新買家。**

今天的 AI 算力市場正在複製這個路徑。

最頂級的前沿模型訓練，確實需要最新世代的 Blackwell 或 Rubin 芯片。但高價值的生產環境推理、企業級的微調、批處理任務，完全可以使用上一代的 Hopper。

而成本敏感型推理、Agent 應用、企業內部工作負載，其實是整個 AI 生態中基數最大、增長最快的領域。

> **許多中小企業、新創公司或特定行業的 AI Agent，並不需要極致的算力，他們需要的是「便宜、穩定、生態相容性好」的算力。這時候，CUDA 支援成熟、價格又親民的 A100，就成了最好的選擇。**

支撐殘值的底層引擎

支撐這個殘值市場的底層引擎，是推理需求的爆發。

訓練模型是一場軍備競賽，週期短、強度大、只集中在少數幾家頂級實驗室。但推理是一個持續性、分散式、海量級的市場。AMD 的 Lisa Su 曾估計，全球大約 60% 的 AI 算力已經被用於推理。

推理任務不需要最頂級的算力，它更看重性價比和吞吐量，這正是舊世代 GPU 最完美的歸宿。

只要非前沿需求層（推理、Agent、企業工作負載）持續擴大，舊卡就會持續有實質需求。殘值的高低，最終取決於這個需求層的厚度，而非 Nvidia 發布新卡的速度。

軟體生態的黏性，例如 CUDA 的相容性，以及已經部署好的機櫃與電力，讓舊卡能夠平滑地過渡到下一個需求階層。新世代的發布並沒有摧毀舊世代的價值，它只是把價值往下推了一層。

債務清償後的純現金流

當我們理解了「瀑布效應」後，再回頭看算力雲的財務模型，就會發現一個重要的利潤轉折點。

假設一家公司用 30 萬美元買下一台 8 卡伺服器。在典型的 4 到 5 年初始合約期內，客戶支付的租金現金流，通常已經覆蓋大部分甚至全部資產級債務與利息，並實現預期的基礎回報。

當初始合約結束後，這台設備在財務上已接近「無槓桿」狀態。**此時，無論它以多便宜的價格出租，其產生的營收扣除電費和運維成本後，幾乎全部都會轉化為純利潤。**

這就是為什麼 CoreWeave 和 Nebius 的管理層現在顯得比較有底氣。那些 2023 到 2024 年買下的、即將還清貸款的 H100，正準備進入這個「無槓桿純利潤期」。

▌舊晶片的第二春

事實上，CoreWeave 自己也在調整商業模式，提高舊晶片的使用率。

過去它本質上是一家「重型設備長租車行」：買最頂級的 GPU 伺服器，整台租出去，合約一簽好幾年。

收入穩定，但痛點很明顯。合約到期後，舊晶片很難再找到願意支付高額「整車長租」的客戶，因為很多客戶永遠在追最新最快的硬體。

為了解決這個痛點，CoreWeave 在 2026 年 3 月底正式推出了「託管推理（Managed Inference）」服務。

這項新業務，相當於 CoreWeave 自己成立了一個「算力 Uber 車隊」。

在這個模式下，CoreWeave 不再整台出租伺服器。它把合約到期、退役下來的舊晶片留在自己手裡，透過軟體組成一個龐大的算力池。

中小企業和 AI 新創不需要、也租不起整台機器，他們只需要在用戶真正使用 AI 時（輸入提示詞、生成圖片），向系統發請求。後台自動調度這些舊晶片完成運算，再按 Token 即時收費。

對客戶來說，根本不在乎後台跑的是哪一代晶片，只在乎回答夠不夠快、費用夠不夠便宜。

對 CoreWeave 來說，這是利潤結構的質變：透過軟體調度，讓原本可能閒置的舊晶片繼續工作，賣的不再是裸金屬時間，而是帶服務溢價的推理成果。

2026 年 Q2 財報會議上，管理層透露，這款上線才幾個月的產品，年化收入（ARR）已經從剛推出時的 100 萬美元，衝到超過 1 億美元。他們預估到 2026 年底至少會到 2.5 億美元，目前的瓶頸是短期產能不足，而不是需求不夠。

▌聰明錢已經在為「殘值」定價

管理層的樂觀可以當成公關，但信貸市場真金白銀的流向卻是實實在在的。

2026 年 8 月初，CoreWeave 完成了一筆 26 億美元的定期貸款。

在過去，銀行借錢給算力公司時極度謹慎。他們要求「債務期限」必須與「客戶合約」綁定，也就是說，只有當 CoreWeave 手握微軟或 OpenAI 的 5 年長約時，銀行才願意給出 5 年期的貸款。

因為在銀行眼裡，GPU 的折舊速度極快，一旦合約結束，這些硬體可能就一文不值。

然而，這筆 26 億美元的新貸款卻留下了兩年的空白期。這筆貸款的期限長達 5 年，但底層對應的客戶合約平均只有 3 年左右。

> **這意味著，在合約結束後的第 4 年和第 5 年，這批 GPU 將面臨沒有預定客戶的「裸奔」狀態。即便如此，摩根大通領頭的頂級機構還是提供了資金，而且市場超額認購。**

這群全市場最精明、最厭惡風險的債權人，用行動做出了判斷：他們願意承擔這兩年的續約與再利用風險。

他們相信，即使 3 年後初始合約到期，這些 GPU 依然能在市場上找到新買家，或透過託管推理等渠道繼續產生足夠現金流來還錢。

從過期牛奶到收租房地產

當然，這並不意味著 GPU 可以永遠用下去。

價格衰減和性能差距依然存在，折舊曲線終究會向下。**但 Burry 那種 2 到 3 年壽命、殘值為零的極端懸崖式假設，並不符合現在的情況。**

對於那些擁有龐大舊世代 GPU 資產的純租賃商來說，這不僅僅是會計數字上的平反。

> **這標誌著他們的商業模式，正在從高風險的資產折舊遊戲，實質性地躍遷為高毛利的長尾收租生意。**

第三十期專欄(出刊日期： 2026-08-26)

黃仁勳藉一場大缺貨改寫比賽規則，記憶體廠紅利沒預期那麼高了



https://www.businessweekly.com.tw/archive/article?strid=7014614

根據近期產業消息，輝達下一代旗艦晶片 Rubin Ultra 的記憶體配置正在進行降規格的測試。

原本市場期待它能配備高達 1TB 的頂級 HBM4E 記憶體，但現在測試的版本降到了 192GB 或 256GB，甚至比上一代 Vera Rubin 的 288GB 還要少。

事實上，輝達之前就做過類似的妥協。例如 Vera CPU 上的記憶體模組容量直接砍半，讓整台伺服器機櫃的總記憶體從 55TB 降到 28TB。

原因其實很簡單，就是全世界都在搶記憶體，製造商實在交不出那麼多貨。

雖然缺貨是業界共識，但我們能從輝達官方的說法，看出他們設計晶片的思維。

輝達官方表示：「我們正在優化計算、網路和記憶體的組合，為客戶交付更多的 AI 系統。」

這句話可以拆成兩個核心重點來看：「**交付更多的 AI 系統**」，以及「優化計算、網路與記憶體的組合」。

為什麼要「交付更多的 AI 系統」？

這是一個非常現實的產產能算術題，也是輝達在供應鏈吃緊時最理性的選擇。

新型記憶體 HBM4E 的產能到了 2027 年依然會非常緊張。如果輝達堅持每一顆晶片都要塞滿 1TB 的記憶體，那麼現有的記憶體總供應量，就只能做出少量的頂級晶片。

> **但如果把單張晶片的記憶體降到 192GB，用同樣的記憶體總量，就能做出大約五倍數量的晶片。**

對微軟、Meta 這些超級客戶來說，他們現在最缺的其實是整體能用的算力。在記憶體總量被封頂的前提下，能拿到更多台「稍微瘦一點」的晶片，絕對比只拿到少數幾台「滿血頂配」的晶片更好。

降低單卡規格，換取整體出貨量的最大化，客戶就能更快拿到更多的設備，把整個算力系統部署起來。

另外，目前的低容量配置很可能只是 2027 年初期缺貨時的臨時作法。

許多分析指出，只要未來記憶體產能順利提升，高容量的版本依然有機會回歸。市場不必把「暫時的測試版」直接當成「永久降規格」。

如何「優化計算、網路和記憶體的組合」？

這裡才是輝達展現真正技術實力的地方。

如果單張晶片的記憶體變小了，遇到需要超大記憶體來跑的先進大語言模型，該怎麼辦？

答案是，現在的大模型本來就不會只靠單一晶片運作。

當單張晶片的容量縮水，把大量晶片高效率串聯起來的「機櫃級網路」就成了關鍵解法。**Rubin Ultra 配合最新的架構，可以透過輝達專屬的專屬高速互連技術（NVLink），把 576 顆晶片串成一個巨大的運算整體。**

在軟體眼裡，這 576 顆晶片就像是一顆超級大晶片。單張晶片只有 192GB 沒關係，串聯起來後，就能共享超過 100TB 的巨大記憶體池。輝達用極致的晶片間通訊技術，順利彌補了單卡記憶體的不足。

同時，減少單張晶片的記憶體層數，也能直接降低發熱量與耗電量。在現在資料中心動輒需要幾百千瓦電力的情況下，控管熱量與功耗也是設備能不能順利裝機運作的關鍵。

此外，單張晶片的記憶體變小，對不同類型的 AI 工作影響其實並不相同。

在 AI 運作的過程中，主要可以拆成兩個階段：

第一階段是「理解問題」（Prefill 階段），這時候需要大量的數學運算來讀取輸入的提示詞，屬於「吃運算資源」的任務，對記憶體容量的依賴相對較低。

第二階段是「生成回答」（Inference 階段），這時候系統需要處理超長文章、複雜對話，並在記憶體裡維護大量的上下文暫存資料（KV Cache）。

這個階段屬於「吃記憶體容量」的任務，一旦記憶體不足，能同時服務的用戶數量就會大幅下降。

這也解釋了為什麼輝達會同時推出其他輔助晶片來做任務分流。

例如，他們推出的 Rubin CPX 晶片，採用成本較低的 GDDR7 記憶體，專門用來處理第一階段純粹吃算力的運算；同時引入 CMX（Context Memory Extension）快閃記憶體層，專門用來存放與調度第二階段爆滿的上下文暫存資料（KV Cache）。

> **把貴昂貴的高速記憶體留給最核心的計算，把不需要極致速度的暫存資料分流給便宜的硬體儲存。**

這套從硬體、網路到儲存層面的全方位協同設計，就是輝達所謂的優化組合。

「優化組合」的副產物：守住毛利率

除了提升產能與系統效率，這種優化策略還順便解決了輝達內部的另一個財務隱憂，那就是成本結構失衡。

回看前幾代產品，記憶體佔整體硬體成本的比例其實不高。但隨著記憶體規格越來越高、價格被炒高，到了上一代產品，記憶體成本已經佔了整台伺服器機櫃的 25% 到 30%，在某些模組中甚至佔了高達 60% 的組件成本。

如果輝達堅持每顆晶片都塞滿最貴的記憶體，意味著客戶買設備的錢，很大一部分會直接流進海力士、三星與美光這些記憶體廠商的口袋，輝達自己能賺到的利潤空間就會被嚴重壓抑。

因此，輝達降低單卡 HBM 記憶體的用量，改用低價一點的記憶體來分擔負擔，正好壓低了記憶體的採購金額。這讓輝達在交付更多設備的同時，順手保護了自己的毛利率，把更多利潤留在自己擁有自主權的晶片與軟體上。

▉ 那記憶體廠商輸了嗎？

其實也沒有。

因為輝達用同樣的記憶體總量造出了更多晶片，整體市場對記憶體的總需求依然在成長。記憶體的結構性短缺預計會持續到 2027 年，定價權依然在供應商手裡。

只是產品結構會有所轉變。過去那些預測「所有頂級晶片都會裝滿最高階記憶體」的過度樂觀模型需要修正，未來中階配置的產品佔比會提高。

記憶體大廠們依然能享受市場缺貨的紅利，只是成長曲線會比最激進的預測稍微平緩一點。

▉ 戰場轉移：為什麼 AMD 也必須做機架？

理解了這個邏輯，就能明白為什麼 AMD 最近也在全力推進自家的整機櫃方案，嘗試把 72 顆晶片封裝在同一個架構裡。

如果 AI 晶片的競爭只停留在「單張晶片」的規格比較，例如比誰的運算速度快、誰的記憶體大，AMD 完全有能力在規格表上與輝達平起平坐。

然而輝達藉由記憶體瓶頸，把比賽規則改了。**現在客戶採購時，看重的是機櫃層級的整體運算效率**。

當單張晶片的記憶體變小，晶片之間的溝通效率就成了決定勝負的關鍵。如果 AMD 只賣單張晶片，讓客戶拿傳統的網路線自己拼湊，整體運作效率就會被輝達的整合生態遠遠甩在後頭。

加上輝達軟體生態系CUDA原本就對多晶片串聯與記憶體管理做過大量優化，硬體規格就算變動，軟體也能幫忙緩衝，這對軟體生態相對弱勢的競爭對手來說壓力更大。

> **所以 AMD 必須跨足機櫃設計，去攻克晶片串聯這塊硬骨頭。在今天的 AI 基礎設施領域，沒有系統級的整體設計，單張晶片規格再亮眼也無法發揮實力。**

輝達利用記憶體瓶頸順勢帶領產業走向系統級競爭，AMD 如果不跟進，就會被困在單卡競爭的框架裡；如果跟進，就必須在輝達已經耕耘多年的領域裡努力追趕。

結語

記憶體是目前 AI 基礎建設最大的瓶頸，這一點無庸置疑。供應量、良率與價格，正實實在在地限制著產品的設計與出貨速度。

但整個產業並沒有坐以待斃，大家正在從不同方向尋找解答：

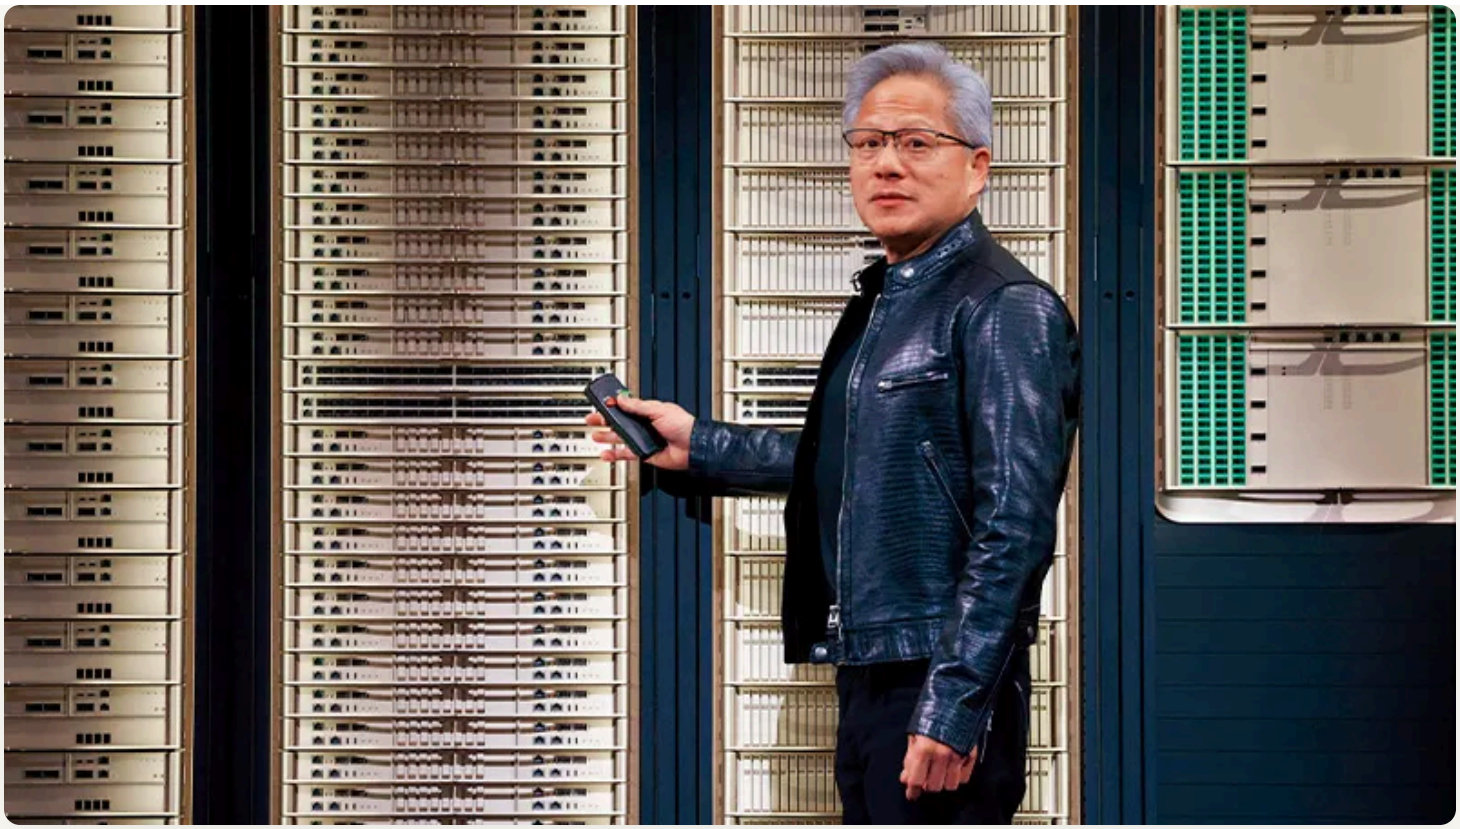
• 尋找單張晶片容量與多卡串聯之間的最佳平衡 • 拆分工作負載，讓便宜的記憶體分擔特定任務 • 提升軟體端的管理與排程效率 • 記憶體原廠持續擴充產能與升級技術

輝達對 Rubin Ultra 的調整，就是面對供應限制時的務實做法：在產能有限的情況下，優先確保能出貨更多設備，並透過更完善的系統設計來補足單卡容量的缺口。

記憶體短缺不會在一夜之間消失，但解決問題的方法已經在各個層面同步推進。

第三十一期專欄(出刊日期： 2026-09-02)

輝達財報透露一個新訊號，為何AI三巨頭都攻開源模型？



https://www.businessweekly.com.tw/archive/article?strid=7014641

過去兩年，大家對AI的概念是這樣的：誰能訓練出最強大的封閉式前沿大模型，誰就能統治未來。

但如果你仔細聽微軟、AWS 最近的財報電話會議，再看看輝達近期的資本動作，你會發現一個新的共識正在形成：

> **沒有任何單一模型可以統治世界。**

▉ 微軟的「調度框架」與利潤槓桿

CEO Satya Nadella 這一年反覆講同一件事：把記憶、上下文、工具調用這些「調度層」，跟底下那顆模型徹底分開。

他要企業問自己一個很實際的問題：**今天把你正在用的那顆通用大模型抽走，公司自己的評分標準、記憶和工作流程，還能不能繼續轉？**

在這個架構裡，底下的模型變成可替換的零件。

量大、重複的日常工作，可以切到便宜的開源模型，或微軟自己養的輕量模型；只有碰到極複雜的推理，才把任務交給 OpenAI 或 Claude 這種頂級模型。

這套分工，微軟先在自己產品裡跑過。

PowerPoint 用自研圖像模型取代原來的貴模型，晶片成本最高降約八成四；Dynamics 365 的客服場景用自研語音模型，最高降約八成九。

公司的說法是：**過去一季推出十幾款圖像、語音、轉錄、編程和資安模型，已經在用量最大的產品裡，把晶片成本打掉五成到九成，把最貴的模型留給真正需要的那一小部分難題**。

財務含義很直接：不是少用 AI，是同一件事，少付最貴那張帳單。

開源則是同一套想法裡、開放給客戶的另一條便宜跑道。跑量的，不必件件都去打頂級模型的價錢。

AWS 的「價格地板」與路由生意

同個禮拜，AWS 的 CEO Andy Jassy 把話挑得更明：AWS 即使沒有自己的頂級前沿大模型，依然能建立一個極度成功的業務。

AWS 的做法是把 Bedrock 變成一個無所不包的模型目錄，裡面甚至包含了 DeepSeek、Qwen 等頂級開源模型。

這背後的商業意圖非常明確，用開源模型來將推理服務的價格降到最低。

當客戶可以在 AWS 的安全環境內以極低價格運行高質量開源模型時，就沒有理由離開 AWS 去尋找第三方廉價服務。

AWS 新推出的 Kiro 編程 Agent 宣稱比競品便宜 50%。它自己的做法是把任務先寫清楚再開工，同樣一件事燒掉更少 Token；Bedrock 上另有智能路由和提示詞快取，負責把請求派給當下夠用、又最便宜的模型。

簡單來說，就是能用便宜的，就不要用貴的。

> **當模型可以隨時被替換，模型的實力就不再是唯一護城河。最值錢變成了誰掌握了客戶的記憶、工作流、企業資料與操作權限。**

如果能深深嵌入企業的工作流程（如 GitHub/Kiro 搶佔寫程式這條工作流），就能掌握真正的定價權。

量歸開源，錢歸閉源

巨頭在財報會上這樣講，第一線的開發者又是怎樣做的？

最清楚的鏡頭，來自 Vercel AI Gateway 和 OpenRouter。你可以把前者想成許多網站與 App 連 AI 的調度台，後者想成會幫你比價、切換模型的中樞。它們反映的是開發者和應用的真實流量。

這兩家掌握第一線AI工作流量的平台，用數據講述了一個清晰的趨勢：**市場正在形成一個典型的「槓鈴結構」**。

在 Vercel 上，開源模型的運算量從今年四月的 11%，到六月爬到近三成；八月二十二日單日甚至衝過 62%，量起來很快。

可是帳單是另一回事：六月開源吃掉近三成運算時，實際花費不到 4%；即便在那個創紀錄的單日，帶走的錢仍不到一成。

OpenRouter 上的情況如出一轍，這個平台上，長時間跑的 Agent 任務已佔約七成運算。

由於這類任務對成本高度敏感，開發者紛紛轉向價格極具優勢的開源模型（如 DeepSeek）。這導致美國前沿實驗室（OpenAI、Anthropic、Google等）在該平台上的流量份額，一年內從 70% 降到了 30% 左右。

這些數據背後的邏輯是：開發者正在對 AI 進行明確的務實分工。

> **海量、重複、長時間運轉的日常任務（例如資料清洗、基礎對話、格式轉換），交給 DeepSeek 或 Qwen 等開源與低成本模型來承擔，藉此把運算成本壓到最低；而一旦遇上極度複雜的邏輯推理或關鍵生成，大家依然會毫不猶豫地呼叫 GPT 或 Claude 的頂級模型，並為此支付高昂的溢價。**

輝達的真正策略

這就能解釋，輝達近期為什麼對開源展現出前所未有的熱情。輝達真正的算盤，從來不是靠每月收幾十美金的訂閱費來賺錢。

黃仁勳發布人生第一則 X 貼文時，發的是一封強調「開源才能讓 AI 深入各行各業」的聯名信，強調 AI 要真正普及到各行各業，關鍵在於讓「免費、權重公開」的開源模型遍地開花。

微軟執行長 Satya Nadella 當天也站在同一陣線支持。這兩位巨頭傳達了一個極其清晰的訊號：**開源必須存在，而且這套開源生態，必須牢牢長在他們掌控的土地上**。

在輝達最新的財報電話會議上，黃仁勳開場就說：去年這個時候，是單一實驗室在推建設；今天是多家前沿實驗室並行擴張，開源生態正在興盛，算力就是營收。

CFO Colette Kress 接著把模型清單念了一遍，閉源那邊是 OpenAI、Anthropic、Grok、Gemini；開源這邊是 DeepSeek、Qwen、Mistral，以及輝達自家的 Nemotron。

結論是：世界兩邊都需要，兩邊都在暴增，而幾乎所有開源模型都跑在輝達的軌道上。

開源對輝達來說，是另一個需求來源。它把「不必件件打前沿帳單」的那一側流量，也留在了輝達的機櫃裡。

▉ 親自填補生態缺口

判斷講完了，接下來是執行。輝達不只是嘴上歡迎開源，它正在親自把這個生態的缺口一個一個填上。

它推出開源的 Nemotron，權重和訓練方法公開，公司可以下載回自己的機器改成自家版本。

相較於當個強大的GPT或Claude，這套模型定位非常明確：**它就是一匹耐操的工作馬，專門扛企業裡量大、重複、長時間運轉的自動化**。

輝達甚至把自動幫任務分類、決定該用哪個模型的「智慧路由軟體」免費公開。

它完全不收軟體過路費，重點是讓所有的任務過路，都發生在輝達的硬體上。

然後，輝達砸下近七十億美元，跟做 AI 寫程式的新創 Poolside 綁在一起：十億入股，六十億拿下對方養模型的流水線授權，再向約百名工程師發出現職邀請，補進 Nemotron 團隊。

輝達要的是這套能快速打造模型的大型產線，既能加速追趕 DeepSeek 等競爭對手，也給了全球企業一個不必把商業機密傳給第三方雲端公司的選項。

黃仁勳的商業邏輯非常直接：大型企業與工廠對商業機密極度敏感，並不喜歡把資料送到別人的伺服器裡「租」模型用。

當企業選擇「租」閉源模型時，錢都被 OpenAI 或 Anthropic 這些軟體公司賺走；但當企業選擇「自己跑」開源模型時，所有的運算量都會直接轉化為對硬體伺服器的剛性需求。

重點在於，Nemotron 是輝達自家工程師量身打造的模型，它天生就在輝達晶片上運作得最流暢、效率最高。

當企業習慣用 Nemotron 來跑量、用輝達的路由工具來調度，就等於被深深綁定在輝達的生態圈裡。要讓這些開源模型跑得又快又省電，最好的選擇就是採購更多、更頂級的輝達 GPU。

> **這正是輝達著名護城河 CUDA 的同一概念。輝達從不靠賣軟體授權賺錢，而是透過提供最順手的免費工具，讓全世界預設在它的軌道上運行。**

模型可以免費給人用，因為只要大家都用開源模型跑運算，最終的贏家，永遠是賣晶片的人。

而這批「自己跑」的客戶，正在變成輝達營收裡增長最快的那一塊。

最新一季，數據中心收入裡，超大規模雲商(Hyperscalers)貢獻約四百八十億美元，但「AI 雲、工業與企業」(ACIE)這個區塊已經追到四百億出頭，年增超過一倍三。

這裡面包括新興 AI 雲、主權 AI、企業私有部署，而後兩者的客戶不願把機密送去租閉源 API，傾向自己下載開源權重、在自己的機房或區域雲裡跑。

當「自己跑」的客戶增長比超大規模雲商還要快的時候，你就明白為甚麼黃仁勳現在的目光都放在開源模型上了。

▉ 三個巨頭的如意算盤

然而，這條策略並非毫無風險，開源同時也帶來了輝達的「反身風險」。

開源確實把整體運算量做大了，對輝達是絕對的好事；但開源與模型輕量化，也讓「不一定要買最新、最貴的高階 GPU」變得極度合理。

當企業開始大量使用小模型、搭配模型量化技術，甚至拿自研晶片或舊款 GPU 來運行開源模型時，單顆晶片的產值可能會面臨下行壓力。

當許多日常活「其實用一張舊卡或便宜晶片就夠跑」的時候，賣路的人，終究也會擔心這條路變得太好走、門檻變得太低。

因此，輝達要把下一座工廠的規格再往上推一層，從 Blackwell 每吉瓦產值約兩百五十億美元，推到 Vera Rubin 的約四百億，把 CPU、GPU、網路、甚至專用推理晶片捆成一座更貴的整套系統。

開源把用家變多，輝達要確保只要你想性能好一點，你還是最需要它。

微軟和 AWS 搶的是 Token 的過路費與工作流綁定；輝達搶的是過路費底下的硬體路面。

> **三家巨頭都歡迎開源把市場蛋糕做大，差別只在：誰在收費站數錢，誰在經營工具箱，而誰，正在全力確保那條 AI 鐵路永遠離不開自己的鋼軌。**

第三十二期專欄(出刊日期： 2026-09-09)

AI做出癌症疫苗、一人一藥成真　莫德納、英矽智能顛覆了什麼？



https://campaign.businessweekly.com.tw/bw/No-2026-794

AI 沒有讓藥物開發變快，它讓失敗變快了。

2026 年七月，一家叫 Insilico Medicine 的公司，宣布啟動關鍵性三期臨床試驗，研究一款新藥。這是全球第一個由 AI 尋找發病目標、並由 AI 設計的小分子藥物走到這個階段。

8 月，Moderna 與 Merck 合作的個人化 mRNA 癌症疫苗，在黑色素瘤的三期臨床試驗中傳出捷報，成功達到主要試驗目標。這是個人化癌症療法與 mRNA 癌症疫苗在三期臨床上的重大突破。

只看新聞，很多人會以為 AI 已經瞬間顛覆了整個製藥業。這話並不完全對。

▉ 瓶頸轉移了

過去開發新藥最難的地方，在於挑選潛力新藥效率極低。科學家要花好幾年查閱無數文獻、在巨量化學空間裡不斷試錯，從幾百萬個選項中試圖找出可能有效的藥物。

AI 大幅縮短了這個準備階段。找資料、分析藥物結構、設計藥物分子，過去要花好幾年的耗時工作，現在電腦幾個星期就能算出答案。以 Insilico 為例，從開始用電腦計算到選出潛力藥物，只需要大約三週。

然而，後續驗證藥物安全與效果的臨床試驗依然非常漫長。從選出藥物到完成初步的人體試驗，依然要花上大約五年。

這是因為電腦算得再快，實體世界的步驟一個也少不了。我們依然需要做動物安全測試、實際把藥做出來、招募合適的病人、耐心觀察病人的服藥反應，最後還要等待政府藥管部門的層層審查。這些實體驗證與等待，佔據了新藥開發絕大部分的時間，也消耗了最多的資金。

> **因此，AI 其實沒有讓「拿到藥證上市」這件事變快，它只是讓「提出假設」和「淘汰錯誤想法」變得極為迅速。**

現在開發新藥面臨的最大考驗，已經從「設計不出新藥」，轉變成「如何證明藥物真的對人體安全有效，以及如何找到最適合吃這種藥的病人」。

AI 的真正價值，不在於幫忙省小錢

很多人以為 AI 用在做藥上，主要是為了省錢、省時間。 這確實有幫助，在把藥做出來進行人體測試之前，確實能節省三到四成的準備費用。

但實際上，前期準備只佔了開發新藥總成本非常小的一部份。真正燒錢、也最讓人害怕的地方，是進行人體臨床試驗時失敗。

一款新藥如果試驗失敗，通常不是因為電腦藥物設計得不好，而是我們一開始就搞錯了發病原因，或是把藥給錯了病人。

因此，AI 最大的潛在價值，並不是幫忙節省前期那一點點費用，而是提高「找對發病目標、用在對的病人身上」的命中率。

如果前期準備省下兩成的費用，只是個小好消息；但如果能讓臨床試驗失敗的機率降低兩成，將會徹底改變整間醫藥公司的命運。

客製化醫療的可能

對於一般的傳統藥物，AI 就像是一個精準的指南針，幫科學家指明方向，但後續的測試之路依然要靠人工一步步走完。

但在「量身打造的客製化醫療」領域，AI 就不只是指南針，而是不可或缺的核心大腦。沒有它，這種醫療模式根本不可能運作。

這之所以是醫療史上的重大突破，是因為過去的癌症治療往往是「一招打天下」。

傳統化療或免疫藥物是針對大部分人的平均狀況設計的，但每個病人的腫瘤突變其實都不一樣，這導致同款藥對某些人有效，對其他人卻完全沒作用，甚至白白承受嚴重副作用。

最新的個人化 mRNA 癌症疫苗，解決的就是這個問題。醫生會先檢查病人腫瘤的基因，交給演算法快速分析，挑選出最容易刺激免疫系統的幾項特徵，最後為這個病人量身打造專屬疫苗。每一位病人拿到的，都是包含自己私有抗原特徵的專屬藥物。

不過，這項技術目前有著明確的適用邊界。它主要用於手術切除後的輔助治療，且適用於免疫反應較強的高突變腫瘤，並需要搭配傳統免疫藥物使用。它代表的是讓某些特定的癌症亞型變得更像可以控制的慢性病，並不等於解決了所有癌症。

此外，這種模式真正的挑戰不只是演算法，更是極致的物流與供應鏈。

從腫瘤切除、基因測序、演算法挑選抗原、符合標準的藥品製造，到最後在關鍵黃金期內送到醫院，每一個環節都在跟時間賽跑。

演算法如果選錯特徵，整條高成本的供應鏈就等於是在生產無效的藥物。

如果用傳統人工方式，根本不可能為每一個病人單獨分析並設計專屬藥物，時間和成本會高到無法想像。只有把分析、設計與生產排程全部交給電腦軟體自動執行，這種「一人一藥」的先進療法才有辦法真正實現。

> **這才是 AI 在生物醫療領域最厲害的地方。它不只是讓科學家工作變快，而是把過去「商業上完全不可能做到」的事，變成了現實。**

▉ 同一個家族，不同的機器

很多人聽到 AI 做藥，腦中浮現的是像 ChatGPT 這類聊天工具。

雖然把它們拆開來看，底層運算邏輯有相似之處，無論是人類語言、基因 DNA 還是蛋白質結構，在電腦眼裡都是一連串有規律的字串，但這兩者在製藥過程中所扮演的角色與背後運作邏輯完全不同。

像 ChatGPT 這類大語言模型，訓練邏輯是預測下一個文字。

它需要吞下幾乎全人類網路上以 TB、PB 計算的文章與書籍，並動用數萬張頂級顯示卡連續運轉好幾個月，消耗數百萬美元的電費與硬體成本。靠著這種龐大算力與上兆參數，它能記住無邊無際的人類知識。

在製藥領域，它擅長閱讀海量醫學文獻、整理研究報告，甚至幫忙提出初步的科學假設。它就像科學家的萬能助手與秘書，能大幅省去整理資料的時間，但它終究只是處理文字與語言邏輯，沒辦法告訴你某個藥物分子會如何與人體結合、到底有沒有毒性，或是對疾病有沒有療效。

另一類像 AlphaFold 這種專門研究生物結構的模型，做的則是完全不同的硬核工作。

它不需要極端龐大的文字算力去硬刷網路，而是吃人類科學家花幾十年在實驗室辛苦測出來的高品質結構數據。資料庫規模雖然非常小，但對數據精準度要求高到極致。

在早期的蛋白質結構模型中，AI 第一步往往不是用 GPU 算，而是靠 CPU 去巨型基因資料庫裡比對進化過程中的相似序列。

很多時候它算得慢，不是顯示卡不夠快，而是 CPU 在海量基因資料庫裡搜尋資料卡住了。完成檢索與學習後，它才能在電腦中精準預測蛋白質的三維立體形狀與結合方式。

把這兩者混為一談，就會誤以為只要對著聊天 AI 發問，就能直接設計出救命神藥。

> **實際上，公開的模型與論文人人都能使用，AI 製藥企業真正的護城河，是擁有獨家的臨床數據、失敗實驗記錄，以及能否將病人的實際治療結果持續灌回模型進行修正。**

能形成這種數據反饋閉環的公司，才具備長期競爭力。

2026 年，真正改變的是什麼

回到AI研發的新藥進入三期臨床試驗，以及癌症疫苗成功達到臨床目標這兩個重大進展。

這些事件的重要之處，是第一次向世界證明：AI 研發的藥物，終於從電腦模擬看起來可行的理論階段，跨越到在真實病人身上確實發揮作用的實質驗證階段。

未來當你看到「AI 又要顛覆製藥業」的新聞時，可以觀察這幾個關鍵問題：這個藥物進入臨床試驗了嗎？走到第幾期？找對病人了嗎？實際試驗數據出來了嗎？

大家真正該追蹤的，是病人服藥後的實際健康數據、供應鏈的週轉效率，以及研發團隊能不能把每次試驗的經驗迅速反饋給 AI 進行修正。

AI 其實沒有讓「拿到藥證上市」這件事變快。它讓提出假設變快了，讓設計新藥變快了，同時也讓發現錯誤變快了。

> **而發現錯誤變快，恰恰是科技進步的開始。**

過去一個錯誤的想法，可能要白白耗費五年才能在臨床試驗中被證實無效；現在有了 AI 輔助，科學家可能只需要幾個月就能發現問題。

能越快淘汰錯誤的方向，就能越快找到正確的答案。這才是 AI 給生物醫療領域最寶貴的價值：更快幫人類排除掉不成功的選項。

新財富備忘錄約稿

輝達最新的NVHBM代表了甚麼？

過去兩年，市場評估 HBM（高頻寬記憶體）的邏輯非常直觀：誰能堆出最多層、拿得出最多產能，誰就能拿到訂單。SK 海力士也憑藉這項優勢，在記憶體市場取得領先地位。

但進入 HBM4 世代，這套評估標準正在改變。關鍵原因在於，HBM 最底下的那一層基座，本質已經出現變化。

▌底層結構的轉變

HBM 是一個垂直堆疊的結構，主要由兩個部分組成：

上層（C-die）：多層堆疊的 DRAM 晶粒，負責儲存資料。

底座（B-die）：位於最下方的基礎晶片，負責將上層資料傳輸給旁邊的 GPU 或 ASIC 主晶片。

在 HBM3E 及之前的世代，這塊底座同樣使用傳統的 DRAM 製程製造，功能相對單純，主要負責標準介面的物理連接。

但到了 HBM4，資料傳送的通道數量直接翻倍，就像把原本的雙線道一口氣擴建為四線道。通道變多、速度變快，產生的熱能與耗電量也大幅飆升，傳統記憶體工廠的技術已經無法處理。

SK 海力士的高層曾指出，雖然每家客戶都提出客製化需求，但傳統記憶體廠過去並不擅長做複雜的晶片設計，很難單靠自家團隊來滿足所有客戶的特殊規格。

為了破解這個瓶頸，業界決定換個做法，把最底下的基座，交給專門做精密運算晶片的代工廠來蓋。

在分工上，SK 海力士的 HBM4 底座選擇與台積電合作，三星動用自家先進代工部門，而美光在 HBM4 則選擇先堅持使用自家的 CMOS 底座。

> **據業界估算，這種邏輯底座的製造成本，已是上層記憶體顆粒的三到四倍。HBM 的成本結構，正悄悄轉變成「一張晶圓代工廠的帳單，再加上疊在上面的記憶體」。**

▉ 從「認證權」到「設計權」

NVIDIA 最近推出的 NVHBM 架構，是這場產業權力重組中相當具主導性的一步。

你可能會問：過去輝達不也在決定要用誰家的 HBM 嗎？這跟現在有什麼不同？

關鍵的差別在於：**NVIDIA 過去掌握的是「認證權」，現在搶奪的則是「設計權」。這是兩種不同層次的商業權力。**

過去的遊戲規則（HBM3E 時代）：主導「認證權」

不論是上層的記憶體還是底部的基座，全由記憶體廠自行設計，並遵循產業公開標準。

NVIDIA 的角色就像是「驗收官」，記憶體廠做好的產品，必須通過輝達的訊號、散熱與穩定度測試才能被採用。當時三星之所以落後，就是卡在認證這一關。

但在過去，記憶體廠依然擁有整顆產品的設計與智慧財產權（IP）。NVIDIA 可以決定買誰的產品、買多少量，卻無法改變產品內部的晶片設計。

未來的遊戲規則（HBM4 時代）：搶奪「設計權」

隨著輝達在8月底推出 NVHBM 規格，他們開始親自設計底部的晶片與傳輸介面。這讓 HBM 與 GPU 之間的連線，從過去通用的標準道路，變成了輝達專用的封閉通道。

記憶體廠賣的不再是一顆「自己設計的完整產品」，而是變成按照輝達提供的圖紙，把 DRAM 顆粒堆疊到輝達設計好的底座上。

第一個公開合作的案例就是亞馬遜，令市場推測可能在的最新Trainium 4晶片中，也會用到 NVHBM。

NVHBM 的商業意圖不單是提升自家 GPU 的效能，更是想將雲端巨頭（CSP）的自研晶片（ASIC）也納入自身的記憶體控制生態系中。

當亞馬遜的 Trainium 採用了 NVHBM，意味著輝達在雲端巨頭試圖「去輝達化」的趨勢下，重新在記憶體層級夾帶了自己的影響力，達成一次策略上的反制。

面對這種綁定，Google 等雲端巨頭也開始積極評估客製化底座的規劃，這順勢促成了三星「一站式代工」以及「台積電結合 IC 設計服務生態系」的客製化聯盟崛起。

▉ 三大記憶體廠的三種應對策略

面對這種產業結構的變化，三大記憶體廠採取了截然不同的商業路徑：

三星：主打「一站式服務」

三星是全球唯一同時擁有記憶體、晶圓代工與先進封裝能力的公司。它的目標客戶，是希望降低對台積電或輝達依賴的雲端巨頭。

三星主打不需分段外包、由它全包製造的優勢，但這套策略的關鍵在於其晶圓代工的良率能否持續獲得客戶信任。

SK 海力士：聚焦「記憶體優勢與外部結盟」

SK 海力士在記憶體技術與客戶關係上保持領先，但 HBM4 的底座晶片與最終封裝均需要仰賴台積電等外部夥伴合作。這意味著在邏輯晶片設計與製造層面，需要更緊密的供應鏈協同。

市場甚至傳出他們甚至開始評估 Intel 代工作為底座的第二供應來源。這個動作本身就說明了一件事：**他們意識到邏輯層是一個戰略弱點，不能只依賴單一合作方**。

美光：採取「標準化與穩健外包」

美光在 HBM4 世代的底座依然由自家完成。但到了 HBM4E（目標 2027 年），美光計劃將底座邏輯晶片外包給台積電生產，先推出 JEDEC 標準品，再推出客製化版本。這是一條先求穩、再求變的路線。

▉ 台灣供應鏈的關鍵角色

在這條新興的客製化 HBM 產業鏈中，台灣半導體業扮演了極為關鍵的硬實力角色。

台積電在這當中幾乎包辦了從製造到封裝的一條龍服務。它不僅幫 SK 海力士生產 HBM4 的標準底座，未來更預計投入最先進的 3 奈米製程，為客戶代工結構更複雜的客製化底座。

最後，台積電再透過先進封裝技術，將主晶片與這棟「記憶體大樓」緊密拼裝在一起。

> **客製化趨勢因為底座升級為高級晶片，讓台積電的不可替代性變得更強**。

而在設計領域，創意電子（GUC）這類 IC 設計服務商，則扮演了極為關鍵的「橋樑」角色。

當 HBM 底座走向客製化，業界最缺的其實是一個能溝通雙方的「翻譯官」。像 Google 或 AWS 這類雲端大廠，自研晶片傳輸資料的方式都有自己的獨家規則；但上層的記憶體顆粒，只聽得懂傳統的讀寫指令。

傳統記憶體廠擅長製造記憶體，卻不擅長為每一家客戶設計複雜的訊號轉換電路；而博通這類大廠，心思則落在設計整顆昂貴的主晶片上。

這中間「把客戶的獨家需求，翻譯成記憶體底座聽得懂的訊號」這項細分工作，恰好是創意電子長期深耕的專長。他們掌握了關鍵的傳輸技術，又能無縫對接台積電的先進製造與封裝。

▉ 時間軸的現實

在投資市場上，最常見的陷阱就是把兩三年後才會實現的遠景，拿來當作眼前的股價推手。

近兩年的獲利主力，依然來自賣到缺貨的標準品 HBM3E 與 HBM4。至於客製化 HBM，絕大多數要到 2027 年完成設計、2028 年才會真正大量出貨。

從現在開始，記憶體廠的議價權將分裂為兩場完全不同的遊戲：

第一場：誰有晶圓？（比拼產能，2026–2027）

全球能供應 HBM 的廠商只有三家，產能已被長期合約鎖定至 2030 年。不管底座怎麼變，上層依然需要 SK 海力士、三星或美光供應記憶體顆粒。

在產能層面，記憶體廠短期內依然握有極高的話語權與高售價。

第二場：誰寫規格？（比拼主導權，2028 以後）

當 NVIDIA 或雲端大廠開始親自設計底座，要求記憶體廠照圖施工時，底座晶片所產生的利潤池就漸漸轉移到了設計者與代工廠身上。

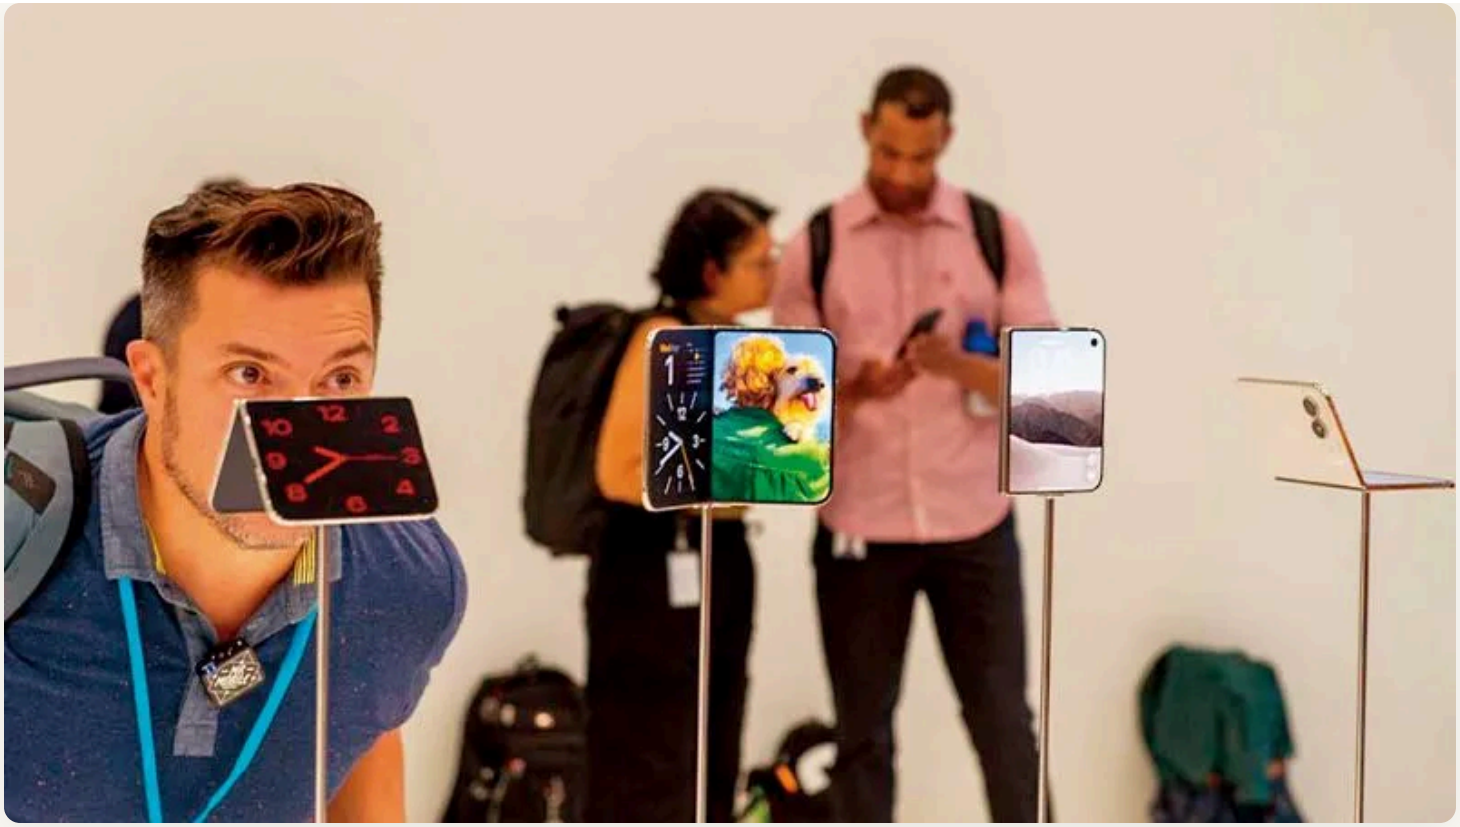
> **記憶體廠並沒有失去拒絕訂單或調控產能的能力，他們正在失去的，是將 HBM 作為「自家獨家產品」來定價的能力。**

前者決定了近兩年的現金流榮景，後者則決定了 2028 年之後，誰能站穩產業鏈中最賺錢的位置。

第三十三期專欄(出刊日期： 2026-09-16)

---

iPhone18漲100美元還不夠　蘋果新舵手首仗成敗看3指標



https://campaign.businessweekly.com.tw/bw/No-2027-861

iPhone 18 Pro 發布，聚光燈總是停留在摺疊機的手感、鏡頭與螢幕設計上。

但在機身深處，一場默默重塑科技版圖的交接正悄悄發生：台積電最新一代的 2 奈米（N2）晶片，首次進入了 iPhone。

回顧 3 奈米首發的年份，蘋果幾乎包下台積電所有的首批產能。但到了 2 奈米世代，產業秩序已經改變。

隨著 AI 伺服器需求大爆發，輝達在台積電2025年的營收佔比已升至約 19%，正式超越蘋果的 17%，高效能運算也占台積電整體營收近六成六。

雖然蘋果依然鎖定了 2 奈米初期約半數的晶圓投片量，維持約 3% 的微幅成長，但這不再是獨佔特權。

> **在漲價會議裡，以往蘋果最愛說的「我是你最大客戶」這句話，將不再成立。**

AMD、高通、聯發科與輝達，都已在 2 奈米的排隊名單上。蘋果和台積電的合作關係正從過去的獨家包場，轉向更動態的產能分配。

▉ 雙贏的時間差與量產曲線

在 AI 巨頭們揮舞著支票搶產能的年份，為什麼台積電還是把 2 奈米的頭班車留給蘋果？

首先是時間節奏的重合。

2026 年多數 AI 旗艦晶片仍留在 3 奈米與伺服器封裝的組合上，真正要大量消化 2 奈米產能的 AI 晶片，大多預計在 2027 年上線。

蘋果秋季發布會的時間點，剛好填補了「新產線具備量產能力、但 AI 客戶尚未全數湧入」的空檔。

其次是生產風險的考量。

2 奈米採用了全新的晶體管架構，早期良率爬坡與設備折舊成本極高。

AI 晶片體積龐大、設計複雜，拿來做新製程初期的試驗風險太高。相對地，蘋果的手機晶片面積小巧、設計規整且需求量高達數千萬顆，是台積電拉升新製程良率、累積生產參數最穩定的消費級載體。

需要強調的是，蘋果鎖定的是「晶圓投片量」而非「晶片顆數」。

由於手機晶片面積遠小於 AI 晶片，同一片晶圓切出的處理器數量遠高於 GPU。蘋果買的是讓台積電新廠第一年維持穩定運轉，台積電給的是讓蘋果獲取最新的晶片節點。

▉ 效能預算：從晶片微縮到並排封裝

台積電官方數據顯示，2 奈米對比上一代在相同功耗下速度提升 10% 至 15%，或者在相同速度下功耗降低 25% 至 30%。

但蘋果卻宣稱 A20 Pro 的處理器快了約 20%、圖像處理與持續效能提升了 40%。

這多出來的性能，其實是蘋果用設計與全新封裝加碼買單換來的。

過去手機晶片為了省空間，習慣像蓋高樓大廈一樣「上下垂直堆疊」，結果熱量全擠在中間散不掉，手機一熱就降頻跑不動。

這次蘋果改用全新的「水平並排封裝」，把主晶片與記憶體像平房一樣平鋪在同一個底板上。

熱源一拆開，機身內的均熱板才能直接貼合晶片背面。這項早在 8 月 Mac M6 上驗證過的熱與介面架構，如今被塞進了更緊湊的 iPhone 封包中，成為極薄且散熱受限的摺疊機 Duo 能持續高效運轉、不至迅速燙手降頻的關鍵。

▌關鍵瓶頸：記憶體與封裝的緊密耦合

不過，這套新架構也遇到了供應鏈的考驗。

蘋果的端側 AI 路線，Apple Intelligence 需要更大的記憶體容量、更寬的介面，卻剛好撞上了同一年的記憶體市場結構轉變。

全球記憶體大廠將產能優先轉向利潤更高的 AI 伺服器 HBM，一般手機用的 LPDDR 陷入緊缺與漲價。

在新式並排封裝下，主晶片與記憶體必須同時到位才能完成封裝。台積電的前端晶圓製造雖然順暢，後端封裝卻因為等不到記憶體而受限。

> **這種「晶片與記憶體必須同時到位才能封裝」的限制，讓蘋果的財報數字也出現了變化。只要等不到記憶體，做好的主晶片就只能堆在倉庫裡卡關，直接讓蘋果財報上的庫存金額從 57 億美元暴增到近 111 億美元。**

面對卡關情況，蘋果調整了產品策略：將有限且封裝完成的晶片組優先供給利潤較高的 Pro 與 Duo 機型，並順延標準版 iPhone 18 的上市時程，確保高昂的封裝成本能發揮最大效益。

▌三方消化的成本結構

2 奈米晶圓報價上調，加上新型並排封裝與價格暴漲的手機記憶體，使整個晶片系統成本顯著飆升。其中，記憶體在整體物料清單（BOM）中的成本比重從過去的約 9% 一路跳升至接近 27%，成為本輪成本上升的主要推手。

面對這筆成本，供應鏈三方以不同方式消化。

蘋果：Pro 系列售價調漲 100 美元，但這筆漲幅根本無法完全覆蓋記憶體與封裝在 BOM 上的增幅。漲價只是轉嫁一部分，延後低毛利的標準版推出、改由高單價的 Duo 錨定頂級市場，利用產品 Mix

的高溢價來補足缺口，才是真正的消化機制。

台積電：2026 財報上真正貢獻利潤的依然是滿載的 N3 與 N5 產線。N2 廠建置與折舊費用使下半年毛利率估計被稀釋 3 至 4 個百分點。對台積電而言，2026 年的 N2 是積累參數與良率的學費期，2027 年 AI 客戶全面導入後才是利潤收割期。

記憶體巨頭：憑藉伺服器 HBM 的強勁需求，順勢拉高 LPDDR 價格，成為本輪手機晶片系統升級中最直接獲取的現金流受益者。

▉ 管理層轉型：從商務談判走向整機工程鎖定

晶片策略的改變，也反映在蘋果內部的管理層交接。

在庫克時代，蘋果與台積電的合作更偏向商業談判，聚焦在產能分配、交期與價格；隨著 CEO John Ternus 與硬體主管 Johny Srouji 上任，雙方的對話轉向「整機系統設計」。

Srouji 團隊在開發初期，就將摺疊機 Duo 的內部空間、電池電壓與散熱路徑等限制，直接納入給台積電的晶片規格中。

這剛好對應台積電從「純晶圓代工」轉型為「晶片系統平台」的戰略。雙方的對話從傳統的產能預訂，轉變為提供穩定的消費級數量與專用封裝產線，進行深入的晶片與封裝協同設計。

> **這種基於多年累積的開發環境、測試模型與專屬封裝產線的工程綁定，讓蘋果即使面對更高的晶圓價格，也無法輕易更換代工廠。**

▉ 未來觀察的關鍵指標

後續有三個指標值得觀察：

第一，看「大容量 Pro」要等多久

別只看 iPhone Pro 整體缺不缺貨，要看 1TB 或 2TB 這種大容量版本是不是等更久。

大容量機型吃的記憶體最多、封裝也最複雜。如果只有大容量版本交期一再拉長，就代表記憶體缺貨與複雜的晶片組裝，真的成了產能的最大瓶頸。

第二，看蘋果接下來的獲利數字

留意蘋果下一季的毛利率，這能證明蘋果的算盤有沒有打對：把 Pro 調漲 100 美元、順勢把大家逼去買昂貴的高階機，到底能不能補回零件成本暴漲的缺口。

第三，看明年的平價版 iPhone 能不能升級

觀察當晶片生產逐漸穩定、記憶體價格回穩後，這套成本昂貴的新晶片技術，能不能順利下放給大眾買得起的標準版手機。

蘋果依然搶到了最先進 2 奈米晶片的頭班車，但這次拿到的是必須跟記憶體綁在一起生產的複雜系統。

> **在台積電面前，最大客戶的位置已經換人，蘋果這次無法再靠強勢砍價來省錢，只能靠「少賣便宜機、多賣高價手機」來保住利潤。**

第三十四期專欄(出刊日期： 2026-09-24)

二〇二七年AI產能6成還沒開工　滅絕論之外，投資人該算「時差帳」

https://www.businessweekly.com.tw/archive/article?strid=7014707

從一位離職員工的警告、一份幾家 CEO 罕見一致簽名的公開信，到各地議會舉起的抗議標語，我們正看到 AI 產業同時面對三種不同層面的「不信任」：

工程師對模型的懷疑、實驗室之間的互相猜疑、以及民眾對數據機房的不放心。

我相信 AI 的長遠價值。但產業在強調 AI 多麼強大、多麼危險時，卻沒有同樣具體地解釋清楚如何驗證、如何負責、以及如何讓地方社區受益。

這樣一來，這些警告就可能真的造成 AI 在實際應用上的阻礙。

工程師不信任模型

九月初，Anthropic 的研究員 Jacob Coxon 離職後公開表示，開發 AI 的人內心深處相信 AI 可能在 2030 年前毀滅人類。他的同事 Hubinger 隨後也說，未來十年 AI 導致人類滅絕的機率可能超過 10%。

不過，我們不必急著倒數世界末日。這句話換個角度看，其實透露了更重要的訊息：**連親手創造模型的人，都無法確定自己到底造出了什麼**。

研究人員擔心的是未來的強大系統是否仍能被控制；企業則面對的是眼前的工作是否能放心交給 AI。

而這種「不確定」正是目前絕大多數企業猶豫不決、遲遲無法大規模採用 AI 的主要原因。

這種缺乏確定性的情況，在日常辦公中最為明顯。

許多公司開始嘗試讓 AI 處理帳務、起草郵件、進行財務計算。AI 可能在五分鐘內完成一套流程，速度快且成果看似不錯。但問題是，你敢不檢查就直接批准嗎？大概沒有多少主管敢這麼做。

因此，下一階段的 AI 競爭，重點不再是看誰的模型回答得更漂亮、更像真人，而是看誰能建立更好的權限限制和人工抽查機制，真正降低「驗證成本」。

能撫平這種不確定性，讓企業敢於放心使用 AI 的結果，才是 AI 能大規模落地的關鍵。

實驗室不信任彼此

當離職員工散播 AI 恐慌時，Anthropic 的執行長 Dario Amodei 並沒有反駁，也沒有發律師函警告。

相反地，他接受 CNN 採訪時表示「我同意他的地方遠多於不同意」。同時，他發表公開信強調，AI 的發展腳步不應一味求快，必須放慢速度，讓防護機制跟上來。

他提出的解決方案是模仿金融業的做法，讓外部獨立的「駐場稽核員」進駐實驗室，監督整個訓練過程。

有趣的是，平時互相競爭的 Sam Altman 和 Elon Musk 在這件事上居然罕見地表示了贊同。安全訴求和商業利益並非絕對對立。一個公司可能真心擔憂風險，同時也能從更高的合規標準中獲益。

因此，真正值得探討的，不是這些 CEO 是否有良心，而是未來的安全規則會是什麼樣子：要求是否與風險相符？評估者是否獨立？小型公司是否有負擔得起的合規途徑？如果規則只是增加了進入門

檻，卻沒有提供更清晰的安全證明，那麼它提高的可能不是信任，而是進入的難度。

大公司有充足的資源來負擔這些繁瑣的審查流程，甚至能將「通過審查」包裝成付費服務賣給客戶。但對資金有限的新創公司而言，這昂貴的合規成本足以讓它們在起跑線上就出局。

簡單來說，Dario 的潛台詞是：「既然這麼危險，那就按照我的標準來控制速度吧。」

> **大型企業呼籲放慢速度，一方面可以在公關上贏得道德分數，另一方面也能名正言順地提高行業門檻，限制競爭對手，將「安全驗證」變成自己的保護傘和新業務。**

然而，這封公開信中存在一個難以解決的劇本矛盾。

Amodei 一方面呼籲業界共同放慢腳步，另一方面卻主張嚴格控制先進晶片，不讓模型權重外洩，並防止中國迎頭趕上。

想想看，在這種「誰落後誰就完蛋」的地緣政治競爭中，大家真的有可能一起鬆開油門嗎？不可能。**真正的減速等於單方面投降，沒有任何 CEO 敢做這樣的豪賭。**

所以，大家心照不宣的真實劇本是：對內多設置幾個檢查關卡，對外絕對不能減速，該蓋的數據機房還是要蓋。這正是這場競賽最矛盾的地方。

每一家 AI 公司的 CEO 都真心認為自己是「最有良心、最懂安全」的那個人。但正因為如此，你才更要搶在「壞人」前面做出最強大的 AI。

於是，所有自詡為正義的玩家，為了爭奪那個「有資格談論安全」的寶座，最終都會做出同一個選擇：把油門踩到底，誰也不敢鬆開。

不過，這封公開信雖然改變不了地緣政治的賽局，卻正在悄悄改變這個產業的遊戲規則。

簡單來說，AI 的賽道正在分化成兩條：一條是「少數巨頭的軍備競賽」。在訓練模型的環節，安全審查、駐場稽核、晶片管制層層加碼，打造最先進模型會變得越來越昂貴、越來越緩慢，最終只剩少數幾家公司能負擔。

另一條是「企業落地的實際考量」。在應用端，企業不需要等待下一代更強大的模型，也不需要 AI 無所不能。他們只想要一件事：結果可靠、能通過內部審查，出了問題有人能負責。

因此，大型企業呼籲減速，真正改變的不是「要不要跑」，而是跑完之後，誰能負擔那筆昂貴的「信任成本」。

選民不信任機房

我認為，「末日敘事」最可能產生的副作用，是讓一場本來可以透過協商解決的地方建設爭議，變得更加難以取得信任。

地方居民本來就在抱怨電費上漲、用水資源被占用和噪音問題。當實驗室每天又向媒體宣稱 AI 多麼危險、即將超越人類甚至可能毀滅世界時，這兩種情緒加在一起，普通民眾腦中浮現的，就成了「這群科技巨頭要蓋一個會搶走我工作、還隨時可能失控的怪物」。

既然實驗室自己都將 AI 形容得如此不可控，那麼大家最自然的反應就是：為什麼我要把我們社區的電力、水源和土地，交給一個可能毀滅我的東西？

這就演變成了一種極具戲劇性的對比：在華府，川普高喊「誰阻擋數據中心，誰就是在幫助中國獲勝！」；但在地方層面，他自己共和黨的州長卻和選民站在一起，怒氣沖沖地一張張撤回數據中心的開工許可。

全美各地對數據中心的抗議聲浪近期迅速升溫。地方居民對電費上漲、用水資源爭奪和噪音的不滿，已經在多個州演變成暫緩建設的政策提案和選戰焦點。

> **這意味著，過去大家以為 AI 算力只缺晶片、缺電、缺錢；現在才發現，那道真正最難跨越的高牆，是「地方政府的蓋章許可」。**

巨頭們花錢購買 GPU 的衝動絲毫未減，但錢砸下去了，機房卻蓋不起來。結果就是整個算力地圖被徹底改寫。

那些動輒需要幾百萬千瓦電力、規模像小鎮一樣大的訓練園區，最容易在公聽會上被阻擋；反而是規模較小、對電力需求較低的「推論機房」，開始轉移陣地，前往審查較寬鬆的州，甚至海外。

這時候，那些早在幾年前就拿到電網併網許可、簽好用水合約、並與當地居民建立良好關係的舊機房，一夜之間成了有價無市的稀缺資產。

大型企業原本想利用「AI 太危險」的說法來迫使政府加強監管、封殺小型競爭對手，沒想到這股恐慌傳到街頭，民眾心想「既然這麼危險，那也別蓋在我家隔壁」，直接將機房的建設時程大幅延後。

兩邊口中都在談「安全」，但最終反映在財報上的，卻是進度延遲、成本增加的結果。

真正的機會

我相信 AI 的長遠價值，但我不會將這份信心直接換算成每一家公司完美的施工進度表。

接下來值得我們分開看待兩場競賽：前沿模型競賽比的是誰能做出更強大的系統，同時證明風險可控；企業落地競賽則比的是誰能將模型能力轉化為可交付、可追蹤、且總體成本划算的實際成果。這兩場競賽是相關的，但速度不必完全一致。

企業不應只問「下一代模型什麼時候問世」，也應該思考：以現有的能力，哪些流程已經值得改造？還需要哪些驗證和責任機制，才能放心擴大使用？

如果安全能夠轉化為清晰的標準、可負擔的驗證方式和明確的責任歸屬，它就不會是 AI 發展的阻礙，反而會是擴大採用的前提。

下一階段真正值得爭取的優勢，不僅是付得起信任的成本，更是有能力將這個成本降下來。

最大的風險

總有人問我：「AI 究竟有沒有需求？」我相信 AI 的長期需求必定會爆發，這點毫無疑問。

但如果問我現在 AI 投資中，哪一個風險被大家嚴重低估了？我認為大家把事情想得太順利了。

目前市場對許多公司的估值，幾乎都建立在一份完美的施工進度表上：預設到 2027、2028 年，那些超級數據中心都能像按了快進鍵一樣準時完工、順利通電，並一口氣裝滿預訂的 GPU。

然而，只要項目的完工日期被地方政府集體延後一個季度，甚至一年，公司的未來營收成長斜率就會先被下修。

> **因此，相較於新聞報導中那些聳人聽聞的 AI 滅絕人類預言，投資人真正需要關注的，其實是這筆被大家忽略的時差帳。滅絕預言會成為頭條新聞，但時差帳會體現在財報裡。**

本機離線版本 • 圖片與內文完整

← 回索引

在原站開啟 ↗